



PENELITIAN INI

DECIPHERING RICE GENOMES AT CHROMOSOME-SCALE RESOLUTION

12S21051 MARTHA BRITANY NAPITUPULU

**PROGRAM STUDI SARJANA SISTEM INFORMASI
FAKULTAS INFORMATIKA DAN TEKNIK ELEKTRO
INSTITUT TEKNOLOGI DEL**

2025



PENELITIAN INI

DECIPHERING RICE GENOMES AT CHROMOSOME-SCALE RESOLUTION

12S21051 MARTHA BRITANY NAPITUPULU

**PROGRAM STUDI SARJANA SISTEM INFORMASI
FAKULTAS INFORMATIKA DAN TEKNIK ELEKTRO
INSTITUT TEKNOLOGI DEL**

2025

ABSTRAK

Nama : Martha Britany Napitupulu
Program Studi : Sarjana Sistem Informasi
Judul : *Deciphering Rice Genomes At Chromosome-Scale Resolution*

Perubahan iklim, degradasi lahan, dan peningkatan salinitas mengancam produksi padi (*Oryza sativa*) dan menuntut sistem budidaya yang lebih berkelanjutan, salah satunya melalui pengembangan padi perenial (*perennial rice*) seperti *Oryza sativa ssp. indica* cv. PR25 hasil hibridisasi antara kultivar tahunan RD23 dan spesies liar perenial *Oryza longistaminata*. Penelitian ini bertujuan mengidentifikasi gen-gen pada PR25 yang merupakan turunan atau memiliki hubungan ortholog dengan gen pada RD23 dan *O. longistaminata*, serta mengkarakterisasi fungsi biologis gen turunan tersebut dalam pembentukan genom dan profil fungsional PR25. Analisis diawali dari tiga genom skala kromosom (PR25.FINAL.fasta, RD23.FINAL.fasta adalah data BGI dan *Oryza_longistaminata_v1.0.dna.toplevel.fa* adalah data publik) yang dievaluasi kualitasnya menggunakan BUSCO dan QUAST, kemudian dianotasi melalui alih anotasi dari genom referensi ZS97 dengan Liftoff, diikuti polishing, ekstraksi CDS dan protein, serta pembersihan sekuens. Sekuens protein bersih ketiga spesies dianalisis dengan OrthoFinder untuk menentukan asal gen PR25 (turunan RD23, *O. longistaminata*, keduanya, atau spesifik PR25) dan diberi anotasi fungsi menggunakan EggNOG-mapper serta InterProScan, lalu diintegrasikan ke dalam satu tabel komprehensif PR25. Hasil penelitian ini diharapkan menghasilkan katalog gen turunan PR25 beserta kategori fungsi biologisnya, sehingga memperjelas integrasi sifat tahunan RD23 dan sifat perenial serta ketahanan stres *O. longistaminata* dalam genom PR25 dan mendukung pengembangan padi perenial yang adaptif dan berkelanjutan.

Kata Kunci : *Padi Perenial, Gen Ortholog, Gen Turunan, Anotasi Fungsi*

ABSTRACT

Nama : Martha Britany Napitupulu
Program Studi : Sarjana Sistem Informasi
Judul : Deciphering Rice Genomes At Chromosome-Scale Resolution

Climate change, land degradation, and increasing salinity threaten rice (*Oryza sativa*) production and call for more sustainable cropping systems, including the development of perennial rice such as *Oryza sativa ssp. indica cv. PR25*, a hybrid between the annual cultivar RD23 and the perennial wild species *Oryza longistaminata*. This study aims to identify PR25 genes that are derived from or orthologous to genes in RD23 and *O. longistaminata* and to characterize the biological functions of these inherited genes within the genomic and functional profile of PR25. The analysis starts from three chromosome-scale genome assemblies (PR25.FINAL.fasta, RD23.FINAL.fasta are BGI data and *Oryza_longistaminata_v1.0.dna.toplevel.fa* is public data) which are assessed with BUSCO and QUAST and annotated by transferring gene models from the *O. sativa indica reference ZS97* using Liftoff, followed by polishing, CDS and protein extraction, and sequence cleaning. Clean protein sequences from the three species are analyzed with OrthoFinder to infer the origin of each PR25 gene (inherited from RD23, from *O. longistaminata*, from both, or specific to PR25) and are functionally annotated using EggNOG-mapper and InterProScan, then integrated into a comprehensive PR25 gene table. The study is expected to produce a genome-wide catalogue of inherited PR25 genes and their biological categories, clarifying how annual traits from RD23 and perennial and stress-tolerance traits from *O. longistaminata* are combined in the PR25 genome and supporting future improvement of perennial rice.

Keywords : *Perennial Rice, Orthologous Genes, Hereditary Genes, Functional Annotation*

DAFTAR ISI

PERNYATAAN ORISINALITAS	iii
HALAMAN PENGESAHAN.....	iv
PERNYATAAN PERSETUJUAN PUBLIKASI PENELITIAN INI UNTUK KEPENTINGAN AKADEMIS	v
ABSTRAK	vi
ABSTRACT.....	vii
KATA PENGANTAR.....	viii
DAFTAR GAMBAR.....	xii
DAFTAR TABEL	xiv
DAFTAR RUMUS	xv
DAFTAR KODE PROGRAM.....	xvi
BAB I PENDAHULUAN.....	1
1.1 Latar Belakang	1
1.2 Pertanyaan Penelitian	6
1.3 Tujuan Penelitian.....	6
BAB II LANDASAN TEORI	8
1.1 Genus <i>Oryza</i>	8
2.1.1 <i>Oryza sativa subsp. indica RD23</i>	9
2.1.2 <i>Oryza longistaminata</i>	11
2.1.3 <i>Oryza sativa subsp. indica kultivar PR25</i>	14
2.2 Perolehan Data Genom sebagai Data Input.....	17
2.3 Metode Penelitian.....	19
2.3.1 Analisis Kualitas Perakitan Genom.....	19
2.3.2 Data preprocessing	31
2.3.3 Identifikasi Gen Turunan dan Fungsi Gen	54
2.3.4 Penelitian Terdahulu.....	79
BAB III ANALISIS.....	85
3.1 Tahapan Penelitian	85
3.2 Analisis Data	89
3.2.1 Data Collection	89
3.2.2 Evaluasi Kualitas Genom	93
3.2.3 Data Preprocessing	112
3.2.4 Analisis Orthologi Gen dengan OrthoFinder.....	126

3.2.5 Analisis Fungsi dan Domain Protein dengan EggNOG-mapper dan InterProScan.....	129
BAB IV DESAIN PENELITIAN.....	132
4.1 Desain Umum Penelitian.....	133
4.2 Desain Evaluasi Kualitas Genom.....	137
4.2.1 Desain Evaluasi Kelengkapan Konten Gen pada Perakitan Genom.....	137
4.2.2 Desain Evaluasi Struktur Perakitan Genom	139
4.3 Desain <i>Preprocessing</i> dan Anotasi Gen.....	142
4.3.1 Desain Anotasi Gen dengan Liftoff.....	142
4.3.2 Desain Standarisasi dan Penggabungan Anotasi Gen dengan AGAT	145
4.3.3 Desain Ekstraksi CDS dan Protein	147
4.3.4 Desain Pembersihan Sekuens Protein.....	149
4.4 Desain Analisis Orthologi Gen dengan OrthoFinder	152
4.5 Desain Anotasi Fungsi dan Domain Protein	154
4.5.1 Desain Anotasi Fungsi Gen dengan EggNOG-mapper v2	154
4.5.2 Desain Analisis Domain dan Motif Protein dengan InterProScan	156
BAB V IMPLEMENTASI.....	158
5.1 Lingkungan Implementasi.....	158
5.2 Batasan Implementasi	159
5.3 Implementasi Evaluasi Kualitas Genom	159
5.3.1 <i>Workflow Description Language (WDL)</i>	159
5.3.2 Evaluasi Kelengkapan Genom dengan BUSCO.....	160
5.3.3 Evaluasi Struktur Assembly Genom dengan QUAST.....	168
5.4 Implementasi Data Preprocessing	171
5.4.1 Implementasi Anotasi Gen dengan AGAT-Liftoff.....	175
5.4.2 Ekstraksi CDS dan Protein dengan Gffread	178
5.4.3 Pembersihan Sekuen Protein	180
5.4.4 Implementasi Pipeline Analisis	184
5.4.5 Implementasi Analisis Orthologi dengan Orthofinder	188
5.4.6 Implementasi Anotasi Fungsi Gen dengan EggNOG-mapper ..	188
5.4.7 Implementasi Analisis Domain dan Motif Protein dengan InterProScan	199
BAB VI HASIL DAN PEMBAHASAN	224
6.1 Analisis Kualitas Perakitan Genom.....	224

6.1.1 Evaluasi Kelengkapan Konten Gen pada Perakitan Genom	224
6.1.2 Evaluasi Struktur Perakitan Genom	225
6.2 Hasil Data Preprocessing	227
6.2.1 Analisis Hasil Anotasi Gen PR25 dan RD23 dengan Liftoff	227
6.2.2 Analisis Hasil Ekstraksi CDS dan Protein dengan gffread.....	231
6.3 Integrasi Data	232
6.3.1 Proporsi gen PR25 dengan anotasi fungsi informatif (KNOWN) dan tidak informatif (UNKNOWN) berdasarkan integrasi eggNOG-mapper v2 dan InterProScan.....	232
6.3.2 Distribusi status anotasi fungsi (KNOWN/UNKNOWN) menurut asal gen	236
6.3.3 Komposisi gen PR25 berdasarkan asal ortholog (BOTH, RD23_only, OL_only).....	237
6.3.4 Fungsi Utama Dominan Gen PR25 (Kategori KNOWN)	238
6.3.5 Top-10 Fungsi_EggNOG (EggNOG-mapper) pada gen PR25 (kategori KNOWN) per kelompok Sumber_Gen	243
6.3.6 Top-10 Fungsi_InterPro (InterProScan) pada gen PR25 (kategori KNOWN) per kelompok Sumber_Gen	247
6.3.7 Top-10 Fungsi_Utama pada gen BOTH (Gen Homologi D23 dengan O. longistaminata) kategori KNOWN	253
6.3.8 Top-10 Fungsi_Utama pada gen RD23_only – kategori KNOWN	255
6.3.9 Top-10 Fungsi_Utama pada gen OL_only – kategori KNOWN	256
BAB VII KESIMPULAN DAN SARAN.....	260
7.1 Kesimpulan.....	260
7.2 Saran.....	264
DAFTAR PUSTAKA.....	xvi
LAMPIRAN.....	xxiii

DAFTAR GAMBAR

Gambar 2. 1 <i>Oryza sativa</i> cultivar RD23	10
Gambar 2. 2 <i>Oryza longistaminata</i>	12
Gambar 2. 3 <i>Oryza sativa</i> cultivar PR25.....	14
Gambar 2. 4 Alur BUSCO	24
Gambar 2. 5 Alur QUAST	29
Gambar 2. 6 Alur Liftoff.....	35
Gambar 2. 7 Pemetaan Liftof pada transkrip manusia ke genom simpanse	38
Gambar 2. 8 Alur AGAT	44
Gambar 2. 9 RBH dalam Ortholog dapat Gagal	56
Gambar 2. 10 Graf Homologi dan Pengelompokkan ke Orthogroups.....	59
Gambar 2. 11 Alur OrthoFinder.....	62
Gambar 2. 12 Alur EggNOG-mapper	65
Gambar 2. 13 Alur Konseptual Interproscan	74
Gambar 2. 14 Alur Interproscan melalui website Galaxy.....	75
Gambar 3. 1 Tahapan Penelitian	85
Gambar 3. 2 Tampilan Isi dari RD23 dan PR25	90
Gambar 3. 3 Molekul DNA.....	90
Gambar 3. 4 Dataset Tanaman untuk BUSCO.....	91
Gambar 3. 5 List of BUSCO v4 lineages	91
Gambar 3. 6 Data ZS97 sebagai Referensi pada Liftoff.....	92
Gambar 3. 7 Berkas Format Pelaporan BUSCO dalam jurnal BUSCO: Assessing Genomic Data Quality and Beyond.....	96
Gambar 3. 8 Data BUSCO PR25	98
Gambar 3. 9 Data BUSCO RD23	99
Gambar 3. 10 Data BUSCO <i>Oryza longistaminata</i>	99
Gambar 3. 11 Jumlah Basa N per 100 kbp.....	104
Gambar 3. 12 Kurva Nx PR25	108
Gambar 3. 13 Kurva Nx RD23	108
Gambar 3. 14 Kurva Nx <i>Oryza longistaminata</i>	109
Gambar 3. 15 Cumulative Length PR25	110
Gambar 3. 16 Cumulative Length RD23	110
Gambar 3. 17 Cumulative Length <i>Oryza longistaminata</i>	111
Gambar 3. 18 Perbandingan Jumlah Gen pada PR25 dan RD23	114
Gambar 3. 19 Jumlah Gen Mapped dan Unmapped Liftoff	116
Gambar 4. 1 Desain Umum Penelitian.....	133
Gambar 4. 2 Desain Evaluasi Kelengkapan Genom BUSCO.....	138
Gambar 4. 3 Desain Evaluasi Struktur Assembly Genom dengan QUAST	140
Gambar 4. 4 Desain Anotasi Gen dengan Liftoff	143
Gambar 4. 5 Desain Standarisasi dan Penggabungan Anotasi dengan AGAT ...	146
Gambar 4. 6 Desain Ekstraksi CDS dan Protein dengan gffread.....	148
Gambar 4. 7 Desain Pembersihan Sekuens Protein	150
Gambar 4. 8 Desain Analisis Orthologi Gen dengan OrthoFinder	152
Gambar 4. 9 Desain Anotasi Fungsi Gen dengan EggNOG-mapper v2.....	155
Gambar 4. 10 Desain Analisis Domain dan Motif Protein dengan InterProScan	156
Gambar 5. 1 Tampilan EggNOG-mapper	190
Gambar 5. 2 Tampilan Opsi Anotasi pada EggNOG-mapper.....	195

Gambar 5. 3 Server Status EggNOG-mapping	197
Gambar 5. 4 Notifikasi EggNOG-mapper melalui Email.....	198
Gambar 5. 5 Tampilan Interproscan melalui website Galaxy.....	200
Gambar 5. 6 Tampilan Basis Data yang digunakan pada Interproscan melalui Galaxy.....	200
Gambar 5. 7 Tampilan Interproscan dengan Aplikasi berlisensi untuk non-komersial melalui Galaxy	202
Gambar 5. 8 Pengaturan Konfigurasi Lanjutan pada Interproscan melalui Galaxy	203
Gambar 6.3. 1 Distribusi Gen PR25 dengan Status Fungsi	233
Gambar 6.3. 2 Jumlah Gen PR25 dengan Status Gen per Sumber Gen.....	236
Gambar 6.3. 3 Distribusi Gen Turunan pada PR25	237
Gambar 6.3. 4 Heatmap Top 10 Fungsi_Utama pada PR25	238
Gambar 6.3. 5 Heatmap Top 10 Fungsi_EggNOG pada PR25.....	243
Gambar 6.3. 6 Top-10 Fungsi_InterPro (InterProScan) pada gen PR25 per kelompok Sumber_Gen	248
Gambar 6.3. 7 Top-10 Fungsi_Utama pada gen BOTH (KNOWN)	254
Gambar 6.3. 8 Top-10 Fungsi_Utama pada gen RD23_only.....	255
Gambar 6.3. 9 Top-10 Fungsi_Utama pada gen OL_only	256

DAFTAR TABEL

Tabel 2. 1 Kelebihan dan Kekurangan Oryza longistaminata.....	12
Tabel 2. 2 Perbedaan RD23, PR25, dan Oryza longistaminata	16
Tabel 2. 3 Penelitian Terkait	79
Tabel 3. 1 Interpretasi Nilai BUSCO	97
Tabel 3. 2 Data BUSCO pada PR25, RD23, Oryza longistaminata	100
Tabel 3. 3 Data QUAST PR25, RD23, dan Oryza longistaminata	104
Tabel 3. 4 Ringkasan Jumlah gene, mRNA, dan CDS	114
Tabel 3. 5 PR25 dan RD23 yang sudah Dipetakan dan Tidak Dipetakan	115
Tabel 3. 6 Jumlah gene, mRNA, CDS AGAT	118
Tabel 3. 7 Hasil Analisis Output Gffread	120
Tabel 3. 8 Hasil Analisis Output Pembersihan Sekuens Protein	124
Tabel 6. 1 Hasil BUSCO	224
Tabel 6. 2 Hasil QUAST	226
Tabel 6. 3 Analisis Output Gffread	232
Tabel 6. 4 Cuplikan dari PR25_Final_Table_for_TA_Functional_Only.xlsx....	234
Tabel 6. 5 Cuplikan dari PR25_Final_Table_for_TA_Unknown_Only.xlsx	234
Tabel 6. 6 Makna Fungsi Gen bagian 1	238
Tabel 6. 7 Makna Fungsi Gen bagian 2	244
Tabel 6. 8 Cuplikasi Isi Output eggNOG mapper dengan Fungsi_EggNOG	246
Tabel 6. 9 Makna Fungsi Gen bagian 3	248
Tabel 6. 10 Cuplikan Isi Output Interproscan dengan Fungsi_Interpro.....	252
Tabel 6. 11 Makna Fungsi Gen bagian 4	255
Tabel 6. 12 Makna Fungsi Gen bagian 5	257

DAFTAR RUMUS

(2.1)	34
(2.2)	34
(2.3)	57
(2.4)	58

DAFTAR KODE PROGRAM

Pseudocode 5. 1 Implementasi WDL BUSCO	162
Pseudocode 5. 2 Task RunBusco Analysis	166
Pseudocode 5. 3 Implementasi WDL QUAST	170
Pseudocode 5. 4 Penyiapan Lingkungan(Environment) dalam Conda	172
Pseudocode 5. 5 Implementasi AGAT-Liftoff.....	177
Pseudocode 5. 6 Ekstraksi CDS dan Protein dengan Gffread.....	179
Pseudocode 5. 7 Pembersihan Sekuen Protein.....	181
Pseudocode 5. 8 Zip Output dari Pembersihan Sekuen Protein.....	189

BAB I

PENDAHULUAN

1.1 Latar Belakang

Padi (*Oryza sativa*) merupakan komoditas pangan yang berperan sangat penting bagi ketahanan pangan, terutama di negara-negara Asia yang menjadikan beras sebagai sumber karbohidrat utama. Kestabilan produksi padi tidak hanya ditentukan oleh ketersediaan varietas berdaya hasil tinggi, tetapi juga oleh kemampuan sistem budidaya menghadapi tekanan lingkungan yang terus meningkat. Di berbagai wilayah budidaya padi, cekaman abiotik seperti salinitas menjadi salah satu faktor yang semakin sering dijumpai, baik karena intrusi air laut di daerah pesisir, perubahan kualitas air irigasi, maupun degradasi lahan yang menyebabkan akumulasi garam. Secara fisiologis, salinitas mengganggu keseimbangan ionik tanaman dan menurunkan kemampuan tanaman menyerap air secara efektif. Dampak tersebut dapat memicu gangguan metabolisme, menurunkan pertumbuhan vegetatif, dan pada akhirnya menurunkan komponen hasil. Bukti eksperimental dalam paper [1] menunjukkan bahwa peningkatan salinitas air irigasi mampu menurunkan jumlah anakan, berat gabah, dan komponen pertumbuhan lain, serta berkaitan dengan peningkatan rasio natrium terhadap kalium di jaringan tanaman yang mencerminkan ketidakseimbangan ionik pada kondisi salin. Kondisi ini menegaskan bahwa upaya peningkatan produktivitas padi perlu berjalan seiring dengan penguatan ketahanan sistem terhadap cekaman lingkungan.

Di sisi lain, tantangan budidaya padi tidak hanya terkait ketahanan terhadap cekaman, tetapi juga terkait keberlanjutan sistem produksi. Sistem budidaya padi yang dominan pada saat ini umumnya berbasis padi tahunan, sehingga penanaman ulang dilakukan setiap musim tanam. Pola tersebut memerlukan kebutuhan benih, tenaga kerja, serta input budidaya yang berulang. Pada beberapa konteks, pengolahan lahan yang berulang juga dapat memperbesar tekanan terhadap kualitas tanah dan meningkatkan biaya produksi. Karena itu, inovasi yang diarahkan pada efisiensi input, stabilitas hasil, dan keberlanjutan produksi menjadi semakin penting. Salah satu pendekatan yang berkembang adalah pengembangan padi

perennial, yaitu padi yang dapat tumbuh kembali dan menghasilkan panen berulang dari satu kali tanam. Pendekatan ini dipandang strategis karena berpotensi mengurangi kebutuhan tanam ulang, menekan kebutuhan benih dan tenaga kerja, serta mempertahankan penutupan lahan secara lebih kontinu.

Relevansi padi perennial tidak hanya bersifat konseptual, tetapi juga didukung bukti lapangan. Penelitian lapangan yang mengevaluasi kinerja padi perennial pada berbagai musim dalam paper [2] menunjukkan bahwa padi perennial dapat mempertahankan produktivitas yang kompetitif dibanding padi tahunan, sekaligus mengurangi kebutuhan tenaga kerja dan benih karena tidak memerlukan penanaman ulang setiap musim. Selain itu, pada skala beberapa tahun budidaya, padi perennial dilaporkan berasosiasi dengan perbaikan indikator tanah tertentu, misalnya peningkatan akumulasi karbon organik dan nitrogen tanah pada beberapa lokasi percobaan [2]. Temuan tersebut memperkuat argumen bahwa padi perennial dapat menjadi alternatif yang menarik untuk memperkuat keberlanjutan sistem produksi padi, terutama bila didukung pengelolaan budidaya yang sesuai. Penelitian lain dalam paper [3] yang menguji skema pengelolaan budidaya padi perennial juga menyimpulkan bahwa sistem padi perennial dapat menjadi sistem yang layak secara ekonomi dan aman secara lingkungan pada kondisi tertentu, sekaligus menunjukkan bahwa beberapa faktor budidaya, termasuk pengelolaan nitrogen, dapat memengaruhi kemampuan pertumbuhan kembali dan stabilitas hasil pada musim berikutnya [3]. Secara keseluruhan, bukti-bukti ini menjelaskan bahwa padi perennial bukan hanya isu varietas, tetapi juga isu sistem produksi yang memerlukan pemahaman biologis dan genetik yang kuat agar dapat dikembangkan secara berkelanjutan.

Pengembangan padi perennial modern tidak dapat dipisahkan dari pemanfaatan sumber daya genetik padi liar. Padi liar menyediakan keragaman genetik yang luas, termasuk gen dan alel yang berpotensi terkait toleransi cekaman, adaptasi lingkungan, dan mekanisme regenerasi vegetatif. Dalam konteks genomik modern, pemanfaatan keragaman ini menjadi semakin mungkin karena ketersediaan genom referensi berkualitas tinggi yang memungkinkan analisis komparatif lintas genom.

Namun, satu genom referensi tunggal sering tidak cukup untuk mewakili keseluruhan keragaman genetik dalam satu spesies atau kelompok kerabat dekat. Studi pangenom padi dalam paper [4] menegaskan bahwa variasi struktural dan variasi jumlah salinan gen dapat berkontribusi pada evolusi, domestikasi, dan perbaikan varietas, sehingga analisis berbasis banyak genom membuka akses pada informasi genetik yang tidak tertangkap oleh satu referensi saja. Selain itu, pengembangan pangenom yang menggabungkan padi liar dan padi budidaya dalam paper [5] menunjukkan bahwa terdapat sekuens genom dalam skala besar yang tidak ada pada referensi klasik, sehingga pangenom menjadi landasan kuat untuk menelusuri sumber keragaman genetik yang relevan bagi pemuliaan. Kerangka ilmiah ini penting karena sifat-sifat kompleks seperti perenialitas dan toleransi cekaman cenderung melibatkan banyak gen, variasi struktural, dan perbedaan komposisi gen fungsional.

Salah satu spesies padi liar yang relevan untuk padi perenial adalah *Oryza longistaminata*, yaitu padi liar Afrika yang bersifat perenial dan memiliki rizoma. Rizoma merupakan organ batang termodifikasi yang tumbuh di bawah tanah dan memungkinkan tanaman bertahan lintas musim serta membentuk tunas baru, sehingga menjadi kunci bagi sifat perenialitas. Ketersediaan genom referensi *O. longistaminata* yang dirakit dan dianotasi dengan kualitas tinggi dalam paper [6] memperkuat peluang analisis genetik dan komparatif, serta memperluas basis data genom padi liar yang dapat dimanfaatkan sebagai sumber gen untuk pemuliaan padi perenial dan padi toleran stres [6]. Selain ketersediaan genom referensi, penelitian genetika pada persilangan antara RD23 dan *O. longistaminata* dalam paper [7] telah menunjukkan bahwa sifat terkait rizoma dikendalikan oleh banyak lokus dan QTL yang bekerja secara bersama. Penelitian tersebut mengidentifikasi lokus efek besar dan puluhan QTL yang memengaruhi karakter rizoma, sehingga mengindikasikan bahwa sifat rimpang (*rhizomatousness*) yang poligenik dan kompleks. Dari sisi biologi perkembangan, studi yang membangun atlas transkriptomik spasiotemporal dalam paper [8] pembentukan rizoma pada *O. longistaminata* memberikan bukti bahwa pembentukan rizoma melibatkan dinamika ekspresi gen yang terkoordinasi dalam tahap-tahap perkembangan organ, dan menambah pemahaman mengenai

kelompok gen serta jalur biologis yang aktif pada proses tersebut. Dengan demikian, *O. longistaminata* tidak hanya penting sebagai donor sifat perenialitas, tetapi juga sebagai model yang menyediakan sumber data genomik dan transkriptomik untuk memahami mekanisme biologis rizoma.

Dalam konteks varietas padi perenial hasil pemuliaan, PR25 (*Perennial Rice* 25, juga dikenal sebagai Yunda25 pada sejumlah publikasi) menjadi salah satu contoh penting karena merupakan hasil pemuliaan yang mengintegrasikan latar belakang padi budidaya tahunan dan padi liar perenial. Bukti lapangan dalam paper [2] menunjukkan bahwa dari satu kali tanam, padi perenial mampu menghasilkan panen berulang selama beberapa musim dan beberapa tahun dengan hasil rata-rata yang kompetitif dibanding padi tahunan yang harus ditanam ulang, serta memberikan keuntungan berupa pengurangan kebutuhan tenaga kerja dan benih akibat berkurangnya penanaman ulang [2]. Pada sisi pembandingan, RD23 merupakan salah satu kultivar padi tahunan yang digunakan dalam paper [3] sebagai pembandingan sistem, sehingga berperan sebagai representasi latar belakang tahunan pada konteks budidaya tertentu. Kombinasi ini menjadikan PR25, RD23, dan *O. longistaminata* sebagai trio yang logis untuk dianalisis secara komparatif, karena secara biologis ketiganya terkait erat, tetapi membawa perbedaan sifat agronomis dan adaptif yang relevan untuk perenialitas.

Walaupun riset lapangan dan riset genetika sifat rizoma telah memberikan gambaran penting tentang potensi padi perenial, masih terdapat kebutuhan ilmiah untuk menjelaskan pembentukan PR25 dari sudut pandang genomik secara lebih sistematis. Dalam penelitian berbasis genom [4], dua lapisan analisis sering menjadi kunci untuk menghasilkan pemahaman yang terukur dan dapat diinterpretasi. Lapisan pertama adalah pemetaan hubungan kekerabatan gen antar-genom melalui konsep ortholog, yaitu gen-gen yang berasal dari nenek moyang yang sama dan dipisahkan oleh peristiwa spesiasi, sehingga dapat digunakan untuk menelusuri kemiripan dan perbedaan genetik lintas genom yang berkerabat. Lapisan kedua adalah ringkasan fungsi biologis gen melalui anotasi fungsi, sehingga dapat diketahui fungsi-fungsi dominan yang muncul pada kelompok gen tertentu. Kedua

lapisan ini menjadi makin penting dalam era pangenom, karena studi pangenom [5] menegaskan bahwa komposisi sekuens dan gen yang tidak ada pada satu referensi saja dapat sangat besar, sehingga pemetaan asal gen dan perbandingan fungsi dapat memberikan gambaran yang lebih lengkap tentang kontribusi keragaman genetik pada varietas target [4], [5].

Berdasarkan kebutuhan tersebut, penelitian ini diarahkan untuk mengisi celah pengetahuan yang spesifik dan terukur: belum tersedianya pemetaan yang jelas mengenai gen PR25 yang berhubungan sebagai ortholog dengan RD23 dan *O. longistaminata* yang kemudian dapat diklasifikasikan menjadi kelompok asal gen yang operasional, serta belum tersusun analisis yang merangkum fungsi biologis dominan pada tiap kelompok asal gen tersebut sehingga membentuk profil fungsional PR25. Dalam penelitian ini, profil fungsional PR25 dipahami sebagai ringkasan komposisi fungsi biologis gen PR25 yang dilihat melalui dominansi kategori anotasi fungsi pada masing-masing kelompok asal gen. Dengan cara ini, analisis tidak berhenti pada daftar gen, tetapi melangkah ke interpretasi biologis mengenai fungsi dominan yang mungkin merefleksikan kontribusi latar belakang tahunan dan latar belakang perenial terhadap karakter PR25.

Penelitian ini diposisikan sebagai analisis genomik komputasional yang memanfaatkan genom skala kromosom yang telah tersedia, bukan penelitian yang berfokus pada produksi data sekuensing atau perakitan genom dari data mentah. Dengan demikian, porsi latar belakang tidak diarahkan pada uraian rinci teknologi sekuensing atau perangkat lunak perakitan genom, melainkan pada alasan ilmiah mengapa analisis komparatif tiga genom tersebut relevan dan penting untuk menjawab dua fokus utama penelitian. Pertama, pemetaan dan klasifikasi gen PR25 berdasarkan hubungan ortholog dengan dua genom pembanding yang mewakili latar belakang tahunan dan latar belakang perenial. Kedua, analisis fungsi biologis dominan pada tiap kelompok asal gen untuk membangun profil fungsional PR25 yang menjadi dasar pembahasan ilmiah pada bab hasil dan pembahasan.

Dengan kerangka tersebut, penelitian ini diharapkan dapat menghasilkan

kontribusi ilmiah yang jelas pada dua aspek. Aspek pertama adalah kontribusi pada pemetaan asal gen PR25 dalam bentuk klasifikasi operasional yang dapat ditelusuri dan diverifikasi melalui hubungan ortholog. Aspek kedua adalah kontribusi pada pemahaman biologis melalui pemetaan fungsi dominan yang merangkum perbedaan komposisi fungsi antar-kelompok asal gen, sehingga pembahasan tidak sekadar menyatakan adanya gen turunan dari tetua tertentu, tetapi juga menjelaskan bagaimana kontribusi tersebut tercermin pada profil fungsi biologis PR25. Hasil yang bersifat terstruktur dan berbasis genom ini dapat menjadi pijakan untuk riset lanjutan yang lebih spesifik, misalnya seleksi kandidat gen, validasi eksperimental, atau perancangan strategi pemuliaan yang lebih terarah untuk meningkatkan stabilitas hasil dan ketahanan pada kondisi lingkungan yang menantang.

1.2 Pertanyaan Penelitian

1. Bagaimana gen-gen pada *Oryza sativa ssp. indica cv. PR25* dapat diidentifikasi dan diklasifikasikan berdasarkan hubungan ortholog dengan *Oryza sativa ssp. indica cv. RD23* dan *Oryza longistaminata* ke dalam kelompok asal gen RD23_only, OL_only, dan BOTH?
2. Fungsi biologis dominan apa yang dimiliki gen-gen PR25 pada setiap kelompok asal gen (RD23_only, OL_only, BOTH) berdasarkan proporsi anotasi fungsi (misalnya domain/family/GO), dan bagaimana perbedaan dominansi serta proporsi fungsi antar-kelompok tersebut membentuk profil fungsional PR25?

1.3 Tujuan Penelitian

1. Mengidentifikasi dan mengklasifikasikan gen PR25 berdasarkan hubungan ortholog dengan RD23 dan *O. longistaminata* untuk menentukan kelompok asal gen (RD23_only, OL_only, BOTH).
2. Menganalisis fungsi biologis dominan pada gen PR25 untuk setiap kelompok asal gen serta menilai kontribusinya terhadap profil fungsional PR25.

1.4 Ruang Lingkup

1. Data dan Objek: Penelitian ini menggunakan tiga genom padi, yaitu *Oryza sativa ssp. indica* cv. PR25 (padi perennial hasil hibridisasi antara cv. RD23 dan *Oryza longistaminata*), *Oryza sativa ssp. indica* cv. RD23, dan *Oryza longistaminata*. Genom PR25 dan RD23 diperoleh dari kerja sama dengan BGI dalam bentuk genom skala kromosom yang telah dirakit, sedangkan genom *O. longistaminata* diperoleh dari basis data publik dalam format FASTA. Selain FASTA genom, penelitian ini menggunakan FASTA protein hasil ekstraksi dari anotasi gen sebagai masukan analisis orthologi dan anotasi fungsi.
2. Batasan penelitian: Penelitian ini dibatasi pada analisis komputasional untuk pemetaan hubungan ortholog dan dominansi fungsi gen PR25 menggunakan tiga genom (PR25, RD23, dan *O. longistaminata*). Penelitian tidak mencakup data ekspresi gen, pemanggilan varian atau variasi struktural rinci, analisis jaringan regulasi, verifikasi fungsional wet lab, maupun evaluasi performa agronomis lapang secara langsung.

BAB II

LANDASAN TEORI

1.1 Genus Oryza

Secara taksonomi, genus adalah tingkatan di bawah famili dan di atas spesies yang mengelompokkan beberapa spesies yang masih berkerabat dekat dan memiliki ciri morfologi maupun genetik yang mirip. Genus *Oryza* termasuk famili Poaceae (rumput-rumputan) dan mencakup dua spesies padi budidaya utama, yaitu *Oryza sativa* (padi Asia) dan *Oryza glaberrima* (padi Afrika), serta sekitar 20–25 spesies padi liar yang tersebar di Asia, Afrika, hingga Oceania [9]. Dalam jurnal [10] dengan berita *The genomes of 13 species of wild and cultivated rice revealed: better conserve and harness the genetic diversity of one of the pillars of global food security* pada 13 spesies *Oryza* liar yang disusun hingga skala kromosom menunjukkan bahwa di tingkat genus ini terdapat lebih dari 100.000 famili gen, dengan sekitar 9–10% di antaranya merupakan famili gen inti yang dipertahankan di seluruh spesies [10]. Hal ini menegaskan bahwa padi liar menyimpan keragaman genetik besar yang belum sepenuhnya dimanfaatkan dalam pemuliaan padi budidaya [9]. Spesies *Oryza* secara klasik dikelompokkan berdasarkan tipe genom (AA, BB, CC, BBCC, CCDD, EE, FF, GG, dan kombinasi lainnya). Spesies dengan genom AA, seperti *O. sativa* dan beberapa padi liar (*O. rufipogon*, *O. nivara*, *O. longistaminata*) relatif mudah disilangkan, sehingga sering dimanfaatkan untuk memindahkan alel ketahanan stres, produktivitas, dan sifat agronomis lain ke varietas budidaya [11] [3].

Oryza sativa merupakan padi budidaya utama dunia dan menjadi sumber kalori pokok bagi lebih dari setengah populasi manusia. Tanaman ini umumnya annual (satu kali siklus hidup per musim tanam) dengan sistem perakaran relatif dangkal hingga sedang, dan telah mengalami domestikasi panjang sehingga gabahnya tidak mudah rontok, mudah dipanen, dan mutu berasnya diseleksi sesuai preferensi konsumen [12], [13]. Sebaliknya, *Oryza longistaminata* adalah padi liar Afrika dengan genom AA yang bersifat perenial dan berizoma, yaitu tanaman membentuk rimpang bawah tanah yang memungkinkan pertumbuhan kembali setelah dipotong atau dipanen. Spesies ini hidup di rawa, bantaran sungai, dan lahan tergenang

Institut Teknologi Del

musiman di Afrika sub-Sahara, dan dikenal memiliki toleransi tinggi terhadap kekeringan, banjir, salinitas, dan beberapa penyakit [14]. Karena sifat perenialnya, sistem akar dan rizoma yang kuat, serta ketahanan stres yang baik, *O. longistaminata* diusulkan sebagai kandidat domestikasi ulang (*de novo domestication*) menggunakan pengeditan genom (misalnya CRISPR/Cas) untuk menghasilkan padi budidaya baru yang lebih tahan terhadap perubahan iklim dibanding kultivar *O. sativa* modern [14].

Secara genetik dan morfologi, *O. sativa* dibagi menjadi dua subspecies utama, yaitu *indica* (*xian*) dan *japonica* (*geng*), ditambah beberapa kelompok lain seperti *aus*, *tropical japonica*, dan *aromatic* [12], [13]. Subspecies *indica* umumnya beradaptasi dengan iklim tropis dan subtropis hangat, memiliki tanaman relatif tinggi dengan daun lebih sempit, cocok untuk sawah irigasi dan lahan dataran rendah, cenderung lebih toleran terhadap suhu tinggi dan beberapa stres abiotik, mendominasi areal produksi padi di Asia Selatan dan Asia Tenggara [13], [15], [16]. Sebaliknya, *japonica* banyak ditanam di daerah beriklim sedang hingga subtropis sejuk dan umumnya lebih unggul dalam kualitas beras (misalnya beras pulen), tetapi kurang adaptif di daerah tropis panas [13], [16]. Dalam penelitian ini, RD23 dan PR25 termasuk dalam kelompok padi budidaya *O. sativa subsp. indica*, sedangkan *O. longistaminata* merupakan kerabat liar perenial dengan genom AA yang menjadi sumber gen penting untuk sifat rizoma dan ketahanan stres.

2.1.1 *Oryza sativa subsp. indica* RD23

RD23 adalah *Oryza sativa* dari Thailand yang terkenal dengan ketahanannya terhadap kekeringan dan salinitas serta dapat dikembangkan sebagai varietas sawah irigasi berdaya hasil tinggi dan banyak digunakan sebagai varietas pembanding (kontrol annual) dalam pengujian padi perenial di Tiongkok dan Asia Tenggara. Varietas ini telah digunakan sebagai induk dalam pemuliaan untuk menghasilkan varietas baru, termasuk PR25. Berdasarkan penelitian [17], RD23 menunjukkan kemampuan adaptasi yang baik terhadap berbagai kondisi lingkungan, menjadikannya subjek penelitian yang menarik untuk meningkatkan ketahanan pangan [17]. Dalam beberapa uji multi-lokasi di Yunnan pada jurnal [11], RD23 dijadikan pembanding utama terhadap padi perenial PR23, karena mewakili padi


Institut Teknologi Del

indica annual unggul yang disukai petani setempat [11].

Ciri-ciri utama RD23 berdasarkan jurnal [11], yaitu:

- Tipe tanaman: padi *indica* annual sawah irigasi.
- Pertumbuhan: tinggi tanaman sedang dengan jumlah anakan produktif cukup tinggi.
- Hasil gabah: hasil gabah per panen tergolong tinggi. Pada jurnal [11] melaporkan kisaran sekitar 5–6 ton per hektar di beberapa lokasi uji, sedikit lebih rendah dibanding padi perenial PR23 [11].
- Kualitas beras: mutu giling dan mutu konsumsi cukup baik, sehingga cocok sebagai varietas pembanding komersial.

Beberapa deskripsi varietas menyebut RD23 mempunyai ketahanan terhadap penyakit tertentu, misalnya hawar daun bakteri dan *ragged stunt virus*, sehingga menarik digunakan sebagai tetua pemuliaan.



Gambar 2. 1 *Oryza sativa* cultivar RD23

(Sumber: Jurnal [2])

Berikut kelebihan RD23:

- Hasil tinggi pada musim tanam awal: Dalam jurnal [3] membandingkan sistem budidaya padi perenial dan padi annual di Jinghong, Yunnan, RD23 digunakan sebagai tetua annual dalam skema persilangan untuk menghasilkan PR23 dan PR25, sedangkan uji lapang rutin padi perenial banyak menggunakan kultivar annual lain (misalnya HXR7) sebagai pembanding langsung di petak percobaan [3]. Di tingkat pemuliaan, RD23 diklasifikasikan sebagai kultivar *indica* sawah irigasi dengan potensi hasil tinggi (sekitar 6–8

Institut Teknologi Del

t ha⁻¹ pada kondisi optimal), sehingga relevan dijadikan tetua untuk membawa sifat hasil tinggi dan adaptasi luas ke dalam galur padi perenial.

- Adaptif di sawah irigasi: Varietas ini beradaptasi baik pada sistem sawah irigasi dengan input pupuk dan pengelolaan yang intensif–menengah, yang merupakan kondisi umum di Asia Tenggara dan sebagian Tiongkok [3], [11].
- Ketahanan penyakit tertentu: Laporan pemuliaan menyebut RD23 memiliki ketahanan terhadap beberapa penyakit utama, sehingga membantu menekan kehilangan hasil pada lingkungan endemik patogen [18].

Berikut kekurangan pada RD23:

- Sifat tahunan dan kemampuan ratoon rendah: RD23 tidak memiliki sifat abadi dimana jika tanaman yang memiliki sifat abadi(*perennial traits*) hidup setidaknya selama 2 tahun atau lebih, tetapi untuk varietas ini memerlukan penanaman ulang tahunan karena memiliki sifat tahunan (*annual traits*) hanya hidup selama 1 tahun dimana kemampuan tumbuh ulang (ratoon) menurun drastis, sehingga lahan perlu dibajak dan ditanam ulang. Hal ini menaikkan biaya tenaga kerja dan input jika dibandingkan sistem padi perenial yang dapat dipanen berkali-kali dari satu kali tanam [17].
- Tidak berizoma: RD23 tidak membentuk rizoma, sehingga tidak dapat menunjukkan pola pertumbuhan perenial tanpa diintrogresikan dengan sifat rizoma dari kerabat liar seperti *O. longistaminata* [4]. Manfaat: Karena hasil panennya yang tinggi dan kemampuan adaptasinya, RD23 berfungsi sebagai sumber daya genetic yang telah banyak digunakan dalam program pemuliaan untuk mengembangkan varietas padi baru dengan sifat yang tahan terhadap salinitas dan kekeringan [17].

Pada penelitian ini, RD23 berperan sebagai sumber gen sifat annual dan hasil tinggi yang diturunkan ke PR25 melalui hibridisasi dengan *O. longistaminata*.

2.1.2 *Oryza longistaminata*

Oryza longistaminata adalah spesies padi liar perenial yang termasuk dalam keluarga Poaceae dan memiliki genom AA. Tumbuhan ini berasal dari Afrika tropis dan tersebar luas dari Senegal hingga Somalia, sampai ke Afrika bagian barat daya

dan Madagaskar terutama di habitat rawa, dataran banjir, dan tepi sungai yang tergenang musiman. Sebagai kerabat liar padi budidaya (*Oryza sativa* dan *Oryza glaberrima*), *Oryza longistaminata* bersifat perenial dan berizoma, dengan rimpang bawah tanah yang memungkinkan tanaman bertahan, tumbuh kembali selama beberapa tahun tanpa penanaman ulang dan memiliki sifat-sifat adaptif terhadap berbagai stres lingkungan [14] [19].



Gambar 2. 2 *Oryza longistaminata*
(Sumber: Wikipedia¹ dan KnowYourWeeds²)

Ciri-ciri *Oryza longistaminata*:

- Daur hidup: perenial dengan rizoma menjalar; perbanyakan terjadi melalui biji dan rizoma.
- Karakteristik tanaman: rumpun lebat, banyak anakan, tinggi tanaman sedang–tinggi.
- Sistem perakaran: akar dalam dan rizoma panjang yang membantu tanaman bertahan terhadap kekeringan periodik dan banjir.
- Tipe genom: AA, sama dengan *O. sativa*, sehingga memudahkan persilangan dan introgresi gen.

Berikut kelebihan dan kekurangan *Oryza longistaminata*:

Tabel 2. 1 Kelebihan dan Kekurangan *Oryza longistaminata*

Kelebihan	Kekurangan
-----------	------------

Institut Teknologi Del

¹ https://ceb.wikipedia.org/wiki/Oryza_longistaminata

² <https://portal.wiktrop.org/species/show/415>

Tahan terhadap stres abiotik dan biotik, yaitu tahan terhadap penyakit hawar daun bakteri, kekeringan, salinitas, serta tahan terhadap lodging (robok) [14].	<i>O. longistaminata</i> memiliki sifat <i>seed shattering</i> (gabah mudah rontok), dormansi biji tinggi, dan ukuran gabah kurang sesuai standar konsumsi, sehingga tidak cocok langsung menjadi varietas budidaya [14].
Rizoma dan kemampuan tumbuh ulang (sifat perenial) memungkinkan sistem budidaya yang mengurangi kebutuhan olah tanah dan penanaman ulang, dan memberi peluang akumulasi karbon dan nitrogen tanah yang lebih tinggi dibanding padi annual sehingga mengurangi erosi tanah, dan efisiensi penggunaan air serta pupuk [2]	Tidak selalu berhasil menghasilkan biji dalam jumlah banyak (sekitar 1–2 t ha ⁻¹) dan lebih mengandalkan perbanyakan vegetatif melalui rizoma
Dapat menjadi kandidat untuk domestikasi ulang melalui pengeditan genom (CRISPR/Cas) untuk menghasilkan padi yang lebih tahan terhadap perubahan iklim	Dapat menjadi gulma karena rizoma panjang, memiliki sifat liar (seperti batang yang tinggi, masa vegetatif panjang, dan tidak serempak berbunga), dan sifat agresif yang bersaing dengan menekan pertumbuhan padi budidaya jika tidak dikelola.

Pemanfaatan dalam Pemuliaan:

- Introgresi sifat tahan penyakit: Gen Xa21 yang berasal dari *O. longistaminata* telah berhasil diintrogresikan ke dalam padi *O. sativa* untuk memberikan ketahanan terhadap hawar daun bakteri.
- Pemuliaan padi perenial: *O. longistaminata* digunakan sebagai parental donor dalam pemuliaan padi perenial yang dapat mengurangi biaya produksi dan dampak lingkungan
- Domestikasi ulang melalui genom editing: Dengan teknologi CRISPR/Cas, *O. longistaminata* dapat didomestikasi ulang untuk menghasilkan varietas

Institut Teknologi Del

baru yang memiliki sifat unggul dari kedua spesies [19].

Dalam penelitian ini, *O. longistaminata* dilihat sebagai sumber gen sifat perenial, rizoma, dan ketahanan stres yang diintrogresikan ke genom PR25.

2.1.3 *Oryza sativa subsp. indica cultivar PR25*

PR25 (*Perennial Rice 25* atau “Yunda25”) adalah padi yang dikembangkan dari hibridisasi antara RD23 dan *Oryza longistaminata*. Varietas ini memiliki potensi besar untuk mendukung sistem produksi pangan berkelanjutan, dengan akar yang dalam yang membantu perbaikan struktur tanah dan konservasi air. Dari satu penanaman, PR25 dapat dipanen hingga delapan kali selama empat tahun, mengurangi kebutuhan akan tenaga kerja dan input produk ikutan. Menurut penelitian [2], menunjukkan bahwa PR25 tidak hanya bertahan pada hasil yang sebanding dengan varietas tahunan, tetapi juga berkontribusi pada peningkatan kualitas tanah dan keanekaragaman hayati. Kemampuannya dalam mengurangi ketergantungan pada input kimia dan memperbaiki kesehatan tanah sejalan dengan kebutuhan global saat ini untuk praktik pertanian yang berkelanjutan [18].



Gambar 2. 3 *Oryza sativa cultivar PR25*

(Sumber: Jurnal [2])

Berikut kelebihan PR25, yakni:

- Perennialitas: Dengan kemampuan menghasilkan beberapa panen dari satu penanaman, padi perenial seperti PR25 mengurangi frekuensi olah tanah,

Institut Teknologi Del

semai, dan tanam ulang, sehingga menurunkan kebutuhan tenaga kerja dan benih. Penelitian [2] menunjukkan bahwa PR25 dapat memberikan hasil yang kompetitif, rata-rata mencapai sekitar 6,8 ton per hektar per panen.

- Ketahanan Terhadap Stres/Tantangan Lingkungan: Berkat kontribusi genetik dari *O. longistaminata*, PR25 menunjukkan ketahanan yang baik terhadap berbagai stres, termasuk fluktuasi cuaca, hama, dan penyakit, serta mempertahankan hasil yang kompetitif dengan padi tahunan. Sifat-sifat ini penting untuk meningkatkan ketahanan pangan dalam menghadapi perubahan iklim global.
- Kualitas Tanah dan Keanekaragaman Hayati: PR25 memiliki akar yang dalam dan penutup tanah yang terus-menerus membantu meningkatkan karbon organik dan nitrogen tanah, membantu memperbaiki struktur tanah, menaikkan pH tanah sekitar 0,3–0,4 satuan, dan meningkatkan kapasitas air tersedia sehingga dapat berkontribusi pada kesehatan ekosistem. Hal ini penting untuk menjaga kesuburan tanah dan mengurangi erosi [2], [20, p. 9].

Berikut kekurangan PR25:

- Manajemen gulma dan pemupukan yang berbeda: karena lahan tidak dibajak dan tidak ditanami ulang setiap musim, pengelolaan gulma dan strategi pemupukan perlu disesuaikan (misalnya pengaturan dosis nitrogen dan kepadatan tanam) agar regrowth tetap kuat dan hasil tidak turun [3].
- Pengendalian Hama dan Penyakit: Risiko patogen dan hama yang ditularkan melalui tanah dapat meningkat dalam sistem abadi (*perennial system*) PR25 [20, p. 18].
- Adaptasi iklim yang spesifik: performa terbaik padi perenial dicapai di lingkungan dengan musim dingin relatif ringan; di daerah dengan suhu rendah ekstrem, kemampuan tumbuh kembali dan hasil dapat menurun sehingga umur produktif tanaman memendek [2] [21, p. 2].

Berikut manfaat PR25:

1. Keuntungan Ekonomi: Mempertahankan hasil panen yang tinggi tanpa penanaman ulang menghasilkan pengurangan biaya budidaya, yang

menguntungkan petani kecil [2, p. 1].

2. Produktivitas Jangka Panjang: Kemampuannya untuk menghasilkan panen berkali-kali menawarkan keuntungan produktivitas jangka Panjang [21, p. 2].

Berikut perbedaan RD23, PR25, dan *Oryza longistaminata*:

Tabel 2. 2 Perbedaan RD23, PR25, dan *Oryza longistaminata*

Aspek	<i>O. sativa subsp. indica</i> cv. RD23	<i>Oryza longistaminata</i>	PR25 (Perennial Rice 25 / Yunda25)
Status taksonomi	Padi budidaya <i>O. sativa subsp. indica</i> tahunan (annual) dari Thailand	Spesies liar Afrika, genom AA, perenial	Hibrida <i>O. sativa subsp. indica</i> RD23 × <i>O. longistaminata</i> (padi perenial)
Rizoma	Tidak ada rizoma sehingga ditanam ulang tiap musim	Rizoma panjang (≤ 100 cm) dan agresif, pertumbuhan vegetatif berkelanjutan	Rizoma pendek hingga sedang (≤ 25 cm), regenerasi 3–4 kali (<i>regrowth</i>), tetapi lebih mudah dikelola dibanding <i>O. longistaminata</i> liar
Tinggi	95–100 cm	> 200 cm	110–120 cm
Hasil Biji	7,2 t ha ⁻¹ (tahunan)	1–2 t ha ⁻¹	6,8 t ha ⁻¹ per tahun (stabil 4 tahun)
Sifat Unggul	Hasil tinggi, adaptif di sawah irigasi, mutu gabah baik, ketahanan penyakit tertentu	Toleran kekeringan, salinitas, banjir, dan beberapa penyakit; sistem akar dan rizoma kuat	Perenial dengan hasil stabil, mengurangi biaya tenaga kerja dan input, memperbaiki karbon dan

Institut Teknologi Del

			nitrogen tanah, serta mendukung kesehatan tanah
Lingkungan utama	Sawah irigasi di wilayah tropis/subtropis (misalnya Yunnan, Asia Tenggara)	Rawa, bantaran sungai, dan lahan tergenang musiman di Afrika sub-Sahara	Sawah irigasi dan subirigasi di daerah tropis/subtropis dengan musim dingin ringan
Frekuensi Panen per Tahun	Setiap siklus ± 110 –125 hari; di sawah irigasi bisa ditanam ulang 2–3 kali setahun (padi indica tahunan)	Spesies liar, biji tidak dipanen secara ekonomi. Jika tumbuh liar hanya dipanen pilih-pilih oleh pengumpul biji liar	Panen 8 kali total. Artinya rata-rata 2 kali panen/tahun selama 4 tahun berturut-turut tanpa menanam ulang.

2.2 Perolehan Data Genom sebagai Data Input

Secara biologis, genom dapat dipahami sebagai seluruh DNA yang dimiliki suatu organisme dalam satu set kromosom, berupa rangkaian basa nukleotida adenin (A), timin (T), sitosin (C), dan guanin (G). Pada tingkat molekuler, urutan keempat basa ini (A, T, C, G) menyusun gen dan daerah non-pengkode di sepanjang kromosom, sehingga kombinasi dan susunannya memuat informasi genetik lengkap organisme tersebut. Hal ini tampak, misalnya, pada metode genome walking yang dikembangkan pada jurnal [22] menjelaskan bahwa basa “N” pada primer degeneratif didefinisikan sebagai salah satu dari A, T, C, atau G, dan memanfaatkan variasi urutan keempat basa tersebut untuk menjelajahi sekuens genom yang belum diketahui. Dengan kata lain, genom pada dasarnya adalah himpunan penuh sekuens DNA berbasis A, T, C, dan G yang terdapat di dalam sel.

Genom digunakan sebagai “satu paket penuh” DNA yang berhasil dirakit sampai tingkat kromosom. Pada jurnal [23] menyusun genom *Brassica rapa* kultivar *Longyou-7* menggunakan data PacBio HiFi dan Hi-C, menghasilkan assembly

berukuran sekitar 413 Mb dengan nilai N50 scaffold 42,25 Mb. Dari total panjang tersebut, kurang lebih 408 Mb sekuens berhasil ditempatkan (*di-anchor*) ke 10 pseudokromosom berdasarkan pola interaksi Hi-C, sehingga sebagian besar DNA genomik sudah teratur dan terorientasi pada masing-masing kromosom. Assembly skala kromosom ini kemudian dipakai sebagai genom referensi untuk kultivar “Longyou-7”, yaitu representasi genom standar yang digunakan sebagai acuan dalam anotasi gen dan analisis genomik lanjutan [23]. Pola serupa terlihat pada tanaman lain yaitu dalam jurnal [23] menyusun genom *Calophaca sinica* menjadi sekitar 1,06 Gb, lalu dengan bantuan data Hi-C menempatkan sekitar 91,6% panjang sekuens ke dalam 8 pseudokromosom dan menilai kelengkapannya dengan BUSCO serta pemetaan ulang short read, sehingga assembly tersebut diperlakukan sebagai genom lengkap spesies itu. Berdasarkan studi/jurnal tersebut, istilah “genom” merujuk pada keseluruhan sekuens DNA (A, T, C, G) yang berhasil dirakit dan ditempatkan ke kromosom.

Konsep yang sama digunakan pada genom hewan dan manusia. Dalam jurnal [24] menyusun 130 assembly haplotipe dari 65 genom manusia dengan kontinuitas median sekitar 130 Mb. Perakitan ini mampu mengisi banyak gap lama, yaitu bagian kromosom yang dulu hanya diwakili deretan basa ‘N’ karena urutannya belum diketahui, dan menghasilkan kromosom yang nyaris lengkap dari telomer satu ke telomer lainnya untuk banyak kromosom. Jurnal [24] tersebut menggambarkan set hasil ini sebagai *nearly complete human genomes*, yaitu urutan DNA yang mencakup hampir seluruh sekuens kromosom yang dapat dideteksi dan dipakai untuk mempelajari variasi struktural kompleks [24]. Adapun berdasarkan studi/jurnal tersebut, genom selalu diperlakukan sebagai set lengkap DNA genomik yang dirangkai ke dalam struktur kromosom dan menjadi dasar analisis genetika, evolusi, dan pemuliaan.

Karena itu, sekuensing genom berarti membaca urutan basa A, T, C, dan G di seluruh genom sampai kedalaman dan cakupan yang cukup untuk membangun genome assembly yang representatif. Dalam jurnal [25] ketika membandingkan sekuensing short read Illumina dan long read Nanopore pada sampel kanker kolorektal, menganalisis komposisi nukleotida A, T, G, dan C di seluruh whole-genome sequencing dan menunjukkan bagaimana data tersebut dipakai untuk

memanggil varian (SNP dan SV) di seluruh genom [25]. Pada jurnal [23], [26] yang merupakan studi genom tanaman, memulai dari sekuensing skala genom (PacBio HiFi, ONT, dan Hi-C), kemudian menggunakan bacaan tersebut untuk merakit genom skala kromosom dan menilai kelengkapannya dengan BUSCO, pemetaan short read, serta analisis struktur genom [23], [26].

Berdasarkan jurnal-jurnal tersebut, dalam Penelitian ini, genom PR25 dan RD23 dapat dijelaskan sebagai set lengkap DNA genomik berbasis A, T, C, dan G yang sudah disekuensing dan dirakit sampai resolusi skala kromosom oleh pihak BGI dan penyedia data publik. Hasil akhirnya disajikan dalam bentuk berkas FASTA genom, yaitu PR25.FINAL.fasta untuk hibrida *Oryza sativa indica* PR25, RD23.FINAL.fasta untuk kultivar RD23, serta genom publik *O. longistaminata* (*Oryza_longistaminata_v1.0.dna.toplevel.fa*). Titik awal Penelitian ini penulis adalah ketiga berkas FASTA genom ini, yang kemudian digunakan untuk Penelitian ini dengan BUSCO, QUAST, Liftoff, OrthoFinder, EggNOG-mapper, dan InterProScan.

2.3 Metode Penelitian

Metode penelitian yang digunakan dalam penelitian ini dimulai dari analisis kualitas genom dengan BUSCO dan QUAST, dilanjutkan dengan data preprocessing (Liftoff, AGAT, gffread, dan pembersihan sekuens protein), identifikasi gen homolog atau turunan dengan OrthoFinder, anotasi fungsi dengan EggNOG-mapper dan InterProScan, serta integrasi data hasil OrthoFinder, EggNOG-mapper, dan InterProScan. Subbab-subbab berikut menjelaskan prinsip dan peran masing-masing alat dalam alur analisis genom PR25, RD23, dan *Oryza longistaminata*. Berikut penjelasan untuk setiap metode yang digunakan.

2.3.1 Analisis Kualitas Perakitan Genom

Adapun analisis kualitas perakitan genom melalui BUSCO dan QUAST, berikut penjelasannya:

2.3.1.1 Evaluasi Kelengkapan Konten Gen pada Perakitan Genom

Untuk melakukan evaluasi kelengkapan Konten gen pada perakitan genom, dilakukan dengan BUSCO. BUSCO (*Benchmarking Universal Single-Copy Orthologs*) adalah perangkat lunak untuk menilai kelengkapan genom, transkriptom, atau set gen anotasi dengan memeriksa keberadaan gen-gen single-copy ortholog yang hampir universal pada suatu kelompok taksonomi dimana dapat dilihat panduan BUSCO. Dataset BUSCO dibangun dari OrthoDB dan berisi gen penanda yang diharapkan muncul sebagai satu salinan pada $\geq 90\%$ spesies dalam suatu garis keturunan [27].

Berdasarkan studi [28], BUSCO menghitung proporsi gen penanda yang ditemukan secara lengkap, terduplikasi, terfragmentasi, atau tidak ditemukan dalam rakitan genom. Metrik tersebut memberikan ukuran kelengkapan yang bermakna secara biologis dan melengkapi metrik teknis seperti jumlah kontig atau N50 [28]. Berdasarkan [28] tentang BUSCO menegaskan bahwa pendekatan ini telah digunakan luas untuk menilai kualitas rakitan dan anotasi genom, membandingkan versi rakitan, serta mendukung aplikasi lain seperti pelatihan gene predictor dan filogenomika [28].

2.3.1.1.1 Kategori Gen

BUSCO mengelompokkan setiap gen penanda ke dalam empat kategori utama, yaitu *Complete and single-copy (C, S)*, *Complete and duplicated (C, D)*, *Fragmented (F)*, dan *Missing (M)*.

1. *Complete (C)*: Gen yang ditemukan lengkap. BUSCO menganggap suatu gen lengkap jika panjangnya sejajar dengan profil BUSCO dan skor identitasnya tinggi. Namun, dalam beberapa kasus mungkin terjadi kesalahan identifikasi, misalnya jika suatu gen tidak ada dalam dataset input atau hanya sebagian hadir namun terdapat homolog dengan identitas tinggi dan panjang sejajar penuh, homolog tersebut mungkin salah diidentifikasi sebagai BUSCO yang lengkap. Namun, batas skor yang dioptimalkan untuk meminimalkan kemungkinan ini tetap ada. Berdasarkan [29] menambahkan bahwa jika suatu gen ditemukan lengkap, baik single-copy maupun duplicated, maka BUSCO matches-nya memiliki skor dalam rentang yang diharapkan dan panjang sejajar dengan

BUSCO profile yang diharapkan [29].

2. *Duplicated (D)*: Gen yang ditemukan lebih dari satu salinan. Tingkat duplikasi yang tinggi dapat dijelaskan oleh peristiwa duplikasi keseluruhan yang baru-baru ini (biologis) atau perakitan kimerik dari haplotipe (teknis). Transkrip dan set protein yang tidak difilter untuk isoform akan menyebabkan proporsi duplikat yang tinggi. Oleh karena itu, sebelum analisis BUSCO, mereka harus difilter [29].
3. *Fragmented (F)*: Gen yang ditemukan sebagian. Hal ini sering terjadi ketika urutan tidak cukup panjang atau kualitas rendah, mengakibatkan gangguan dalam perakitan gen penuh. Banyaknya gen yang terfragmentasi mungkin menunjukkan bahwa genom belum dirakit dengan baik atau bahwa kesalahan sekuen mencegah perakitan yang tepat. Juga dapat menunjukkan bahwa beberapa daerah genom sulit untuk dirakit karena kompleksitas tinggi, seperti daerah yang kaya akan pengulangan. Berdasarkan [28] mengatakan jika suatu gen sebagian ada dan terdapat homolog dengan identitas tinggi dan panjang sejajar penuh, homolog tersebut mungkin salah diidentifikasi sebagai BUSCO yang ditemukan lengkap tetapi sebenarnya terfragmentasi [29].
4. *Missing (M)*: Gen yang tidak ditemukan sama sekali. Banyaknya gen yang hilang seringkali menunjukkan adanya kesenjangan dalam perakitan di mana gen yang penting seharusnya ada namun tidak ada. Dapat disebabkan oleh *coverage* sekuen yang rendah, kesalahan selama proses perakitan, atau faktor biologis seperti kehilangan gen pada spesies yang diteliti. Banyaknya gen yang hilang juga dapat menunjukkan kesalahan dalam anotasi genom atau bias sekuen, di mana beberapa daerah genom tidak terwakili atau hilang sama sekali. Berdasarkan [28] dijelaskan bahwa jika suatu gen tidak ada dalam dataset input, atau hanya sebagian hadir (fragment tinggi), dan suatu homolog dengan identitas tinggi dan panjang sejajar penuh hadir, mungkin terjadi kesalahan identifikasi sebagai BUSCO yang ditemukan lengkap, tetapi sebenarnya gen tersebut hilang [29].

2.3.1.1.2 Skor Kelengkapan BUSCO

Skor kelengkapan BUSCO umumnya dinyatakan sebagai persentase gen penanda

yang diklasifikasikan sebagai *Complete (C)*, dan sering dipecah menjadi *Complete and single-copy (S)* dan *Complete and duplicated (D)*. Dalam banyak studi genom modern busco, seperti [28], nilai C di atas kira-kira 95% dipakai sebagai indikasi praktis bahwa rakitan genom tersebut sudah cukup lengkap untuk analisis lanjutan, meskipun BUSCO sendiri tidak menetapkan ambang batas resmi dan interpretasinya tetap harus disesuaikan dengan kelompok organisme serta tujuan analisis [27], [28]. Studi [28] menekankan bahwa proporsi C, D, F, dan M perlu dibaca dalam konteks biologis dan teknis. Proporsi D yang tinggi, misalnya, dapat berasal dari duplikasi gen atau genom (biologis), tetapi juga bisa disebabkan oleh perakitan kimerik dari haplotipe berbeda atau set protein/transkriptom yang belum difilter isoformnya. Untuk data transkriptom yang hanya mencakup jaringan atau tahap perkembangan tertentu, skor kelengkapan BUSCO secara alami akan lebih rendah, sehingga konsistensi antar sampel dan tujuan eksperimen menjadi pertimbangan utama [28].

Praktiknya, banyak studi genom terbaru melaporkan nilai C BUSCO sebagai bukti bahwa rakitan yang dihasilkan cukup lengkap. Misalnya, pada jurnal [30] dengan rakitan genom ngengat *Theretra oldenlandiae* menunjukkan kelengkapan BUSCO 99,2% (99,1% single-copy, 0,1% duplicated, 0,2% fragmented, 0,6% missing), sedangkan dalam studi [31] dengan rakitan genom rusa Visayan (*Rusa alfredi*) dilaporkan memiliki BUSCO complete 95,5% dan digunakan sebagai indikator bahwa rakitan sudah memadai untuk analisis evolusi dan anotasi gen lebih lanjut [30], [31].


2.3.1.1.3 Mekanisme BUSCO

Untuk menilai kelengkapan dan kualitas genom atau transkriptom dengan membandingkannya terhadap sekumpulan gen universal yang diharapkan ada dalam suatu kelompok organisme. BUSCO menggunakan algoritma berbasis profil *Hidden Markov Model (HMM)* dan pencocokan urutan untuk mengidentifikasi gen-gen ini. BUSCO menggunakan HMMER3 untuk membandingkan urutan prediksi dengan profil HMM dari dataset BUSCO. Setiap profil HMM mewakili keluarga gen ortholog. *Hidden Markov Model (HMM)* adalah model statistik yang digunakan

untuk memprediksi urutan gen atau protein dengan membandingkannya terhadap profil konservasi evolusioner. Dalam konteks BUSCO, profil HMM dibangun dari kumpulan gen universal (*single-copy orthologs*) yang telah teridentifikasi di berbagai spesies dalam kelompok taksonomi tertentu. Setiap profil HMM merepresentasikan pola konservasi residu asam amino atau basa nukleotida dari gen-gen ini, termasuk daerah yang sangat konservatif (misalnya domain fungsional) dan daerah yang lebih variabel. BUSCO menggunakan profil ini untuk mencari kecocokan dalam genom target melalui algoritma pencocokan seperti HMMER [32].

Dalam praktiknya, pencarian kandidat BUSCO dilakukan dengan menjalankan *hmmsearch* (HMMER3) antara protein kandidat dan profil HMM BUSCO. Hasil pencocokan berupa bit score, E-value, dan panjang alignment kemudian dievaluasi terhadap ambang batas yang telah ditentukan untuk setiap gen BUSCO secara terpisah. Informasi ambang ini disimpan di berkas *scores_cutoff* (nilai skor minimum HMMER agar suatu hit dianggap ortholog BUSCO) dan *lengths_cutoff* (batas panjang minimum agar suatu hit dinilai lengkap) [28]. Dengan demikian, BUSCO tidak menggunakan satu angka ambang universal (misalnya satu nilai bit score atau E-value untuk semua gen), tetapi memanfaatkan cutoff spesifik per marker yang diturunkan dari distribusi skor dan panjang pada spesies rujukan di OrthoDB. Pendekatan ini membuat klasifikasi *Complete*, *Fragmented*, dan *Missing* menjadi lebih sensitif dan spesifik untuk setiap lineage [28]. Sebagai contoh, dalam jurnal [33] mengevaluasi kelengkapan sejumlah genom alga dengan membandingkan berbagai metrik kualitas, termasuk BUSCO, dan menunjukkan bahwa pemilihan dataset lineage yang tepat penting untuk mendapatkan estimasi kelengkapan yang stabil [33].

BUSCO menilai kelengkapan genom berdasarkan keberadaan gen-gen single-copy ortholog yang hampir universal dalam suatu kelompok taksonomi. Panel gen marker ini diambil dari basis data OrthoDB dan diperbarui secara berkala, misalnya bersamaan dengan rilis OrthoDB v10/v11, sehingga mencakup ribuan genom eukariot, prokariot, dan virus [32] [27].



Gambar 2. 4 Alur BUSCO

Berikut penjelasan alur kerja pada gambar 2.4:

1. Input data

BUSCO mendukung beberapa jenis input genomik, yaitu *genome assembly*, *annotated gene set (protein)*, dan *transcriptome* [28], [32]. *Genome assembly* direpresentasikan sebagai berkas FASTA yang berisi kontig atau scaffold/kromosom; *annotated gene set* berupa sekuens protein hasil anotasi; sedangkan *transcriptome* berupa transkrip RNA yang sudah dirakit. Dalam penelitian ini, BUSCO digunakan untuk menilai *genome assembly* PR25, RD23, dan *Oryza longistaminata*, sehingga jalur yang dipakai adalah *genome mode*.

2. Pemilihan dataset lineage BUSCO

Setiap analisis BUSCO harus menggunakan dataset lineage yang sesuai, misalnya *embryophyta_odb10* atau *poales_odb10* untuk tanaman. Dataset ini berisi kumpulan ortholog yang dipilih berdasarkan dua kriteria, yaitu hadir pada mayoritas spesies dalam lineage, dan tetap single-copy pada sebagian besar spesies tersebut, sehingga mewakili gen penanda yang konservatif dan informatif untuk kelengkapan genom [32]. Pada BUSCO v5, diperkenalkan fitur *auto-lineage*, di mana BUSCO terlebih dahulu melakukan penempatan filogenetik (*phylogenetic placement*) terhadap input lalu otomatis memilih dataset yang paling cocok jika pengguna tidak menentukan lineage secara manual [32].

3. Ekstraksi gen kandidat BUSCO

Setelah lineage dipilih, BUSCO mengekstraksi protein kandidat BUSCO dari

data input. Cara ekstraksi bergantung pada mode yang digunakan. Pada genome mode (yang digunakan dalam penelitian ini), genome *assembly* belum memiliki anotasi gen, sehingga BUSCO menjalankan gene finder/gene mapper untuk memprediksi atau memetakan gen dan menghasilkan sekuens protein kandidat. Versi BUSCO v5/v6 mendukung beberapa alat, di antaranya MetaEuk, Miniprot, dan AUGUSTUS [28], [32]. Miniprot diperkenalkan pada jurnal [34] yang memetakan sekuens protein ke genom dengan mempertimbangkan intron, splicing, dan kemungkinan frameshift [34]. Dalam user guider BUSCO V6 menyatakan bahwa sejak versi 5.7.0, Miniprot menjadi default untuk eukaryotic genome mode, karena lebih cepat dan umumnya menghasilkan skor kelengkapan sedikit lebih tinggi dibanding AUGUSTUS atau MetaEuk pada banyak genom eukariot besar [27]. Alternatifnya, BUSCO dapat menggunakan MetaEuk (efisien untuk metagenom eukariot) atau AUGUSTUS (ab initio gene prediction) jika pengguna mengaktifkan opsi tertentu. [32]. Pada protein mode, BUSCO tidak perlu melakukan prediksi gen karena input sudah berupa anotasi protein. Sekuens protein tersebut langsung diperlakukan sebagai kandidat BUSCO. Pada transcriptome mode, BUSCO terlebih dahulu mengekstraksi *Open Reading Frame (ORF)*, yaitu segmen urutan transkrip yang berpotensi dikode menjadi protein (dimulai dari kodon start dan berakhir pada kodon stop tanpa gangguan stop codon di tengah). ORF ini kemudian diterjemahkan menjadi sekuens protein kandidat yang selanjutnya dibandingkan dengan profil HMM marker BUSCO [28].

4. Pencocokan ke profil HMM BUSCO

Semua protein kandidat kemudian dibandingkan dengan profil *Hidden Markov Model (HMM)* dari setiap gen marker BUSCO menggunakan program *hmmsearch* dari paket HMMER3 [28]. Setiap profil HMM dibangun dari multiple sequence alignment ortholog BUSCO dalam satu keluarga gen, sehingga merekam pola konservasi residu asam amino di sepanjang protein. Hasil *hmmsearch* memberikan *bit score* (skor log-odds HMM), E-value, dan *coverage* (proporsi panjang model/gen BUSCO yang tercakup oleh alignment). Skor yang tinggi, E-value yang rendah, dan coverage yang besar

menunjukkan kecocokan yang kuat antara kandidat dan gen BUSCO yang dimaksud.

5. Klasifikasi tiap gen BUSCO

BUSCO kemudian menggabungkan informasi skor dan panjang alignment untuk mengklasifikasikan setiap gen marker ke dalam kategori *Complete*, *Fragmented*, atau *Missing*, dengan membedakan *Complete* menjadi *Single-copy* (*S*) dan *Duplicated* (*D*). Untuk setiap dataset lineage, BUSCO menyediakan berkas `scores_cutoff` dan informasi distribusi panjang (*length expectations*) bagi tiap gen BUSCO [28]. Jika terdapat satu kandidat dengan skor $HMM \geq score_cutoff$ dan panjang alignment berada dalam rentang panjang yang diharapkan, marker tersebut diklasifikasikan sebagai *Complete single-copy* (*C, S*). Jika lebih dari satu kandidat memenuhi kriteria skor dan panjang untuk marker yang sama, maka diklasifikasikan sebagai *Complete duplicated* (*C, D*), yang dapat mencerminkan duplikasi gen secara biologis maupun artefak teknis seperti haplotig yang belum digabung [32]. Jika ada kecocokan dengan skor $\geq score_cutoff$ tetapi panjang alignment hanya mencakup sebagian kecil dari panjang gen yang diharapkan, marker dikategorikan sebagai *Fragmented* (*F*). Hal ini biasanya menunjukkan bahwa rakitan genom masih terfragmentasi atau ada wilayah yang sulit dirakit [28]. Jika tidak ada kandidat yang mencapai skor minimal, marker dianggap *Missing* (*M*), yang dapat mengindikasikan bagian genom yang belum tertangkap, bias sekuensing, atau kehilangan gen secara biologis sehingga interpretasinya perlu mempertimbangkan konteks evolusioner spesies [32].

6. Ringkasan dan output

Pada langkah akhir, BUSCO merangkum hasil klasifikasi seluruh marker menjadi metrik kelengkapan genom yang bermakna secara biologis, yaitu persentase *Complete* (*C*) yang dipisah menjadi *Single-copy* (*S*) dan *Duplicated* (*D*), serta persentase *Fragmented* (*F*) dan *Missing* (*M*) [28], [32]. Hasil ini dilaporkan dalam berkas `short_summary` (teks/JSON) dan `full_table.tsv`, dan dapat divisualisasikan sebagai diagram batang yang menunjukkan distribusi C/S, C/D, F, dan M [32]. Studi genom modern 2020–2025 secara rutin melaporkan skor BUSCO sebagai indikator utama

kelengkapan genome assembly. Misalnya, berbagai genome tanaman, hewan, dan jamur dilaporkan memiliki BUSCO Complete di atas 95–97%, dan nilai tersebut dijadikan dasar bahwa rakitan genom sudah cukup lengkap untuk anotasi gen, analisis komparatif, dan studi filogenomik lanjutan. [35]

2.3.1.2 Evaluasi Struktur Perakitan Genom

Untuk melakukan evaluasi struktur perakitan genom pada perakitan genom, dilakukan dengan QUAST. QUAST (*Quality Assessment Tool for Genome Assemblies*) merupakan perangkat lunak bioinformatika yang digunakan untuk menilai kualitas hasil perakitan genom berdasarkan kombinasi metrik statistik dan metrik berbasis alignment terhadap genom referensi. Tool ini dapat dijalankan baik dengan genom referensi (*reference-based mode*) maupun tanpa referensi (*reference-free mode*). Ketika referensi tersedia, QUAST menyelaraskan kontig hasil perakitan ke genom referensi dan menghitung berbagai ukuran kualitas struktural (*misassembly, genome fraction, mismatch, indel*). Jika referensi tidak tersedia, QUAST tetap dapat mengestimasi kualitas dengan menganalisis distribusi panjang kontig, N50, L50, dan kandungan GC. Pendekatan ini tercermin dalam studi [36], yang menggunakan QUAST untuk membandingkan beberapa assembler metagenom baik dengan maupun tanpa referensi, serta pada penggunaan QUAST v5 dalam pipeline genom modern [36].


Beberapa metrik inti yang dihitung QUAST berkaitan dengan kontinuitas perakitan (*contiguity*). Jumlah kontig (*number of contigs*) dan panjang total perakitan (*total length*) memberikan gambaran umum seberapa terfragmentasi rakitan dan seberapa dekat panjangnya terhadap ukuran genom yang diharapkan. Metrik N50 didefinisikan sebagai panjang kontig terpendek di antara kumpulan kontig terpanjang yang secara kumulatif mencakup $\geq 50\%$ dari total panjang assembly; semakin tinggi nilai N50, umumnya semakin baik kontinuitas rakitan. L50 adalah jumlah minimum kontig terpanjang yang diperlukan untuk mencapai 50% total panjang assembly sehingga semakin kecil L50 menunjukkan bahwa sebagian besar genom tercakup oleh sedikit kontig panjang. Selain itu, yang memperhitungkan ukuran genom referensi adalah NG50, yang dihitung dengan prinsip serupa namun

terhadap panjang genom yang diharapkan, bukan panjang *assembly*. Definisi ini konsisten dengan pedoman evaluasi perakitan atau *assembly* yang diuraikan dalam jurnal [37] dan didukung pula oleh penggunaan QUAST v5.3.0 pada evaluasi genom bakteri *Borrelia*, di mana N50 dan jumlah kontig dilaporkan sebagai indikator utama kualitas rakitan.

Selain metrik kontinuitas, QUAST menghitung berbagai metrik kesalahan struktural dan akurasi sekuens terutama ketika genom referensi tersedia. Misassembly didefinisikan sebagai kejadian di mana segmen kontig menunjukkan pola alignment yang tidak konsisten terhadap referensi, misalnya inversi, relokasi, atau penggabungan fragmen yang berasal dari lokasi berbeda. QUAST juga mengestimasi tingkat *mismatches* (substitusi basa) dan indels (penyisipan/penghapusan) per 100 kilobasa, sehingga peneliti dapat menilai seberapa jauh sekuens yang dirakit menyimpang dari referensi. Di samping itu, QUAST melaporkan *genome fraction*, yaitu persentase basa referensi yang tercakup oleh kontig hasil perakitan, serta jumlah dan panjang fragmen yang tidak teralign. Kombinasi metrik ini dimanfaatkan dalam jurnal [36] untuk membandingkan performa beberapa assembler pada dataset metagenom, dan dijadikan indikator penting dalam pipeline kualitas genom bakteri dan virus [36]. QUAST juga menyediakan informasi tambahan seperti komposisi GC (*GC content*) dan statistik kontig terpanjang (*largest contig*), yang membantu mengidentifikasi potensi bias teknis atau artefak perakitan yang terkait dengan komposisi basa. Dalam jurnal [36] menggunakan QUAST v5.3.0 untuk mengevaluasi rakitan genom *Borrelia lusitaniae* dan menekankan bahwa genome dengan N50 tinggi, jumlah kontig rendah, dan GC content yang konsisten dengan nilai yang diharapkan menunjukkan kualitas perakitan yang baik. Laporan QUAST meliputi berkas teks ringkas, tabel TSV, dan laporan HTML interaktif (misalnya Icarus contig browser dan grafik misassembly), sehingga memudahkan peneliti menelusuri kontig bermasalah maupun membandingkan beberapa hasil perakitan dalam satu tampilan terintegrasi.

Dengan fitur-fitur tersebut, QUAST menjadi komponen penting dalam pipeline analisis genom modern, khususnya untuk memastikan integritas struktural dan

kualitas teknis rakitan sebelum digunakan untuk anotasi gen, analisis komparatif, atau studi evolusioner. Artikel panduan genom tahun 2020 menempatkan tahap *assembly quality check* sebagai langkah wajib sebelum anotasi, dengan menekankan metrik contiguity (N50, NG50, L50, jumlah kontig), ukuran total *assembly*, dan kesesuaian terhadap genom referensi. Dalam praktiknya, genom dengan nilai N50 yang tinggi, sedikit kontig, dan tingkat *misassembly* serta mismatch/indel yang rendah biasanya dianggap cukup matang untuk dilanjutkan ke tahap anotasi dan analisis fungsional [37]. Berikut alur/cara kerja QUAST:



Gambar 2. 5 Alur QUAST

Berikut penjelasan pada gambar tersebut:

1. Data Input

QUAST menerima satu atau lebih assembly genom dalam format FASTA sebagai input utama. Selain itu, pengguna dapat menambahkan genom referensi (untuk mode berbasis alignment) dan, dalam beberapa kasus, anotasi gen atau data tambahan lain. Dalam jurnal [36] menjalankan QUAST pada beberapa assembly untuk tiga dataset metagenom dan menunjukkan bagaimana tool ini dapat dipakai baik dengan maupun tanpa referensi, sedangkan manual QUAST v5.3.0 mendeskripsikan struktur input untuk mode single-genome dan multi-assembly [36].

2. Alignment ke genom referensi (jika tersedia)

Jika genom referensi disediakan, QUAST akan menyelaraskan setiap kontig atau scaffold ke referensi tersebut menggunakan aligner yang terintegrasi (misalnya minimap2 atau aligner lain yang dikonfigurasi pada versi terbaru). Untuk data metagenom dalam jurnal [36] menjelaskan bahwa semua kontig terlebih dahulu dipartisi menjadi kelompok-kelompok berdasarkan referensi yang paling cocok; kemudian, QUAST dijalankan per referensi, dan kontig

yang tidak teralign dianalisis secara terpisah dalam mode tanpa referensi [36].

3. Hitungan statistik dasar *assembly*

Setelah alignment (atau langsung dari FASTA jika tidak ada referensi), QUAST menghitung statistik umum: jumlah kontig, panjang total *assembly*, panjang kontig terpanjang, dan metrik kontinuitas seperti N50, L50, dan NG50. Pada jurnal [37] menggunakan QUAST v5.3.0 untuk menghitung jumlah kontig, N50, dan GC content pada beberapa *assembly* *Borrelia* dan menafsirkan N50 yang tinggi dan sedikit kontig sebagai indikasi *assembly* yang lebih kontinu. PLOS 2020 menegaskan definisi formal N50/NG50 dan menempatkannya sebagai metrik utama pada tahap *check the assembly quality* [37].

4. Hitungan metrik berbasis referensi

Dengan memanfaatkan alignment, QUAST kemudian mengidentifikasi misassembly, yaitu kejadian ketika segmen kontig tidak konsisten posisinya terhadap referensi (misalnya terjadi inversi, perpindahan ke kromosom lain, atau penggabungan dua region yang berjauhan). Dalam jurnal [37] memperlihatkan laporan misassembly dan grafik terkait yang dihasilkan QUAST untuk beberapa assembler pada dataset CAMI, MetaHIT, dan HMP. Selain itu, QUAST menghitung *genome fraction* (proporsi genom referensi yang tertutupi kontig), jumlah mismatch dan indel per 100 kb, serta jumlah basa yang tetap tidak teralign. Semua metrik ini terdokumentasi dalam manual QUAST v5.3.0 sebagai bagian dari output standar ketika referensi diberikan [37].

5. Ringkasan & visualisasi output

Langkah terakhir, QUAST menghasilkan beberapa jenis output:

- Laporan ringkas dalam bentuk teks (misalnya report.txt) dan tabel (report.tsv) untuk tiap *assembly*.
- Laporan HTML interaktif yang memuat grafik *misassembly*, grafik distribusi panjang kontig, grafik *genome fraction*, dan modul visual seperti *Icarus contig browser* yang memudahkan peneliti menelusuri kontig dan posisinya terhadap referensi.
- Ringkasan komparatif ketika beberapa *assembly* dianalisis sekaligus,

sehingga metrik untuk setiap assembler dapat dibandingkan secara langsung. Pada jurnal [36] menampilkan grafik *misassembly* dan *genome fraction* dari QUAST untuk membandingkan empat assembler metagenom [36], sedangkan manual QUAST v5.3.0 menjelaskan struktur direktori keluaran dan jenis laporan yang dihasilkan. Pipeline-pipeline genom modern yang dikutip dalam jurnal [37] juga memasukkan langkah “run QUAST dan interpretasikan N50/GC/jumlah kontig” sebagai bagian dari evaluasi akhir assembly sebelum BUSCO dan analisis lanjutan [37].

2.3.2 Data preprocessing

Adapun *data preprocessing* yang dilakukan pada Penelitian ini dilakukan dengan liftoff, AGAT, gffread, dan pembersihan sekuens protein. Berikut penjelasan untuk proses data preprocessing yang dilakukan.

2.3.2.1 Anotasi Gen Hasil Liftoff

Liftoff adalah perangkat lunak *genome annotation lift-over* yang memindahkan anotasi gen (gen, transkrip, ekson) dari satu assembly genom referensi ke assembly genom target yang berasal dari spesies sama atau kerabat dekat. Jurnal [38] menggambarkan Liftoff sebagai perangkat lunak mengambil dua genome assemblies dan anotasi GFF3/GTF referensi, menyelaraskan gen referensi ke genom target, lalu mencari pemetaan yang memaksimalkan kemiripan sekuens sambil mempertahankan struktur ekson, transkrip, dan gen [38].

Berbeda dengan UCSC LiftOver. UCSC LiftOver membutuhkan chain file (.over.chain.gz) yang berisi peta pasangan posisi antara assembly lama dan baru; ketika koordinat chr:start–end dimasukkan, tool ini hanya membaca peta tersebut untuk menentukan posisi baru tanpa melakukan alignment ulang. Sebaliknya, Liftoff tidak memakai chain file terpisah. Program ini menerima FASTA genom referensi, FASTA genom target, dan anotasi referensi (GFF3/GTF) sebagai input, lalu menyelaraskan urutan gen referensi ke genom target dengan Minimap2 dan membangun ulang anotasi gen di assembly target berdasarkan hasil alignment tersebut [38]. Tujuan utama Liftoff:

1. Memanfaatkan genom referensi berkualitas tinggi

Alih-alih menganotasi genom baru dari nol, gen dari genom model (yang anotasinya sudah bagus) diproyeksikan ke genom target yang mirip [38].

2. Mempercepat anotasi genom baru / pan-genome

Beberapa studi pan genome memakai Liftoff untuk memetakan gen referensi ke puluhan genom kultivar atau aksesori:

- Pada jurnal [39], anotasi Araport1.1 di-liftover ke tiap genom dengan Liftoff v1.6.3 (parameter `-exclude_partial -a 0.9 -s 0.9 -polish`) untuk menjaga konsistensi ID gen ATxG [39].
- Pada jurnal [40]: pipeline anotasi dimulai dengan lift-over gene model tomat Heinz dan terong Brinjal menggunakan algoritma Liftoff sebelum ditambah bukti RNA-seq.

3. Komponen penting dalam ekosistem anotasi modern

Jurnal [41] mengenai anotasi genom lintas pohon kehidupan mengevaluasi 12 metode, dan menempatkan Liftoff sebagai salah satu metode annotation transfer berbasis liftover yang bekerja baik bila ada genom referensi berkualitas tinggi yang dekat secara evolusioner.

4. Landasan bagi perangkat lunak baru

Pada jurnal [42] menyebut Liftoff sebagai “*leading homology-based annotation transfer tool*”, lalu memperluasnya dengan menambah proteom (*protein–DNA alignment*) [42].

Berikut cara kerja liftoff, yaitu:

2.3.2.1.1 Input & Ekstraksi Gen dari Genom Referensi

Input: FASTA genom referensi (sudah teranotasi baik), FASTA genom target, Anotasi referensi dalam format GFF3/GTF (gen–transkrip–ekson) [38].

Liftoff membaca file GFF3/GTF dan membangun struktur hierarkis gen–transkrip–ekson. Berdasarkan koordinat di anotasi ini, Liftoff mengekstrak urutan DNA setiap gen (biasanya seluruh gen termasuk intron) dari FASTA referensi menggunakan indeks FASTA sehingga subsekuens bisa diambil tanpa memuat seluruh genom ke memori [38].

2.3.2.1.2 Penyelarasan gene-to-genome dengan Minimap2

Berbeda dari WGA yang menyelaraskan seluruh kromosom, Liftoff menggunakan

pendekatan *gene-to-genome*:

- *Query*: urutan gen referensi (misal 5–20 kb).
- *Reference*: seluruh genom target.

Untuk penyelarasan, Liftoff memanggil Minimap2, aligner sekuens panjang yang memakai kerangka seed–chain–align:

- *Seeding*: mengekstrak minimizer dari genom target dan query sebagai titik kecocokan awal.
- *Chaining*: menyusun anchors yang kolinear menjadi rantai kandidat posisi terbaik.
- *Alignment*: melakukan alignment detail di sepanjang rantai untuk menghitung match, mismatch, insersi, dan delesi [41].

Output tahap ini adalah satu atau beberapa alignment kasar setiap gen referensi ke posisi tertentu di genom target.

2.3.2.1.3 Pemecahan alignment menjadi blok ekson & konstruksi graf

Dalam jurnal [38] menjelaskan bahwa Liftoff tidak memakai alignment mentah Minimap2 apa adanya. Alignment tersebut [38]:

1. Dipecah menjadi blok tanpa gap (*ungapped blocks*): Alignment dipecah di setiap insersi/delesi, menghasilkan blok-blok tanpa gap. Liftoff fokus pada blok yang menutupi bagian ekson; blok yang hanya mengenai intron tidak terlalu diutamakan.
2. Dijadikan simpul (node) dalam graf berarah (DAG): Setiap blok ekson valid menjadi node. Dua node dihubungkan oleh edge jika berada di kromosom dan strand yang sama, urutan koordinat 5'→3' konsisten, jarak antar blok di genom target masih sebanding dengan jarak di genom referensi.
3. Diberi bobot penalti: Liftoff memberi penalti untuk mismatch dan gap di dalam ekson; variasi pada intron dibuat lebih toleran. Ini membuat algoritma lebih sensitif terhadap perubahan yang bisa merusak struktur kodon.
4. Pencarian jalur terbaik: Dengan menambahkan node “Start” dan “End”, Liftoff menerapkan algoritma jalur terpendek pada graf tersebut untuk menemukan kombinasi blok dengan penalti total minimum. Jalur terbaik ini ditafsirkan sebagai representasi struktur gen referensi yang paling konsisten di genom target (urutan ekson, orientasi, dan kemiripan sekuens).

2.3.2.1.4 Penentuan kualitas pemetaan & output anotasi

Dari jalur blok terbaik, Liftoff:

1. Menghitung metrik kualitas per gen / per transkrip

Secara konsep Liftoff memakai dua ukuran utama, yaitu:

- Persentase identitas sekuens (Identity)

$$Identity (\%) = \frac{M}{L_{align}} \times 100 \quad (2.1)$$

dengan M = jumlah posisi yang match dan L_{align} = panjang alignment (match + mismatch + posisi bergap yang disejajarkan). Definisi ini konsisten dengan definisi sequence identity di alat seperti BLAST dan Minimap2 [43].


- Cakupan alignment (Coverage)

$$Coverage (\%) = \frac{L_{align}}{L_{gene_{ref}}} \times 100 \quad (2.2)$$

dengan L_{gene_ref} = panjang total gen referensi (ekson pertama – ekson terakhir). Gen dengan identity dan coverage tinggi (mis. $\geq 90-95\%$) biasanya diterima sebagai pemetaan yang valid; nilai rendah menandakan gen yang hilang, divergen, atau terfragmentasi. Prinsip threshold gabungan identity–coverage ini juga digunakan oleh studi-studi pan-genome tanaman yang memakai Liftoff [39], [40]

2. Menulis anotasi baru di genom target

Jika pemetaan memenuhi kriteria, Liftoff mengonversi koordinat ekson/transkrip ke sistem koordinat genom target, menjaga struktur hierarkis gen–transkrip–ekson, dan menuliskan anotasi baru dalam format GFF3/GTF [38]. Fitur yang tidak memenuhi ambang identitas/cakupan dicatat sebagai “*unmapped*”. Informasi ini berguna untuk analisis gen hilang (*gene loss*), perubahan struktural besar, atau kekurangan kualitas *assembly* [41].



Gambar 2. 6 Alur Liftoff

Berikut penjelasan diagram cara kerja liftoff dalam gambar 2.6:

1. Data input (FASTA ref, FASTA target, GFF3/GTF)

Pada tahap pertama, Liftoff membutuhkan tiga jenis berkas:

- Genom referensi dalam format FASTA, yaitu assembly yang sudah punya anotasi gen lengkap
- Genom target dalam format FASTA, yaitu assembly baru yang ingin diberi anotasi
- File anotasi referensi dalam format GFF3 atau GTF yang berisi koordinat gen, transkrip, dan ekson pada genom referensi.

Pada jurnal [38] mendeskripsikan Liftoff sebagai alat yang “*takes as input a reference genome assembly, annotations in GFF or GTF format, and a target genome assembly, and outputs a mapped annotation on the target assembly*”, menegaskan bahwa kombinasi tiga input ini adalah fondasi utama proses lift-over anotasi [38].

2. Ekstraksi gen referensi

Setelah data dimuat, Liftoff membaca file GFF3/GTF referensi untuk membangun struktur hierarkis gen–transkrip–ekson, kemudian mengekstrak urutan DNA lengkap tiap transkrip (termasuk ekson dan intron) dari FASTA genom referensi. Intinya, setiap gen referensi diperlakukan sebagai satu unit kerja yang akan disejajarkan ke genom target. Deskripsi ini konsisten dengan penjelasan bahwa Liftoff “*aligns the complete exon–intron structure of each annotated transcript from a source to a target*” sehingga informasi batas ekson pada anotasi referensi benar-benar dimanfaatkan dalam proses pemetaan [43].

3. *Alignment gene-to-genome (Minimap2)*

Pada tahap ketiga, urutan tiap gen referensi yang sudah diekstrak dijadikan

query dan disejajarkan ke seluruh genom target menggunakan aligner sekuens panjang, yaitu Minimap2. Liftoff tidak melakukan whole-genome alignment kromosom-ke-kromosom, tetapi alignment gen-ke-genom (*gene-to-genome*): setiap gen referensi di-align ke FASTA target untuk mencari lokasi dengan kemiripan sekuens tertinggi sambil mengizinkan adanya intron dan variasi struktural moderat. Jurnal [38] menjelaskan bahwa program ini “*uses sequence alignment software to align gene sequences from a source to a target assembly*” dan dokumentasi populer terbaru tentang Liftoff juga menegaskan bahwa Minimap2 digunakan sebagai mesin utama pemetaan DNA, sehingga proses ini menjadi langkah inti untuk menemukan kandidat posisi homolog tiap gen di genom target.

4. Pemrosesan alignment (blok tanpa gap)

Hasil alignment dari Minimap2 kemudian tidak langsung dijadikan anotasi, tetapi terlebih dahulu diproses lebih lanjut. Liftoff memecah setiap alignment menjadi blok-blok tanpa gap (*ungapped blocks*), lalu mengidentifikasi mana di antara blok tersebut yang benar-benar menutupi wilayah ekson (bukan intron saja). Blok yang hanya mengenai intron umumnya diabaikan, karena struktur fungsional gen lebih banyak ditentukan oleh ekson. Jurnal [38] menjelaskan bahwa Liftoff “*splits each alignment into ungapped blocks and retains only those that overlap exons*”, sebagai cara untuk memfokuskan evaluasi kualitas pemetaan pada bagian gen yang paling relevan secara fungsional [38].

5. Graf blok ekson & pemilihan jalur terbaik

Pada tahap berikutnya, semua blok ekson hasil pemrosesan alignment direpresentasikan sebagai node dalam sebuah graf berarah tanpa siklus (DAG). Dua blok dihubungkan dengan edge jika keduanya berada pada kromosom yang sama, strand yang sama, dan urutan posisinya konsisten dari 5' ke 3', dengan jarak yang wajar bila dibandingkan dengan gen referensi. Liftoff memberikan bobot penalti pada node dan edge berdasarkan jumlah mismatch dan gap di dalam ekson, kemudian menambahkan simpul Start dan End dan menjalankan algoritma jalur terpendek untuk mencari kombinasi blok dengan penalti total minimum. Jalur ini dianggap sebagai struktur gen


target yang paling konsisten dengan gen referensi [38].

6. Evaluasi kualitas mapping (*identity & coverage*)

Setelah jalur terbaik dipilih untuk satu gen, Liftoff menghitung kualitas pemetaan menggunakan dua metrik utama: persentase identitas sekuens (*sequence identity*) dan cakupan alignment (*alignment coverage*). Identity menggambarkan proporsi posisi yang match dalam alignment ($M / L_{align} \times 100\%$), sedangkan coverage menunjukkan proporsi panjang gen referensi yang tercakup oleh alignment ($L_{align} / L_{gene_ref} \times 100\%$). Dalam jurnal [38], Liftoff menunjukkan bahwa lebih dari 99,9% gen dapat dipetakan antara GRCh37 dan GRCh38 dengan identitas rata-rata $>99,9\%$, dan sekitar 98,3% gen protein-coding manusia dapat dipetakan ke genom simpanse dengan identitas rata-rata 98,2%, menegaskan bahwa kombinasi identity dan coverage tinggi merupakan indikator kuat pemetaan gen yang andal [38]. Jurnal [43] kemudian memanfaatkan lagi metrik ini untuk membandingkan anotasi hasil lift-over antara banyak *assembly*.

7. Output anotasi & ringkasan

Tahap terakhir menghasilkan anotasi gen baru pada genom target serta ringkasan kualitas pemetaan. Liftoff menuliskan anotasi dalam format GFF3 atau GTF pada koordinat genom target, mempertahankan struktur gen–transkrip–ekson sedekat mungkin dengan referensi dan menyertakan atribut seperti persentase identitas dan cakupan untuk tiap fitur. Selain itu, Liftoff juga menyusun daftar gen yang tidak terangkat (*unmapped*) atau hanya terpetakan sebagian, yang dapat dipakai untuk mengidentifikasi gen hilang, gen divergen, atau masalah pada *assembly* target. Jurnal [43] menunjukkan bagaimana anotasi hasil Liftoff ini dapat dianalisis lebih lanjut untuk mendeteksi varian sekuens, perubahan synteny, dan *copy-number*, sementara jurnal [41] menempatkan pendekatan transfer anotasi seperti Liftoff sebagai komponen penting dalam strategi anotasi genom lintas spesies dan lintas versi *assembly*.



Gambar 2. 7 Pemetaan Liftof pada transkrip manusia ke genom simpanse

(Sumber: Jurnal [38])

Gambar 2.7 menunjukkan langkah yang diambil Liftoff ketika memetakan satu transkrip manusia ENST00000598723.5 ke homolognya di genom simpanse PTRv2 kromosom 19.

Langkah utamanya adalah:

1. Ambil struktur gen referensi (ekson 1–5).
2. Minimap2 membuat tiga alignment parsial ke genom simpanse.
3. Liftoff memecah alignment menjadi blok tanpa gap (A–F).
4. Blok-blok ini dimasukkan ke graf berarah (DAG), diberi bobot, lalu dicari jalur dengan penalti minimum (A–B–C–D–F) [38]

Berikut penjelasan gambar 2.7:

1. Panel atas: transkrip referensi manusia

Bagian paling atas menunjukkan:

- Transkrip ENST00000598723.5 (transkrip manusia)
- Terdiri dari 5 ekson, ditampilkan sebagai kotak berwarna exon 1 (biru), Exon 2 (merah), Exon 3 (hijau), Exon 4 (ungu), Exon 5 (kuning).
- Di atas tiap kotak ada angka posisi (misalnya 206, 4551, 4648, dst.) yang

merepresentasikan koordinat nukleotida di genom manusia.

Maknanya: ini adalah “bentuk asli” gen yang mau di-lift-over ke genom simpanse.

2. Panel Tengah: kromosom PTRv2 chr19 dan Alignment 1–3

Di bawah gen manusia, ada sebuah skema kromosom PTRv2 chr19 (kromosom 19 simpanse). Lalu tiga baris alignment:

- Alignment 1 (blok A–D, warna hijau) menunjukkan: satu alignment panjang di kromosom 19 yang memuat empat blok tanpa gap, yaitu A, B, C, D (masing-masing diwarnai seperti ekson 1–4). Lalu, garis putus-putus di antara blok A–B–C–D = introns / gap di alignment (bagian non-ekson atau bagian yang di-skip), dan di bawahnya ada angka koordinat genom target (misal 50658220, 50658593, dst.): ini posisi blok di genom simpanse. Artinya: empat ekson pertama dari transkrip manusia punya kecocokan cukup bagus di satu region besar genom simpanse dengan menggunakan Minimap2 menemukan alignment 1 ini [38].
- Alignment 2 (blok E, warna ungu) hanya berisi satu blok, diberi label E, mewakili kandidat ekson 5 di posisi lain pada kromosom 19. Koordinat di bawahnya (50484444, 50488016) adalah posisi blok E di genom simpanse. Jadi: kemungkinan tempat ekson ke-5, tapi di lokasi yang berbeda.
- Alignment 3 (blok F, warna oranye) hanya berisi satu blok, label F, kandidat ekson 5 lain di lokasi berbeda. Koordinat di bawahnya (50677369, 50677902). Jadi sekarang Liftoff punya dua kandidat posisi untuk ekson 5: E dan F.

3. Panel bawah: graf blok ekson (node A–F, Start, End)

Bagian paling bawah adalah inti algoritma Liftoff:

- Node (simpul) dalam graf berarah memiliki node Start dan End (awal–akhir jalur) dan node A, B, C, D, E, F, yaitu setiap node $\approx$ satu blok tanpa gap yang mencakup ekson tertentu, A–D = blok ekson 1–4 (dari Alignment 1), E dan F = dua kandidat ekson 5 (dari Alignment 2 dan 3). Di dalam node (misalnya “A, weight=...”) ada angka kecil yang merupakan bobot node = penalti mismatch di dalam ekson. Dalam caption aslinya disebut: bobot node = $2 \times$ jumlah mismatch di ekson (default: 2 per mismatch). [38]

- Edge (garis penghubung) dan bobotnya
Garis antara node adalah edge. Edge menghubungkan dua blok jika berada di kromosom yang sama, strand yang sama, urutan posisinya konsisten 5'→3', jarak antar blok masih “masuk akal” dibanding jarak di gen referensi.
- Bobot edge = penalti gap di dalam ekson sehingga terdapat gap open penalty (2) + gap extension penalty (1 × panjang gap). Jika gap hanya terjadi di intron (bukan di ekson), edge bisa berbobot 0 (artinya aman, tidak merusak ekson) [38]. Di gambar, angka seperti 511, 512, 48 di dekat garis panah (→), itu contoh total penalti di sepanjang jalur tertentu (jumlah bobot node dan edge).
- Node E hanya punya sedikit koneksi karena node E berada di strand yang berbeda dengan A–D dan F sehingga Liftoff mengharuskan satu jalur menggunakan blok yang sama kromosom, satu strand. Maka E hanya dihubungkan ke Start dan End, tidak ke A–B–C–D–F [38]. Secara biologis, E mungkin alignment yang salah arah (antisense) atau berasal dari paralog lain sehingga tidak cocok untuk jalur utama.
- Pemilihan jalur terbaik
Liftoff kemudian menambahkan node Start dan End, menghitung total penalti untuk semua jalur dari Start ke End dengan menjumlahkan bobot semua node dan semua edge yang dilewati, lalu memilih jalur dengan penalti minimum. Di gambar, jalur yang disorot (biasanya garis tebal): Start → A → B → C → D → F → End. Jalur ini menggunakan ekson 1–4 dari Alignment 1 (A–D), memilih F sebagai ekson 5 (kandidat terbaik) dan mengabaikan E, memiliki penalti total paling kecil (identitas tinggi, gap di ekson sedikit atau tidak ada). Hasil akhirnya: struktur gen di genom simpanse = ekson A–B–C–D–F (posisi sesuai kromosom 19 PTRv2).

Kesimpulan dari penjelasan gambar tersebut, yaitu

- Ini hanya satu contoh gen (ENST00000598723.5) yang di-liftover dari manusia ke simpanse [38].
- Minimap2 tidak selalu memberi satu alignment yang sempurna; kadang ada beberapa alignment parsial (seperti Alignment 1–3).
- Liftoff memecah alignment jadi blok ekson (A–F) dan menyatukannya dalam

graf, lalu mencari kombinasi blok yang paling konsisten dan paling mirip dengan gen referensi.

- Jalur terpilih (A–B–C–D–F) adalah representasi akhir gen target → inilah yang ditulis ke file GFF3/GTF sebagai anotasi gen di genom simpanse.

Dalam penelitian ini, prinsip yang sama digunakan untuk memetakan gen dari genom referensi *Oryza sativa indica* ZS97 dan *Oryza longistaminata* ke genom target PR25 dan RD23. Setiap gen referensi, yang terdiri dari beberapa ekson, disejajarkan ke genom PR25/RD23, dipecah menjadi blok ekson, dan Liftoff memilih kombinasi blok terbaik untuk membangun struktur gen baru pada genom target.

2.3.2.2 AGAT (Another Gtf/Gff Analysis Toolkit)

AGAT (Another GTF/GFF Analysis Toolkit) adalah sekumpulan skrip berbasis perl untuk memanipulasi, menstandarkan, dan menganalisis anotasi genom dalam format GTF/GFF, dikembangkan oleh NBIS (*National Bioinformatics Infrastructure Sweden*). Dokumentasi resminya mendefinisikan AGAT sebagai “*GTF/GFF toolkit*” yang mampu menangani hampir semua operasi yang dibutuhkan pada file anotasi format GTF/GFF tersebut [44], [45].

Format GFF/GTF yang diproses oleh AGAT merupakan format teks ber-tab dengan sembilan kolom per baris, di mana tujuh kolom pertama (*seqid, source, type, start, end, score, strand*) mendeskripsikan lokasi dan karakteristik dasar fitur genom, kolom kedelapan (*phase*) menyimpan informasi fase pembacaan untuk fitur CDS, dan kolom kesembilan (*attributes*) berisi pasangan tag=value seperti ID dan Parent yang digunakan untuk memodelkan hubungan hierarkis antara gen, transkrip, dan elemen penyusunnya [44]. Pada jurnal [46] mencantumkan AGAT sebagai perangkat lunak yang digunakan untuk menangani anotasi gen.

Tujuan penggunaan AGAT dalam anotasi genom

1. Menstandarkan & “mensanitasi” berkas GFF/GTF

Dokumentasi AGAT dalam NBISweden/AGAT: AGAT v1.5.1 menjelaskan

bahwa salah satu fungsi inti toolkit ini adalah mengubah berkas anotasi dalam berbagai varian GTF/GFF menjadi GFF3 yang lengkap, teratur, dan terstandar, dengan cara memeriksa dan memperbaiki format, menambahkan fitur/atribut yang hilang (misalnya gene, mRNA, exon, atribut ID dan Parent), memperbaiki koordinat fitur, menghilangkan fitur duplikat, mengelompokkan fitur yang terkait dalam satu lokus, dan mengurutkan fitur sehingga kompatibel dengan indeksasi dan visualisasi [44]. Semua ini dikemas terutama dalam skrip `agat_convert_sp_gxf2gxf.pl` yang direkomendasikan oleh Swedish Reference Genome Portal untuk mengkonversi GTF dan GFF lama menjadi GFF3 modern.

Dalam Penelitian ini, Liftoff menghasilkan anotasi `PR25.from_ZS97.gff3` yang secara biologis sudah berisi model gen, tetapi masih berpotensi memiliki struktur hierarki yang tidak konsisten, mengandung ID duplikat, belum sepenuhnya mengikuti konvensi GFF3 yang “rapi”. AGAT digunakan untuk menstandarkan file-file ini sehingga downstream tool seperti `gffread` (yang mensyaratkan GTF/GFF3 yang well-formed) bisa bekerja stabil, dan anotasi dapat dikombinasikan dengan anotasi lain (misalnya gen unik dari *O. longistaminata*) tanpa konflik struktur [44], [47].

2. Menggabungkan dan melengkapi anotasi

AGAT menyediakan skrip khusus untuk menggabungkan anotasi dari beberapa sumber dan melengkapi lokus yang belum terwakili penuh:

- `agat_sp_complement_annotations.pl` untuk melengkapi anotasi yang tidak saling overlap dari dua sumber berbeda,
- `agat_sp_merge_annotations.pl` untuk menggabungkan anotasi menjadi satu berkas yang konsisten [44].


Contoh pipeline anotasi genom terkini dapat dilihat dalam jurnal [46], [47] yang memadukan prediksi gen otomatis dengan anotasi referensi) menggunakan kombinasi langkah, yaitu satu set anotasi dijadikan backbone, lalu set lain yang berisi fitur tambahan (misalnya gen non-model spesies, atau anotasi fungsional tambahan) digabungkan untuk menghasilkan anotasi komposit yang lebih lengkap.

Dalam penelitian, berkas `PR25.add_OL.gff3`, `PR25.add_OL.gff3_polished`,

PR25.final_ZS97_backbone_plus_OLunique.gff3 menggambarkan bahwa anotasi backbone PR25 (turunan dari ZS97 via Liftoff) ditambah (add) dengan gen unik yang berasal dari *O. longistaminata* (OLunique), kemudian dipoles menjadi satu anotasi final yang lebih lengkap. AGAT sangat cocok untuk tugas seperti ini karena memang menyediakan fungsi *“complement/merge annotations”* untuk menggabungkan beberapa sumber anotasi ke dalam satu berkas GFF3 yang seragam [44]. Hal ini relevan langsung dengan tujuan TA, yaitu mengidentifikasi gen-gen turunan PR25 yang berasal dari RD23 dan *O. longistaminata*. Agar analisis ortholog (Orthofinder) dan fungsi (EggNOG-mapper, InterProScan) akurat, anotasi struktural PR25 harus sudah mencerminkan kedua sumber gen tersebut dalam satu berkas GFF3 final.

3. Menghitung statistik anotasi dan kualitas model gen

AGAT juga menyediakan modul statistik, yaitu `agat_sp_statistics.pl` yang dapat menghitung statistik struktur anotasi (jumlah gen, mRNA, CDS, distribusi panjang, dsb.), dan `agat_sp_functional_statistics.pl` yang dapat membuat ringkasan statistik anotasi fungsional. Modul ini dipakai dalam berbagai pipeline berbasis Nextflow/nf-core untuk QC anotasi, misalnya modul `agat_spstatistics` yang menghasilkan berkas .txt berisi statistik ringkas anotasi GFF/GTF. Dalam Penelitian ini, statistik seperti jumlah gen, jumlah transkrip, rata-rata panjang gen/CDS, distribusi ekson, dan sebagainya, penting untuk membandingkan kompleksitas anotasi PR25 vs RD23 vs *O. longistaminata*, memastikan anotasi yang telah diproses, misalnya Dalam penelitian, menggunakan PR25.final_ZS97_backbone_plus_OLunique.gff3 yang masih konsisten dan biologis masuk akal sebelum diekspor ke FASTA dan dianalisis sebagai protein, meskipun statistik akhirnya olah lagi di Jupyter Notebook, AGAT menyediakan ringkasan awal yang membantu QC.



Gambar 2. 8 Alur AGAT

Alur proses AGAT

Berdasarkan dokumentasi resmi AGAT [44], berikut alur kerja AGAT tersebut:

1. Input anotasi dan data pendukung

AGAT menerima Berkas anotasi GFF/GTF dimana kalau dalam TA itu PR25.from_ZS97.gff3, RD23.from_ZS97.gff3 (hasil Liftoff), dan anotasi tambahan yang mengandung gen unik *O. longistaminata* (yang kemudian membentuk PR25.add_OL.gff3).

2. Standarisasi format dan sanitasi anotasi

Langkah inti di tahap ini biasanya menggunakan skrip `agat_convert_sp_gxf2gxf.pl`, yang menurut dokumentasi NBISweden/AGAT: AGAT v1.5.1, yaitu membaca anotasi dalam berbagai varian GFF/GTF, memeriksa konsistensi format dan struktur, menambahkan fitur parent yang hilang (misalnya gene dan mRNA jika hanya ada CDS/exon), menambahkan fitur turunan (misalnya exon, UTR) jika diperlukan, menambahkan atribut wajib seperti ID dan Parent, memperbaiki ID agar unik, memperbaiki koordinat fitur (misalnya CDS phase, overlap), mengelompokkan fitur yang saling berkaitan dalam satu lokus, mengurutkan fitur dan (opsional) menyiapkan file untuk di-tabix. Dalam penelitian ini, tahap ini dapat dijelaskan sebagai proses AGAT menstandarkan anotasi hasil Liftoff untuk PR25 dan RD23, sehingga struktur gen–mRNA–CDS di berkas GFF3 menjadi konsisten dan sesuai spesifikasi GFF3 modern sebelum dikombinasikan dan digunakan oleh gffread.

3. Perbaikan model gen dan atribut (*fix and manage*)

Toolkit AGAT menyediakan sekumpulan skrip kategori “*Fix*” dan “*Manage*” yang dapat digunakan bila diperlukan, yaitu

- `agat_sp_fix_cds_phases.pl`: memperbaiki fase CDS

- `agat_sp_fix_overlapping_genes.pl`: memperbaiki gen yang saling overlap tidak wajar
- `agat_sp_manage_IDs.pl`: menata ulang dan menstandarkan ID fitur
- `agat_sp_manage_attributes.pl`: mengelola atribut (menambah/menghapus/mengubah nilai atribut),
- `agat_sp_manage_introns.pl`, `agat_sp_add_introns.pl`: membuat dan mengelola fitur intron jika diperlukan.

Tahap ini dapat dikatakan sebagai “pemolesan” (polishing) anotasi yang sejalan dengan penamaan file di output dalam TA, yaitu `PR25.add_OL.gff3_polished` yang merupakan gabungan anotasi PR25 dengan gen OL yang telah dipoles (memperbaiki struktur dan atribut) menggunakan kombinasi skrip AGAT kategori *Fix/Manage*. Ini penting untuk memastikan bahwa ketika menggabungkan backbone PR25 dari ZS97 dengan gen unik OL, model gen hasil gabungan masih konsisten dan dapat diproses oleh gffread maupun OrthoFinder tanpa error struktur.

4. Penggabungan anotasi backbone dan gen tambahan

Setelah anotasi backbone (hasil Liftoff) dan anotasi tambahan (gen unik *O. longistaminata*) distandarkan, AGAT dapat digunakan untuk menggabungkan keduanya. Dokumentasi AGAT, NBISweden/AGAT: AGAT v1.5.1 menyebut skrip:

- `agat_sp_complement_annotations.pl`: melengkapi anotasi di lokus non-overlapping (misalnya backbone dari ZS97 dilengkapi gen tambahan dari OL di posisi yang belum teranotasi)
- `agat_sp_merge_annotations.pl`: menggabungkan dua anotasi menjadi satu berkas.

Dalam penelitian ini, file `PR25.add_OL.gff3` dapat dijelaskan sebagai hasil penggabungan anotasi backbone PR25 dengan anotasi gen unik OL, dan `PR25.final_ZS97_backbone_plus_OLunique.gff3` merupakan berkas GFF3 final yang berisi gabungan backbone PR25 (turunan ZS97) plus gen unik *O. longistaminata* yang telah distandarkan dan dipoles. Studi [47] memakai strategi serupa, yaitu anotasi digabungkan dan dilengkapi agar representasi gen menjadi selengkap mungkin sebelum analisis ortholog dan fungsi.

5. Statistik anotasi dan QC akhir

Selanjutnya, AGAT dapat menjalankan skrip statistik, yaitu:

- `agat_sp_statistics.pl`: menghasilkan ringkasan tekstual berisi jumlah gen, mRNA, CDS, panjang rata-rata, distribusi fitur, dan lainnya,
- `agat_sp_functional_statistics.pl`: bila anotasi sudah diikuti informasi fungsi (GO, InterPro) [44].

Modul statistik ini juga digunakan dalam pelatihan anotasi genom lainnya, misalnya modul Helixer yang meminta pengguna menghitung statistik GFF3 dengan AGAT (jumlah gen, panjang rata-rata, dan lainnya) untuk mengevaluasi hasil anotasi. AGAT digunakan untuk menghasilkan statistik ringkas anotasi PR25, RD23, dan *O. longistaminata* sebagai bagian dari pengendalian mutu (*quality control*) sebelum berkas GFF3 final diekspor menjadi sekuens CDS/protein dan tahap selanjutnya.

6. Output: GFF3 final untuk gffread

Output utama AGAT di pipeline Penelitian ini, yaitu berkas anotasi GFF3 final yang telah distandarkan format dan struktur, dipoles (fix & manage), digabungkan antara backbone PR25/RD23 dan gen unik OL, dan telah melewati QC statistik. Dalam penelitian ini, berikut output filenya untuk tahap ini:

- `PR25.final_ZS97_backbone_plus_OLunique.gff3` (input utama gffread untuk PR25),
- `RD23.from_ZS97.gff3` (setelah distandarkan),
- Berkas antara: `PR25.add_OL.gff3`, `PR25.add_OL.gff3_polished`.

Berkas output tersebut yang kemudian:

- Masuk ke gffread sehingga menghasilkan `PR25.final.cds.all.fa`, `PR25.final.pep.all.fa`, `RD23.final.cds.all.fa`, `RD23.final.pep.all.fa` (dan variasi lain yang terlihat di folder `D:\result\output_bio\proteins\`).
- Protein hasil gffread kemudian dibersihkan (filter & deduplikasi) menjadi `PR25.clean.fa`, `RD23.clean.fa`, `OL.clean.fa` di `D:\result\output_bio\clean_proteins\`.
- File clean proteins inilah yang akhirnya digunakan oleh Orthofinder,

EggNOG-mapper, dan InterProScan untuk identifikasi ortholog (gen turunan PR25 dari RD23 dan OL), anotasi fungsi (COG, GO, domain InterPro, dan lainnya).

Dengan demikian, AGAT berperan sebagai jembatan antara tahap transfer anotasi gen (Liftoff) dan tahap analisis fungsi (Orthofinder, EggNOG-mapper, InterProScan), dengan cara memastikan bahwa anotasi GFF3 yang digunakan oleh gffread sudah lengkap, konsisten, dan merepresentasikan baik gen turunan RD23 maupun gen turunan *O. longistaminata* pada genom PR25.

2.3.2.3 Gffread

Pada jurnal [48] memperkenalkan GffRead (gffread) sebagai bagian dari paket GFF Utilities, yaitu program baris perintah berbasis C++ yang secara khusus dibuat untuk memproses anotasi genom dalam format GFF3, GTF, dan BED. Mereka menjelaskan bahwa gffread awalnya dikembangkan sebagai alat cepat untuk verifikasi, penyaringan (filtering), dan konversi anotasi GTF/GFF3, serta untuk *“quick extraction of transcript sequences from the genome sequence”*. Jurnal [48] menekankan bahwa fungsi gffread kemudian berkembang menjadi alat yang “kompleks dan serbaguna” yang dapat menyortir, memfilter, remap, mengelompokkan transkrip ke dalam lokus, serta menghasilkan file FASTA berisi transkrip, CDS, dan protein dari anotasi yang diberikan [48].

Dalam praktiknya, gffread digunakan sebagai komponen inti dalam pipeline anotasi genom yang berskala besar. Pada jurnal [48] menyebut bahwa GFF Utilities telah digunakan dalam berbagai proyek anotasi genom, penemuan gen baru, dan evaluasi struktur gen, karena kemampuannya menangani file anotasi besar secara efisien [48]. Studi genom ikan *doctor fish* dengan jurnal [49] yang disusun hingga tingkat kromosom, memanfaatkan GffRead v0.12.7 untuk menghasilkan kumpulan sekuens protein dari kombinasi genom dan anotasi sebelum dilakukan analisis kualitas dengan BUSCO dan inferensi orthogroup dengan OrthoFinder, sehingga menegaskan peran gffread sebagai jembatan antara anotasi struktural dan analisis fungsional maupun [49]

2.3.2.3.1 Fungsi utama Gffread

Pada jurnal [48] menjelaskan bahwa fungsi gffread dapat dikelompokkan ke beberapa kategori utama, yaitu validasi dan “pembersihan” anotasi, filtering transkrip berdasarkan kriteria struktural, konversi format GFF3↔GTF/BED, dan ekstraksi sekuens cDNA, CDS, dan protein ke FASTA. Pada jurnal [48] menunjukkan bahwa gffread memiliki opsi seperti -E untuk mengekspos kesalahan pada file anotasi, -T untuk mengubah keluaran menjadi GTF, serta serangkaian opsi filtering (misalnya -l untuk membuang transkrip pendek, -i untuk membatasi panjang intron maksimum, -U untuk membuang transkrip satu ekson, dan --no-pseudo untuk menghapus gen yang bertanda pseudogen). Selain itu, tabel opsi output menunjukkan bahwa gffread dapat menulis file FASTA transkrip (-w), CDS (-x), dan protein (-y) secara langsung dari anotasi dan genom referensi [48].

Fungsi ekstraksi sekuens ini digunakan luas di penelitian genom terkini. Dalam jurnal [49], genom ikan *Garra rufa* melaporkan bahwa mereka menghasilkan sekuens protein dari genom dan anotasi dengan GffRead v0.12.7, kemudian memilih isoform protein terpanjang per gen sebagai input untuk BUSCO dan OrthoFinder dalam analisis ortholog dan filogeni [49]. Studi populasi oleh jurnal [50] tentang variasi struktural pada populasi sapi juga menyatakan bahwa mereka mengekstrak CDS dan sekuens protein dari anotasi genom menggunakan gffread (v0.12.7) sebagai dasar untuk membandingkan repertoar protein antar populasi [50]. Hal ini memperlihatkan bahwa, di luar definisi formal, gffread dipakai nyata sebagai alat standar untuk mengubah koordinat anotasi menjadi file FASTA yang siap dianalisis secara komparatif dan fungsional.

Selain itu, penelitian-penelitian terkini menunjukkan bahwa gffread tidak hanya dipakai untuk mengekstrak sekuens, tetapi juga untuk merapikan dan mereduksi redundansi anotasi. Studi tentang gen baru pada embrio sapi oleh jurnal [51] menggunakan pipeline rekonstruksi transkriptom yang menggabungkan short-read dan long-read, kemudian menggabungkan transkrip menjadi lokus gen dan mengurangi redundansi anotasi dengan bantuan gffread sebelum melakukan analisis diferensial ekspresi dan anotasi fungsional [51]. Penelitian lain tentang

dinamika famili enzim glikosidase GH1 pada Lepidoptera oleh jurnal [52] menggunakan GffRead v0.12.7 untuk memfilter CDS yang tidak memiliki kodon awal atau kodon stop dan menghapus sekuens redundan sebelum analisis filogenetik dan anotasi domain, menegaskan peran gffread dalam kontrol kualitas anotasi [52].

Dalam Penelitian ini, gffread ditempatkan setelah anotasi struktural dengan Liftoff pada genom PR25 dan RD23, dengan fungsi yang secara konsep sama seperti pada studi-studi tersebut: file GFF3 hasil Liftoff digabungkan dengan genom PR25.FINAL.fasta dan RD23.FINAL.fasta untuk menghasilkan file FASTA transkrip, CDS, dan protein. Pola semacam ini paralel dengan penggunaan gffread di jurnal [49], [50] dimana sekuens protein hasil gffread menjadi input langsung untuk analisis kualitas anotasi, inferensi ortholog, dan analisis fungsional lanjut [49], [50].

2.3.2.3.2 Cara kerja internal gffread

Pada jurnal [48] menjelaskan bahwa GFF Utilities, termasuk gffread, dibangun di atas kelas C++ bernama GffObj (struktur data yang menyimpan satu transkrip beserta fitur-fitur penyusunnya (ekson, CDS, atribut gen)) yang mengimplementasikan fungsi parsing dan pengindeksan GFF. Karena format GFF/GTF tidak mewajibkan fitur-fitur yang terkait (misalnya ekson dari satu transkrip) muncul berurutan di berkas, parser gffread harus menyimpan informasi transkrip di memori sampai seluruh berkas selesai dibaca. Identitas fitur seperti ID transkrip disimpan dalam struktur hash string untuk mempercepat penentuan relasi hierarkis (misalnya hubungan transkrip-gen), sementara nama sekuens referensi dan atribut GFF lain ditampung sebagai ID numerik yang dipetakan ke string. Fitur genom (objek GffObj: struktur data yang menyimpan satu transkrip beserta fitur-fitur penyusunnya (ekson, CDS, atribut gen)) kemudian disimpan dalam array dinamis yang diurutkan berdasarkan posisi genom, sehingga pemeriksaan tumpang-tindih dan penyaringan berdasarkan posisi dapat dilakukan dengan cepat [48].

Setelah parsing, gffread membentuk struktur anotasi hirarkis gene → transcript →

exon/CDS di dalam memori. Dalam jurnal [48] menyebut bahwa gffread membaca rekaman GTF/GFF3 atau BED, menyimpannya dalam koleksi GffObj yang dapat disortir dan difilter menurut berbagai kriteria. Fitur-fitur seperti exon dan CDS yang berbagi ID transkrip yang sama digabungkan ke dalam satu objek transkrip, dan gffread dapat mengelompokkan transkrip yang tumpang tindih menjadi lokus ketika opsi pengelompokan diaktifkan. Dalam mode ini, gffread dapat memunculkan fitur baru bertipe locus yang berisi daftar ID transkrip/gen yang termasuk di dalamnya, serta mengidentifikasi transkrip “redundan” yang berbagi rantai intron yang sama atau tumpang tindih lebih dari 80% panjangnya [48].

Selama pembacaan anotasi, gffread juga menjalankan cek validitas CDS dan struktur transkrip. Jurnal [48] menjelaskan bahwa apabila anotasi memuat fitur CDS, gffread dapat memeriksa apakah transkrip memiliki kodon awal dan kodon stop yang lengkap dan apakah terdapat kodon stop di tengah rangka baca; opsi seperti -J dapat digunakan untuk hanya menyimpan transkrip dengan CDS lengkap, sedangkan -V dapat membuang transkrip yang mengandung kodon stop di dalam rangka baca. Selain itu, tabel opsi filtering (misalnya -N untuk membuang transkrip dengan intron non-kanonik dan -C untuk memilih transkrip yang memiliki CDS) menunjukkan bahwa gffread secara aktif memanfaatkan informasi struktur intron–ekson dan CDS untuk mengklasifikasikan, mempertahankan, atau membuang transkrip sebelum menulis ulang anotasi atau menghasilkan FASTA [48].

Ketika pengguna menyediakan genom FASTA dan mengaktifkan opsi -w, -x, atau -y, gffread menjalankan tahap ekstraksi sekuens. Jurnal [48] menggambarkan bahwa gffread dapat menghasilkan FASTA berisi transkrip yang diperoleh dengan “mengestrak dan menggabungkan semua ekson dari tiap transkrip”, membuat FASTA berisi sekuens pengkode (CDS) untuk setiap transkrip berfitur CDS, dan menulis FASTA protein yang merupakan translasi CDS setiap transkrip [48].

Studi populasi ikan oleh [49] dan analisis beban struktural pada genom tanaman oleh [53] memanfaatkan fungsi ini untuk menghasilkan set sekuens protein dari anotasi genom dengan GffRead v0.12.7 sebelum menjalankan BUSCO, OrthoFinder, dan analisis komparatif lainnya, sehingga menggambarkan cara kerja

dari koordinat anotasi menjadi sekuens spliced dan protein dalam konteks penelitian nyata [49], [53].

2.3.2.3.3 Alur kerja gffread

Pada genom ikan *doctor fish* yang dirakit hingga tingkat kromosom, jurnal [49] menyusun anotasi gen terlebih dahulu, kemudian menggunakan GffRead v0.12.7 untuk menghasilkan sekuens protein dari kombinasi genom dan anotasi. Set protein ini dipakai untuk dua tujuan utama: mengukur kelengkapan anotasi gen menggunakan BUSCO berbasis protein, dan melakukan inferensi orthogroup lintas spesies dengan OrthoFinder untuk analisis filogenomik [49]. Pola serupa muncul dalam kajian beban struktural dan efeknya pada adaptasi lokal tanaman oleh [53], di mana sekuens protein dari masing-masing genom diekstrak dengan GffRead v0.12.7, digabungkan ke satu file protein besar, lalu digunakan sebagai dasar analisis fungsional dan komparatif pada tingkat proteom [53].

Di sisi lain, studi transkriptom dan anotasi gen baru juga memanfaatkan gffread sebagai penghubung antara anotasi dan analisis fungsional. Jurnal [54] pada studi RNA-seq siput *Bulinus truncatus* menyatakan bahwa menggunakan GffRead dalam jurnal untuk mengekstrak transkrip dari anotasi, kemudian memanfaatkan TransDecoder untuk mengambil CDS dan sekuens asam amino yang digunakan dalam anotasi fungsional dan analisis ekspresi diferensial [48], [54]. Pada jurnal [51] dalam rekonstruksi transkriptom embrio sapi menggunakan pipeline yang merekonstruksi ribuan transkrip, kemudian menggunakan gffread bersama alat lain untuk mengurangi redundansi dan mengelompokkan transkrip menjadi lokus gen sebelum melakukan analisis fungsi dan validasi eksperimental dengan CRISPR-Cas9 [51].

Pola penggunaan gffread sebagai penghubung antara anotasi genom dan analisis fungsional juga tampak jelas pada studi beban struktural dan adaptasi lokal tanaman oleh jurnal [53]. Jurnal [53] tersebut menjelaskan bahwa sekuens protein dari setiap genom diekstrak menggunakan GffRead v0.12.7, lalu semua berkas protein tersebut digabungkan menjadi satu berkas input, yang kemudian dipakai untuk analisis komparatif dan penilaian dampak mutasi terhadap fungsi gen. Pemakaian gffread

di sini menunjukkan bahwa anotasi GFF/GTF dapat langsung diubah menjadi himpunan protein untuk analisis evolusi dan fungsi dalam skala genom [53]. Dengan pola yang serupa, jurnal [52] memanfaatkan GffRead v0.12.7 untuk menyaring CDS pada keluarga gen glikosidase GH1 di 61 genom Lepidoptera, yang menyatakan bahwa CDS yang tidak memiliki kodon awal atau tidak memiliki kodon stop difilter menggunakan GffRead v0.12.7, dan sekuens redundan dihapus, sehingga yang tersisa hanyalah model gen GH1 berkualitas tinggi untuk analisis filogeni, kejadian duplikasi–kehilangan gen, dan anotasi domain protein. Hal ini menegaskan bahwa gffread tidak hanya digunakan untuk mengekstrak sekuens dari anotasi, tetapi juga untuk meningkatkan kualitas set CDS sebelum dianalisis lebih lanjut [52].

Dalam penelitian ini, alur kerja gffread mengikuti pola umum tersebut tetapi diterapkan spesifik pada genom PR25 dan RD23. Setelah genom dirakit hingga skala kromosom dan dianotasi secara struktural menggunakan Liftoff, file GFF3 hasil Liftoff digabungkan dengan genom PR25.FINAL.fasta dan RD23.FINAL.fasta. Gffread kemudian digunakan untuk membersihkan dan menormalkan anotasi, mengekstrak transkrip, CDS, dan protein ke FASTA, dan menyediakan file protein sebagai input langsung untuk InterProScan, EggNOG-mapper, dan OrthoFinder. Pola ini secara konseptual sejajar dengan penggunaan gffread pada penelitian [49], [53] di mana gffread menjadi penghubung dari anotasi struktural ke analisis fungsional dan komparatif berbasis protein.

2.3.2.3.4 Kelebihan dan keterbatasan gffread

Kelebihan utama gffread adalah efisiensi, cakupan fungsi, dan integrasinya yang luas dalam pipeline anotasi modern. Dalam jurnal [48] mendeskripsikan gffread sebagai utilitas C++ yang mampu mengonversi, menyortir, memfilter, dan mentransformasikan anotasi GTF/GFF, sekaligus menghasilkan sekuens transkrip, CDS, dan protein dalam format FASTA. Selain itu, jurnal [48] tersebut juga menekankan bahwa struktur data seperti hash tables dan array dinamis membuat gffread efisien untuk menangani anotasi genom berukuran besar dan menyediakan opsi verifikasi serta pembersihan anotasi (misalnya -E, -T, -N, -U, -w, -x, -y) [48].

Penggunaan gffread sebagai “penghubung” dari anotasi ke sekuens terlihat dalam berbagai studi terbaru, salah satunya jurnal [49] yang menggunakan GffRead v0.12.7 untuk mengekstrak sekuens protein dari genom dan anotasi sebelum analisis homolog dan anotasi fungsi dengan eggNOG-mapper [49]. Berdasarkan jurnal [55] memanfaatkan gffread v0.12.7 untuk menghasilkan sekuens transkrip dari anotasi genom sebagai input penilaian kelengkapan dengan BUSCO [55]. Pada [49] mencantumkan gffread v0.12.7 sebagai salah satu perangkat lunak utama dalam tahap pemrosesan anotasi sebelum analisis beban struktural dan fungsional pada genom tanaman [49].

Keterbatasan gffread terutama terkait ruang lingkup dan ketergantungannya pada kualitas anotasi input. Jurnal [48] menegaskan bahwa GFF Utilities berfokus pada manipulasi anotasi yang sudah ada, bukan prediksi gen baru: gffread hanya bekerja pada fitur gene, mRNA, exon, dan CDS yang sudah terdefinisi di GTF/GFF, serta menyediakan opsi untuk membuang transkrip dengan CDS yang tidak valid (misalnya intron non-kanonik, adanya kodon stop di tengah frame, atau CDS tidak lengkap) melalui opsi seperti -J, -N, dan -V [48]. Studi-studi downstream menunjukkan bahwa anotasi awal sering mengandung CDS bermasalah sehingga perlu difilter dengan gffread, diantaranya yaitu dalam jurnal [52] menyatakan bahwa “*CDS sequences lacking start or stop codons were filtered using GffRead v0.12.7, and redundant sequences were removed*” ketika menyusun himpunan gen GH1 berkualitas tinggi di 61 genom *Lepidoptera* [52], jurnal [56] menerapkan strategi serupa pada famili GT1 dengan menghapus sekuens tanpa kodon awal/stop menggunakan gffread v0.12.7 [56], dan jurnal [57] melaporkan bahwa mereka mengubah GTF menjadi FASTA multi-isoform dan menggunakan gffread v0.12.7 dengan opsi -J untuk membuang pseudogen dan gen yang CDS-nya terputus oleh kodon stop sebelum analisis fungsi pada genom eukariot penambat nitrogen [57]. Temuan-temuan ini menguatkan bahwa gffread sangat kuat untuk membersihkan dan mengekstrak sekuens, tetapi kualitas cDNA, CDS, dan protein yang dihasilkannya tetap bergantung pada akurasi dan konsistensi anotasi struktural yang diberikan di tahap sebelumnya.

2.3.3 Identifikasi Gen Turunan dan Fungsi Gen

Untuk melakukan identifikasi gen turunan dari *Oryza indica* varian RD23 dan *Oryza longistaminata* pada *Oryza indica* varian PR25 menggunakan Orthofinder dan eggNOG-MAPPER.

2.3.3.1 Identifikasi Gen dengan Orthofinder

OrthoFinder adalah perangkat lunak yang digunakan untuk mengidentifikasi hubungan ortolog dan paralog antar gen dari berbagai spesies, atau secara lebih formal merupakan perangkat lunak *phylogenetic orthology inference* yaitu penentuan pasangan gen ortholog dan paralog secara filogenetik dengan membangun dan merekonsiliasi pohon gen (gene tree) dan pohon spesies (species tree), bukan sekadar berdasarkan skor kesamaan sekuens. Dari input berupa satu berkas proteom per spesies, OrthoFinder secara otomatis menyimpulkan (menginfer) struktur hubungan evolusi gen dan menghasilkan beberapa keluaran utama, yaitu mengelompokkan gen ke dalam orthogroup yang merepresentasikan keluarga gen yang berasal dari satu gen leluhur, menentukan (menginfer) pasangan ortholog dan paralog di dalam dan antarspesies, menyusun gene tree berakar untuk setiap orthogroup, menentukan (menginfer) species tree berakar yang konsisten dengan mayoritas gene tree, memetakan peristiwa duplikasi gen ke cabang-cabang species tree, serta menghitung berbagai statistik genomik komparatif seperti jumlah dan distribusi ukuran orthogroup serta proporsi gen yang memiliki ortholog. Deskripsi fungsi ini sejalan dengan paparan jurnal [58] yang menyebut bahwa OrthoFinder memperluas inferensi orthogroup berakurasi tinggi menjadi pipeline lengkap untuk inferensi ortholog filogenetik, gene tree berakar, peristiwa duplikasi gen, species tree berakar, dan statistik komparatif genomik.

Pada studi [59], menunjukkan bahwa OrthoFinder termasuk metode dengan akurasi *orthogroup* tertinggi ketika dibandingkan dengan berbagai algoritma ortologi lain pada kumpulan orthogroup acuan terkurasi. Lalu, dalam jurnal [60], [61], juga menggunakan OrthoFinder sebagai salah satu metode yang diuji pada beragam benchmark orthology berbasis gene tree dan species tree, menegaskan posisinya sebagai metode orthology filogenetik yang kompetitif. Selain itu, paket cogeqc

dalam jurnal [62] menganggap orthogroup hasil OrthoFinder sebagai salah satu standar rujukan ketika menilai kualitas data genomik komparatif, terutama karena orthogroup yang dihasilkan konsisten dengan pola domain protein dan synteny.


Dalam penelitian ini, OrthoFinder dijalankan pada tiga proteom, yaitu PR25, RD23, dan *Oryza longistaminata*, untuk mengelompokkan gen ke orthogroup lintas ketiga genom, mengidentifikasi apakah suatu gen PR25 memiliki ortholog pada RD23, *O. longistaminata*, keduanya, atau tidak terdeteksi, menyediakan gene tree dan species tree sebagai kerangka filogenetik untuk menafsirkan “gen turunan” yang berkontribusi pada pembentukan genom PR25.

Ortholog adalah gen pada spesies berbeda yang berasal dari satu gen leluhur yang terpisah oleh peristiwa spesiasi. Paralog adalah gen yang muncul karena duplikasi gen dalam satu garis keturunan (misalnya duplikasi segmental atau duplikasi genom lengkap), bukan karena spesiasi [58], [63]. Metode orthology klasik sering menggunakan pendekatan *reciprocal best hit* (RBH) berbasis BLAST, yaitu dua gen dianggap ortholog jika saling menjadi best hit satu sama lain pada pencarian BLAST/DIAMOND di dua spesies. Namun evaluasi modern dengan jurnal [59], [60] menunjukkan dua masalah utama RBH:

- Ortholog sejati tidak teridentifikasi – jika terjadi duplikasi gen, ortholog sejati bisa “tertutup” paralog yang sangat mirip sehingga tidak muncul sebagai best hit.
- Ortholog salah diidentifikasi – pasangan dengan skor tertinggi tetapi bukan ortholog sejati dapat terpilih sebagai RBH sehingga menghasilkan false positive [59], [60].

Selain itu, *incomplete lineage sorting* (ILS) menyebabkan sebagian gene tree memiliki topologi berbeda dari species tree karena garis keturunan alel belum sempat mengkoalesen sebelum spesiasi beruntun terjadi. Fenomena ini cukup sering ditemukan dalam studi filogenomik modern dan memperumit inferensi ortholog jika hanya mengandalkan skor kesamaan sekuens [60]. Untuk mengatasi keterbatasan ini, OrthoFinder tidak hanya mengandalkan RBH, tetapi

menggunakan pendekatan berbasis orthogroup dan rekonsiliasi gene tree–species tree. Orthogroup didefinisikan sebagai himpunan semua gen yang diturunkan dari satu gen leluhur pada nenek moyang terakhir bersama spesies yang dianalisis; di dalam satu orthogroup dapat terdapat ortholog antarspesies maupun berbagai jenis paralog, selama semuanya berasal dari gen leluhur yang sama [58].



Gambar 2. 9 RBH dalam Ortholog dapat Gagal

(Sumber: Jurnal [58])

Gambar 2.9 menggambarkan bagaimana RBH bisa gagal:

- Panel A: ada gene tree yang menunjukkan ortholog sejati untuk “gene 1” di Species A, B, C. Namun pasangan RBH (garis kuning) tidak mencakup semua ortholog sejati sehingga ada false negative (FN).
- Panel B: skenario lain di mana RBH memilih pasangan dengan skor tertinggi tapi sebenarnya adalah paralog, sehingga ortholog sejati tidak terpilih maka muncul false positive (FP) dan false negative sekaligus. Konsep kegagalan RBH seperti ini menjadi salah satu motivasi utama dikembangkan pendekatan berbasis gene tree, species tree, dan rekonsiliasi seperti yang diadopsi OrthoFinder [58], [60].

Karena RBH punya keterbatasan tersebut, OrthoFinder memakai konsep orthogroup dan pendekatan filogenetik sehingga Orthogroup merupakan semua gen yang berasal dari satu gen leluhur pada last common ancestor spesies yang

Institut Teknologi Del

dianalisis; satu orthogroup boleh berisi ortholog antarspesies dan paralog, selama masih satu keluarga [58]. Berikut tahapan orthofinder.

2.3.3.1.1 Tahap awal OrthoFinder: input proteom, BLAST all-vs-all, normalisasi skor, pembentukan orthogroup

1. Input proteom: Pengguna memberikan satu FASTA protein per spesies (misal PR25.faa, RD23.faa, OL.faa). Inilah yang dihasilkan dari gffread [58].
2. BLAST/DIAMOND all-vs-all: OrthoFinder menjalankan pencarian kesamaan sekuens protein all-vs-all menggunakan DIAMOND BLASTP (default) atau BLASTP, menghasilkan bit score untuk setiap pasangan protein lintas spesies [58].

3. Normalisasi skor bit terhadap panjang dan jarak evolusi

Pada jurnal [63] menunjukkan bahwa skor BLAST mentah bias terhadap panjang gen, yaitu protein yang lebih panjang hampir selalu memperoleh bit score lebih tinggi sehingga lebih mudah bergabung ke orthogroup, meskipun tingkat konservasi per residu tidak lebih tinggi [63]. Dalam jurnal [63] memodelkan hubungan antara bit score dan hasil kali panjang dua protein dalam ruang log-log, lalu menormalisasi skor sehingga pasangan dengan tingkat konservasi mirip tetapi panjang berbeda menjadi lebih sebanding [63]. Untuk menghilangkan bias ini, OrthoFinder memperkenalkan normalisasi skor bit sebagai berikut:

Untuk setiap pasangan protein q-h:

- L_q = panjang sekuens query (jumlah asam amino),
- L_h = panjang sekuens hit,
- $L_{qh} = L_q \times L_h$ = hasil kali panjang keduanya,
- B_{qh} = bit score BLAST/DIAMOND.

Dari himpunan hit terbaik pada berbagai rentang L_{qh} , himpunan hit terbaik tersebut memasang regresi linear di ruang log-log:

$$\llbracket \log \rrbracket_{-10} B_{qh} = a \llbracket \log \rrbracket_{-10} L_{qh} + b \quad (2.3)$$

dengan a = kemiringan (slope), b = intercept yang diperoleh dengan metode *least squares* [63].

Persamaan ini mendefinisikan skor ideal yang diharapkan untuk panjang

tertentu:

$$B'_{qh} = 10^{a \log_{10} L_{qh} + b} = 10^b L_{qh}^a \quad (2.4)$$


Sehingga:

- $B'_{qh} \approx 1$, kemiripan sesuai ekspektasi pada panjang tersebut
- $B'_{qh} > 1$, kemiripan lebih kuat dari ekspektasi (kandidat kuat berada dalam orthogroup yang sama)
- $B'_{qh} < 1$, kemiripan lebih lemah dari ekspektasi.

Paket cogeqc pada jurnal [62] mengevaluasi ulang bias ini dan menyimpulkan bahwa normalisasi skor bit OrthoFinder efektif mengurangi bias panjang dan skor kemiripan, meskipun tidak menghilangkannya sepenuhnya.

4. Membangun graf homologi dan mengelompokkan orthogroup dengan MCL
 - Setelah skor dinormalisasi B'_{qh} , kemudian digunakan untuk membangun graf homologi dengan node (gen/protein), dan edge yang menghubungkan pasangan gen dengan skor signifikan (berbobot skor ternormalisasi), bobot edge merupakan nilai B'_{qh} [58].
 - Graf ini kemudian dikelompokkan menggunakan *Markov Cluster Algorithm (MCL)*, algoritma graph clustering berbasis random walk dengan dua operasi utama, yaitu *expansion* merupakan mensimulasikan random walk yang lebih panjang melalui pemangkatan matriks transisi, dan *inflation* merupakan menaikkan pangkat elemen matriks dan menormalkan ulang untuk menajamkan perbedaan antar cluster. Iterasi *expansion-inflation* memecah graf menjadi blok-blok stabil yang kemudian diinterpretasikan sebagai orthogroup [59], [59] Studi Orthobench 2020 menunjukkan bahwa kombinasi normalisasi skor dan clustering MCL ini menghasilkan orthogroup yang paling konsisten terhadap gene-tree ground truth dibandingkan berbagai metode orthology lain [59].

Pada penelitian ini, berkas Orthogroups.tsv dan Orthogroups.GeneCount.tsv yang dihasilkan pada tahap ini digunakan untuk menghitung jumlah orthogroup PR25_only, RD23_only, OL_only, serta orthogroup yang dibagi bersama ketiga genom. Setiap cluster stabil diinterpretasikan sebagai orthogroup [58].



Gambar 2. 10 Graf Homologi dan Pengelompokan ke Orthogroups

(Sumber: Jurnal [63])

Gambar 2.10 menjelaskan bahwa:

- Panel A – *True relationship unknown*
Menunjukkan gene tree ‘sebenarnya’ yang ingin dipulihkan: Orthogroup 1 (a1, a2, b1, b2, c1) dan Orthogroup 2 (a3, b3, c3).
- Panel B – *BLAST all-vs-all*
Semua gen dari Species A, B, C di-BLAST satu sama lain sehingga diperoleh bit score untuk setiap pasangan.
- Panel C – *Normalise scores*
Grafik kiri: korelasi semu antara BLAST bit score dan gene length, di mana “Top hits” selalu cenderung gen lebih panjang. Grafik kanan: setelah dinormalisasi, hubungan dengan panjang menjadi datar; skor yang tinggi sekarang mencerminkan kemiripan per residu, bukan sekadar panjang.
- Panel D – *Select genes for clustering*
Contoh skor ternormalisasi untuk gene a1; titik hijau (RBBs) yang melampaui ambang batas dipilih sebagai kandidat koneksi dalam graf orthogroup; titik lain ditolak.
- Panel E – *Create orthogroup graph*
Node = gen, edge = pasangan dengan skor ternormalisasi tinggi, graf ini menjadi basis clustering.
- Panel F – *Orthogroups*

Setelah MCL, graf terpecah menjadi dua cluster (Orthogroup 1 dan 2) yang konsisten dengan gene tree “true” di Panel A [59], [63].

2.3.3.1.2 Tahap lanjutan: gene tree, species tree, rooting, dan DLC

Setelah orthogroup terbentuk, OrthoFinder v2 melakukan langkah-langkah filogenetik berikut:

1. Inferensi *gene tree* untuk setiap orthogroup

OrthoFinder membangun gene tree untuk setiap orthogroup menggunakan DendroBLAST (memanfaatkan matriks skor BLAST sebagai aproksimasi jarak), atau pipeline *multiple sequence alignment* (mis. MAFFT) dengan inferensi pohon *maximum likelihood* (mis. IQ-TREE, FastTree) untuk akurasi lebih tinggi [58].

2. Inferensi *species tree* tak berakar (STAG)

Algoritma *STAG* (*Species Tree from All Genes*) menggabungkan informasi semua gene tree untuk menyusun species tree tak berakar yang konsisten dengan pola mayoritas gen, termasuk gen multi-copy [62].

3. *Rooting species tree* (STRIDE)

Algoritma *STRIDE* (*Species Tree Root Inference from Gene Duplication Events*) menggunakan lokasi duplikasi gen di sepanjang gene tree sebagai sinapomorfii untuk menentukan posisi akar species tree secara outgroup-free. STRIDE terbukti dapat menempatkan akar species tree dengan benar pada berbagai dataset skala besar [62].

4. *Rooting gene tree* menggunakan *species tree* berakar

Species tree berakar kemudian digunakan untuk mengatur arah waktu pada gene tree (dari leluhur ke keturunan).

5. Analisis *Duplication–Loss–Coalescence* (DLC)

Dengan gene tree dan species tree yang sudah berakar, OrthoFinder melakukan rekonsiliasi mengklasifikasikan node sebagai spesiasi atau duplikasi, menghitung jumlah duplikasi/kehilangan yang diperlukan agar gene tree konsisten dengan species tree, menandai cabang species tree yang kaya peristiwa duplikasi [58].

Tahapan filogenetik ini membuat OrthoFinder mampu menangani efek *whole-genome duplication* maupun *incomplete lineage sorting*, sehingga inferensi ortholog/paralog lebih sesuai dengan sejarah evolusi spesies dibanding metode yang hanya mengandalkan skor kesamaan sekuens. Dalam [59], [60] menunjukkan bahwa strategi berbasis *gene tree-species tree* ini memberikan keunggulan akurasi di banyak kasus/skenario [59], [60].

Output Orthofinder yang digunakan dalam penelitian

Dari seluruh hasil OrthoFinder, beberapa keluaran yang dimanfaatkan secara langsung dalam penelitian ini adalah:

1. Orthogroups.tsv dan Orthogroups.GeneCount.tsv

Berisi daftar orthogroup beserta jumlah gen per spesies. Berkas ini digunakan untuk menghitung jumlah orthogroup spesifik PR25, RD23, *O. longistaminata*, dan orthogroup yang dibagi bersama, serta menjadi dasar visualisasi komposisi orthogroup di Bab Hasil.

2. Direktori Orthologues/

Menyimpan tabel pasangan ortholog untuk setiap pasangan spesies (misalnya Orthologues_PR25__v__RD23.tsv, Orthologues_PR25__v__*Oryza longistaminata*.tsv). Informasi ini dipakai untuk mengklasifikasikan setiap gen PR25 sebagai “gen turunan RD23”, “gen turunan *O. longistaminata*”, “kontribusi kedua parental”, atau “tanpa ortholog terdeteksi”.


3. Species_Tree_rooted.txt dan direktori Gene_Trees/

Menyediakan species tree berakar dan gene tree untuk setiap orthogroup, yang menjadi konteks filogenetik ketika membahas keluarga gen tertentu (misalnya gen terkait toleransi stres atau sifat agronomis).

4. Statistik genomik komparatif

OrthoFinder merangkum jumlah orthogroup, distribusi ukuran orthogroup, proporsi gen yang berada di orthogroup, jumlah peristiwa duplikasi per cabang species tree, dan indeks ringkasan lain yang lazim digunakan dalam studi [62] untuk menganalisis core genome, gen spesifik garis keturunan, dan ekspansi keluarga gen.

Dalam penelitian ini, orthofinder digunakan untuk OrthoFinder memakai tiga proteom ini untuk membentuk orthogroup, mengidentifikasi ortholog PR25–RD23–O. longistaminata, menginfer gene tree dan species tree, dan menaksir peristiwa duplikasi gen



Gambar 2. 11 Alur OrthoFinder

(Sumber: Jurnal [58])

Penjelasan gambar 2.11 memperlihatkan alur kerja OrthoFinder yang digunakan dalam penelitian ini, dimulai dari inferensi orthogroup hingga penentuan ortholog dan statistik genomik komparatif. Tahap Orthogroup inference dengan algoritma OrthoFinder, yang menunjukkan inferensi orthogroup dari input proteom multi-spesies melalui pencarian kemiripan sekuens berbasis DIAMOND/BLAST, normalisasi skor bit, pembentukan graf homologi, dan pengelompokan dengan *Markov Cluster Algorithm* (MCL). Tahap *Gene tree inference* untuk setiap orthogroup, menggambarkan inferensi gene tree untuk setiap orthogroup, sedangkan tahap *Species tree inference* dan *Species tree rooting* memperlihatkan inferensi species tree tak berakar dan penentuan akarnya menggunakan algoritme STAG dan STRIDE. Tahap *Gene tree rooting* memperlihatkan rooting gene tree dengan memanfaatkan species tree berakar, dan tahap *Hybrid overlap* dan *DLC analysis* untuk memanggil ortholog dan peristiwa duplikasi menunjukkan analisis *hybrid species-overlap* dan *Duplication–Loss–Coalescence (DLC)* pada gene tree berakar untuk mengidentifikasi ortholog dan peristiwa duplikasi gen. Tahap (g) Tabel hasil ortholog per spesies menggambarkan contoh tabel hasil ortholog per spesies beserta ringkasan statistik genomik komparatif (jumlah orthogroup,

distribusi ukuran orthogroup, proporsi gen yang memiliki ortholog), yang dalam penelitian ini dimanfaatkan untuk mengidentifikasi gen turunan PR25 dari RD23 dan *Oryza longistaminata* serta membedakan kontribusi masing-masing parental terhadap komposisi gen PR25.

2.3.3.2 Identifikasi Fungsi Gen dengan EggNOG-MAPPER

EggNOG-MAPPER (*evolutionary genealogy of genes: Non-supervised Orthologous Groups Mapper*) adalah alat yang digunakan untuk melakukan anotasi fungsional urutan baru, seperti genom, transkriptom, atau katalog gen metagenomik dengan memanfaatkan kelompok ortolog dan filogeni yang telah dihitung sebelumnya dari database eggNOG. Alat ini menggunakan kelompok ortolog (*orthologous groups*, *Orthologous Groups (OG)*) dan filogeni yang telah diprahitung (*precomputed orthology*) yang telah dihitung sebelumnya dari **basis data eggNOG** (*evolutionary genealogy of genes: Non-supervised Orthologous Groups*) untuk mentransfer informasi fungsional dari ortolog yang detail [64]. EggNOG sendiri adalah singkatan dari *evolutionary genealogy of genes: Non-supervised Orthologous Groups*, yaitu basis data kelompok ortolog yang dibentuk melalui analisis ribuan genom dan menyediakan anotasi fungsional, riwayat evolusi gen, dan memetakan sekuens baru ke OG pada berbagai level taksonomi.

Tujuan Utama EggNOG-Mapper

1. Memberikan anotasi fungsional yang konsisten dengan kategori COG/eggNOG, istilah *Gene Ontology*, *KEGG Orthology*, nomor EC, *domain protein*, dan deskripsi fungsi untuk setiap sekuens query dengan memanfaatkan ortologi yang telah dihitung di eggNOG, bukan hanya kesamaan sekuens mentah [64].
2. Meningkatkan presisi anotasi yaitu penggunaan ortologi (*orthology-based functional transfer*) diketahui memberikan keandalan lebih tinggi dibandingkan sekadar homologi umum, seperti BLAST, karena menghindari transfer anotasi dari paralog yang lebih dekat, karena ortolog (gen yang terpisah oleh spesiasi) cenderung mempertahankan fungsi yang mirip, sedangkan paralog (gen duplikat dalam satu genom) lebih sering mengalami

divergensi fungsi. EggNOG-mapper secara eksplisit membatasi transfer fungsi dari *fine-grained orthologs* untuk meningkatkan kualitas anotasi [64].

3. Efisiensi dan skalabilitas dalam EggNOG-mapper v2 dengan mengintegrasikan mesin pencarian cepat seperti DIAMOND dan MMseqs2 sehingga dapat menganotasi jutaan sekuens pada skala genom dan metagenom dengan kecepatan signifikan, dan dalam jurnal [64] menunjukkan bahwa versi v2 jauh lebih efisien dibanding versi sebelumnya dan kompetitif dibanding pipeline anotasi fungsional lain.
4. Aksesibilitas pada EggNOG-mapper tersedia dalam dua mode: sebagai program mandiri (*emapper.py*) dan sebagai layanan resmi secara online sehingga pengguna dapat memilih menjalankan anotasi di server lokal/cluster HPC atau cukup mengunggah berkas FASTA ke web server untuk keperluan anotasi rutin tanpa perlu instalasi kompleks [64].


Peran spesifik EggNOG-mapper dalam pipeline ini adalah mengisi kolom anotasi fungsional (kategori COG/eggNOG, GO, KO, EC, domain, dan nama protein) untuk setiap protein, yang kemudian dipetakan kembali ke ID gen standar (misalnya PR25gChr01G000010), sehingga memungkinkan analisis perbandingan fungsi gen antara PR25, RD23, dan *Oryza longistaminata*.

Basis data eggNOG 5.0/6.0

EggNOG-mapper v2 bekerja di atas basis data eggNOG yang menyimpan jutaan *orthologous groups* (OG) beserta pohon filogenetik dan anotasi fungsionalnya, dimana dalam jurnal [65] menyediakan >17 juta OG yang dihitung pada 1.601 level taksonomi dan mencakup 12.535 spesies referensi, terdiri atas 10.756 bakteri, 457 arkea, dan 1.322 eukariot.

Setiap OG di eggNOG 6.0 dianotasi menggunakan fungsi yang diambil dari KEGG, Gene Ontology, UniProtKB, BiGG, CAZy, CARD, Pfam, dan SMART, sehingga memungkinkan EggNOG-mapper untuk mentransfer informasi fungsi (GO, KO, EC, domain, dan sebagainya) dari OG dan ortolog ke sekuens query [65]. Karena itu, kualitas dan kelengkapan basis data (termasuk cakupan OG, update anotasi, dan

kalibrasi ambang signifikansi) memengaruhi sensitivitas dan akurasi anotasi fungsional. sehingga pembaruan pada eggNOG 6.0 dan optimasi threshold kesamaan sekuens menjadi faktor penting untuk meningkatkan jumlah anotasi yang benar.



Gambar 2. 12 Alur EggNOG-mapper

(Sumber: Jurnal [64])

Cara Kerja EggNOG-mapper

EggNOG-mapper v2 terdiri atas empat tahap utama yang dapat dilihat pada gambar 2.12, yaitu pada tahap A: prediksi gen (opsional), tahap B: pencarian kesesuaian sekuens (search), tahap C: inferensi ortologi, dan tahap D: transfer anotasi fungsional dan penulisan keluaran [65].

1. Pada tahap prediksi gen (opsional), jika input berupa genom atau kontig nukleotida, EggNOG-mapper v2 dapat menjalankan prediksi gen *de novo* menggunakan Prodigal untuk menghasilkan sekuens protein yang kemudian digunakan sebagai query anotasi; fitur ini khusus diperkenalkan di v2 untuk memudahkan anotasi langsung dari kontig metagenom [65].
2. Pada tahap pencarian sekuens (*search*), sekuens protein query disejajarkan terhadap database protein eggNOG menggunakan salah satu dari tiga

Institut Teknologi Del

perangkat lunak pencari sequence, yaitu DIAMOND (default dan sangat cepat), MMseqs2, atau HMMER3, sehingga diperoleh sekumpulan search hits yang masing-masing disertai skor kesesuaian, nilai E-value, dan parameter cakupan sekuens [64].

3. EggNOG-mapper kemudian menerapkan ambang batas signifikansi (misalnya maksimum *E-value* dan minimum *coverage*) untuk menyaring hasil pencarian dan memilih *hit terbaik sebagai seed ortholog*, yaitu protein referensi dalam eggNOG yang dianggap representatif untuk query tersebut dan akan dipakai sebagai titik awal inferensi ortologi [64].
4. Pada tahap inferensi ortologi, *seed ortholog* yang diperoleh dari tahap pencarian sekuens dipetakan ke *orthologous group* (OG) yang relevan di dalam basis data eggNOG. Berdasarkan OG dan pohon filogenetik yang telah dihitung sebelumnya, EggNOG-mapper kemudian memilih anggota OG yang merupakan ortolog paling relevan bagi setiap query, sambil membedakan tipe hubungan seperti one-to-one, one-to-many, dan many-to-many. Pendekatan ini disebut sebagai fine-grained orthology, dan dianggap lebih andal untuk transfer fungsi dibandingkan sekadar deteksi homologi umum karena hubungan ortolog didasarkan pada topologi pohon filogenetik dan peristiwa spesiasi/duplikasi yang sudah dianalisis sebelumnya [64], [65]. Pengguna dapat mengatur ruang lingkup taksonomi (*taxonomic scope*) ketika menghasilkan laporan ortolog (misalnya membatasi hanya pada Viridiplantae atau menggunakan mode otomatis), sehingga hanya ortolog dari klad yang relevan yang digunakan sebagai sumber transfer anotasi fungsi. Fitur ini sejalan dengan desain EggNOG-mapper v2 yang menyediakan laporan ortologi pasangan (*pairwise orthology report*) berdasarkan cakupan taksonomi dan tipe ortolog yang dipilih pengguna [64].
5. Pada tahap anotasi fungsional, EggNOG-mapper mengumpulkan semua informasi fungsi yang tersedia untuk OG dan ortolog yang dipilih, termasuk kategori COG/eggNOG, istilah *Gene Ontology*, *KEGG Orthology* dan *pathway*, nomor EC, *domain protein*, serta deskripsi fungsi, kemudian mentransfer informasi tersebut ke setiap sekuens query yang sesuai [64]. Informasi yang telah ditransfer kemudian ditulis ke dalam tabel anotasi

(.emapper.annotations), serta berkas pendukung seperti laporan ortolog dan berkas GFF yang sudah dihias dengan anotasi fungsional, yang memudahkan visualisasi dan integrasi dengan pipeline anotasi struktural lainnya.

Parameter dan metrik yang digunakan

Tahap pencarian sekuens di EggNOG-mapper mengandalkan mesin seperti DIAMOND, MMseqs2, dan HMMER3, yang menilai setiap alignment menggunakan skor kesesuaian, nilai E-value, dan cakupan alignment (*coverage*) untuk mengukur seberapa kuat dan seberapa lengkap kecocokan antara query dan protein referensi [64]. EggNOG-mapper menggunakan ambang batas *E-value* maksimum dan *coverage* minimum untuk menyaring search hits dan hanya mempertahankan kecocokan yang cukup kuat sebagai kandidat *seed ortholog*. Jurnal [64] menggambarkan bahwa tahap “search” di EggNOG-mapper v2 memanggil DIAMOND/MMseqs2/HMMER3 terhadap basis data eggNOG dan kemudian meneruskan hits yang lolos threshold ke tahap inferensi ortologi, sementara jurnal [66] menunjukkan bahwa DIAMOND sendiri menggunakan E-value threshold yang bergantung pada tingkat sensitivitas sebagai filter utama untuk menentukan hits yang dilanjutkan ke tahap berikutnya [64], [66].

Secara statistik, *E-value* menggambarkan jumlah kecocokan dengan skor sama atau lebih tinggi dari suatu alignment yang diharapkan muncul secara kebetulan ketika menelusuri basis data dengan ukuran tertentu; semakin kecil nilai E-value, semakin kecil kemungkinan kecocokan tersebut terjadi secara acak, sehingga alignment dianggap lebih signifikan. Penjelasan ini konsisten dengan deskripsi nilai E-value pada berbagai toolkit analisis sekuens modern, misalnya MPI Bioinformatics Toolkit dalam jurnal [67], menampilkan kolom *E-value* sebagai ukuran signifikansi hit, serta dengan jurnal [68], tentang statistik BLAST yang menekankan E-value, panjang alignment, dan persentase identitas sebagai indikator utama apakah suatu hit merupakan homolog yang sah atau tidak [67], [68].

Coverage pada tahap ini menggambarkan persentase panjang sekuens query atau

target yang tercakup oleh alignment; coverage yang tinggi berarti bahwa sebagian besar domain fungsional penting diwakili dalam alignment tersebut. Dalam jurnal [68], [69], menekankan bahwa interpretasi kesesuaian sekuens sebaiknya mempertimbangkan kombinasi E-value, panjang alignment, *coverage*, dan persentase identitas untuk membedakan hit yang benar-benar homolog dari kecocokan pendek yang kebetulan, dan bahwa variasi parameter ini dapat menghasilkan kualitas alignment yang berbeda, mulai dari sangat longgar hingga sangat ketat [68], [69].

Dalam jurnal [68], [69], juga menunjukkan bahwa pemilihan ambang E-value dan coverage yang sesuai tujuan analisis dan jenis dataset (misalnya genom tunggal dengan katalog gen metagenomik) berpengaruh langsung terhadap jumlah dan kualitas anotasi gen yang diperoleh: threshold yang terlalu longgar meningkatkan jumlah hit tetapi berisiko memasukkan anotasi salah, sedangkan threshold yang terlalu ketat dapat mengurangi sensitivitas dan membuat banyak sekuens tetap tidak teranotasi. Diskusi mengenai pengaturan threshold tersebut banyak muncul ketika mengevaluasi pipeline anotasi dan klasifikasi gen berbasis pencarian sekuens, termasuk pada studi yang mengkaji validitas pengelompokan keluarga gen dan kualitas alignment [68], [69]. Pada bagian ini menjelaskan EggNOG-mapper memanfaatkan E-value dan coverage dari DIAMOND/MMseqs2/HMMER3 sebagai filter kualitas sebelum suatu hit digunakan sebagai seed ortholog dan menjadi dasar transfer anotasi fungsi [64], [66]

Implementasi EggNOG-mapper pada genom PR25, RD23, dan *Oryza longistaminata*

Dalam penelitian ini, EggNOG-mapper digunakan setelah anotasi struktural dan ekstraksi protein selesai, sehingga posisinya berada pada tahap anotasi fungsional berbasis ortologi dalam pipeline:

Liftoff → gffread → FASTA protein → OrthoFinder → EggNOG-mapper (web) → InterProScan → integrasi hasil.

Set protein hasil Liftoff dan gffread untuk PR25, RD23, dan *Oryza longistaminata*

diunggah ke web EggNOG-mapper v2 sebagai input protein sequences; server kemudian menjalankan seluruh tahapan (pencarian sekuens, pemilihan *seed ortholog*, inferensi ortologi, dan transfer anotasi fungsional) dan menghasilkan berkas .emapper.annotations, laporan ortolog, serta GFF teranotasi yang disimpan sebagai dasar tabel anotasi fungsional per gen [64]. Tabel anotasi EggNOG-mapper ini kemudian digabung dengan hasil OrthoFinder (orthogroup dan relasi ortolog) dan InterProScan (*domain protein*) melalui pemetaan ID protein ke ID gen PR25/RD23/OL yang telah distandarkan, sehingga setiap gen memiliki informasi struktur (posisi genom), relasi ortologi, dan anotasi fungsi untuk dianalisis lebih lanjut pada Bab Hasil dan Pembahasan [64].

Output

Output dari eggNOG-MAPPER sebagai berikut:

1. Tab-Separated Text Files: Berisi istilah fungsional yang diprediksi per query.
2. GFF Files: Berkas yang dihiasi dengan anotasi fungsional, yang dapat digunakan untuk visualisasi dan analisis lebih lanjut.
3. Orthology Assignment Tables: Tabel yang mencakup tugas ortologi.
4. Taxonomic Placements: Informasi tentang penempatan taksonomi [64].

2.3.3.3 Identifikasi Domain dan Motif Protein dengan Interproscan

InterPro adalah basis data terintegrasi yang menyediakan analisis fungsi sekuens protein dengan cara mengklasifikasikannya ke dalam famili serta memprediksi keberadaan domain dan situs penting yang terkonservasi. InterPro melakukan ini dengan mengintegrasikan model prediktif (*signature*) dari banyak protein signature databases anggota, kemudian menggabungkan signature yang ekuivalen ke dalam satu entri InterPro yang memiliki deskripsi fungsi, referensi literatur, relasi antar-famili, dan pemetaan ke *Gene Ontology (GO)* [70], [71].

Pada jurnal [70], [71], melaporkan bahwa sumber daya ini kini mencakup puluhan ribu famili dan domain protein, termasuk integrasi model dari 13 database anggota seperti Pfam, PROSITE, SMART, PANTHER, CATH-Gene3D, SUPERFAMILY, CDD/NCBIFAM, TIGRFAMs, PIRSE, PRINTS, HAMAP, dan SFLD, serta berperan sebagai arsip jangka panjang bagi database lama [70], [71]. Dalam

ekosistem tersebut, InterProScan adalah perangkat lunak yang berfungsi sebagai mesin pencarian (*search engine*) untuk InterPro. InterProScan menerima input berupa sekuens protein atau nukleotida, menjalankan berbagai metode pencarian dari database anggota (misalnya HMM Pfam, motif PROSITE, model PANTHER, dan lainnya), lalu mengembalikan daftar domain, motif, entri InterPro, dan anotasi GO yang cocok untuk setiap protein [70], [71], [72]. Adapun berikut tujuan Interproscan:

1. Mengidentifikasi domain dan motif protein

Dengan mencocokkan sekuens protein terhadap signature yang dikembangkan oleh Pfam, PROSITE, SMART, CATH-Gene3D, SUPERFAMILY, CDD, dan database anggota lain, InterProScan mengungkap domain struktural, motif aktif, dan situs konservatif yang menjadi dasar fungsi protein [70], [73], [74], [75].

2. Mengklasifikasikan protein ke dalam famili fungsional

InterPro menggabungkan signature ekuivalen ke dalam satu entri InterPro dan menghubungkannya dengan famili PANTHER, PIRSF, TIGRFAMs, dan HAMAP. Ini membantu membedakan protein yang mungkin memiliki domain serupa tetapi berada dalam famili evolusioner dan fungsi yang berbeda, serta mengenali kelompok protein yang berperan dalam proses biologis tertentu [70], [73], [76].

3. Memberikan anotasi fungsional terstandar (GO dan pathway)

Melalui skema InterPro2GO, entri InterPro dipetakan ke istilah Gene Ontology (GO) untuk biological process, molecular function, dan cellular component, sehingga InterProScan secara otomatis menempelkan anotasi GO berdasar domain/famili yang terdeteksi [73].

4. Studi *The InterPro protein families and domains database: 20 years on* dan *InterProScan 5: Genome-scale Protein Function Classification* menggunakan InterProScan untuk menambahkan domain dan GO pada hampir semua gen yang diprediksi, sebelum dilakukan analisis fungsional dan komparasi fungsi skala genom [70], [72].

5. Memberi dasar komparasi fungsi antar spesies

Domain dan GO lebih konservatif daripada sekuens penuh, sehingga anotasi

InterProScan memungkinkan perbandingan repertoar domain dan kategori fungsi antara PR25, RD23, dan *O. longistaminata*. Dengan menghubungkan status gen turunan (misal RD23_only, OL_only, BOTH) ke domain/GO tertentu, dapat menganalisis fungsi gen mana yang paling berkontribusi pada pembentukan PR25 sebagai padi perenial.

Dalam Penelitian ini, InterProScan digunakan setelah diperoleh protein hasil pembersihan (RD23.clean.fa, PR25.clean.fa, OL.clean.fa), sehingga setiap gen turunan pada PR25 dapat diberi label domain dan GO yang kemudian digabung dengan hasil OrthoFinder dan EggNOG-mapper di Jupyter, misalnya kolom Fungsi_InterPro dan Fungsi_Kombinasi pada tabel PR25.

2.3.3.3.1 Signature dan Database Anggota Interpro

Pada subbab ini menjelaskan mengenai signature dan database yang digunakan pada interproscan.

2.3.3.3.1.1 Signature

Di InterPro, setiap *signature* adalah model matematis yang merepresentasikan pola konservasi sekuens pada suatu famili, domain, atau situs fungsional. Model ini dapat berupa profil Hidden Markov Model (HMM), profil posisi (position-specific scoring matrix), regular expression-based motif.

Signature dikembangkan oleh masing-masing database anggota (member database). InterPro lalu menggabungkan signature ekuivalen dari beberapa anggota ke dalam satu entri InterPro yang memiliki deskripsi fungsi dan pemetaan GO [70], [73].

2.3.3.1.1.2 Database anggota InterPro

Pada jurnal [70], [71], mendokumentasikan 13 protein signature databases yang saat ini menjadi anggota aktif [70], [71]. Berikut perannya dalam InterProScan:


1. CATH-Gene3D – domain berbasis struktur 3D
 - CATH mengklasifikasikan domain struktur protein dari PDB ke dalam superfamilies evolusioner dan memberi anotasi fungsi [77], [78]
 - Gene3D memperluas informasi ini ke tingkat sekuens dengan membuat HMM untuk domain struktural dan menerapkannya ke proteom.

- Di InterProScan, match CATH-Gene3D menandakan bahwa suatu region protein PR25/RD23/OL masuk ke superfamily struktural tertentu, berguna untuk menafsirkan hubungan struktur–fungsi.
2. CDD / NCBIFAM – domain konservatif dan arsitektur domain
 - CDD adalah koleksi model domain dan keluarga protein yang dibangun dari multiple sequence alignment dan digunakan untuk anotasi domain konservatif dan arsitektur domain melalui SPARCLE [75].
 - Di InterProScan, signature CDD/NCBIFAM membantu mendeteksi domain klasik seperti kinase, helikase, dan enzim metabolik yang sangat terkonservasi.
 3. Pfam – famili dan domain protein berbasis HMM
 - Pfam adalah basis data domain/famili protein yang sangat luas, di mana tiap keluarga direpresentasikan sebagai alignment dan profile HMM [74].
 - Penelitian dalam jurnal *Pfam: The protein families database in 2021* menambahkan ratusan famili baru dan meng-update banyak domain, termasuk untuk SARS-CoV-2. Pengembangan terbaru juga melaporkan integrasi lebih kuat dengan InterPro [74].
 - Dalam InterPro, Pfam menjadi tulang punggung anotasi domain, terutama untuk domain enzimatik, regulator, sinyal, dan transmembran.
 4. PANTHER – famili, subfamili, dan pohon filogenetik
 - PANTHER adalah sistem klasifikasi evolusioner dan fungsional untuk gen/protein dari semua domain kehidupan, berbasis >15.000 pohon filogenetik famili protein dan dilengkapi anotasi GO dan pathway [76].
 - Di InterProScan, signature PANTHER menghubungkan protein ke famili/subfamili dengan anotasi GO yang kaya; ini penting untuk melihat konteks evolusioner gen turunan PR25.
 5. *PROSITE Patterns & PROSITE Profiles* – motif pendek dan profil domain
 - PROSITE menyediakan patterns (motif pendek yang sangat konservatif, misalnya situs aktif atau motif Zn-finger) dan profiles untuk domain yang lebih panjang.
 - Dalam InterProScan, PROSITE kuat untuk mendeteksi situs fungsional spesifik yang sering tidak tertangkap oleh domain yang lebih luas di Pfam.

6. SMART – domain modular regulator dan sinyal
 - SMART adalah sumber daya untuk identifikasi domain yang dapat dipindahkan (genetically mobile domains) dan analisis arsitektur domain modul [79].
 - Versi terbaru (v9) mencakup >1300 domain yang dikurasi manual, banyak di antaranya terkait regulasi transkripsi, sinyal, dan interaksi protein.
 - Di InterProScan, SMART menambahkan anotasi domain regulator dan sinyal pada protein padi.
7. CATH-Gene3D dan SUPERFAMILY – lapisan superfamily struktural
 - SUPERFAMILY menggunakan profil HMM untuk mengklasifikasikan domain ke dalam superfamilies SCOP dan menyediakan anotasi struktural/fungsional lintas proteom [77], [78].
 - Bersama CATH-Gene3D, SUPERFAMILY memberi lapisan “superfamily struktural” yang membantu memahami hubungan jauh antar-domain di PR25/RD23/OL.
8. HAMAP, TIGRFAMs, PIRSF, SFLD, PRINTS – famili khusus dan enzim
Dalam jurnal [71], [73] merangkum beberapa database ini sebagai sumber signature untuk:
 - HAMAP: keluarga protein mikroba dengan aturan anotasi kaya (fungsi, kofaktor, lokasi subseluler).
 - TIGRFAMs: famili protein (banyak di bakteri/arka) dengan model HMM equivalog, di mana anggota diasumsikan mempertahankan fungsi nenek moyangnya.
 - PIRSF: klasifikasi famili protein penuh (bukan per-domain), berdasarkan homologi dan arsitektur domain serupa.
 - SFLD: superfamily enzim yang menekankan hubungan struktur–fungsi dan mekanisme reaksi.
 - PRINTS: fingerprints berupa kombinasi motif konservatif yang secara kolektif mengenali satu famili protein.

Dalam InterProScan, signature dari kelompok ini memberikan anotasi fungsi yang spesifik (misalnya tipe enzim atau subunit kompleks tertentu), pelengkap Pfam/PROSITE/SMART.

Secara keseluruhan, InterPro menggunakan kombinasi 13 database ini untuk mengklasifikasikan protein ke dalam famili dan domain, lalu InterProScan memanfaatkan semua signature tersebut untuk menganotasi proteom pengguna, termasuk proteom PR25, RD23, dan *O. longistaminata* di penelitian ini [71], [73].



Gambar 2. 13 Alur Konseptual Interproscan

(Sumber: Jurnal [71])


Gambar 2.13 merupakan alur konseptual pemrosesan sekuens protein oleh ekosistem InterPro: sekuens protein dari UniProtKB (kiri) terlebih dahulu dianalisis oleh InterProScan untuk mengidentifikasi domain, motif, dan situs penting berdasarkan protein signature databases anggota (tengah); hasilnya kemudian diklasifikasikan dan dianotasi di InterPro (kanan), yang menambah setiap entri dengan deskripsi fungsi, referensi literatur, serta pemetaan ke istilah Gene Ontology (GO) dan sumber daya terkait lainnya [71], [73].

Gambar 2.13 merangkum hubungan antara sekuens protein mentah, perangkat lunak InterProScan, dan basis data InterPro sebagaimana dijelaskan dalam pembaruan InterPro terbaru. Pada jurnal [71], menggambarkan bahwa InterPro merupakan sumber daya bebas akses untuk klasifikasi sekuens protein ke dalam famili dengan cara mengintegrasikan model prediktif (signatures) dari berbagai basis data anggota, lalu memprediksi keberadaan domain dan situs penting pada sekuens tersebut [71]. Pada jurnal [73], menegaskan bahwa database InterPro menyediakan klasifikasi integratif sekuens UniProtKB ke dalam famili sekaligus

mengidentifikasi domain fungsional dan situs terkonservasi, sementara InterProScan berperan sebagai perangkat lunak yang memungkinkan sekuens protein maupun nukleotida dicocokkan terhadap kumpulan signature tersebut [73]. Secara konseptual, bagian kiri gambar merepresentasikan sekuens protein dari UniProtKB (analog dengan berkas PR25.clean.fa, RD23.clean.fa, dan OL.clean.fa yang diunggah ke Galaxy), bagian tengah menunjukkan tahap identifikasi domain dan motif oleh InterProScan berdasarkan signature Pfam, PROSITE, PANTHER, CATH-Gene3D, SUPERFAMILY, CDD/NCBIFAM, dan anggota lain, sedangkan bagian kanan menggambarkan entri InterPro yang telah ditambah dengan deskripsi fungsi, literatur, serta anotasi GO (InterPro2GO) dan statistik cakupan proteom [71]. Dalam penelitian ini, alur yang divisualisasikan pada gambar tersebut persis dengan tahap ketika protein PR25, RD23, dan *O. longistaminata* dianotasi domain/GO melalui InterProScan di platform Galaxy sebelum hasilnya diintegrasikan dengan OrthoFinder dan EggNOG-mapper pada tahap analisis fungsi dan identifikasi gen turunan yang berkontribusi pada pembentukan PR25.

2.3.3.3.2 Alur kerja InterProScan

Berikut penjelasan untuk alur interproscan dalam penelitian ini di website galaxy



Gambar 2. 14 Alur Interproscan melalui website Galaxy

Berdasarkan jurnal[71], [72], [73], alur kerja InterProScan dalam anotasi fungsi protein dapat dijelaskan sebagai berikut:

1. Data input sekuens dan konfigurasi analisis
 - Input utama: berkas FASTA berisi sekuens protein (RD23.clean.fa, PR25.clean.fa, OL.clean.fa dari folder clean_proteins).
 - Menentukan database anggota yang akan dijalankan (Pfam, PANTHER, PROSITE, SMART, CATH-Gene3D, SUPERFAMILY, CDD, dan

sebagainya), format output (TSV, GFF3, XML, JSON), mode eksekusi (standalone, klaster, atau melalui Galaxy).

Pada platform *Galaxy Europe/UseGalaxy*, InterProScan tersedia sebagai batch tool yang memungkinkan anotasi ribuan protein sekaligus dan menghasilkan output multi-format [73].

2. Eksekusi metode signature per database (paralel)

- InterProScan membagi kumpulan sekuens menjadi beberapa chunk dan menjalankan HMMER terhadap database Pfam, PANTHER, CATH-Gene3D, SUPERFAMILY, dan lainnya. Lalu, Pattern/profil matching terhadap PROSITE dan aplikasi lain sesuai database anggota.
- Proses ini dijalankan paralel pada banyak worker, sehingga cocok untuk genom berskala besar [71].

Setiap kombinasi (protein, database anggota) menghasilkan daftar hits: ID protein, ID signature, posisi domain (start–end), skor, dan e-value.

3. Integrasi hasil dan pemetaan ke InterPro

Setelah semua analisis signature selesai:

- InterProScan menggabungkan seluruh hits signature per protein.
- Menggunakan tabel pemetaan internal, tiap signature (misalnya Pfam PF00069, PANTHER PTHRxxxxx) dipetakan ke satu atau beberapa entri InterPro [70], [73].
- InterProScan mengelola overlap (misalnya beberapa signature menggambarkan domain sama) dan menghilangkan redundansi, sambil tetap menyimpan informasi rinci untuk setiap hit.

Hasilnya adalah profil domain terintegrasi per protein, lintas semua database anggota.

4. Penambahan anotasi fungsi (GO dan lainnya)

Berdasarkan entri InterPro yang ditemukan:

- InterProScan menambahkan deskripsi fungsi domain/famili dari entri InterPro.
- Melalui pemetaan InterPro2GO, InterProScan menempelkan istilah GO yang terkait (process, function, component) pada setiap domain/famili yang cocok [73].

- Untuk beberapa entri, informasi tambahan seperti hubungan ke pathway atau database lain juga disertakan.

Tahap ini menghasilkan anotasi fungsi terstandar untuk tiap protein, yang kemudian dapat digunakan pada analisis fungsi dan komparasi antar spesies.

5. Penulisan output multi-format

InterProScan mengeksport hasil ke beberapa format yang umum, yaitu:

- TSV/tabular: satu baris per hit, memuat ID protein, database, ID signature, ID InterPro, koordinat, skor/e-value, dan daftar GO.
- GFF3: domain/motif direpresentasikan sebagai fitur pada “genom protein”; berguna untuk visualisasi di genome browser.
- XML dan JSON: format terstruktur lengkap yang mudah di-parse untuk analisis dan integrasi lanjutan [71].

Dalam Penelitian ini, hal ini tercermin pada berkas Galaxy214-[InterProScan on data 204 (tsv)].tabular, Galaxy216-[InterProScan on data 204 (gff3)].gff3, Galaxy215-[InterProScan on data 204 (xml)].xml, Galaxy217-[InterProScan on data 204 (json)].json yang kemudian digunakan pada Jupyter sebagai input untuk tahap integrasi fungsi.

2.3.3.3.3 Kelebihan dan keterbatasan InterProScan

Berikut kelebihan dan kekurangan interproscan untuk penelitian ini:

2.3.3.3.3.1 Kelebihan

1. Integratif dan komprehensif

InterPro menggabungkan signature dari 13 database anggota besar (Pfam, PROSITE, PANTHER, CATH-Gene3D, SUPERFAMILY, CDD/NCBIFAM, SMART, TIGRFAMs, HAMAP, PIRSF, PRINTS, SFLD), sehingga InterProScan memberikan gambaran fungsi protein yang lebih luas dan konsisten dibanding jika masing-masing database dijalankan secara personal (tiap database memiliki tiap proses) [71], [73]

2. Aktif diperbarui

Dalam jurnal [71], [73], melaporkan penambahan ribuan entri baru, integrasi struktur prediksi AlphaFold, serta perluasan cakupan famili dan domain. Versi InterProScan 5.59–5.64 juga menyesuaikan diri dengan update ini [71], [73].

3. Standar de-facto di studi genom modern

Pada jurnal [70], menjadikan InterProScan sebagai komponen utama pipeline anotasi, misalnya digunakan untuk menganotasi domain dan GO pada seluruh gene models sebelum analisis fungsi lanjutan [70].

2.3.3.3.2 Keterbatasan

1. Terbatas pada domain/famili yang sudah dikenal
Protein dengan domain yang benar-benar baru (belum terwakili di Pfam/PROSITE/PANTHER/DB lain) tidak dapat dianotasi InterProScan. Ini adalah keterbatasan umum semua pendekatan berbasis database [70], [73].
2. Komputasi intensif
Menjalankan seluruh database anggota terhadap puluhan ribu protein membutuhkan waktu dan sumber daya komputasi besar, sehingga InterProScan biasanya dijalankan di server dan memanfaatkan paralelisasi multi-level.
3. Ketersediaan metode tambahan tergantung instalasi
Pada beberapa instalasi (termasuk di beberapa instance Galaxy), metode tertentu yang punya batasan lisensi (misalnya prediksi sinyal peptida) mungkin tidak diaktifkan, sehingga prediksi fitur tersebut perlu diperoleh dari alat lain [70], [73].

Dalam pipeline penelitian ini, InterProScan menempati tahap anotasi fungsi setelah seluruh sekuens protein PR25, RD23, dan *Oryza longistaminata* dibersihkan dan disiapkan sebagai berkas .clean.fa hasil kombinasi Liftoff–AGAT–gffread. Pada tahap interproscan ini, setiap sekuens protein dianalisis terhadap kumpulan signature multi-database (Pfam, PROSITE, PANTHER, CATH-Gene3D, SUPERFAMILY, CDD/NCBIFAM, dan anggota InterPro lainnya) sehingga untuk tiap protein diperoleh profil domain, entri InterPro, serta istilah *Gene Ontology* (GO) yang ditulis dalam berkas keluaran TSV, GFF3, XML, dan JSON di direktori out_interproscan, sesuai konsep klasifikasi dan anotasi terintegrasi. Hasil InterProScan ini kemudian tidak berdiri sendiri, melainkan diintegrasikan kembali pada tahap “integrasi fungsi” di Jupyter Notebook bersama OrthoFinder (yang menyediakan orthogroup dan pasangan ortholog PR25–RD23–*O. longistaminata* untuk menandai gen turunan bertipe RD23_only, OL_only, maupun BOTH) dan EggNOG-mapper (yang memberikan anotasi COG, KEGG Orthology, dan GO tambahan). Seluruh informasi tersebut digabung ke dalam satu tabel akhir, misalnya PR25_Final_Table_for_TA.tsv, yang berisi ID gen PR25, sumber asal gen (RD23, *O. longistaminata*, atau keduanya), profil domain dan entri InterPro dari InterProScan, serta kategori fungsi gabungan (COG/KEGG/GO/Fungsi_Kombinasi), sehingga InterProScan berperan sebagai

penghubung penting antara hasil inferensi ortholog/orthogroup dan interpretasi biologis fungsi gen turunan yang dianalisis dalam menjawab pertanyaan penelitian tentang kontribusi fungsi gen RD23 dan *O. longistaminata* terhadap pembentukan sifat PR25.

2.3.4 Penelitian Terdahulu

Berikut adalah beberapa penjelasan tentang penelitian terkait *Deciphering Rice Genomes at Chromosome-Scale Resolution* dan penjelasan serupa dalam beberapa jurnal yang berhubungan dengan penelitian terkait.

Tabel 2. 3 Penelitian Terkait

Judul	Metode	Hasil	Relevan pada Penelitian ini	Perbedaan Utama terhadap Penelitian Ini
A Super Pan Genomic Landscape Of Rice (2022) [80]	Menyusun super pan-genome berbasis graf dari 251 aksesion padi (Asia dan Afrika; budidaya dan liar) dengan pendekatan <i>de novo long-read assembly</i> , lalu melakukan anotasi dan analisis variasi struktural serta variasi kehadiran/ke tiadaan gen (<i>presence/absence</i>).	Pan-genome tersebut menunjukkan SVs dan presence/absence yang luas, membantu identifikasi keluarga gen tertentu (misalnya NLR) serta mengaitkan SV dengan variasi sifat agronomis melalui dampaknya pada ekspresi gen sekitar.	Mendukung argumen bahwa variasi struktural dan presence/absence membuat interpretasi berbasis satu genom referensi kurang memadai, sehingga katalog gen yang konsisten dan dapat diaudit (seperti yang dibangun untuk PR25) menjadi penting. Menjadi dasar konseptual untuk menempatkan PR25 (hibrida) dalam konteks variasi genom luas, walaupun tidak membangun pan-genome	Pada jurnal ini fokus membangun super pan genome (banyak aksesion) untuk mengungkap SV, presence absence gene, dan keragaman lintas kelompok padi dengan menggunakan <i>de novo long read assembly</i> skala besar dan representasi graf pan genome. Sedangkan pada Penelitian ini fokus membangun katalog gen PR25 yang konsisten (berbasis integrasi output multi tool), lalu membuat pengelompokan operasional RD23 only, OL

Institut Teknologi Del

			graf.	only, BOTH, NONE untuk interpretasi komparatif dengan menggunakan assembly assessment (BUSCO, QUAST), Liftoff dan AGAT, gffread dan <i>cleaning proteome</i> , OrthoFinder, EggNOG mapper, InterProScan, Integrasi data.
Pan-Genome Analysis Of 33 Genetically Diverse Rice Accessions Reveals Hidden Genomic Variations (2021) [4]	Membangun sumber daya pan-genome dari puluhan aksesion padi melalui <i>de novo</i> assembly multi-genom dan analisis variasi struktural dan variasi jumlah salinan gen (gene copy number variations) untuk menjelaskan variasi fenotip/ekspresi.	SV dan variasi jumlah salinan gen berkontribusi pada “variasi tersembunyi” yang tidak mudah terdeteksi jika hanya memakai satu referensi, serta berhubungan dengan ekspresi gen dan sifat agronomis.	Mengandalkan bukti lintas-genom (orthology) dan bukan satu referensi tunggal. menegaskan bahwa kategori seperti RD23_only, OL_only, BOTH adalah kategori operasional deteksi ortholog (sensitif terhadap kualitas perakitan/anotasi), bukan klaim pewarisan genom secara absolut. Lalu, menguatkan konteks “mengapa analisis multi-genom dan	Pada jurnal fokus mengekstrak variasi genom tersembunyi (SV dan variasi jumlah salinan gen) dari banyak genom aksesion padi dengan keluaran katalog SV dan gCNV skala aksesion. Sedangkan dalam penelitian ini fokus bukan mengukur SV lintas populasi, tetapi menyatukan bukti orthology, anotasi fungsi, status known unknown untuk membentuk profil fungsional dominan PR25 dengan keluaran gen PR25 terintegrasi

			integrasi bukti penting”, meskipun pipeline TA tidak berfokus pada SV discovery skala pan-genome.	beserta status orthology dan ringkasan fungsi domain.
Sustained Productivity And Agronomic Potential Of Perennial Rice (2022) [2]	Uji lapangan multi-lokasi dan multi-musim yang membandingkan sistem budidaya padi perennial (contoh PR25) vs annual, termasuk pengukuran produktivitas, kebutuhan tenaga kerja, serta indikator tanah selama beberapa siklus panen.	Menunjukkan bahwa sistem padi perennial dapat mempertahankan produktivitas secara berkelanjutan dan mengurangi kebutuhan tanam ulang, dengan implikasi efisiensi dan aspek keberlanjutan tertentu pada level sistem budidaya.	Mendukung mengapa PR25 sebagai padi perennial/hibrida penting diteliti (nilai keberlanjutan, regrowth, efisiensi sistem)	Pada jurnal, domain agronomi dan keberlanjutan sistem tanam (hasil panen, tenaga kerja, tanah). Sedangkan dalam penelitian ini, domain genomik komputasional dan integrasi anotasi untuk katalog gen.
Telomere-To-Telomere African Wild Rice (Oryza Longistaminata) Reference Genome Reveals Segmental And	Menyusun genom telomere-to-telomere Oryza longistaminata menggunakan kombinasi data sekuensing modern (multi-platform) untuk mencapai perakitan	Menghasilkan referensi genom O. longistaminata yang sangat lengkap pada skala kromosom dan memetakan variasi segmental/struktural yang relevan bagi pemahaman kontribusi	Menggunakan O. longistaminata sebagai wild parent. Kualitas assembly dan kompleksitas variasi struktural pada genom liar adalah faktor yang langsung mempengaruhi sensitivitas orthology detection dan interpretasi	Pada jurnal tersebut menghasilkan assembly T2T baru dan analisis variasi struktural dan ekspansi gen keluarga tertentu pada O. longistaminata. Sedangkan dalam penelitian ini, menggunakan assembly publik O. longistaminata sebagai pembandingan

Structural Variation (2025) [81]	kromosom tingkat tinggi, disertai evaluasi kualitas dan analisis variasi struktural serta duplikasi segmental.	genetik spesies liar untuk perbaikan padi.	“OL_only/BOT H”. Studi ini juga menjadi rujukan yang kuat untuk menegaskan bahwa genom <i>O. longistaminata</i> memiliki karakteristik struktural yang kompleks, sehingga pipeline TA perlu memakai quality assessment dan aturan integrasi agar interpretasi tidak bias.	dalam pipeline integrasi PR25 (bukan menghasilkan T2T baru).
Assessing the quality of comparative genomic data and results with the cogeqc R/Bioconductor package (2021) [62]	Memperkenalkan cogeqc, paket R/Bioconductor untuk penilaian kualitas dalam komparatif genomik, yang mencakup: penilaian kualitas perakitan genom dan anotasi dalam konteks filogenetik, penilaian kualitas inferensi orthogroup (misalnya hasil OrthoFinder)	Melalui aplikasi pada dataset nyata, penulis menunjukkan bahwa cogeqc dapat dipakai untuk merangkum kualitas genom (termasuk indikator seperti kelengkapan gen), serta membantu memilih parameter yang lebih optimal pada inferensi orthogroup dan analisis sinteni	Relevan sebagai kerangka quality control (QC) yang selaras dengan pipeline TA (assembly assessment>orthology>interpretasi). Secara praktis, cogeqc dapat diposisikan sebagai: pelengkap argumen mengapa quality assessment (misalnya BUSCO dan metrik perakitan) harus dilakukan sebelum orthology, dan rujukan	Fokus artikel ini adalah pengembangan perangkat QC (cogeqc) dan demonstrasi penggunaannya lintas dataset, bukan analisis mendalam pada satu kasus biologis PR25. Artikel ini menilai kualitas orthogroup dan/atau sinteni secara umum, sedangkan TA, menekankan integrasi multi-output (BUSCO, QUASt, LiftOff, AGAT, gffread, OrthoFinder, eggNOG-mapper, InterProScan)

	dan penilaian kualitas deteksi sinteni. Paket dirancang agar mudah diintegrasikan dengan perangkat lain dan menghasilkan ringkasan dalam bentuk plot.	dengan membandingkan keluaran dari beberapa konfigurasi dan menilai kualitasnya secara kuantitatif dan visual	metodologis bahwa hasil orthogroup perlu dievaluasi kualitasnya dan dapat dibandingkan lintas parameter untuk mengurangi bias.	untuk membangun katalog gen PR25 dan ringkasan fungsi dominan per kelompok bukti ortholog.
The InterPro protein families and domains database : 20 years on (2021) [70]	Pengembangan dan pembaruan basis data InterPro untuk mengintegrasikan banyak “signature” protein (keluarga, domain, motif) dari berbagai member database, serta menyediakan pemetaan fungsional (misalnya ke GO) dan dukungan anotasi berbasis signature	Menyajikan pembaruan konten dan kapabilitas InterPro sebagai central resource anotasi keluarga dan domain protein lintas genom, termasuk dukungan integrasi bukti signature untuk interpretasi fungsi protein.	Relevan sebagai dasar ilmiah untuk tahap protein domain profiling pada pipeline TA (InterProScan menghasilkan domain/family evidence yang kemudian diringkas sebagai fungsi dominan per kelompok orthology).	Berkontribusi pada sumber daya anotasi (database), bukan membangun katalog gen PR25. Dalam TA, InterPro dipakai sebagai komponen bukti yang diintegrasikan bersama OrthoFinder dan eggNOG untuk membentuk katalog gen PR25 dan ringkasan dominansi fungsi.
eggNOG-mapper v2: functional annotation,	Metode functional annotation berbasis orthology melalui eggNOG-mapper v2,	Menunjukkan bahwa eggNOG-mapper v2 dirancang untuk anotasi fungsi skala besar secara	Relevan sebagai dasar ilmiah untuk tahap functional annotation pada pipeline TA (eggNOG sebagai bukti	Fokus pada tool anotasi fungsi. Pada TA, fokus pada integrasi multi tool outputs (quality assessment, lift over/standardisasi,


orthology assignments, and domain prediction at the metagenomic scale (2021) [64]	untuk mempercepat penugasan fungsi (misalnya GO/COG/KEGG dan label terkait) pada skala besar, dengan kerangka kerja berbasis sumber daya orthology eggNOG.	efisien (termasuk konteks metagenomik) dan menyediakan keluaran anotasi fungsional yang dapat dipakai sebagai bukti komplementer terhadap anotasi domain.	fungsional berbasis orthology yang digabungkan dengan bukti domain InterProScan).	<i>orthology grouping</i> , fungsi dominan) untuk membangun katalog gen PR25 dan membandingkan profil fungsi antar kelompok.
---	--	---	---	--

BAB III

ANALISIS

3.1 Tahapan Penelitian

Tahapan penelitian disajikan pada gambar flowchart berikut ini.



Gambar 3. 1 Tahapan Penelitian

Penelitian ini terdiri atas delapan tahapan utama, yaitu *problem statement*, *literature review*, *data collection*, *data analysis*, *design*, implementasi, hasil dan pembahasan, serta kesimpulan dan saran. Seluruh tahapan tersebut dirancang untuk menjawab pertanyaan peneliti ini dengan mengungkap kontribusi gen dari *Oryza longistaminata* dan *O. sativa indica* cv. RD23 terhadap genom *O. sativa indica* cv. PR25, dan mengidentifikasi fungsi gen-gen turunan tersebut

Problem Statement

Penelitian ini dilatarbelakangi oleh kebutuhan untuk memahami kontribusi genetik tetua *Oryza sativa indica* cv. RD23 dan *Oryza longistaminata* terhadap genom *Oryza sativa indica* cv. PR25 sebagai hasil hibridisasi. RD23 dikenal sebagai kultivar indica budidaya yang produktif, sedangkan *O. longistaminata* merupakan padi liar perennial dengan sifat-sifat penting seperti toleransi cekaman dan pertumbuhan melalui rimpang yang dimanfaatkan sebagai sumber gen dalam pemuliaan padi. Meskipun persilangan antara RD23 dan *O. longistaminata* telah menghasilkan galur dan varietas perennial rice seperti PR25, karakterisasi genomik yang secara khusus memetakan gen-gen PR25 yang berhomologi dengan kedua tetua serta mengaitkannya dengan fungsi biologisnya masih terbatas. Oleh karena itu, penelitian ini menyusun pendekatan analisis genomik komparatif berbasis pipeline bioinformatika (Liftoff, gffread, OrthoFinder, EggNOG-mapper, dan

Institut Teknologi Del

InterProScan) untuk mengungkap pola kontribusi gen RD23 dan *O. longistaminata* ke dalam genom PR25 serta fungsi gen turunan yang terdapat di dalamnya.

Literature Review

Tinjauan pustaka dalam penelitian ini mencakup beberapa aspek utama. Pertama, literatur mengenai biologi padi dan keragaman genetik genus *Oryza*, termasuk peran *O. longistaminata* sebagai spesies liar yang sering dimanfaatkan sebagai donor sifat penting dalam pemuliaan padi, serta karakter RD23 dan posisi PR25 sebagai varietas hasil hibridisasi. Hal ini memberikan konteks biologis ketika hasil analisis genom nanti diinterpretasikan. Kedua, dikaji konsep-konsep dasar terkait homologi gen, ortholog, paralog, orthogroup, serta pemanfaatannya dalam analisis hubungan gen antar genom. Ketiga, ditinjau metode dan alat bioinformatika yang digunakan dalam penelitian, yaitu BUSCO dan QUAST untuk menilai kualitas dan kelengkapan genom; Liftoff untuk mentransfer anotasi gen dari genom referensi ZS97 ke PR25 dan RD23; gffread untuk mengekstrak sekuens transkrip, CDS, dan protein; OrthoFinder untuk mengelompokkan gen dalam orthogroup dan memetakan hubungan homologi; serta EggNOG-mapper dan InterProScan untuk melakukan anotasi fungsi dan domain protein. Tinjauan ini memberikan landasan ilmiah bahwa kombinasi alat-alat tersebut sesuai untuk menjawab tujuan penelitian.

Data Collection

Tahap pengumpulan data berfokus pada pengumpulan dan penyiapan data genom yang akan dianalisis. Genom *O. sativa indica* cv. PR25 dan cv. RD23 diperoleh dari BGI dalam format FASTA dengan nama PR25.FINAL.fasta dan RD23.FINAL.fasta sebagai hasil perakitan genom penuh. Genom *O. longistaminata* diperoleh dari basis data publik dalam bentuk berkas terkompresi *Oryza_longistaminata.O_longistaminata_v1.0.dna.toplevel.fa.gz* yang kemudian diekstrak menjadi berkas FASTA genom utuh. Selain itu, genom dan anotasi referensi *Oryza sativa indica* Zhenshan 97 (ZS97) dikumpulkan untuk digunakan pada tahap transfer anotasi dengan Liftoff.

Data Analysis

Tahap ini bertujuan mengubah data genom mentah menjadi informasi biologis yang relevan dengan pertanyaan penelitian. Analisis diawali dengan evaluasi kualitas dan kelengkapan genom menggunakan BUSCO dan QUAST guna memastikan bahwa genom PR25, RD23, dan *O. longistaminata* layak digunakan untuk analisis komparatif. Selanjutnya, anotasi gen pada PR25 dan RD23 diperoleh melalui Liftoff dengan memanfaatkan genom dan anotasi ZS97 sebagai referensi. Berkas anotasi hasil Liftoff kemudian diproses dengan gffread untuk mengekstrak sekuens transkrip, CDS, dan terutama protein dalam format FASTA. Sekuen protein dari PR25, RD23, dan *O. longistaminata* digunakan sebagai input OrthoFinder untuk membentuk orthogroup dan mengidentifikasi gen-gen PR25 yang berhomologi dengan gen di kedua tetua, sehingga mendukung analisis kontribusi gen parental. Selanjutnya, sekumpulan protein tersebut dianotasi secara fungsional menggunakan EggNOG-mapper dan dianalisis domain serta motifnya dengan InterProScan. Hasil ketiga alat ini kemudian siap diintegrasikan pada tahap berikutnya untuk menjawab pertanyaan mengenai fungsi gen turunan pada PR25.

Design

Tahap desain berfokus pada perancangan alur kerja (*workflow*) dan struktur data yang digunakan dalam penelitian. Desain sistem mencakup penyusunan alur proses mulai dari input data, evaluasi kualitas (BUSCO dan QUAST), anotasi menggunakan Liftoff, ekstraksi sekuens dengan gffread, analisis orthology dengan OrthoFinder, anotasi fungsi dan domain melalui EggNOG-mapper dan InterProScan, hingga integrasi hasil di Visual Studio Code. Desain ini memastikan bahwa seluruh langkah analisis terhubung secara sistematis dan berkontribusi langsung pada pencapaian tujuan penelitian.

Implementation

Tahap implementasi merupakan realisasi desain pipeline dalam lingkungan komputasi. Pada tahap ini, seluruh perangkat lunak yang diperlukan, seperti BUSCO, QUAST, Liftoff, gffread, OrthoFinder, EggNOG-mapper, dan InterProScan diinstal dan dikonfigurasi. Lalu, menjalankan setiap langkah analisis sesuai dengan alur yang telah dirancang: menjalankan BUSCO dan QUAST pada

ketiga genom, melakukan transfer anotasi dengan Liftoff untuk PR25 dan RD23, mengekstrak sekuens protein dengan gffread, dan menjalankan OrthoFinder untuk inferensi orthogroup. Selanjutnya, protein dianotasi menggunakan EggNOG-mapper dan InterProScan. Hasil setiap tahap disimpan dalam struktur folder yang terorganisasi untuk memudahkan integrasi dan penelusuran kembali.

Results and Discussion

Tahap ini berfokus pada penyajian dan interpretasi hasil analisis dalam konteks pertanyaan penelitian. Hasil BUSCO dan QAST digunakan untuk menggambarkan kualitas dan kelengkapan genom PR25, RD23, dan *O. longistaminata*. Output Liftoff dan gffread memberikan gambaran jumlah serta karakteristik gen dan protein yang dianalisis. Hasil OrthoFinder kemudian dimanfaatkan untuk mengidentifikasi dan membahas pola orthogroup serta hubungan homologi gen antara PR25 dan kedua tetua, sehingga terlihat kontribusi gen parental terhadap komposisi gen di genom PR25. Selanjutnya, hasil anotasi fungsi dari EggNOG-mapper dan domain dari InterProScan pada gen-gen PR25 yang berhomologi dengan RD23 dan/atau *O. longistaminata* dibahas untuk menjelaskan fungsi-fungsi utama gen turunan yang terdapat pada PR25.

Conclusion and Suggestions

Penelitian ini berhasil mengidentifikasi gen-gen pada *Oryza sativa indica* cv. PR25 yang berhomologi dengan gen pada *O. sativa indica* cv. RD23 dan *Oryza longistaminata*, sehingga memberikan gambaran mengenai kontribusi genetik kedua tetua terhadap komposisi genom PR25. Melalui anotasi fungsional dan domain protein, gen-gen turunan tersebut diketahui terlibat dalam berbagai fungsi dan proses biologis yang berpotensi mendukung sifat-sifat agronomis dan adaptif PR25. Berdasarkan temuan ini, disarankan agar penelitian selanjutnya melakukan validasi eksperimental terhadap gen-gen kandidat, misalnya melalui analisis ekspresi gen atau uji fungsi di lapangan, serta memperluas analisis ke varietas padi lain untuk menambah konteks komparatif. Selain itu, pengembangan lebih lanjut terhadap pipeline bioinformatika dan integrasi dengan data omik lainnya diharapkan dapat meningkatkan ketepatan interpretasi fungsi gen turunan dan

pemanfaatannya dalam program pemuliaan padi.

3.2 Analisis Data


Pada subbab ini menjelaskan data yang digunakan (*data collection*), yaitu data genom dari PR25 dan RD23, serta data referensi. Selain itu, subbab ini menjelaskan evaluasi kualitas genom, analisis data preprocessing.

3.2.1 Data Collection

Data yang digunakan dalam penelitian ini terdiri atas data genom utama dan data referensi. Data genom utama berupa berkas hasil perakitan genom (*genome assembly*) tiga spesies padi, yaitu *Oryza sativa indica* cv. PR25, *O. sativa indica* cv. RD23, dan *Oryza longistaminata* dalam format FASTA (.fa/.fasta), yaitu format teks standar yang menyimpan urutan DNA sebagai satu baris definisi yang diawali tanda > pada header diikuti baris-baris urutan nukleotida A, T, C, dan G sebagai penyusun DNA. Pada data referensi mencakup dataset BUSCO untuk penilaian kualitas dan kelengkapan genom, serta genom dan anotasi *O. sativa* subsp. *indica* cv. Zhenshan 97 (ZS97) sebagai genom rujukan untuk proses anotasi. Seluruh data ini dikumpulkan untuk mendukung tahapan analisis genom.


3.2.1.1 Data Genom

Data genom utama yang digunakan dalam penelitian ini merupakan hasil perakitan genom dari tiga genotipe padi, yaitu *Oryza sativa indica* cv. PR25, *Oryza sativa indica* cv. RD23, dan *Oryza longistaminata*. Genom *Oryza sativa indica* cv. PR25, *Oryza sativa indica* cv. RD23 diperoleh dari Beijing Genomics Institute (BGI) dalam bentuk berkas FASTA dengan nama PR25.FINAL.fasta dan RD23.FINAL.fasta. Kedua berkas tersebut berisi sekuens DNA genomik hasil perakitan yang digunakan sebagai titik awal untuk analisis kualitas, anotasi, dan perbandingan genomik pada penelitian ini.



Gambar 3. 2 Tampilan Isi dari RD23 dan PR25

Gambar 3.2 tersebut merupakan cuplikan isi berkas RD23.FINAL.fasta dan PR25.FINAL.fasta. Setiap sekuens dalam berkas FASTA diawali oleh satu baris definition line yang dimulai dengan karakter > sebagai penanda identitas contig atau scaffold, kemudian diikuti oleh baris-baris yang berisi urutan basa nukleotida A, T, C, dan G. Keempat basa nukleotida tersebut yaitu Adenin (A), Timin (T), Sitosin (C), dan Guanin (G) yang merupakan penyusun utama DNA yang menyandi informasi genetik organisme atau kode genetik pada DNA, sehingga struktur berkas FASTA inilah yang menjadi dasar bagi seluruh analisis genomik berikutnya [82].



Gambar 3. 3 Molekul DNA

(Sumber: NCRAD³)

Selain dua genom indica tersebut, penelitian ini juga menggunakan genom *Oryza longistaminata* sebagai representasi tetua liar PR25. Genom *O. longistaminata* diunduh dari basis data publik dalam bentuk berkas terkompresi *Oryza_longistaminata.O_longistaminata_v1.0.dna.toplevel.fa.gz* yang kemudian diekstrak sehingga diperoleh berkas FASTA genom utuh, yaitu "D:\result\unzip\Oryza_longistaminata.O_longistaminata_v1.0.dna.toplevel.fa".

Oryza longistaminata dipilih karena spesies ini dikenal sebagai padi liar yang sering dimanfaatkan sebagai sumber alel menguntungkan, seperti sifat perennial dan

³ <https://ncrad.org/genetics-of-ad/genetic-testing>

toleransi terhadap berbagai cekaman lingkungan, misalnya kondisi kekeringan, genangan, atau lingkungan tumbuh yang kurang optimal, sehingga relevan sebagai tetua pembanding bagi PR25 dalam analisis kontribusi genetik.

3.2.1.2 Data Referensi

Data referensi pada penelitian ini digunakan untuk dua tujuan utama, yaitu menilai kualitas dan kelengkapan perakitan genom PR25, RD23, dan *Oryza longistaminata*, serta menyediakan genom dan anotasi acuan untuk proses transfer anotasi gen. Untuk tujuan pertama digunakan dataset BUSCO, sedangkan untuk tujuan kedua digunakan genom referensi *Oryza sativa subsp. indica cv. Zhenshan 97 (ZS97)*.




Gambar 3. 4 Dataset Tanaman untuk BUSCO

pleosporales_odb10.2019-11-20	6641
poales_odb10.2019-11-20	4896
polyporales_odb10.2019-11-20	4464

Gambar 3. 5 List of BUSCO v4 lineages

BUSCO (Benchmarking Universal Single-Copy Orthologs) menyediakan himpunan gen ortholog salinan tunggal (*single-copy orthologs*) yang sangat terkonservasi di berbagai kelompok filogenetik. Setiap himpunan disebut lineage dataset dan dikelompokkan menurut filogeni utama, seperti *Bacteria*, *Fungi*, *Plants*, hingga *hewan*. Pada halaman “Plant datasets Odb10” (Gambar 3.4) ditampilkan daftar lineage untuk kingdom tumbuhan, salah satunya adalah Poales, yaitu ordo yang mencakup famili Poaceae tempat genus *Oryza* berada. Dalam penelitian ini digunakan lineage poales_odb10 yang berisi 4.896 gen BUSCO (Gambar 3.5) sebagai representasi gen-gen inti yang seharusnya terdapat pada genom anggota ordo Poales.

Dengan menjalankan BUSCO menggunakan dataset poales_odb10 pada genom PR25, RD23, dan *O. longistaminata*, dihitung proporsi gen BUSCO yang berstatus lengkap (*complete*), terfragmentasi (*fragmented*), atau hilang (*missing*). Hasil ini memberikan gambaran kuantitatif mengenai kualitas dan kelengkapan masing-masing perakitan genom sebelum digunakan pada tahapan analisis berikutnya.



```

D: > result > output_bio > ZS97.dna_sm.toplevel.fa
1 >1 dna_sm:chromosome chromosome:ZS97RS3:1:1:44754788:1 REF
2 ctaaacctaaaccctaaaccctaaaccctaaaccctaaaccctaaaccctaaaccctaa
3 accctaaaccctaaaccctaaaccctaaaccctaaaccctaaaccctaaaccctaaaccct
4 aaaccctaaaccctaaaccctaaaccctaaaccctaaaccctaaaccctaaaccctaaac
5 cctaaaccctaaaccctaaaccctaaaccctaaaccctaaaccctaaaccctaaaccctaa
6 aaccctaaaccctaaaccctaaaccctaaaccctaaaccctaaaccctaaaccctaaacc
7 ctaaacctaaaccctaaaccctaaaccctaaaccctaaaccctaaaccctaaaccctaa
8 accctaaaccctaaaccctaaaccctaaaccctaaaccctaaaccctaaaccctaaaccct
9 taaaccctaaaccctaaaccctaaaccctaaaccctaaaccctaaaccctaaaccctaa
10 ccctaaaccctaaaccctaaaccctaaaccctaaaccctaaaccctaaaccctaaaccct
11 aaaccctaaaccctaaaccctaaaccctaaaccctaaaccctaaaccctaaaccctaaac
12 cctaaaccctaaaccctaaaccctaaaccctaaaccctaaaccctaaaccctaaaccctaa

```

Gambar 3. 6 Data ZS97 sebagai Referensi pada Liftoff

Selain dataset BUSCO, penelitian ini juga memanfaatkan genom dan anotasi referensi *O. sativa* subsp. *indica* cv. Zhenshan 97 (ZS97). Genom referensi ZS97 diunduh dari basis data publik dalam format format terkompresi (.fa.gz), diekstrak menjadi berkas FASTA genom utuh beserta berkas anotasinya, misalnya berkas *Oryza_sativa_zs97.ZS97RS3.dna_sm.toplevel.fa.gz* yang kemudian diekstrak menjadi berkas FASTA genom utuh (Gambar 3.6 memperlihatkan cuplikan isi genom ZS97). ZS97 merupakan salah satu genom referensi padi *indica* yang telah dirakit dan dianotasi dengan kualitas tinggi sehingga sesuai digunakan sebagai acuan untuk pemetaan anotasi.

Pada tahap selanjutnya, genom dan anotasi ZS97 digunakan sebagai input referensi dalam tool Liftoff untuk melakukan liftover anotasi gen ke genom PR25 dan RD23. Dengan cara ini, diperoleh berkas anotasi (GFF/GTF) PR25 dan RD23 yang konsisten dengan genom referensi, sehingga sekuens gen dan protein yang diekstrak dari kedua genom tersebut dapat digunakan secara andal dalam analisis homologi (OrthoFinder) serta anotasi fungsi dan domain (EggNOG-mapper dan

InterProScan). Dengan demikian, lineage BUSCO poales_odb10 berperan sebagai rujukan kualitas genom, sedangkan genom referensi ZS97 berperan sebagai rujukan anotasi gen bagi PR25 dan RD23 dalam penelitian ini.

3.2.2 Evaluasi Kualitas Genom

Setelah seluruh data genom utama, yaitu *Oryza sativa indica* cv. PR25, *O. sativa indica* cv. RD23, dan *Oryza longistaminata*, dikumpulkan dan, jika semula berada dalam format terkompresi (.fa.gz), diekstrak menjadi berkas FASTA genom utuh dengan nama *Oryza_longistaminata.O_longistaminata_v1.0.dna.toplevel.fa*, tahap selanjutnya adalah mengevaluasi kualitas perakitan ketiga genom tersebut sebelum digunakan pada proses anotasi dan analisis perbandingan genomik. Evaluasi kualitas ini penting untuk memastikan bahwa perakitan yang digunakan memiliki kontinuitas yang memadai dan mengandung sebagian besar gen inti yang diharapkan ada pada genom padi, sehingga data genom yang dianalisis cukup “bersih” dan stabil, supaya hasil analisis orthologi dan anotasi fungsi gen tidak terganggu oleh kesalahan pada proses perakitan genom.

Dalam praktik penilaian genom modern, kualitas perakitan umumnya digambarkan melalui tiga aspek utama, yaitu continuity, completeness, dan correctness, yang dalam beberapa kajian pan-genome tanaman dirujuk sebagai prinsip “3C” evaluasi perakitan. Pada penelitian ini, dua aspek pertama: kontinuitas (*continuity*) dan kelengkapan ruang gen (*completeness*) menjadi fokus utama karena keduanya paling langsung memengaruhi keandalan anotasi gen dan analisis perbandingan genomik antara PR25, RD23, dan *O. longistaminata*.

Melalui kombinasi QUAST dan BUSCO (lineage poales_odb10) ini, diperoleh gambaran yang komprehensif mengenai kualitas perakitan genom PR25, RD23, dan *O. longistaminata*. Hasil evaluasi tersebut kemudian digunakan sebagai dasar untuk menilai kelayakan ketiga genom sebagai input pada tahapan anotasi gen (Liftoff), ekstraksi sekuens protein (gffread), analisis orthologi (OrthoFinder), serta anotasi fungsi dan domain (EggNOG-mapper dan InterProScan) pada subbab berikutnya. Kualitas genom referensi ZS97 sendiri mengacu pada studi-studi sebelumnya yang

telah melaporkan dua genom referensi bebas celah (*gap-free*) untuk ZS97RS3 dan MH63RS3 dengan kelengkapan gen yang sangat tinggi, sehingga dalam penelitian ini ZS97 diperlakukan sebagai genom rujukan yang sudah tervalidasi dan tidak dievaluasi ulang menggunakan QUAST maupun BUSCO.

3.2.2.1 Evaluasi Kelengkapan Genom dengan BUSCO

Evaluasi kualitas perakitan genom merupakan tahap penting dalam analisis bioinformatika karena menentukan seberapa representatif dan lengkap genom yang digunakan untuk anotasi gen dan analisis komparatif. Dalam penelitian ini, kelengkapan genom dinilai menggunakan BUSCO (*Benchmarking Universal Single-Copy Orthologs*), yaitu alat yang mengukur gene space completeness berdasarkan keberadaan gen-gen ortholog salinan tunggal yang terkonservasi pada suatu kelompok taksonomi. BUSCO memanfaatkan himpunan gen ortholog salinan tunggal (sering disebut sebagai gen BUSCO) yang diturunkan dari basis data OrthoDB dan menghasilkan metrik kelengkapan yang bermakna secara biologis berdasarkan kandungan gen yang diharapkan. Metrik ini dirancang untuk melengkapi metrik teknis seperti jumlah *contig/scaffold* dan nilai N50, dan saat ini digunakan secara luas sebagai salah satu metode standar untuk mengevaluasi kualitas genom dan anotasi pada berbagai organisme [32] [28].

Secara konsep, setiap lineage dataset BUSCO merepresentasikan kumpulan gen ortholog salinan tunggal yang diharapkan ada pada hampir semua anggota suatu klad (misalnya *Bacteria*, *Fungi*, atau *Poales*). Dengan menelusuri apakah gen-gen BUSCO tersebut ditemukan dalam keadaan lengkap, terduplikasi, terfragmentasi, atau hilang pada suatu perakitan genom, BUSCO memberikan estimasi langsung terhadap kelengkapan ruang gen yang relevan secara biologis. Pendekatan ini banyak digunakan pada studi genom tumbuhan dan khususnya Poaceae yang memerlukan penilaian kelengkapan gen sebelum dilakukan anotasi gen dan fungsional.

Dalam penelitian ini, BUSCO dijalankan pada ketiga genom utama, yaitu *Oryza sativa indica* cv. PR25, *O. sativa indica* cv. RD23, dan *Oryza longistaminata*, menggunakan mode genom (*genome mode*) dan lineage dataset poales_odb10. Dataset poales_odb10 terdiri atas kumpulan gen ortholog salinan tunggal (gen

BUSCO) yang terkonservasi pada ordo Poales, sehingga secara taksonomi paling sesuai untuk menilai kelengkapan genom padi dan kerabat dekatnya, serta lebih spesifik dibandingkan lineage tingkat kingdom seperti *embryophyta_odb10* yang mencakup seluruh tumbuhan darat [32].

Hasil analisis BUSCO akan mengklasifikasikan gen-gen ortolog pada lineage Poales ke dalam empat kategori utama, yaitu:

1. *Complete (Lengkap)*

Gen berhasil dideteksi secara utuh dan lengkap. Kategori ini dibagi lagi menjadi:

- *Complete and Single-Copy (S)*: Gen ditemukan lengkap dan hanya satu salinan (sesuai ekspektasi evolusioner).
- *Complete and Duplicated (D)*: Gen ditemukan lengkap namun dengan lebih dari satu salinan, menunjukkan kemungkinan adanya duplikasi, baik duplikasi genetik alami, hasil dari poliploidi atau dari perakitan.

2. *Fragmented (F)*

Gen ditemukan namun tidak dalam bentuk utuh, hanya sebagian sekuensnya terdeteksi. Hal ini menandakan bahwa perakitan belum berhasil menyusun keseluruhan urutan gen secara lengkap.

3. *Missing (M)*

Gen tidak terdeteksi sama sekali di genom. Ini bisa disebabkan oleh kegagalan dalam proses perakitan, keterbatasan data sekuensing, atau ketidakhadiran gen tersebut dalam spesimen (jika memang tidak diwariskan).

Format pelaporan C, S, D, F, dan M ini merupakan standar dalam output BUSCO dan digunakan luas pada penilaian kualitas genom, termasuk pada berbagai studi genom Poaceae yang memanfaatkan BUSCO sebagai bagian dari kontrol kualitas genom dan anotasi. Adapun pada jurnal [28], [29] tersebut dapat dilihat format pelaporan BUSCO pada gambar berikut.

Table 1 Example of the batch_summary.txt file Obtained by Running BUSCO Auto-Lineage Workflow on Multiple Inputs

Input_file	Dataset	C	S	D	F	M	n	Scores_archaea_odb10	Scores_bacteria_odb10	Scores_eukaryota_odb10
GCF_002155651.1_ASM221556v1_genomic.fna	sulfolobales_odb10	95.5	95.1	0.4	0.6	3.9	1244	C:95.4%[S:95.4%,D:0.0%],F:2.1%,M:2.5%,n:194	C:14.5%[S:14.5%,D:0.0%],F:10.5%,M:75.0%,n:124	C:7.9%[S:7.5%,D:0.4%],F:5.1%,M:87.0%,n:255
GCA_900452565.1_34347_D01_genomic.fna	legionellales_odb10	95.6	95.6	0.0	2.6	1.8	772	C:17.0%[S:16.5%,D:0.5%],F:4.1%,M:78.9%,n:194	C:91.1%[S:91.1%,D:0.0%],F:6.5%,M:2.4%,n:124	C:4.7%[S:4.3%,D:0.4%],F:2.0%,M:93.3%,n:255
GCA_003366055.1_ASM336605v1_genomic.fna	bacteria_odb10	63.7	63.7	0.0	8.9	27.4	124	C:7.2%[S:7.2%,D:0.0%],F:1.5%,M:91.3%,n:194	C:63.7%[S:63.7%,D:0.0%],F:8.9%,M:27.4%,n:124	C:0.8%[S:0.8%,D:0.0%],F:1.2%,M:98.0%,n:255
GCA_003367175.1_ASM336717v1_genomic.fna	burkholderiales_odb10	99.5	98.5	1.0	0.4	0.1	688	C:18.0%[S:17.0%,D:1.0%],F:5.7%,M:76.3%,n:194	C:100.0%[S:100.0%,D:0.0%],F:0.0%,M:0.0%,n:124	C:5.5%[S:4.7%,D:0.8%],F:3.5%,M:91.0%,n:255
GCA_003353085.1_ASM335308v1_genomic.fna	alteromonadales_odb10	99.5	99.1	0.4	0.2	0.3	820	C:21.1%[S:21.1%,D:0.0%],F:4.6%,M:74.3%,n:194	C:99.2%[S:96.0%,D:3.2%],F:0.8%,M:0.0%,n:124	C:4.7%[S:3.9%,D:0.8%],F:2.0%,M:93.3%,n:255
GCF_000182965.3_ASM18296v3_genomic.fna	saccharomycetes_odb10	98.6	98.0	0.6	0.8	0.6	2137	C:58.8%[S:55.2%,D:3.6%],F:6.2%,M:35.0%,n:194	C:30.6%[S:29.0%,D:1.6%],F:16.9%,M:52.5%,n:124	C:94.9%[S:93.3%,D:1.6%],F:2.4%,M:2.7%,n:255

(Continued)

Gambar 3. 7 Berkas Format Pelaporan BUSCO dalam jurnal BUSCO: Assessing Genomic Data Quality and Beyond

(Sumber: Jurnal [28])

Gambar 3.7 menampilkan contoh berkas batch_summary.txt yang dihasilkan BUSCO ketika *Auto-Lineage Workflow* dijalankan pada beberapa berkas genom secara bersamaan. Setiap baris merepresentasikan satu rakitan genom (input_file), sedangkan kolom Dataset menunjukkan himpunan linier BUSCO yang digunakan untuk penilaian (misalnya arthropoda_odb10, bacteria_odb10, atau eukaryota_odb10). Di bagian tengah tabel terdapat kolom C, S, D, F, M, dan n yang merupakan ringkasan numerik dari klasifikasi BUSCO yang telah dijelaskan sebelumnya: C adalah persentase gen BUSCO lengkap (Complete = S + D), S adalah gen lengkap satu salinan (*Complete and Single-Copy*), D adalah gen lengkap yang terduplikasi (*Complete and Duplicated*), F adalah gen terfragmentasi (*Fragmented*), M adalah gen yang tidak terdeteksi (*Missing*), dan n adalah jumlah total gen marker BUSCO dalam dataset lineage tersebut. Dengan demikian, genom dengan nilai C tinggi dan nilai F serta M rendah pada gambar tersebut dapat langsung diinterpretasikan sebagai rakitan yang sangat lengkap, sedangkan genom dengan C lebih rendah dan F/M tinggi mencerminkan kualitas perakitan yang masih perlu diperbaiki, sebagaimana praktik umum evaluasi genom menggunakan BUSCO [28].

Di sisi kanan tabel, kolom Score_arthropoda_odb10, Score_bacteria_odb10, dan Score_eukaryota_odb10 (dan skor serupa untuk lineage lain) menggambarkan

bagaimana setiap rakitan genom dinilai terhadap beberapa himpunan lineage BUSCO yang berbeda. Auto-Lineage Workflow secara otomatis membandingkan kecocokan genom terhadap berbagai lineage dan memilih skor tertinggi sebagai lineage yang paling sesuai; lineage inilah yang kemudian digunakan untuk pelaporan nilai C, S, D, F, dan M utama di tabel. Pendekatan ini memastikan bahwa penilaian kelengkapan genom benar-benar didasarkan pada himpunan gen ortolog yang paling relevan secara filogenetik, seperti yang dijelaskan oleh *BUSCO: Assessing Genomic Data Quality and Beyond* dalam protokol BUSCO terbaru [32].

Untuk menilai kualitas keseluruhan perakitan genom, penelitian ini menggunakan persentase gen dalam kategori *Complete* ($C = S + D$) sebagai indikator utama, dengan tetap mempertimbangkan besarnya kategori *Fragmented* dan *Missing*. Studi-studi genom modern umumnya menginterpretasikan genom sebagai “berkualitas tinggi” ketika nilai *Complete* BUSCO terhadap lineage yang sesuai berada di atas $\pm 90\text{--}95\%$, terutama bila dikombinasikan dengan metrik teknis yang baik (misalnya N50 tinggi dan jumlah contig yang rendah) [28].

Untuk menilai kualitas keseluruhan perakitan, persentase gen dalam kategori *Complete* menjadi indikator utama dimana dapat dilihat pada interpretasi nilai BUSCO berikut ini:

Tabel 3. 1 Interpretasi Nilai BUSCO

Persentase Complete (C)	Kualitas Perakitan	Interpretasi
$\geq 90\%$	Sangat Baik	Perakitan genom sangat lengkap, dengan mayoritas ortolog terdeteksi secara utuh. Cocok untuk analisis lanjut seperti anotasi gen dan studi komparatif.
70–89%	Cukup Baik	Perakitan tergolong baik, tetapi masih terdapat sejumlah gen yang terfragmentasi atau hilang. Mungkin memerlukan kurasi tambahan.
$< 70\%$	Perlu Perbaikan	Menunjukkan bahwa banyak gen universal tidak terdeteksi atau hanya sebagian terdeteksi. Hal ini dapat

Persentase Complete (C)	Kualitas Perakitan	Interpretasi
		mengindikasikan masalah teknis pada proses perakitan atau kualitas data awal yang rendah.

Dengan merujuk pada kriteria di atas, peneliti dapat menilai apakah ketiga genom tersebut memiliki kelengkapan ruang gen yang memadai untuk digunakan pada tahapan berikutnya, yaitu transfer anotasi gen menggunakan Liftoff, ekstraksi sekuens protein menggunakan gffread, analisis orthologi dengan OrthoFinder, serta anotasi fungsi dan domain menggunakan EggNOG-mapper dan InterProScan.

```
# BUSCO version is: 6.0.0
# The lineage dataset is: poales_odb10 (Creation date: 2020-08-05, number of genomes: 12, number of BUSCOs: 4896)
# Summarized benchmarking in BUSCO notation for file /data/TA1/pr25/01.chromosome/result/3ddna/review/PR25.FINAL.fasta
# BUSCO was run in mode: euk_genome_min
# Gene predictor used: miniprot

***** Results: *****

C:99.8%[S:98.1%,D:1.6%],F:0.1%,M:0.1%,n:4896,E:7.1%
4884 Complete BUSCOs (C) (of which 345 contain internal stop codons)
4804 Complete and single-copy BUSCOs (S)
80 Complete and duplicated BUSCOs (D)
6 Fragmented BUSCOs (F)
6 Missing BUSCOs (M)
4896 Total BUSCO groups searched

Assembly Statistics:
13 Number of scaffolds
272 Number of contigs
395899173 Total length
0.033% Percent gaps
31 Mbp Scaffold N50
29 Mbp Contigs N50

Dependencies and versions:
hmmsearch: 3.4
bbtools: None
miniprot_index: 0.17-r279
miniprot_align: 0.17-r279
```

Gambar 3. 8 Data BUSCO PR25

Analisis BUSCO dengan *lineage* dataset poales_odb10 dan mode euk_genome_min memperlihatkan bahwa genom PR25 juga memiliki nilai Complete (C) sebesar 99,8%, terdiri atas 98,1% gen BUSCO salinan tunggal (S) dan 1,6% gen duplikasi (D), dengan Fragmented (F) dan Missing (M) masing-masing hanya 0,1% dari 4.896 gen BUSCO. Statistik perakitan menunjukkan genom PR25 tersusun dalam 13 scaffold dan 272 contig dengan total panjang sekitar 396 Mb, persentase gap 0,033%, serta N50 scaffold 31 Mb dan N50 contig 29 Mb, sehingga menegaskan bahwa perakitan PR25 berada pada kategori sangat baik dan layak digunakan untuk tahapan selanjutnya.

```
# BUSCO version is: 6.0.0
# The lineage dataset is: poales_odb10 (Creation date: 2020-08-05, number of genomes: 12, number of BUSCOs: 4896)
# Summarized benchmarking in BUSCO notation for file /data/TA1/Rd23/02.chromosome/result/3ddna/review/RD23.FINAL.fasta
# BUSCO was run in mode: euk_genome_min
# Gene predictor used: miniprot

***** Results: *****

C:99.8%[S:98.0%,D:1.7%],F:0.1%,M:0.1%,n:4896,E:7.4%
4884 Complete BUSCOs (C) (of which 359 contain internal stop codons)
4799 Complete and single-copy BUSCOs (S)
85 Complete and duplicated BUSCOs (D)
6 Fragmented BUSCOs (F)
6 Missing BUSCOs (M)
4896 Total BUSCO groups searched

Assembly Statistics:
199 Number of scaffolds
237 Number of contigs
406272223 Total length
0.005% Percent gaps
32 Mbp Scaffold N50
29 Mbp Contigs N50

Dependencies and versions:
hmmsearch: 3.4
bbtools: None
miniprot_index: 0.17-r279
miniprot_align: 0.17-r279
```

Gambar 3. 9 Data BUSCO RD23

Hasil BUSCO menggunakan mode `euk_genome_min` dan prediktor gen `miniprot` menunjukkan bahwa genom RD23 memiliki nilai *Complete* (C) sebesar 99,8% dengan rincian 98,0% gen BUSCO salinan tunggal (S) dan 1,7% gen duplikasi (D), sedangkan *Fragmented* (F) dan *Missing* (M) masing-masing hanya 0,1% dari total 4.896 gen BUSCO. Statistik perakitan menunjukkan 199 scaffold dengan total panjang sekitar 406 Mb, persentase gap 0,005%, serta nilai N50 sebesar 32 Mb untuk scaffold dan 29 Mb untuk contig, yang secara keseluruhan mengindikasikan perakitan genom RD23 yang sangat lengkap dan berkualitas tinggi.

```
# BUSCO version is: 6.0.0
# The lineage dataset is: poales_odb10 (Creation date: 2020-08-05, number of genomes: 12, number of BUSCOs: 4896)
# Summarized benchmarking in BUSCO notation for file /data/unzip/Oryza_longistaminata.0_longistaminata_v1.0.dna.toplevel.fa
# BUSCO was run in mode: euk_genome_min
# Gene predictor used: miniprot

***** Results: *****

C:90.2%[S:87.5%,D:2.6%],F:5.0%,M:4.9%,n:4896,E:12.1%
4414 Complete BUSCOs (C) (of which 533 contain internal stop codons)
4286 Complete and single-copy BUSCOs (S)
128 Complete and duplicated BUSCOs (D)
244 Fragmented BUSCOs (F)
238 Missing BUSCOs (M)
4896 Total BUSCO groups searched

Assembly Statistics:
60198 Number of scaffolds
145408 Number of contigs
326442508 Total length
9.798% Percent gaps
93 kbp Scaffold N50
16 kbp Contigs N50

Dependencies and versions:
hmmsearch: 3.4
bbtools: None
miniprot_index: 0.17-r279
miniprot_align: 0.17-r279
```

Gambar 3. 10 Data BUSCO *Oryza longistaminata*

Hasil BUSCO menunjukkan bahwa genom referensi *O. longistaminata* memiliki nilai *Complete* (C) sebesar 90,2% dengan 87,5% gen BUSCO salinan tunggal (S) dan 2,6% gen duplikasi (D), sementara *Fragmented* (F) dan *Missing* (M) masing-masing 5,0% dan 4,9% dari total 4.896 gen BUSCO. Statistik perakitan

memperlihatkan struktur genom yang lebih tersegmentasi dibandingkan PR25 dan RD23, dengan 60.198 scaffold dan 145.408 contig, total panjang sekitar 326 Mb, persentase gap 9,798%, serta nilai N50 sebesar 93 kbp untuk scaffold dan 16 kbp untuk contig. Meskipun demikian, nilai *Complete* yang mencapai $\geq 90\%$ menunjukkan bahwa *O. longistaminata* tetap memberikan representasi yang baik untuk spesies liar kerabat padi, dan karakteristik *Fragmented*, *Missing*, serta N50 tersebut dipandang sebagai informasi tambahan yang menjadi konteks penting dalam interpretasi analisis komparatif selanjutnya.

Tabel 3. 2 Data BUSCO pada PR25, RD23, *Oryza longistaminata*

Genom	Complete (%)	Complete and Single-Copy (%)	Complete and Duplicate (%)	Fragmented (%)	Missing(%)
PR25	99.8	98.1	1.6	0.1	0.1
RD23	99.8	98.0	1.7	0.1	0.1
<i>Oryza longistaminata</i>	90.2	87.5	2.6	5.0	4.9

Tabel tersebut merangkum hasil analisis BUSCO dengan dataset poales_odb10 pada ketiga genom yang digunakan dalam penelitian ini, yaitu PR25, RD23, dan *Oryza longistaminata*. Secara umum, PR25 dan RD23 menunjukkan kelengkapan gen yang hampir identik dengan nilai BUSCO Complete masing-masing sebesar 99,8%. Pada kedua genom tersebut, sebagian besar gen BUSCO Poales terdeteksi sebagai salinan tunggal (*Complete and Single-Copy*) dengan proporsi 98,1% pada PR25 dan 98,0% pada RD23, sementara gen duplikasi (*Complete and Duplicated*) hanya berkisar 1,6–1,7%. Proporsi Fragmented dan Missing pada kedua genom ini sangat rendah (0,1% masing-masing), sehingga keduanya dapat dikategorikan sebagai perakitan genom berkualitas sangat baik dan sangat layak digunakan sebagai dasar untuk penelitian ini.

Genom *Oryza longistaminata* memiliki nilai BUSCO Complete sebesar 90,2%

dengan 87,5% gen BUSCO salinan tunggal dan 2,6% gen duplikasi. Nilai ini masih berada dalam kategori “sangat baik” ($\geq 90\%$ Complete), yang berarti sebagian besar gen inti Poales telah terwakili dengan baik pada genom spesies liar ini. Dibandingkan PR25 dan RD23, *O. longistaminata* menunjukkan persentase Fragmented (5,0%) dan Missing (4,9%) yang lebih tinggi, yang mencerminkan karakter perakitan genom yang lebih tersegmentasi. Meskipun demikian, genom *O. longistaminata* tetap memberikan representasi yang informatif sebagai kerabat liar padi.

3.2.2.2 Analisis Kualitas Struktur Genom dengan QUAST

Analisis kualitas struktur perakitan genom *Oryza sativa indica* cv. PR25, *Oryza sativa indica* cv. RD23, dan *Oryza longistaminata* dilakukan menggunakan QUAST (*Quality Assessment Tool for Genome Assemblies*). QUAST dipilih karena secara luas digunakan dalam studi genom tanaman untuk mengevaluasi dan membandingkan hasil perakitan berdasarkan metrik-metrik yang menggambarkan panjang, fragmentasi, dan komposisi nukleotida genom.

Pada penelitian ini, QUAST dijalankan secara terpisah untuk masing-masing genom dengan menggunakan berkas FASTA hasil perakitan, yaitu PR25.FINAL.fasta, RD23.FINAL.fasta, *Oryza_longistaminata.O_longistaminata_v1.0.dna.toplevel.fa*. Seluruh analisis dilakukan pada contig/scaffold dengan panjang minimum 500 bp sesuai pengaturan standar QUAST, sehingga fokus evaluasi berada pada fragmen perakitan yang berkontribusi signifikan terhadap struktur genom. QUAST menghitung sejumlah metrik ringkasan yang umum digunakan untuk menilai kualitas perakitan genom padi dan kerabatnya, di antaranya sebagai berikut.

Total length

Total length menunjukkan panjang total perakitan genom untuk masing-masing sampel. Nilai ini dibandingkan dengan kisaran ukuran genom padi yang dilaporkan di literatur (sekitar 430 Mb untuk *Oryza sativa* dengan 12 kromosom) untuk mendeteksi indikasi *over-assembly* (perakitan terlalu panjang) atau *under-assembly* (perakitan terlalu pendek). Konsistensi panjang genom terakit dengan kisaran tersebut menjadi indikasi awal bahwa ukuran genom sudah mendekati nilai biologis

Institut Teknologi Del

yang diharapkan.

Number of contigs/scaffolds dan Largest contig

Number of contigs/scaffolds menggambarkan tingkat fragmentasi perakitan genom. Jumlah kontig atau scaffold yang lebih sedikit umumnya menunjukkan bahwa genom terakit lebih kontinu dan lebih dekat dengan susunan tingkat kromosom. Selain itu, QUAST juga melaporkan *largest contig*, yaitu panjang fragmen terpanjang dalam perakitan, yang memberikan gambaran sejauh mana genom dapat direkonstruksi dalam unit-unit besar. Nilai largest contig yang tinggi, terutama jika disertai jumlah contig yang relatif sedikit, mencerminkan perakitan yang lebih terstruktur.

N50 dan L50

1. N50 adalah panjang contig/scaffold pada posisi di mana 50% dari total panjang genom berada dalam contig/scaffold dengan panjang $\geq$ nilai tersebut.
2. L50 adalah jumlah minimum contig/scaffold yang dibutuhkan untuk mencapai 50% total panjang genom.

Secara umum, N50 yang lebih besar dan L50 yang lebih kecil menunjukkan perakitan dengan kontiguitas yang lebih baik, karena sebagian besar genom terwakili oleh sedikit fragmen yang panjang. Kombinasi kedua metrik ini digunakan untuk menilai sejauh mana perakitan mendekati struktur genom yang diharapkan pada tingkat kromosom.

N90 dan L90

Selain N50 dan L50, QUAST juga melaporkan N90 dan L90, yang menggunakan prinsip serupa tetapi untuk cakupan 90% panjang genom.

1. N90 adalah panjang contig/scaffold pada posisi di mana 90% dari total panjang genom berada dalam contig/scaffold dengan panjang $\geq$ nilai tersebut.
2. L90 adalah jumlah minimum contig/scaffold yang diperlukan untuk mencakup 90% dari total panjang genom.

Nilai N90 yang lebih besar dan L90 yang lebih kecil menunjukkan bahwa tidak hanya bagian terbesar genom, tetapi juga sebagian besar sisa genom tersusun dalam fragmen yang relatif panjang, sehingga memberikan informasi tambahan mengenai

tingkat fragmentasi perakitan pada skala yang lebih ketat.

GC content (%)

GC content adalah persentase basa G dan C dalam perakitan genom. Pada penelitian ini, nilai GC content digunakan untuk memeriksa konsistensi komposisi nukleotida masing-masing perakitan dengan kisaran GC yang umumnya dilaporkan untuk genom padi dan anggota Poaceae (~42–44%). Nilai GC yang seragam dan berada dalam kisaran tersebut mendukung bahwa perakitan tidak menunjukkan indikasi kontaminasi besar atau bias teknis yang ekstrem.

Misassemblies

QUAST juga melaporkan jumlah misassembly, yaitu indikasi penggabungan fragmen genom yang tidak tepat, misalnya ketika *region* yang seharusnya berada jauh satu sama lain atau pada kromosom berbeda justru bergabung dalam satu contig/scaffold, serta adanya inversi atau translokasi besar yang tidak konsisten dengan struktur genom referensi. Informasi ini penting untuk menilai stabilitas struktur perakitan sebelum genom digunakan sebagai dasar anotasi gen dan analisis komparatif.

Jumlah N per 100 kbp

Selain metrik sebelumnya, QUAST melaporkan jumlah basa N per 100 kbp sebagai indikator keberadaan gap atau posisi nukleotida yang tidak teridentifikasi dalam perakitan. Nilai # N's per 100 kbp yang lebih rendah menunjukkan bahwa genom terakit memiliki lebih sedikit posisi ambigu dan gap, sehingga memberikan representasi urutan nukleotida yang lebih lengkap dan informatif untuk analisis lanjutan.

All statistics are based on contigs of size ≥ 500 bp, unless otherwise noted (e.g., "# contigs (≥ 0 bp)" and "Total length (≥ 0 bp)" include all contigs).

```

Assembly PR25.FINAL
# contigs ( $\geq 0$  bp) 13
# contigs ( $\geq 1000$  bp) 13
# contigs ( $\geq 5000$  bp) 13
# contigs ( $\geq 10000$  bp) 13
# contigs ( $\geq 25000$  bp) 13
# contigs ( $\geq 50000$  bp) 13
Total length ( $\geq 0$  bp) 395899173
Total length ( $\geq 1000$  bp) 395899173
Total length ( $\geq 5000$  bp) 395899173
Total length ( $\geq 10000$  bp) 395899173
Total length ( $\geq 25000$  bp) 395899173
Total length ( $\geq 50000$  bp) 395899173
# contigs 13
Largest contig 43956531
Total length 395899173
GC (%) 43.65
N50 31960027
N90 24176651
auN 32093870.9
L50 6
L90 11
# N's per 100 kbp 32.71

```

Gambar 3. 11 Jumlah Basa N per 100 kbp

Tabel 3. 3 Data QUAST PR25, RD23, dan Oryza longistaminata

<i>Assembly</i>	<i># contigs</i>	<i>Total length (bp)</i>	<i>Largest contig</i>	<i>GC (%)</i>	<i>N50 (bp)</i>	<i>N90 (bp)</i>	<i>L50</i>	<i>L90</i>	<i># N's per 100 kbp</i>
PR25.FI NAL	13	395899 173	4395653 1	43.65	31960 027	24176 651	6	11	32.71
RD23.FI NAL	199	406272 223	4473077 9	43.87	32118 244	26005 425	6	11	4.68
Oryza_lo ngistami nata.O_1 ongistam inata_v1. 0.dna.top level		314945 577	1127032	41.53	97754	14606	877	3883	10155 .31

Berikut penjelasan untuk tabel 3.2 tersebut:

1. Jumlah contig dan total panjang genom

Ketiga genom memiliki panjang total yang berada di kisaran ratusan megabasa, dengan PR25 $\approx 395,9$ Mbp, RD23 $\approx 406,3$ Mbp, dan Oryza longistaminata $\approx 314,9$ Mbp. PR25 dan RD23 berada dekat dengan kisaran

ukuran genom padi yang umum dilaporkan (390–410 Mbp), sehingga secara panjang keseluruhan *assembly* konsisten dengan ekspektasi genom padi. Sebaliknya, *Oryza longistaminata* sedikit lebih pendek dan memiliki 22.477 contig, jauh lebih banyak dibanding PR25 (13 contig) dan RD23 (199 contig), yang menunjukkan bahwa perakitan *Oryza longistaminata* jauh lebih terfragmentasi, sementara PR25 terutama, dan RD23, sudah tersusun jauh lebih menyatu.

2. *Largest contig* dan kedekatan dengan skala kromosom

Pada *Largest contig*, PR25 memiliki contig terpanjang 43.956.531 bp (~44 Mbp), RD23 dengan contig terpanjang 44.730.779 bp (~44,7 Mbp), sedangkan *Oryza longistaminata* hanya 1.127.032 bp (~1,13 Mbp). Dari data ini terlihat bahwa PR25 dan RD23 sama-sama memiliki contig terbesar di kisaran >40 Mbp, yang sebanding dengan ukuran satu kromosom padi (sekitar 30–45 Mbp), sehingga keduanya sudah mendekati *assembly* skala kromosom. Sementara itu, contig terpanjang *Oryza longistaminata* hanya sekitar 1,1 Mbp, menegaskan bahwa genom ini belum tersusun sampai level kromosom dan masih berupa kumpulan banyak contig pendek.

3. N50/N90 dan L50/L90 sebagai indikator kontiguitas

Nilai N50 pada PR25 dan RD23 sangat mirip, masing-masing sekitar 31,96 Mbp dan 32,12 Mbp, dengan L50 = 6 pada keduanya. Artinya, hanya enam contig terbesar yang sudah cukup untuk menutupi 50% panjang genom PR25 dan RD23, dan setiap contig yang menyumbang porsi ini berukuran sekitar satu lengan kromosom atau lebih. Nilai N90 pada PR25 (24,18 Mbp) dan RD23 (26,01 Mbp) dengan L90 = 11 menunjukkan bahwa 90% genom sudah tercakup hanya oleh sebelas contig, kembali menegaskan tingginya tingkat kontiguitas kedua *assembly* tersebut. Sebaliknya, *Oryza longistaminata* memiliki N50 hanya ~97,8 kbp dengan L50 = 877, serta N90 ~14,6 kbp dengan L90 = 3.883, yang berarti ratusan hingga ribuan contig kecil diperlukan untuk menutupi 50–90% genom. Hal ini jelas menggambarkan perakitan yang sangat terfragmentasi dibanding PR25 dan RD23.

4. GC content dan konsistensi komposisi genom

Dari sisi komposisi nukleotida, ketiga genom menunjukkan GC content yang relatif mirip dan masih berada dalam kisaran khas genom padi dan Poaceae. PR25 memiliki GC 43,65%, RD23 dengan 43,87%, dan *Oryza longistaminata* dengan 41,53%. Nilai ini menunjukkan bahwa meskipun tingkat fragmentasi *Oryza longistaminata* tinggi, komposisi GC keseluruhan tetap wajar secara biologis. Kedekatan GC antara PR25 dan RD23 juga sejalan dengan hubungan keduanya sebagai varietas *Oryza sativa indica*, sementara *Oryza longistaminata* yang merupakan spesies liar memiliki GC sedikit lebih rendah namun masih dalam rentang yang dapat diterima.

5. Jumlah N per 100 kbp dan keberadaan gap


Kolom # N's per 100 kbp menggambarkan banyaknya basa ambigu "N" dalam perakitan. RD23 menunjukkan nilai yang sangat rendah, hanya 4,68 N per 100 kbp, menandakan jumlah gap yang minimal dan kualitas urutan nukleotida yang sangat baik. PR25 memiliki 32,71 N per 100 kbp, sedikit lebih tinggi tetapi masih dalam kisaran yang masih dapat diterima untuk analisis lanjutan, terutama mengingat tingkat kontiguitasnya yang tinggi. Berbeda dengan keduanya, *Oryza longistaminata* memiliki nilai 10.155 N per 100 kbp, jauh lebih tinggi dan konsisten dengan banyaknya contig pendek; hal ini menunjukkan banyaknya gap atau region yang tidak terdefinisi dengan baik, sehingga genom ini perlu diperlakukan sebagai referensi yang berguna di tingkat lokal (misalnya gen tertentu), tetapi memiliki keterbatasan jika digunakan untuk analisis struktural skala kromosom.

Secara keseluruhan, tabel QUAST menunjukkan bahwa PR25 dan RD23 memiliki kualitas struktural assembly yang setara dan tinggi, dengan sedikit contig, N50 dan N90 besar, serta L50/L90 kecil, yang secara bersama-sama menunjukkan bahwa keduanya sudah mendekati genom skala kromosom yang siap untuk tahap selanjutnya. Sementara itu, *Oryza longistaminata* meskipun memiliki GC content yang masih wajar, menunjukkan jumlah contig yang sangat banyak, N50 sangat kecil, dan jumlah N yang sangat tinggi, sehingga menggambarkan perakitan yang jauh lebih terfragmentasi dan penuh gap. Dalam konteks TA-mu, PR25 dan RD23

dapat dipandang sebagai genom utama dengan kualitas struktural tinggi, sedangkan *Oryza longistaminata* bertindak sebagai genom referensi liar yang tetap informatif tetapi memiliki keterbatasan pada aspek struktur dan kelengkapan perakitan.


Selain tabel itu, output dari QUAST yaitu Nx plot dan cumulative length. Nx plot merupakan generalisasi dari konsep N50/N90 yang banyak digunakan dalam penilaian kualitas perakitan genom. Untuk suatu nilai x tertentu (misalnya 10, 50, atau 90), Nx didefinisikan sebagai panjang minimum contig (y) di mana akumulasi semua contig dengan panjang $\geq y$ sudah mencakup x% dari total panjang assembly. Dengan kata lain, nilai Nx menggambarkan seberapa besar kontig yang dibutuhkan untuk menutupi persentase tertentu dari genom. Nx plot kemudian adalah grafik yang memvisualisasikan hubungan antara nilai x pada sumbu horizontal (0–100%) dan panjang Nx pada sumbu vertikal, sehingga tidak hanya menampilkan satu titik N50 atau N90, tetapi seluruh kurva yang menggambarkan perubahan kontiguitas dari N10 hingga N90. Kurva yang bertahan pada nilai panjang tinggi dan turun secara perlahan menunjukkan bahwa genom tersusun oleh sedikit contig panjang (assembly sangat kontinu), sedangkan kurva yang cepat turun mencerminkan banyaknya contig pendek dan tingkat fragmentasi yang lebih tinggi.

Cumulative length plot adalah grafik yang menunjukkan akumulasi panjang contig ketika contig diurutkan dari yang terpanjang hingga terpendek. Pada plot ini, sumbu horizontal merepresentasikan indeks contig (urutan contig ke-1, ke-2, dan seterusnya), sedangkan sumbu vertikal menunjukkan total panjang kumulatif dari contig-contig tersebut. QUAST mendefinisikan kurva ini sebagai jumlah basa pada x contig pertama, dengan x bertambah dari 1 sampai jumlah contig total, sehingga kurva dapat digunakan untuk melihat apakah sebagian besar panjang genom ditopang oleh beberapa contig besar atau justru tersebar pada banyak contig kecil. Jika kurva naik sangat curam di awal lalu cepat mendatar, berarti hanya sedikit contig besar yang sudah mampu menutupi hampir seluruh genom. Sebaliknya, kurva yang naik perlahan dan baru mendekati *plateau* setelah banyak contig menandakan bahwa genom tersusun atas banyak contig kecil yang masing-masing menyumbang panjang relatif sedikit.



Gambar 3. 12 Kurva Nx PR25


Kurva Nx untuk PR25 menunjukkan bahwa panjang contig tetap berada pada kisaran puluhan megabasa di sepanjang rentang X hingga mendekati N90. Pada X mendekati 50, panjang contig masih sekitar ~32 Mbp, sesuai dengan nilai N50 PR25, dan baru turun ke sekitar ~14 Mbp di dekat N100. Pola ini menegaskan bahwa sebagian besar panjang genom PR25 disusun oleh sejumlah kecil contig yang masing-masing berukuran sangat besar (skala kromosom), konsisten dengan nilai N50 dan L50 pada tabel yang menunjukkan kontiguitas tinggi dan fragmentasi yang rendah.



Gambar 3. 13 Kurva Nx RD23


Kurva Nx RD23 sangat mirip dengan PR25: pada bagian awal (X kecil) panjang

contig berada di kisaran >40 Mbp, kemudian menurun perlahan hingga sekitar ~32 Mbp di dekat N50 dan tetap berada di kisaran puluhan megabasa sampai mendekati N90. Penurunan tajam baru terlihat sangat dekat dengan N100, ketika contig terkecil mulai berkontribusi. Hal ini sejalan dengan nilai N50 dan N90 RD23 pada tabel, yang hampir identik dengan PR25, sehingga mengonfirmasi bahwa secara kontiguitas struktural RD23 berada pada kualitas yang sebanding dengan PR25 meskipun jumlah contig totalnya lebih banyak.




Gambar 3. 14 Kurva Nx *Oryza longistaminata*

Berbeda dengan dua genom sebelumnya, kurva Nx *O. longistaminata* berada pada skala kilobasa (kbp), bukan megabasa. Pada X mendekati 0, panjang contig hanya sekitar ~1,1 Mbp dan turun sangat cepat ke kisaran ratusan kilobasa bahkan di $X < 20$. Selanjutnya, kurva terus menurun secara tajam hingga di sekitar N90 panjang contig tinggal puluhan kilobasa. Pola ini konsisten dengan nilai N50 (~97,8 kbp) dan N90 (~14,6 kbp) serta L50/L90 yang sangat besar pada tabel, dan memperjelas bahwa perakitan *O. longistaminata* terfragmentasi dibanding PR25 dan RD23, dengan tidak ada contig yang mencapai skala kromosom.



Gambar 3. 15 *Cumulative Length PR25*


Kurva *cumulative length* PR25 menampilkan kenaikan yang relatif mulus dan hampir linear dari indeks contig 1 sampai 13, hingga mencapai total panjang sekitar ~395 Mbp. Ketidadaan “ekor panjang” di bagian akhir menunjukkan bahwa semua 13 contig berkontribusi signifikan terhadap panjang genom dan masing-masing berada di kisaran puluhan megabasa. Pola ini sejalan dengan fakta bahwa PR25 hanya terdiri dari 13 contig dengan N50 tinggi, sehingga dapat disimpulkan bahwa perakitan PR25 sangat kompak dan mendekati skala kromosom.



Gambar 3. 16 *Cumulative Length RD23*

Pada RD23, kurva *cumulative length* naik sangat tajam pada beberapa contig pertama, kemudian segera mencapai plateau di kisaran 400 Mbp, sementara indeks contig masih terus bertambah hingga mendekati 199. Hal ini menunjukkan bahwa

sebagian besar panjang genom RD23 sudah tercakup oleh sejumlah kecil contig besar di awal, sedangkan ratusan contig berikutnya relatif berukuran kecil dan hanya menambah sedikit panjang total. Pola ini konsisten dengan nilai N50 besar namun #contig total yang lebih banyak dibanding PR25, dan menggambarkan bahwa RD23 memiliki inti genom yang tersusun dalam kontig besar, dengan “sisanya” berupa contig kecil yang kemungkinan merupakan fragmen terminal atau region sulit dirakit.



Gambar 3. 17 *Cumulative Length Oryza longistaminata*

Kurva cumulative length untuk *Oryza longistaminata* menunjukkan kenaikan tajam hanya pada beberapa ribu contig pertama, kemudian perlahan mendekati plateau di sekitar ~315 Mbp sementara indeks contig terus meningkat hingga melampaui 22.000. Pola ini mengindikasikan bahwa meskipun terdapat sejumlah contig yang relatif lebih panjang di bagian awal, total panjang genom secara keseluruhan tersebar pada ribuan contig sehingga setiap contig individual hanya menyumbang porsi panjang yang relatif kecil. Banyaknya contig berukuran kecil di bagian ekor kurva mencerminkan tingginya fragmentasi perakitan dan konsisten dengan nilai jumlah contig yang sangat besar, nilai N50 yang kecil, serta jumlah basa N per 100 kbp yang tinggi pada tabel hasil QUAST.

Sebaliknya, Nx plot (Gambar 3.12 dan 3.13) dan kurva cumulative length (Gambar

3.15 dan 3.16) untuk PR25 dan RD23 menunjukkan bahwa sebagian besar panjang genom sudah tercakup dalam sejumlah kecil contig berukuran puluhan megabasa. Hal ini selaras dengan nilai N50 yang besar, L50 yang kecil, serta jumlah contig yang relatif sedikit pada tabel, sehingga secara keseluruhan menggambarkan perakitan yang memiliki kontiguitas tinggi dan struktur genom yang lebih tersusun. Adapun Nx plot (Gambar 3.14) dan kurva *cumulative length* (Gambar 3.17) untuk *Oryza longistaminata* memperlihatkan bahwa genom ini tersusun dari puluhan ribu contig, dengan panjang contig yang menurun cepat ke kisaran kilobasa dan kontribusi panjang genom yang tersebar di banyak unit kecil. Hasil ini menegaskan bahwa perakitan *Oryza longistaminata* memiliki tingkat fragmentasi yang lebih tinggi dan masih mengandung sejumlah gap, sehingga perakitan tersebut tetap bermanfaat sebagai referensi sekuens dan sumber informasi genetik, namun perlu dipertimbangkan secara hati-hati ketika digunakan untuk analisis yang sensitif terhadap struktur genom yang kontigu.

Berdasarkan hasil evaluasi ini, genom PR25 dan RD23 dinilai memiliki kualitas dan kontiguitas yang memadai untuk dianotasi lebih lanjut, sedangkan genom *Oryza longistaminata* tetap dimanfaatkan sebagai referensi sekuens dalam analisis homologi. Oleh karena itu, tahapan berikutnya dalam penelitian ini adalah melakukan data preprocessing berupa anotasi gen, ekstraksi sekuens CDS dan protein, serta pembersihan dataset protein sebelum dilakukan tahap anotasi selanjutnya.

3.2.3 Data Preprocessing

Pada subbab ini merupakan penjelasan data preprocessing yang dilakukan untuk Ekstraksi CDS dan Protein dengan gffread, Anotasi Gen dengan Liftoff, Standarisasi dan penggabungan anotasi dengan AGAT, Analisis Orthologi Gen dengan OrthoFinder, Analisis Fungsi dan Domain Protein dengan EggNOG-mapper dan InterProScan

3.2.3.1 Anotasi Gen dengan Liftoff

Pada tahap ini dilakukan anotasi gen pada genom *O. sativa indica* cv. PR25 dan *O. sativa indica* cv. RD23 menggunakan perangkat lunak Liftoff. Liftoff memetakan anotasi gen dari genom referensi ke genom target berdasarkan kesesuaian urutan

dan struktur gen, sehingga sangat cocok digunakan untuk pasangan genom yang masih berkerabat dekat. Dalam penelitian ini, genom referensi yang digunakan adalah *O. sativa subsp. indica cv. Zhenshan 97 (ZS97)* yang telah memiliki anotasi gen yang terkurasi dengan baik dan banyak digunakan sebagai rujukan genom indica.

Secara khusus, Liftoff dijalankan dengan input utama berupa: berkas genom referensi ZS97 dalam format FASTA beserta anotasi gennya dalam format GFF3, dan berkas genom target PR25 dan RD23 dalam format FASTA. Berdasarkan kombinasi tersebut, Liftoff melakukan pencocokan (alignment) antara gen-gen ZS97 dan urutan genom PR25 maupun RD23, kemudian menghasilkan output berupa berkas anotasi baru dalam format GFF3 yang berisi koordinat gen, mRNA, CDS, ekson, dan UTR pada masing-masing genom target. Selain itu, Liftoff juga menghasilkan berkas statistik ringkas (misalnya PR25.final_stats.txt, RD23.stats.txt) dan daftar gen referensi yang tidak berhasil dipetakan (berkas .unmapped.txt). Salah satu karakteristik penting Liftoff adalah bahwa, selama suatu gen referensi berhasil dipetakan ke genom target, ID gen dan transkrip dari genom referensi dipertahankan pada anotasi hasil. Artinya, gen-gen homolog pada ZS97, PR25, dan RD23 akan memiliki ID yang sama. Pendekatan ini menguntungkan untuk analisis komparatif karena memudahkan pelacakan gen yang ekuivalen di antara beberapa genom tanpa perlu melakukan penamaan ulang secara manual, menjaga konsistensi antara anotasi referensi dan anotasi genom target, serta menyederhanakan tahapan analisis orthology dan anotasi fungsi pada tahap berikutnya.

Dalam penelitian ini, Liftoff dijalankan untuk dua skenario utama. Pertama, anotasi ZS97 dipetakan secara langsung ke genom PR25 dan RD23 sehingga dihasilkan berkas anotasi PR25.from_ZS97.gff3 dan RD23.from_ZS97.gff3. Kedua, khusus untuk PR25 dilakukan tahap pemolesan anotasi dengan menggabungkan kerangka anotasi berbasis ZS97 dengan gen-gen yang unik dari *Oryza longistaminata* sehingga diperoleh anotasi akhir PR25.final_ZS97_backbone_plus_OLunique.gff3


Ringkasan jumlah fitur gene, mRNA, dan CDS yang dihasilkan dari ketiga berkas

tersebut ditunjukkan pada tabel berikut:

Tabel 3. 4 Ringkasan Jumlah gene, mRNA, dan CDS

Anotasi	Gene	mRNA	CDS
PR25_from_ZS97	34800	49622	274237
RD23_from_ZS97	35028	49882	276882
PR25_final_backbone_plus_OL	37581	52252	279032

Berdasarkan Tabel 3.3, PR25 dan RD23 memiliki jumlah gen yang sebanding ketika anotasi ditransfer langsung dari ZS97, yaitu masing-masing 34.800 dan 35.028 gen. Jumlah mRNA dan CDS juga berada pada kisaran yang mirip, mencerminkan bahwa struktur anotasi pada kedua genom target relatif konsisten terhadap genom referensi. Setelah anotasi PR25 dipoles dengan menambahkan gen unik yang berasal dari *O. longistaminata*, jumlah gennya meningkat menjadi 37.581 gen dengan 52.252 mRNA dan 279.032 CDS. Peningkatan ini menggambarkan kontribusi tambahan informasi genetik dari tetua liar ke dalam genom PR25. Perbandingan jumlah gen antar ketiga skenario anotasi tersebut divisualisasikan pada gambar berikut:



Gambar 3. 18 Perbandingan Jumlah Gen pada PR25 dan RD23

Gambar 3.18 menunjukkan bahwa PR25 dan RD23 memiliki jumlah gen yang hampir sama ketika hanya mempertimbangkan anotasi yang berasal dari ZS97, sehingga dapat diasumsikan bahwa sebagian besar gen inti *indica* berhasil ditransfer ke kedua genom. Namun, batang untuk PR25_final_backbone_plus_OL berada sedikit lebih tinggi, yang konsisten dengan penambahan gen unik dari *O.*


longistaminata. Secara biologis, hal ini mendukung hipotesis bahwa sebagian sifat PR25 sebagai galur hibrida perennial dapat dikaitkan dengan gen-gen tambahan yang berasal dari tetua liar tersebut.

Selain gen yang berhasil dipetakan, Liftoff juga menghasilkan daftar gen referensi yang tidak terproyeksi ke genom target dan disimpan dalam berkas PR25.from_ZS97.unmapped.txt dan RD23.from_ZS97.unmapped.txt. Jumlah gen yang berhasil dipetakan (mapped) dan yang tidak terpetakan (*unmapped*) untuk PR25 dan RD23 dirangkum pada tabel berikut:

Tabel 3. 5 PR25 dan RD23 yang sudah Dipetakan dan Tidak Dipetakan

Genom	<i>Mapped</i>	<i>Unmapped</i>
PR25	34800 (97.52%)	885 (2.48%)
RD23	35028 (98.16%)	657 (1.84%)

Tabel 3.4 memperlihatkan bahwa PR25 memiliki 34.800 gen yang berhasil dipetakan dan 885 gen yang tidak terpetakan, dengan tingkat keberhasilan anotasi sekitar 97,52%. Sementara itu, RD23 memiliki 35.028 gen mapped dan 657 gen unmapped dengan tingkat keberhasilan 98,16%. Persentase mapped yang tinggi pada kedua genom menunjukkan bahwa perakitan PR25 dan RD23 cukup kompatibel dengan genom referensi ZS97, sehingga hasil anotasi dapat dipercaya untuk digunakan pada analisis ortologi dan fungsi gen pada tahap berikutnya. Perbandingan jumlah gen mapped dan unmapped secara visual ditunjukkan pada gambar berikut:



Gambar 3. 19 Jumlah Gen Mapped dan Unmapped Liftoff

Selain menghitung jumlah gen mapped dan unmapped, Liftoff juga menyediakan berkas statistik ringkas PR25.final_stats.txt dan RD23.stats.txt yang merangkum komponen penyusun anotasi, seperti jumlah gen, mRNA, CDS, ekson, UTR, dan intron. Untuk PR25, berkas ini melaporkan 37.581 gen dan 52.252 mRNA, dengan 52.210 CDS dan 308.251 ekson. Di antara mRNA tersebut, 26.422 memiliki UTR di kedua sisi (5' dan 3'), sedangkan 36.502 memiliki sedikitnya satu UTR. UTR (untranslated region) adalah segmen transkrip mRNA yang tidak diterjemahkan menjadi protein tetapi berperan dalam regulasi stabilitas dan efisiensi translasi. Liftoff juga menghitung jumlah ekson pada CDS, UTR 5' (five_prime utr), UTR 3' (three_prime utr), serta jumlah intron pada CDS. Pola statistik yang serupa juga terlihat pada berkas RD23.stats.txt, sehingga mengindikasikan bahwa struktur anotasi mRNA dan komponen gen pada PR25 dan RD23 relatif sebanding.

Seluruh informasi pada tabel 3.4 dan gambar 3.19 tersebut diperoleh melalui sebuah skrip Python sederhana. Skrip tersebut terdiri atas beberapa langkah:

1. Fungsi `count_features()` membaca berkas GFF3 hasil Liftoff (PR25.from_ZS97.gff3;RD23.from_ZS97.gff3;PR25.final_ZS97_backbone_plus_OLunique.gff3) baris demi baris, memeriksa kolom ketiga sebagai tipe fitur, lalu menjumlahkan berapa kali tipe gene, mRNA, dan CDS muncul
2. Fungsi `count_unmapped()` menghitung jumlah baris non-komentar pada berkas .unmapped.txt sebagai jumlah gen referensi yang tidak terpetakan

Institut Teknologi Del

3. Bagian utama (main()) menggabungkan hasil perhitungan tersebut ke dalam tabel ringkas, menghitung persentase mapped dan unmapped, serta memanggil fungsi `plot_gene_counts()` dan `plot_mapped_vs_unmapped()` untuk menghasilkan grafik batang yang ditampilkan sebagai gambar tersebut
4. Pada saat yang sama, skrip membuka berkas `PR25.final_stats.txt` dan `RD23.stats.txt` dan menampilkan beberapa baris awal ke terminal, yang kemudian diringkas menjadi paragraf deskriptif mengenai jumlah UTR, ekson, dan intron tersebut. Dengan demikian, seluruh visualisasi dan ringkasan statistik pada subbab ini yang langsung diturunkan dari output Liftoff.

3.2.3.2 Standarisasi dan penggabungan anotasi dengan AGAT

Setelah anotasi gen pada PR25 dan RD23 diperoleh melalui Liftoff, dilakukan tahap standarisasi dan pemolesan berkas anotasi menggunakan AGAT (*Another GTF/GFF Analysis Toolkit*). AGAT merupakan seperangkat skrip yang dirancang khusus untuk menangani beragam variasi format GTF/GFF, mengecek dan memperbaiki sintaks anotasi, menambahkan atribut yang hilang, mengurutkan fitur, menggabungkan beberapa sumber anotasi, dalam dokumentasi [44] format hingga mengekstrak sekuens FASTA. Dokumentasi resmi AGAT bernama [44] menjelaskan bahwa toolkit ini dapat memeriksa, memperbaiki, dan melengkapi informasi yang hilang pada berkas anotasi sehingga menghasilkan file GFF3 yang lengkap, teratur, dan terstandar, serta menyediakan berbagai skrip berawalan `agat_` untuk hampir semua operasi umum pada file anotasi genom [44]. Rilis terbaru AGAT didistribusikan melalui Bioconda dan Zenodo sebagai “*Another Gff Analysis Toolkit to handle annotations in any GTF/GFF format*”, dan banyak diadopsi dalam pipeline anotasi genom, salah satunya dalam jurnal [83] untuk mengatasi masalah interoperabilitas antar tool [44], [83].

Dalam penelitian ini, AGAT digunakan terutama untuk menstandarkan hasil liftover anotasi ZS97 oleh Liftoff dan anotasi gen unik *O. longistaminata* ke dalam format GFF3 yang bersih dan konsisten, serta menggabungkan kedua sumber

anotasi tersebut menjadi anotasi akhir PR25 yang merepresentasikan kontribusi kedua tetua. Pendekatan ini sejalan dengan praktik yang dilaporkan pada studi [84], [85], dimana skrip AGAT seperti `agat_convert_sp_gxf2gxf.pl` dan `agat_sp_merge_annotations.pl` dimanfaatkan untuk mengonversi, memeriksa, dan menggabungkan anotasi dari berbagai sumber sebelum digunakan pada analisis lanjutan [84], [85].

Secara garis besar, alur kerja AGAT pada data PR25 adalah sebagai berikut. Pertama, berkas anotasi PR25.from_ZS97.gff3 hasil Liftoff dan anotasi tambahan yang berasal dari *O. longistaminata* dikonversi dan diperiksa menggunakan parser AGAT sehingga seluruh fitur (*gene*, mRNA, CDS, ekson, UTR) memiliki hierarki dan atribut yang lengkap serta memenuhi standar GFF3. Kedua, anotasi backbone berbasis ZS97 dan anotasi gen unik *O. longistaminata* digabungkan menggunakan skrip penggabungan AGAT sehingga dihasilkan berkas PR25.add_OL.gff3 yang memuat kedua komponen tersebut. Ketiga, dilakukan tahap pemolesan lanjutan (misalnya perbaikan ID, pengurutan fitur berdasarkan koordinat genom, serta penghapusan fitur yang redundan) hingga diperoleh berkas akhir PR25.final_ZS97_backbone_plus_OLunique.gff3 yang dipakai sebagai input untuk gffread pada subbab berikutnya.

Dampak penggunaan AGAT terhadap struktur anotasi dapat dilihat dari perubahan jumlah fitur gene, mRNA, dan CDS sebelum dan sesudah penggabungan anotasi. Ringkasan yang disajikan pada tabel berikut, yang diperoleh dengan skrip Python sederhana untuk menghitung kemunculan tipe fitur pada berkas GFF3.

Tabel 3. 6 Jumlah gene, mRNA, CDS AGAT

File	Gene	mRNA	CDS
PR25.from_ZS97.gff3	34800	49622	274237
PR25.add_OL.gff3	27671	27671	133493
PR25.final_ZS97_backbone_plus_OLunique.gff3	37581	52252	279032

Berdasarkan Tabel 3.5, berkas PR25.from_ZS97.gff3 yang dihasilkan langsung oleh Liftoff memuat 34.800 fitur bertipe *gene*, 49.622 mRNA, dan 274.237 CDS. Angka ini merepresentasikan backbone anotasi PR25 yang sepenuhnya diturunkan dari genom referensi *O. sativa indica* cv. ZS97, sehingga dapat dianggap sebagai

himpunan gen inti (core genes) yang dibagikan antara ZS97 dan PR25. Jumlah mRNA yang lebih tinggi dibanding gene menunjukkan bahwa banyak gen memiliki lebih dari satu isoform transkrip, sebagaimana lazim pada genom padi yang kaya variasi alternative splicing.

Berkas PR25.add_OL.gff3 berisi 27.671 gene, 27.671 mRNA, dan 133.493 CDS, yang secara biologis dapat diinterpretasikan sebagai komponen tambahan yang berasal dari gen-gen unik *Oryza longistaminata* atau segmen genom yang tidak tercakup dalam backbone ZS97. Jumlah gene dan mRNA yang sama mengindikasikan bahwa pada set ini sebagian besar gen dimodelkan dengan satu isoform utama per gen, sementara jumlah CDS yang besar menunjukkan bahwa setiap gen rata-rata tersusun atas beberapa ekson pengkode (coding exons). File ini tidak menggantikan anotasi ZS97, melainkan melengkapi backbone sebelumnya dengan informasi genetika yang spesifik dari tetua liar.

Setelah kedua komponen anotasi tersebut digabung dan dipoles dengan AGAT, berkas akhir PR25.final_ZS97_backbone_plus_OLunique.gff3 memuat 37.581 gene, 52.252 mRNA, dan 279.032 CDS. Nilai-nilai ini lebih tinggi daripada backbone awal (PR25.from_ZS97.gff3), terutama pada jumlah gene (bertambah sekitar 2.781 gen) dan mRNA (bertambah sekitar 2.630 transkrip). Peningkatan ini menunjukkan bahwa AGAT berhasil mengintegrasikan gen-gen tambahan dari *O. longistaminata* ke dalam anotasi PR25 sekaligus mempertahankan struktur gen hasil liftover ZS97. Dengan kata lain, PR25.final_ZS97_backbone_plus_OLunique.gff3 merepresentasikan anotasi PR25 yang sudah lengkap: mengandung gen inti indikator yang diturunkan dari ZS97, beserta gen-gen kontribusi tetua liar yang diduga berperan pada sifat perenial dan adaptasi lingkungan PR25. Berkas inilah yang kemudian digunakan sebagai dasar untuk ekstraksi CDS dan protein dengan gffread pada subbab berikutnya.

3.2.3.3 Ekstraksi CDS dan Protein dengan gffread

Pada tahap ini, anotasi gen hasil Liftoff dimanfaatkan untuk mengekstrak sekuens CDS (coding sequence) dan protein dari genom PR25 dan RD23 menggunakan alat

baris perintah gffread. Ekstraksi ini penting karena analisis lanjutan seperti OrthoFinder, EggNOG-mapper, dan InterProScan tidak bekerja langsung pada berkas anotasi GFF3, tetapi memerlukan input berupa sekuens nukleotida CDS atau sekuens asam amino protein dalam format FASTA. Secara umum, gffread dijalankan dengan memberikan input berupa:

1. Berkas anotasi gen dalam format GFF3
 - untuk PR25: PR25.final_ZS97_backbone_plus_OLunique.gff3
 - untuk RD23: RD23.from_ZS97.gff3
2. Berkas genom target dalam format FASTA,
 - untuk PR25: PR25.FINAL.fasta
 - untuk RD23: RD23.FINAL.fasta

Dari kombinasi anotasi GFF3 dan genom FASTA tersebut, gffread kemudian menghasilkan output berupa berkas FASTA yang berisi seluruh CDS yang diprediksi (.cds.all.fa) dan seluruh protein yang diterjemahkan dari CDS (.pep.all.fa). Dalam penelitian ini, hasil ekstraksi yang digunakan untuk analisis lebih lanjut adalah berkas protein:

- D:\result\output_bio\proteins\PR25.final.pep.all.fa
- D:\result\output_bio\proteins\RD23.final.pep.all.fa

yang memuat seluruh sekuens protein yang diturunkan dari anotasi gen hasil Liftoff pada PR25 dan RD23.

Tabel 3. 7 Hasil Analisis Output Gffread

Genom	Jumlah Sequence (n_seq)	Panjang Minimum (aa)	Panjang Maksimum (aa)	Panjang rata-rata
PR25	52209	1	6122	393.33
RD23	49849	1	5499	406.43

Berdasarkan tabel tersebut, gffread berhasil mengekstrak lebih dari 50.000 sekuens protein dari masing-masing genom, dengan jumlah 52.209 protein untuk PR25 dan 49.849 protein untuk RD23. Rentang panjang protein yang dihasilkan cukup lebar, mulai dari 1 asam amino hingga lebih dari 5.000 asam amino, dengan panjang rata-rata sekitar 393 aa untuk PR25 dan 406 aa untuk RD23. Nilai-nilai ini menunjukkan

bahwa dataset protein mencakup baik protein pendek (misalnya peptida regulator atau fragmen kecil), maupun protein besar yang tersusun dari banyak domain.

Keberadaan sekuens yang pendek (panjang 1 aa) biasanya berasal dari CDS yang kecil, dan pada tahap berikutnya dapat difilter lebih lanjut melalui langkah pembersihan sekuens protein (subbab 3.2.3.3). Secara keseluruhan, statistik ini mengonfirmasi bahwa proses ekstraksi dengan gffread menghasilkan kumpulan protein yang besar dan beragam, yang siap digunakan sebagai input untuk analisis orthologi dan anotasi fungsi.

Seluruh angka pada tabel tersebut diperoleh melalui sebuah skrip Python sederhana yang membaca berkas FASTA hasil gffread dan meringkas panjang masing-masing sekuens. Secara garis besar, skrip tersebut terdiri atas beberapa langkah berikut:

1. Fungsi untuk membaca FASTA dan menghitung panjang sekuens

Fungsi (misalnya bernama `summarize_fasta()`) membuka berkas FASTA protein, lalu:

- membaca file baris demi baris
- mengenali baris header yang diawali dengan karakter > sebagai awal sekuens baru,
- menggabungkan semua baris berikutnya (yang berisi huruf A, C, G, T, atau asam amino) sebagai satu sekuens penuh
- menghitung panjang setiap sekuens (jumlah karakter non-header)
- menyimpan panjang-panjang tersebut dalam sebuah list.

2. Dari list panjang tersebut, kemudian fungsi menghitung dengan:

- `n_seq`: jumlah total sekuens dalam file (banyaknya header >)
- `min_len`: panjang sekuens paling pendek,
- `max_len`: panjang sekuens paling panjang,
- `mean`: rata-rata panjang sekuens, yaitu jumlah seluruh panjang dibagi `n_seq`.

3. Bagian utama (main) yang memanggil fungsi untuk PR25 dan RD23

Di bagian utama skrip. ditentukan path file protein hasil gffread:

- `D:\result\output_bio\proteins\PR25.final.pep.all.fa` untuk PR25
- `D:\result\output_bio\proteins\RD23.final.pep.all.fa` untuk RD23

Masing-masing file diproses dengan `summarize_fasta()`, dan hasilnya (`n_seq`,

min_len, max_len, mean) dicetak ke layar dalam bentuk tabel teks, sehingga muncul output seperti:

Genom	n_seq	min_len	max_len	mean

PR25	52209	1	6122	393.33
RD23	49849	1	5499	406.43

Nilai-nilai yang dicetak tersebut kemudian menjadi dasar bahwa dataset protein hasil gffread sudah terdefinisi dengan baik sebelum digunakan pada tahap analisis orthologi (OrthoFinder) dan fungsi (EggNOG-mapper, InterProScan).

Dengan demikian, subbab 3.2.3.3 tidak hanya menjelaskan bahwa gffread digunakan untuk mengekstrak CDS dan protein, tetapi juga menunjukkan bentuk nyata outputnya dan bagaimana output tersebut diringkas secara kuantitatif menggunakan kodingan sederhana.

3.2.3.4 Pembersihan Sekuen Protein

Setelah sekuens CDS dan protein diekstraksi dengan gffread, dilakukan tahap pembersihan sekuens protein (protein sequence cleaning) untuk memastikan bahwa dataset yang digunakan pada analisis orthologi dan anotasi fungsi berada dalam kualitas yang baik. Proteome hasil prediksi gen masih berpotensi mengandung sekuens sangat pendek, sekuens terfragmentasi, atau artefak anotasi (misalnya gabungan ekson yang keliru atau domain yang tidak lengkap). Evaluasi akurasi inferensi orthogroup pada dataset Orthobench oleh [59], menunjukkan bahwa kualitas dan kelengkapan proteome input berperan penting dalam kinerja metode orthology seperti OrthoFinder, karena keberadaan banyak fragmen atau anotasi yang keliru dapat mengganggu pembentukan orthogroup yang tepat [59].

Pada penelitian ini, pembersihan dilakukan terhadap tiga set data protein:

1. PR25 – berkas protein hasil ekstraksi anotasi akhir
D:\result\output_bio\proteins\PR25.final.pep.all.fa dibersihkan menjadi:
D:\result\output_bio\clean_proteins\PR25.clean.fa
2. RD23 – berkas protein hasil ekstraksi anotasi

D:\result\output_bio\proteins\RD23.final.pep.all.fa dibersihkan menjadi

D:\result\output_bio\clean_proteins\RD23.clean.fa

3. *Oryza longistaminata* – berkas protein publik

D:\TA1\combined_pep\Oryza_longistaminata.O_longistaminata_v1.0.pep.al

l.fa dibersihkan menjadi D:\result\output_bio\clean_proteins\OL.clean.fa

Kriteria pembersihan dan standar alfabet asam amino

Secara konseptual, pembersihan sekuens protein pada penelitian ini menerapkan beberapa kriteria utama berikut.

1. Konsistensi dengan alfabet asam amino IUPAC–IUBMB

Setiap sekuens diperiksa agar hanya mengandung huruf kode asam amino standar menurut rekomendasi IUPAC–IUBMB. *IUPAC (International Union of Pure and Applied Chemistry)* bersama *IUBMB (International Union of Biochemistry and Molecular Biology)*, yaitu menetapkan kode satu huruf dan tiga huruf untuk 20 asam amino kanonik (A, C, D, E, F, G, H, I, K, L, M, N, P, Q, R, S, T, V, W, Y) beserta simbol tambahan yang diakui seperti B (Asp/Asn), Z (Glu/Gln), dan X (residu tidak diketahui). Tabel resmi *IUPAC–IUBMB* untuk kode asam amino satu huruf secara luas digunakan sebagai rujukan dalam biologi molekuler. Pada tahap pembersihan, sekuens yang memuat karakter di luar alfabet ini diperlakukan sebagai tidak valid. Bagian sekuens yang mengandung karakter tersebut dibuang atau dipotong sehingga sekuens akhir yang digunakan pada analisis orthologi dan anotasi fungsi konsisten dengan alfabet asam amino standar yang juga digunakan dalam basis data protein referensi dan pedoman nomenklatur varian.

2. Penanganan sekuens pendek atau tidak informatif

Sekuens yang pendek (misalnya hanya 1–2 asam amino) umumnya tidak merepresentasikan protein fungsional penuh dan sering kali merupakan hasil prediksi yang tidak lengkap atau fragmen. Keberadaan banyak fragmen pendek dapat mengganggu penyelarasan sekuens dan menurunkan keandalan pengelompokan orthogroup. Pada jurnal [59] menunjukkan bahwa evaluasi akurasi orthogroup sangat sensitif terhadap definisi himpunan protein yang dibandingkan; proteome yang tidak terkurasi dapat menyebabkan kesalahan

interpretasi hasil *benchmark Orthobench* [59]. Karena itu, tahap pembersihan dalam penelitian ini membantu mengurangi pengaruh sekuens sangat pendek atau tidak informatif sehingga distribusi panjang protein lebih merefleksikan proteome fungsional yang akan dianalisis pada tahap orthology dan anotasi fungsi.

3. Normalisasi format dan konsistensi proteome

Pembersihan juga menormalkan format FASTA sehingga setiap ID protein unik memiliki tepat satu sekuens berupa deret karakter asam amino tanpa spasi atau simbol non-standar. Pendekatan ini selaras dengan praktik kurasi pada *UniProt Knowledgebase (UniProtKB)*, yang berupaya menyediakan himpunan sekuens protein yang komprehensif dan berkualitas tinggi serta mengurangi redundansi pada tingkat proteome sambil menjaga konsistensi anotasi fungsional [86].

Dengan demikian, pembersihan yang dilakukan pada penelitian ini tidak mengubah jumlah ID protein, tetapi dapat mengubah isi sekuens untuk sebagian ID (misalnya karena pemotongan karakter di luar alfabet IUPAC atau fragmen kecil di ujung sekuens) dan sedikit menggeser distribusi panjang sekuens. Proteome input yang bersih dan konsisten diharapkan menjadi dasar yang lebih andal untuk inferensi ortholog dan analisis komparatif berikutnya.

Hasil pembersihan sekuens protein dihitung menggunakan skrip Python yang dapat membaca berkas FASTA sebelum dan sesudah pembersihan, mengubah isi file menjadi pasangan ID sekuens, membandingkan isi sekuens untuk setiap ID yang sama antara file final dan clean, serta menghitung statistik panjang sekuens (jumlah sekuens, panjang minimum, maksimum, dan rata-rata) pada kedua kondisi. Pada Bab ini hanya disajikan ringkasan hasil dan interpretasinya, sedangkan rincian implementasi skrip (struktur fungsi dan potongan kode) dijelaskan pada Bab V (Implementasi), sehingga Bab III tetap berfokus pada alur analisis data dan hasil utama.

Tabel 3. 8 Hasil Analisis Output Pembersihan Sekuens Protein

Genom	File	Total	ID	ID sama	Min	Max	Rata-
-------	------	-------	----	---------	-----	-----	-------

		ID	sama di final dan clean	tapi sekuens berbeda	(aa)	(aa)	rata (aa)
PR25	Final	52209	52209	(acuan)	1	6122	393,33
	Clean	52209	52209	6071	1	5883	392,05
RD23	Final	49849	49849	(acuan)	1	5499	406,43
	Clean	49849	49849	2706	1	5395	405,78
Oryza longistaminata	Final	31686	31686	(acuan)	2	5154	364,48
	Clean	31686	31686	0	2	5154	364,48

Berdasarkan tabel tersebut, dapat dilihat bahwa berkas final pada masing-masing genom digunakan sebagai acuan pembandingan, sehingga kolom “ID sama tapi sekuens berbeda” tidak diisi nilai numerik dan ditandai dengan simbol “– (acuan)”. Artinya, file final berfungsi sebagai patokan ketika menilai berapa banyak sekuens yang berubah pada file clean, sehingga hanya baris clean yang melaporkan jumlah ID dengan sekuens yang berbeda dibanding acuan tersebut.

Pada PR25, jumlah ID protein tetap 52.209 sebelum dan sesudah pembersihan, tetapi terdapat 6.071 ID pada berkas clean yang sekuensnya berbeda dibanding berkas final sebagai acuan. Panjang maksimum sekuens sedikit berkurang (dari 6.122 aa menjadi 5.883 aa), dan rata-rata panjang sekuens menurun tipis dari 393,33 aa menjadi 392,05 aa. Hal ini menunjukkan bahwa pembersihan terutama memengaruhi subset sekuens yang panjang atau mengandung karakter tidak standar, tanpa mengurangi jumlah ID protein yang dianalisis sehingga cakupan proteome PR25 tetap terjaga.

Pada RD23, pola serupa terlihat: total ID tetap 49.849, dengan 2.706 ID pada berkas clean yang sekuensnya berbeda dibanding berkas final sebagai acuan. Panjang maksimum berkurang dari 5.499 aa menjadi 5.395 aa, dan rata-rata panjang sekuens turun sedikit dari 406,43 aa menjadi 405,78 aa. Perubahan kecil ini konsisten dengan proses normalisasi ringan yang menghapus karakter non-IUPAC atau

bagian sekuens yang tidak valid, tanpa mengubah gambaran global proteome RD23.

Pada *Oryza longistaminata*, tidak ditemukan perbedaan sekuens antara file final dan clean: jumlah ID, panjang minimum, maksimum, dan rata-rata identik, dan kolom “ID sama tapi sekuens berbeda” pada baris clean bernilai 0. Hal ini menunjukkan bahwa dataset protein publik *O. longistaminata* yang digunakan sudah memenuhi kriteria dasar yang diterapkan dalam proses pembersihan, sehingga tahap ini berfungsi terutama sebagai verifikasi bahwa proteome publik tersebut siap digunakan sebagai referensi dalam analisis komparatif.

Proteome yang telah dibersihkan (.clean.fa) kemudian digunakan sebagai input untuk analisis orthologi dan anotasi fungsi pada tahap berikutnya. Inferensi ortholog dalam penelitian ini dilakukan dengan OrthoFinder, yang kinerjanya dievaluasi terhadap benchmark orthogroup terkurasi dalam studi [59]. Studi tersebut menunjukkan bahwa pendekatan orthogroup berbasis pohon gen yang digunakan OrthoFinder mampu mencapai akurasi tinggi ketika proteome input terdefinisi dengan baik [59].

Selain itu, anotasi fungsi gen berbasis orthology dilakukan menggunakan eggNOG-mapper v2, yaitu alat anotasi fungsional yang memanfaatkan kelompok ortholog dalam basis data eggNOG v5 untuk memberikan anotasi GO, KO, domain, dan kategori fungsi lainnya pada skala genom dan metagenom. Dalam jurnal [64], menjelaskan bahwa eggNOG-mapper v2 dirancang untuk menganotasi data genom dan metagenomik besar dengan cepat berdasarkan informasi *orthology* yang telah dipra-hitung, sehingga kualitas dan konsistensi sekuens protein input menjadi faktor penting bagi keandalan anotasi fungsi yang dihasilkan [64].

3.2.4 Analisis Orthologi Gen dengan OrthoFinder

Setelah diperoleh himpunan sekuens protein yang sudah dibersihkan untuk ketiga genom (*O. sativa indica* cv. PR25, *O. sativa indica* cv. RD23, dan *Oryza longistaminata*), tahap berikutnya adalah melakukan analisis gen ortologi

menggunakan perangkat lunak OrthoFinder. OrthoFinder digunakan untuk mengelompokkan gen-gen homolog ke dalam orthogroup dan menginferensikan hubungan ortholog dan paralog antar spesies, sehingga sangat relevan untuk menjawab pertanyaan bagaimana gen-gen dari *O. longistaminata* dan RD23 berkontribusi ke genom hibrida PR25.

Dalam penelitian ini, OrthoFinder dijalankan dengan input utama berupa berkas FASTA protein yang sudah melalui proses ekstraksi dan pembersihan:

- D:\result\output_bio\clean_proteins\PR25.clean.fa untuk *O. sativa indica* cv. PR25,
- D:\result\output_bio\clean_proteins\RD23.clean.fa untuk *O. sativa indica* cv. RD23,
- D:\result\output_bio\clean_proteins\OL.clean.fa untuk *Oryza longistaminata*.

Masing-masing berkas merepresentasikan proteome non-redundan dari PR25, RD23, dan *O. longistaminata* dalam bentuk sekuens asam amino. OrthoFinder kemudian melakukan serangkaian langkah analisis internal, yang secara konseptual dapat diringkas sebagai berikut:

1. Pencarian kesamaan sekuens (*all-vs-all sequence search*)

Seluruh protein dari ketiga spesies dipasangkan satu sama lain dan dibandingkan menggunakan algoritma pencarian kesamaan (sequence similarity search) berkecepatan tinggi (misalnya DIAMOND). Tahap ini menghasilkan matriks kesamaan yang merepresentasikan tingkat kemiripan setiap pasangan protein.

2. Pengelompokan ke dalam orthogroup

Berdasarkan pola kesamaan sekuens, OrthoFinder mengelompokkan protein ke dalam orthogroup, yaitu himpunan gen dari beberapa genom yang berasal dari satu gen leluhur yang sama. Orthogroup ini menjadi unit dasar untuk membandingkan komposisi genetik di antara PR25, RD23, dan *O. longistaminata*.

3. Inferensi pohon spesies dan pohon gen

Untuk setiap orthogroup, OrthoFinder menyusun multiple sequence alignment dan menginferensikan pohon gen (*gene tree*). Pohon-pohon gen tersebut kemudian digunakan bersama untuk merekonstruksi pohon spesies (*species tree*) dan membedakan peristiwa spesiasi (membentuk ortholog) dari duplikasi gen (membentuk paralog).

4. Penentuan relasi ortholog–paralog

Dengan memetakan pohon gen ke pohon spesies, OrthoFinder mengklasifikasikan setiap pasangan gen antargenome sebagai *one-to-one ortholog*, *one-to-many ortholog*, atau paralog, serta mengidentifikasi ekspansi atau kontraksi famili gen tertentu.

5. Output OrthoFinder yang paling penting untuk penelitian ini meliputi:

- Orthogroups.tsv – tabel yang memetakan setiap gen ke orthogroup tertentu dari PR25, RD23, dan *O. longistaminata*.
- Orthogroups.GeneCount.tsv – matriks jumlah gen per orthogroup per spesies yang berguna untuk melihat ekspansi/kontraksi famili gen.
- Berkas di folder Orthologues/ – daftar pasangan ortholog spesifik antar pasangan spesies (misalnya PR25–RD23, PR25–OL).
- Species_Tree_rooted.txt dan berkas di folder Gene_Trees/ – pohon spesies dan pohon gen yang menggambarkan hubungan kekerabatan antar genom.

Adapun hasil-hasil tersebut akan digunakan untuk:

- Mengidentifikasi gen PR25 yang memiliki ortholog hanya pada RD23, hanya pada *O. longistaminata*, atau pada keduanya.
- Menafsirkan kontribusi relatif masing-masing tetua terhadap komposisi genetik PR25 melalui pola keanggotaan orthogroup dan jumlah gen per orthogroup.
- Menyusun daftar gen kandidat yang berpotensi terkait dengan sifat perennial atau ketahanan yang diwariskan dari tetua liar *O. longistaminata*.

Pada subbab ini, OrthoFinder dijelaskan dari sisi alur analisis data, yaitu jenis input yang digunakan (proteome bersih PR25, RD23, dan *O. longistaminata*), tahapan umum pemrosesan (pencarian kemiripan, pembentukan orthogroup, rekonstruksi

pohon), serta jenis output yang dihasilkan.

3.2.5 Analisis Fungsi dan Domain Protein dengan EggNOG-mapper dan InterProScan

Setelah hubungan orthologi gen antar PR25, RD23, dan *O. longistaminata* diidentifikasi dengan OrthoFinder, tahap berikutnya adalah menganotasi fungsi dan domain protein agar setiap gen tidak hanya diketahui posisinya dalam orthogroup, tetapi juga diikuti dengan informasi biologis seperti kategori fungsi, lintasan metabolik, dan motif/domain struktur. Pada penelitian ini, dua jenis alat anotasi digunakan secara komplementer, yaitu eggNOG-mapper dan InterProScan.

Untuk itu digunakan dua jenis pendekatan anotasi fungsi berbasis ortologi dengan EggNOG-mapper dan anotasi motif/domain protein dengan InterProScan. Kedua pendekatan ini saling melengkapi: eggNOG-mapper memberikan konteks fungsional dan pathway (misalnya GO, KEGG, COG), sedangkan InterProScan memetakan domain dan motif konservatif yang sering terkait langsung dengan fungsi biokimia protein.

3.2.5.1 Anotasi Fungsi Gen dengan EggNOG-mapper

EggNOG-mapper digunakan untuk melakukan anotasi fungsi berdasarkan orthologi yang tersimpan dalam basis data EggNOG. Pendekatan ini memanfaatkan fakta bahwa gen yang merupakan ortholog cenderung mempertahankan fungsi yang serupa, sehingga fungsi dapat “diturunkan” dari gen referensi yang sudah teranotasi dengan baik ke gen-gen pada genom yang baru dianalisis.

Dalam penelitian ini, EggNOG-mapper dijalankan menggunakan input utama berupa berkas protein yang telah dibersihkan:

- PR25.clean.fa
- RD23.clean.fa
- OL.clean.fa

Untuk setiap sekuens protein, EggNOG-mapper secara konseptual melakukan:

1. Pencarian ortholog dalam basis data EggNOG

Protein kueri dicocokkan terhadap basis data klaster ortholog EggNOG menggunakan pencarian sekuens berkecepatan tinggi. Setiap protein ditempatkan ke dalam satu atau beberapa kelompok ortholog (NOG/COG).

2. Transfer anotasi fungsi

Berdasarkan *ortholog* yang ditemukan, EggNOG-mapper mentransfer berbagai jenis anotasi ke protein kueri, antara lain:

- Kategori fungsional *COG* (*Clusters of Orthologous Groups*), yaitu kelompok protein ortholog dari berbagai spesies yang berasal dari satu gen leluhur yang sama dan umumnya memiliki fungsi biologis yang serupa (fungsi umum seperti “signal transduction”, “transcription”, “defense mechanisms”)
- Istilah *Gene Ontology* (*GO*) untuk aspek biological process, molecular function, dan cellular component
- Anotasi KEGG pathway dan Enzyme Commission (EC) jika tersedia
- Informasi deskripsi fungsi tingkat tinggi (misalnya “kinase”, “transcription factor”, dan sebagainya).

3. Penyusunan tabel anotasi per protein

Output utama yang dihasilkan berupa tabel (misalnya dalam format TSV) yang berisi satu baris per protein, lengkap dengan ID protein dan seluruh anotasi fungsi yang berhasil dipetakan. Tabel-tabel ini kemudian akan diintegrasikan dengan hasil OrthoFinder pada bab selanjutnya untuk:

- Mengelompokkan gen PR25 turunan RD23 dan *O. longistaminata* ke dalam kategori fungsi utama
- Mengidentifikasi kelompok fungsi yang mungkin terkait dengan sifat agronomis spesifik (misalnya ketahanan stres, metabolisme tertentu, atau regulasi siklus hidup).

3.2.5.2 Analisis Motif/Domain Protein dengan InterProScan

Selain anotasi fungsi berbasis ortologi, dilakukan juga analisis domain dan motif protein menggunakan InterProScan. InterProScan memindai sekuens protein terhadap berbagai basis data domain dan motif konservasi (misalnya Pfam, SMART, SUPERFAMILY, TIGRFAMs, PROSITE, dan lainnya) untuk mengidentifikasi motif struktural dan domain fungsional tertentu.

Dalam penelitian ini, InterProScan dijalankan setidaknya pada proteome PR25 yang telah dibersihkan (PR25.clean.fa), dan dapat diperluas ke RD23 dan *O. longistaminata* bila diperlukan untuk perbandingan yang lebih detail. Secara umum, langkah-langkah InterProScan adalah:

1. Pemindaian sekuens terhadap basis data domain

Setiap sekuens protein dianalisis untuk mencari kecocokan dengan model domain (misalnya HMM Pfam) atau motif konservasi lainnya. Hasilnya adalah daftar domain yang ditemukan pada setiap protein, beserta posisi domain pada sekuens (awal–akhir dalam satuan asam amino).

2. Pemetaan fungsi dan GO dari domain

Banyak domain dalam InterPro terhubung dengan anotasi GO dan, dalam beberapa kasus, lintasan biologis tertentu. Dengan demikian, InterProScan tidak hanya menunjukkan domain apa yang terdapat pada protein, tetapi juga memberikan indikasi fungsi molekuler dan proses biologis yang mungkin terkait.

3. Penyusunan output anotasi domain

InterProScan menghasilkan berkas anotasi (misalnya format TSV atau GFF3) yang berisi ID protein, nama dan ID domain (misalnya ID Pfam/InterPro), posisi domain pada sekuens, dan istilah GO atau keterangan fungsi yang terkait.

4. Output InterProScan kemudian akan dipadukan dengan hasil EggNOG-mapper untuk:

- Memvalidasi dan mendapatkan anotasi fungsi yang diperoleh dari pendekatan orthology,
- Mengidentifikasi domain atau motif spesifik yang sering muncul pada gen PR25 yang berasal dari RD23 atau *O. longistaminata*,
- Menyusun ringkasan kategori domain utama yang berkontribusi terhadap sifat-sifat genom PR25.

BAB IV

DESAIN PENELITIAN

Bab ini menjelaskan rancangan alur analisis genom yang digunakan dalam penelitian “*Deciphering Rice Genomes at Chromosome-Scale Resolution*”. Desain penelitian berfokus pada bagaimana serangkaian proses dalam penelitian ini dilakukan dimulai dengan evaluasi kualitas genom dengan BUSCO dan QUAST, data preprocessing dengan liftoff, AGAT, gffread, serta identifikasi gen turunan beserta fungsinya dengan OrthoFinder, EggNOG-mapper, dan InterProScan. Lalu, proses tersebut diintegrasikan secara berurutan untuk:


1. Memastikan kualitas genom PR25, RD23, dan *Oryza longistaminata*
2. Menyusun anotasi gen dan proteome yang konsisten
3. Mengidentifikasi hubungan ortholog–paralog antar genom
4. Mengungkap fungsi serta domain protein dari gen-gen PR25 yang merupakan turunan RD23 dan *O. longistaminata*.

Secara garis besar, pipeline penelitian disusun sebagai rangkaian proses bertahap dari data masukan hingga integrasi keluaran, dengan tahapan utama sebagai berikut.

1. Evaluasi kualitas genom dan kelengkapan konten gen (BUSCO dan QUAST)
2. Anotasi gen pada PR25 dan RD23 berbasis lift over (Liftoff) menggunakan referensi ZS97
3. Standardisasi serta konsolidasi anotasi gen (AGAT) sebagai prasyarat ekstraksi sekuens
4. Ekstraksi sekuens CDS dan protein serta pembentukan proteome bersih (gffread dan pembersihan proteome)
5. Analisis orthology lintas spesies (OrthoFinder) untuk pembentukan orthogroup dan pasangan ortholog
6. Anotasi fungsi dan anotasi domain atau motif protein pada PR25 (eggNOG mapper v2 dan InterProScan).
7. Integrasi keluaran untuk identifikasi asal usul dan interpretasi fungsi gen PR25

4.1 Desain Umum Penelitian

Berikut desain umum penelitian yang dilakukan selama penelitian ini



Gambar 4. 1 Desain Umum Penelitian

Berdasarkan Gambar Desain Umum Penelitian (Bab IV), penelitian ini dirancang sebagai alur analisis bertahap end to end, yaitu rangkaian proses dari data masukan hingga keluaran akhir yang terintegrasi. Fokus analisis mencakup tiga genom padi: PR25 (genom hibrida), RD23 (tetua budi daya), dan *Oryza longistaminata* (tetua liar). Alur ini disusun untuk memastikan bahwa genom yang dianalisis memiliki kualitas memadai, memiliki anotasi gen yang konsisten, dapat dibandingkan melalui analisis *orthology* (*orthology*: hubungan gen yang berasal dari satu gen leluhur yang sama akibat peristiwa spesiasi), serta ditambah dengan anotasi fungsi gen dan domain atau motif protein, sebelum seluruh keluaran digabungkan pada tahap integrasi untuk mendukung interpretasi biologis.

1. Data genom dan data referensi yang digunakan
 - Data genom (FASTA): Data utama penelitian berupa berkas assembly genom dalam format FASTA untuk PR25, RD23, dan *O. longistaminata*. Ketiga genom ini digunakan sebagai basis evaluasi kualitas, pembentukan anotasi

gen, penyusunan proteome, dan analisis komparatif lintas spesies.

- Data referensi dan basis data anotasi: Terdapat data genom dan anotasi referensi ZS97 (FASTA dan GFF3) digunakan sebagai sumber struktur gen untuk proses lift over (lift over: pemetaan atau pemindahan anotasi gen dari genom referensi ke genom target yang berkerabat dekat) dengan Liftoff pada PR25 dan RD23. Lalu, ada BUSCO lineage poales digunakan sebagai acuan marker gene konservatif untuk menilai kelengkapan konten gen pada genom kelompok rumput rumputan (Poaceae). Ketiga, basis data eggNOG digunakan oleh eggNOG mapper v2 yaitu eggNOG 5, untuk menghasilkan anotasi fungsi berbasis penugasan orthology (misalnya GO, KEGG, EC, COG atau OG). Basis data InterPro digunakan oleh InterProScan untuk identifikasi domain, motif, dan keluarga protein, serta pemetaan Gene Ontology melalui InterPro2GO (InterPro2GO: tabel pemetaan kurasi manual yang menghubungkan entri InterPro dengan istilah GO).
- 2. Tahap evaluasi kualitas genom ditempatkan pada awal alur karena kualitas assembly menentukan reliabilitas anotasi gen dan analisis komparatif berikutnya. Evaluasi dilakukan melalui dua pendekatan yang saling melengkapi.
- Evaluasi kelengkapan konten gen pada perakitan genom dengan BUSCO
BUSCO digunakan pada *genome mode* (*genome mode*: evaluasi langsung pada sekuens genom) dengan lineage Poales. Pada versi terbaru BUSCO [32], identifikasi gen BUSCO pada genom eukariot dilakukan melalui gene mapping menggunakan Miniprot (*gene mapping*: pemetaan kandidat gen berdasarkan kesesuaian terhadap sekuens acuan), kemudian kandidat yang ditemukan divalidasi menggunakan profile HMM melalui HMMER (profile HMM: model statistik konservasi domain protein untuk mendeteksi anggota keluarga gen). Keluaran utama BUSCO berbentuk *status Complete (single copy atau duplicated)*, *Fragmented*, dan *Missing*, yang menjadi indikator kelengkapan konten gen.
- Evaluasi kualitas struktur assembly tanpa referensi dengan QUAST (reference free)
QUAST digunakan untuk mengevaluasi kualitas struktur assembly pada

mode *reference free* (*reference free*: evaluasi tanpa genom rujukan), dengan menghitung metrik kontiguitas dan statistik dasar seperti jumlah kontig, total panjang, persentase GC, N50, N90, L50, L90, serta ringkasan Nx. Tahap ini melengkapi BUSCO karena BUSCO berfokus pada kelengkapan konten gen, sedangkan QUAST berfokus pada kualitas struktur assembly [87].

3. Setelah genom dinyatakan layak berdasarkan evaluasi kualitas, tahap berikutnya adalah pembentukan anotasi gen yang konsisten.
 - Anotasi gen melalui lift over menggunakan Liftoff: Liftoff memetakan anotasi gen dari genom referensi ZS97 ke genom target PR25 dan RD23. Prinsip pemetaan Liftoff adalah mencari pemetaan yang memaksimalkan identitas sekuens sambil mempertahankan struktur fitur (misalnya exon, transkrip, dan gen). Keluaran tahap ini adalah berkas anotasi GFF3 hasil lift over pada PR25 dan RD23.
 - Standardisasi dan konsolidasi format anotasi menggunakan AGAT: AGAT digunakan untuk memastikan berkas anotasi memiliki struktur dan atribut yang konsisten, termasuk pemeriksaan dan perbaikan informasi fitur serta penyeragaman menjadi format GFF3 terstandar. Tahap ini penting karena interoperabilitas antarperangkat lunak anotasi bergantung pada konsistensi struktur feature hierarchy (gene–mRNA–CDS–UTR) dan kelengkapan atribut.
4. Ekstraksi CDS, protein, dan pembentukan proteome bersih bertujuan menghasilkan sekuens biologis (CDS dan protein) yang diperlukan untuk analisis orthology serta anotasi fungsi dan domain.
 - Ekstraksi CDS dan protein menggunakan gffread: gffread digunakan untuk mengekstraksi CDS (coding DNA sequence: gabungan segmen pengkode protein) berdasarkan koordinat pada GFF3 dan sekuens genom FASTA, lalu menerjemahkan CDS menjadi sekuens protein. Keluaran utama tahap ini adalah FASTA CDS dan FASTA protein.
 - Pembersihan proteome (*proteome cleaning*): Proteome hasil ekstraksi disaring untuk memastikan validitas sekuens, misalnya memastikan karakter asam amino valid, menghindari residu ambigu, serta meminimalkan sekuens yang berpotensi artefaktual (contohnya sekuens sangat pendek yang tidak

- informatif). Keluaran tahap ini adalah proteome bersih untuk PR25, RD23, dan *O. longistaminata* yang siap digunakan oleh perangkat lunak komparatif.
5. Setelah proteome bersih tersedia, analisis dilanjutkan ke komparatif lintas spesies dan anotasi biologis utama pada PR25.
- Analisis orthology lintas spesies menggunakan OrthoFinder
OrthoFinder menggunakan proteome multi spesies (PR25, RD23, dan *O. longistaminata*) untuk membentuk orthogroup (*orthogroup*: kelompok gen homolog yang diturunkan dari satu gen leluhur pada leluhur terakhir bersama) dan menginferensi ortholog (*ortholog*: pasangan gen antarspesies yang berasal dari spesiasi), serta dapat menghasilkan gene tree dan species tree jika diperlukan untuk interpretasi filogenetik. Keluaran ini digunakan sebagai dasar penelusuran hubungan gen PR25 terhadap tetua RD23 dan *O. longistaminata*. Dokumentasi resmi OrthoFinder dalam paper [58], menjelaskan keluaran inti tersebut, dan penerapan konsep orthogroup dan orthology pada OrthoFinder dalam konteks analisis genom skala besar juga didukung oleh publikasi jurnal [88] yang membahas pemanfaatan orthogroup pada pipeline filogenomik [88].
 - Anotasi fungsi gen menggunakan eggNOG mapper v2
eggNOG mapper v2 digunakan untuk memberi anotasi fungsi berbasis orthology pada protein PR25. Keluaran tahap ini meliputi label fungsi seperti *GO* (*Gene Ontology*: kosakata terstandar untuk fungsi, proses biologis, dan lokasi seluler), *KEGG* (*Kyoto Encyclopedia of Genes and Genomes*: anotasi jalur dan sistem biologis), *EC* (*Enzyme Commission*: klasifikasi enzim), dan kategori COG atau *OG* (*Cluster of Orthologous Groups* dan *Orthologous Groups*: pengelompokan gen berdasarkan *orthology*) [64].
 - Anotasi domain, motif, keluarga protein, dan pemetaan GO menggunakan InterProScan
InterProScan digunakan untuk menelusuri protein PR25 terhadap signature dari berbagai basis data anggota InterPro guna mengidentifikasi domain (domain: unit struktural atau fungsional protein), motif (motif: pola konservatif yang sering terkait fungsi tertentu), serta keluarga protein. Hasil InterProScan dipetakan ke GO melalui InterPro2GO untuk menambahkan

interpretasi fungsi berbasis domain atau keluarga protein [70].

6. Tahap akhir adalah integrasi seluruh keluaran menjadi dataset analitis terpadu. Integrasi mencakup: hasil evaluasi kualitas genom (BUSCO dan QUAST), anotasi gen terstandar (Liftoff dan AGAT), sekuens CDS dan proteome bersih (gffread dan pembersihan proteome), relasi orthogroup dan ortholog (OrthoFinder), serta anotasi fungsi dan domain (eggNOG mapper v2 dan InterProScan). Integrasi ini menjadi dasar penyusunan tabel, ringkasan, dan interpretasi yang menghubungkan asal-usul gen PR25 dalam konteks relasinya terhadap RD23 dan *O. longistaminata*, sekaligus mengaitkannya dengan fungsi biologis dan karakteristik domain atau motif protein.

4.2 Desain Evaluasi Kualitas Genom


Berikut desain evaluasi kualitas genom dengan menggunakan BUSCO dan QUAST dalam subbab ini.

4.2.1 Desain Evaluasi Kelengkapan Konten Gen pada Perakitan Genom

Tahap ini bertujuan mengevaluasi kelengkapan konten gen atau kelengkapan ruang gen (gene space completeness) pada rakitan genom PR25, RD23, dan *Oryza longistaminata*. Berdasarkan paper [32], BUSCO menilai kelengkapan dengan memanfaatkan harapan berbasis evolusi terhadap komposisi gen yang seharusnya ada pada suatu kelompok taksonomi melalui gen penanda universal single copy ortholog, sehingga menghasilkan ukuran kelengkapan berbasis biologis yang melengkapi metrik struktur rakitan seperti N50 yang tidak secara langsung merepresentasikan kelengkapan gen [32].

Hasil BUSCO pada tahap ini digunakan sebagai tahap kendali mutu berbasis biologis, untuk memastikan bahwa rakitan genom yang dianalisis memiliki cakupan gen inti yang memadai sebelum digunakan pada tahapan analisis berikutnya, seperti

harmonisasi anotasi, inferensi orthologi, dan anotasi fungsi.



Gambar 4. 2 Desain Evaluasi Kelengkapan Genom BUSCO

Berikut penjelasan setiap blok pada Gambar 4.2 Diagram alur evaluasi kelengkapan konten gen (BUSCO mode *genome*):

- Input data genom (FASTA).
Input adalah berkas rakitan genom dalam format FASTA untuk masing masing genom yang dievaluasi.
- Penetapan konfigurasi BUSCO (mode *genome* dan *lineage*).
Konfigurasi utama mencakup: mode *genome* karena input berupa rakitan genom, dan pemilihan *lineage dataset* yang relevan secara taksonomi, misalnya *Poales (poales_odb10)*, agar marker BUSCO yang diperiksa sesuai dengan kelompok organisme yang dikaji.
- Pencarian kandidat marker pada genom melalui pemetaan gen (subblok Miniprot).
Pada penilaian rakitan genom eukariota, BUSCO menggunakan Miniprot sebagai pemetaan gen (*gene mapper*) bawaan. Miniprot memetakan *protein marker* BUSCO yang disediakan oleh lineage dataset ke sekuens genom untuk menghasilkan kandidat lokus marker pada rakitan genom. Rincian algoritmik Miniprot tidak menjadi fokus Bab 4 ini karena Miniprot

merupakan komponen internal pada *workflow BUSCO mode genome*.


- Validasi kandidat berbasis profil HMM marker BUSCO (HMMER).
Kandidat lokus yang diperoleh kemudian divalidasi menggunakan profil Hidden Markov Model (HMM) dari dataset BUSCO melalui komponen HMMER, sehingga hanya kandidat yang memenuhi kriteria kecocokan terhadap profil konservasi marker yang diakui sebagai marker terdeteksi.
- Klasifikasi status marker BUSCO.
Berdasarkan hasil validasi, BUSCO mengklasifikasikan setiap marker ke kategori standar: Complete (Single copy), Complete (Duplicated), Fragmented, atau Missing.
- Output
Output ringkasan yang dicatat dari eksekusi BUSCO pada penelitian ini adalah berkas `short_summary.(nama file).txt` yang memuat ringkasan kategori C, S, D, F, M (*Complete, Single copy, Duplicated, Fragmented, Missing*). Ringkasan ini digunakan sebagai indikator utama untuk menilai kelengkapan ruang gen pada rakitan genom yang dievaluasi. Adapun output detail yang dicatat adalah `full_table.tsv`, yaitu tabel lengkap status setiap marker BUSCO beserta informasi pendukungnya. Tabel ini digunakan sebagai bahan penelusuran apabila diperlukan verifikasi hasil ringkasan. Secara umum, BUSCO juga dapat menghasilkan keluaran lain seperti ringkasan dalam format JSON, daftar marker hilang, serta keluaran tabular HMMER. Namun pada eksekusi menggunakan DCS cloud, keluaran yang dicatat dan digunakan pada penelitian ini dibatasi pada berkas ringkasan teks dan tabel hasil tersebut. Ringkasan BUSCO dimanfaatkan untuk menyatakan bahwa rakitan genom yang dianalisis cukup lengkap pada tingkat konten gen, sehingga layak digunakan sebagai dasar tahap analisis berikutnya dalam pipeline penelitian.

4.2.2 Desain Evaluasi Struktur Perakitan Genom

Evaluasi struktur rakitan genom dilakukan dengan QUAST untuk memperoleh ringkasan kualitas struktur rakitan dari genom PR25, RD23, dan *Oryza longistaminata* sebelum digunakan pada tahapan analisis lanjutan. Pada mode tanpa

genom rujukan, QUAST menghasilkan ukuran struktur yang dapat dihitung langsung dari kontig, seperti jumlah kontig, panjang total rakitan, kontig terpanjang, persentase GC, jumlah basa N, serta ukuran kontiguitas N50 dan L50, disertai grafik ringkasan.

Dalam penelitian ini, keluaran QUAST digunakan sebagai pemeriksaan kelayakan struktur rakitan. Ringkasan metrik QUAST digunakan untuk mendukung keputusan bahwa rakitan genom memadai untuk dipakai sebagai masukan pada tahap berikutnya, yaitu alih anotasi gen, ekstraksi sekuens CDS dan protein, analisis orthologi, serta anotasi fungsi dan domain. Penggunaan QUAST untuk pelaporan metrik struktur rakitan seperti N50 dan L50 sebagai evaluasi awal kualitas rakitan juga dilaporkan pada jurnal [89].



Gambar 4. 3 Desain Evaluasi Struktur Assembly Genom dengan QUAST

Gambar 4.3 Diagram alur evaluasi struktur rakitan genom (mode tanpa genom rujukan)

Berikut penjelasan untuk alur evaluasi struktur rakitan genom:

- **Input rakitan genom**
Input berupa berkas FASTA rakitan genom yang berisi kumpulan kontig. Pada mode tanpa genom rujukan, QUAST menghitung metrik struktur langsung dari kontig tersebut tanpa melakukan penyelarasan ke genom referensi.
- **Eksekusi QUAST tanpa genom rujukan**
Adapun eksekusi QUAST ini dilakukan dalam sistem dari BGI, yaitu DCS Cloud. Karena perintah tidak menyertakan opsi `-r`, QUAST tidak menjalankan modul evaluasi yang memerlukan genom rujukan (misalnya penilaian berbasis kesalahan penempatan segmen terhadap referensi). Sebagai gantinya, QUAST memusatkan evaluasi pada statistik kontig dan

ukuran kontiguitas yang dapat dihitung tanpa referensi.

- **Ketentuan bawaan tentang panjang kontig untuk perhitungan metrik**
Karena tidak ada opsi `--min-contig` pada skrip di DCS Cloud, QUAST memakai nilai bawaan. Dalam keluaran QUAST, sebagian besar metrik ringkasan dihitung menggunakan kontig minimal 500 pasangan basa, sementara beberapa baris yang diberi label “ ≥ 0 bp” menghitung semua kontig. Inilah alasan laporan menampilkan beberapa baris ambang panjang kontig.
- **Perhitungan statistik dasar struktur rakitan**
QUAST menghitung ukuran struktur dasar, yaitu jumlah kontig, panjang total rakitan, panjang kontig terpanjang, persentase GC, dan jumlah basa N (serta pada laporan tertentu, kepadatan basa N per 100 kilo pasangan basa). Ukuran ini dipakai untuk membandingkan tingkat keterfragmentasian rakitan dan ringkasan komposisi antar genom yang dianalisis.
- **Perhitungan ukuran kontiguitas dan pembuatan grafik ringkasan**
QUAST menghitung N50 dan L50, lalu menghitung kumpulan nilai Nx (misalnya N10 sampai N90) yang kemudian ditampilkan sebagai Nx plot. Selain itu QUAST membuat kurva panjang kumulatif dan grafik kandungan GC sebagai ringkasan visual struktur rakitan. Hal ini selaras dengan komponen laporan QUAST yang umum (Nx plot, cumulative plot, dan GC plot) dan juga dengan deskripsi komponen Icarus serta contig size viewer.
- **Penyusunan keluaran laporan**
Setelah perhitungan selesai, QUAST menulis laporan dalam beberapa format sehingga tabel metrik dan grafik dapat digunakan dalam pelaporan hasil penelitian.
- **Output**
Keluaran yang digunakan sebagai sumber data untuk menyusun tabel hasil dan ringkasan pelaporan adalah report.txt (ringkasan metrik utama dalam teks), report.tsv (ringkasan metrik dalam tabel), report.pdf dan report.html (laporan ringkas berisi tabel dan grafik), Nx_plot.pdf (grafik Nx berdasarkan kumpulan nilai Nx), cumulative_plot.pdf (grafik panjang kumulatif berdasarkan urutan kontig dari terpanjang ke terpendek),

GC_content_plot.pdf dan variasinya (misalnya RD23.FINAL_GC_content_plot.pdf), contig_size_viewer.html (visualisasi interaktif ukuran kontig), icarus.html (halaman akses visualisasi interaktif Icarus, bila dihasilkan), quast.log (catatan eksekusi untuk verifikasi proses), Fungsi Icarus dan contig size viewer sebagai komponen visualisasi QUAST dijelaskan pada dokumentasi QUAST.

Dalam penelitian ini, output QUAST dimanfaatkan untuk:

- Menyusun tabel hasil evaluasi struktur rakitan (misalnya jumlah kontig, panjang total, kontig terpanjang, persentase GC, jumlah basa N, N50, dan L50) untuk PR25, RD23, dan *O. longistaminata*.
- Memberikan dasar bahwa struktur rakitan genom memadai untuk digunakan pada tahapan analisis berikutnya, sehingga evaluasi struktur (QUAST) melengkapi evaluasi kelengkapan konten gen (BUSCO). Contoh penggunaan QUAST v5.2.0 untuk menilai rakitan sebelum analisis lanjutan juga terlihat pada artikel rakitan genom skala kromosom terbaru.

4.3 Desain *Preprocessing* dan Anotasi Gen


Tahap ini mencakup anotasi gen PR25 dan RD23 melalui lift-over dari genom referensi ZS97 (Liftoff), ekstraksi CDS & protein (gffread), dan pembersihan sekuens protein.

4.3.1 Desain Anotasi Gen dengan Liftoff

Proses alih anotasi gen dilakukan untuk memperoleh anotasi gen pada genom *Oryza sativa* ssp. *indica* cv. PR25 dan *Oryza sativa* ssp. *indica* cv. RD23 dengan cara memindahkan (*lift over*) anotasi gen dari genom referensi yang telah memiliki anotasi matang, yaitu *Oryza sativa* ssp. *indica* cv. ZS97, ke genom target yang dianalisis. Proses ini diperlukan agar PR25 dan RD23 memiliki anotasi gen yang konsisten dan sebanding, sehingga dapat digunakan sebagai dasar pada tahap berikutnya, yaitu ekstraksi sekuens CDS dan protein, inferensi orthologi, serta anotasi fungsi dan domain.

Secara prinsip, perangkat lunak Liftoff digunakan untuk memetakan anotasi gen

dari genom referensi ke genom target yang masih satu spesies atau berkerabat dekat dengan mempertahankan struktur fitur gen (hubungan gen, transkrip, ekson, dan CDS) sejauh memungkinkan, sambil mengutamakan kesesuaian sekuens antara referensi dan target.



Gambar 4. 4 Desain Anotasi Gen dengan Liftoff

Berikut penjelasan dari Gambar Diagram alur alih anotasi gen (Liftoff)

- Input data referensi dan target.
Data referensi terdiri dari berkas FASTA genom ZS97 dan berkas anotasi ZS97 dalam format GFF3 yang memuat fitur gen beserta relasi antar fitur (gen, transkrip, ekson, CDS). Data target terdiri dari FASTA genom PR25 dan FASTA genom RD23. Pada tahap ini, seluruh berkas disiapkan sebagai masukan proses alih anotasi.
- Pembacaan dan rekonstruksi struktur anotasi referensi.
Liftoff membaca anotasi ZS97 dan menyusun struktur hierarkinya, sehingga setiap gen pada referensi dipahami sebagai satu unit fitur yang terhubung dengan satu atau lebih transkrip, serta fitur ekson dan CDS yang menyusunnya. Struktur ini menjadi acuan saat mencari lokasi padanan di genom target.
- Penyelarasan anotasi referensi ke genom target untuk memperoleh kandidat pemetaan.
Untuk setiap gen referensi, Liftoff melakukan penyelarasan terhadap genom target untuk menemukan lokasi kandidat yang paling sesuai. Tahap ini bertujuan memperoleh koordinat kandidat pada PR25 dan RD23 yang berpotensi merepresentasikan fitur gen yang sama atau sangat mirip dengan

referensi.

- Evaluasi kualitas pemetaan dan seleksi hasil yang valid.
Kandidat pemetaan kemudian dievaluasi agar hanya pemetaan yang berkualitas memadai yang dicatat sebagai anotasi pada genom target. Evaluasi dilakukan dengan mempertimbangkan kesesuaian sekuens dan kelengkapan pemetaan, serta konsistensi struktur fitur gen (misalnya keterjagaan susunan fitur ekson dan CDS). Kandidat yang tidak memenuhi kriteria kualitas tidak dimasukkan ke anotasi akhir.
- Penanganan gen duplikat dan gen yang tidak terpetakan.
Jika suatu gen referensi memiliki lebih dari satu lokasi pemetaan yang valid pada genom target, kondisi tersebut dapat tercatat sebagai pemetaan lebih dari satu salinan. Sebaliknya, jika gen referensi tidak memperoleh pemetaan yang memenuhi kriteria kualitas, gen tersebut tercatat sebagai tidak terpetakan. Informasi ini penting untuk menjelaskan cakupan keberhasilan alih anotasi terhadap genom target.
- Penyusunan berkas anotasi hasil alih anotasi.
Hasil akhir proses ini adalah berkas anotasi baru (format GFF3) untuk PR25 dan RD23 yang berisi fitur gen beserta fitur turunannya (transkrip, ekson, CDS) dengan koordinat yang telah disesuaikan ke genom target. Berkas anotasi ini menjadi dasar operasional untuk tahap berikutnya dalam pipeline penelitian.
- Output
Keluaran utama dari proses alih anotasi adalah berkas GFF3 anotasi PR25 hasil alih anotasi (digunakan sebagai anotasi operasional PR25) dan berkas GFF3 anotasi RD23 hasil alih anotasi (digunakan sebagai anotasi operasional RD23). Selain berkas anotasi utama, Liftoff menyediakan informasi pendukung yang merekam gen yang berhasil dipetakan, gen yang terpetakan lebih dari satu lokasi, serta gen yang tidak terpetakan, sehingga capaian alih

anotasi dapat dilaporkan sebagai bagian dari kendali mutu tahap anotasi.

Berkas GFF3 hasil alih anotasi dipakai sebagai fondasi untuk:

- Ekstraksi sekuens CDS dan protein.
- Penyusunan masukan yang konsisten untuk inferensi orthologi.
- Penyelarasan interpretasi anotasi fungsi dan domain pada tahap anotasi fungsi berikutnya.


Dengan demikian, proses alih anotasi memastikan bahwa analisis turunan yang dilakukan pada PR25 dan RD23 bertumpu pada anotasi gen yang seragam dan dapat dibandingkan.

4.3.2 Desain Standarisasi dan Penggabungan Anotasi Gen dengan AGAT

Another GTF/GFF Analysis Toolkit (AGAT) adalah seperangkat tool baris perintah yang dirancang untuk menangani berbagai varian format GTF dan GFF, serta melakukan hampir semua operasi umum pada anotasi genom: standarisasi, perbaikan sintaks, penggabungan anotasi, filtrasi, hingga ekstraksi sekuens FASTA. Dokumentasi resmi AGAT bernama NBISweden/AGAT: AGAT v1.5.1 menjelaskan bahwa skrip utama `agat_convert_sp_gxf2gxf.pl` mampu check, fix, pad missing information pada fitur dan atribut (misalnya menambahkan fitur gene/mRNA yang hilang, menambah atribut ID dan Parent, memperbaiki lokasi fitur, menghapus duplikasi, dan mengurutkan fitur) sehingga menghasilkan berkas GFF3 yang lengkap, teratur, dan terstandar. Paket ini didistribusikan melalui Bioconda dan berbagai lingkungan komputasi sebagai “Another Gff Analysis Toolkit (AGAT), suite of tools to handle gene annotations in any GTF/GFF format”, dan telah digunakan luas dalam pipeline anotasi genom modern untuk menyelesaikan masalah interoperabilitas format dan menggabungkan anotasi dari berbagai sumber [44].

Dalam penelitian ini, AGAT digunakan sebagai tahap standarisasi dan penggabungan anotasi setelah Liftoff dan sebelum ekstraksi CDS/protein dengan `gffread`. Untuk PR25, Liftoff menghasilkan file `PR25.from_ZS97.gff3` yang berisi backbone anotasi berbasis ZS97. Di sisi lain, terdapat kumpulan anotasi gen unik dari *Oryza longistaminata* yang perlu digabungkan ke dalam genom PR25. AGAT

memanfaatkan parser internalnya untuk membaca kedua berkas anotasi tersebut, memperbaiki atribut yang hilang atau tidak konsisten, menggabungkannya menjadi PR25.add_OL.gff3, akhirnya PR25.final_ZS97_backbone_plus_OLunique.gff3 yang sudah terstandar. Untuk RD23, AGAT digunakan terutama untuk memastikan bahwa berkas RD23.from_ZS97.gff3 memenuhi standar GFF3 (ID unik, hierarki gene–mRNA–CDS konsisten, dan fitur terurut) sehingga aman digunakan oleh gffread. Dengan demikian, AGAT berperan sebagai jembatan teknis yang menjamin bahwa anotasi hasil Liftoff dan gen unik OL dapat digabung dan digunakan secara konsisten pada tahap ekstraksi proteome, analisis orthologi, dan anotasi fungsi.



Gambar 4. 5 Desain Standarisasi dan Penggabungan Anotasi dengan AGAT

Gambar 4.5 memperlihatkan posisi AGAT dalam alur desain penelitian. Tahap pertama (kotak paling kiri) adalah pengumpulan berkas anotasi hasil liftover Liftoff (PR25.from_ZS97.gff3 dan RD23.from_ZS97.gff3) serta anotasi gen unik yang berasal dari *Oryza longistaminata*. Berkas-berkas ini memiliki struktur GFF3 yang bisa berbeda-beda dan berpotensi mengandung atribut yang tidak lengkap, duplikasi ID, maupun ketidakkonsistenan dalam hierarki fitur (gene–mRNA–CDS–UTR), seperti yang umum terjadi pada berbagai “flavour” GTF/GFF [44]. Pada tahap kedua dan ketiga, AGAT digunakan untuk menstandarkan dan menggabungkan anotasi tersebut. Skrip `agat_convert_sp_gxf2gxf.pl` menerapkan fungsi `check–fix–pad` untuk mengubah berbagai variasi GTF/GFF menjadi GFF3 yang lengkap dan terurut, dengan menambahkan fitur atau atribut yang hilang, menghapus duplikasi, serta mengoreksi posisi fitur.

Selanjutnya, `agat_sp_merge_annotations.pl` menggabungkan anotasi backbone PR25/RD23 berbasis ZS97 dengan anotasi gen unik *O. longistaminata* ke dalam satu berkas, sambil menangani ID yang sama dan fitur yang tumpang-tindih. Script


ini menggunakan parser AGAT yang dirancang khusus untuk mengatasi “keanehan” pada berkas anotasi dan memastikan konsistensi hasil gabungan.

Tahap keempat dan kelima menghasilkan anotasi final yang siap digunakan oleh gffread. Setelah pemolesan akhir (misalnya dengan skrip AGAT tambahan untuk memperbaiki gen tumpang tindih atau memfilter model yang tidak diinginkan), diperoleh berkas PR25.final_ZS97_backbone_plus_OLunique.gff3 sebagai anotasi lengkap PR25 yang memuat baik gen inti indica maupun gen unik *O. longistaminata*, serta berkas RD23.from_ZS97.gff3 yang telah distandarisasi. Anotasi inilah yang kemudian menjadi dasar ekstraksi CDS dan protein oleh gffread pada tahap “anotasi gen dan pembentukan proteome”, serta menjadi titik awal bagi analisis orthologi dan anotasi fungsi pada langkah-langkah berikutnya. Dengan demikian, AGAT memastikan bahwa seluruh pipeline downstream bekerja pada anotasi yang kompatibel dan terkurasi, sesuai praktik yang dianjurkan dalam studi-studi anotasi genom terkini.

4.3.3 Desain Ekstraksi CDS dan Protein

Setelah anotasi struktur gen pada genom PR25 dan RD23 diperoleh dari tahap sebelumnya (hasil liftover dan standarisasi anotasi), penelitian ini memerlukan tahap yang mengonversi anotasi berbasis koordinat (GFF3) menjadi representasi sekuens dalam format FASTA CDS dan FASTA protein. Tahap ini penting karena analisis lanjutan seperti kurasi proteome, inferensi orthologi, serta anotasi fungsi dan domain protein membutuhkan input berupa sekuens, bukan hanya koordinat anotasi. Pada rancangan ini, gffread digunakan sebagai utilitas pemrosesan berkas GFF atau GTF yang mampu membaca anotasi dan FASTA genom, melakukan pemeriksaan dasar konsistensi anotasi, mengekstraksi CDS berbasis fitur, serta

menerjemahkan CDS menjadi sekuens protein.



Gambar 4. 6 Desain Ekstraksi CDS dan Protein dengan gffread

Alur kerja ekstraksi CDS dan protein dengan gffread dalam penelitian ini dapat dibagi menjadi lima tahap utama berikut:

1. Input Data Anotasi GFF3 dan FASTA Genom

Tahap pertama adalah menyiapkan semua berkas yang dibutuhkan oleh gffread, yaitu anotasi genom PR25: berkas GFF3 anotasi PR25 hasil AGAT, yaitu PR25.final_ZS97_backbone_plus_OLunique.gff3) dan berkas GFF3 anotasi RD23 hasil Liftoff, yaitu RD23.from_ZS97.gff3), serta anotasi genom RD23: Berkas FASTA genom PR25.FINAL.fasta dan RD23.FINAL.fasta. Berkas GFF3 menyediakan koordinat genomik fitur (seqid, start, end, strand) untuk gene, mRNA, exon, dan CDS, sedangkan berkas FASTA menyediakan sekuens nukleotida genom yang akan dipotong sesuai koordinat tersebut. Kombinasi kedua berkas ini memungkinkan gffread untuk mengambil segmen DNA yang tepat untuk tiap transkrip dan CDS.

2. Pembacaan Berkas dan Validasi Keterhubungan Fitur Anotasi

Dalam tahap ini, gffread membaca fitur pada GFF3 dan memeriksa keterhubungan struktur anotasi melalui atribut seperti ID dan Parent, agar relasi antar fitur (misalnya gen, mRNA (transkrip), exon, dan CDS) konsisten dan dapat diproses. Validasi ini penting untuk mengurangi risiko kesalahan ekstraksi, yaitu transkrip tidak lengkap, relasi fitur tidak tersambung, dan kesalahan ekstraksi lainnya, karena anotasi yang tidak konsisten dapat memunculkan peringatan atau menyebabkan

sebagian transkrip tidak terekstraksi.

3. Penyusunan CDS Tersambung per Transkrip

Jika satu transkrip memiliki beberapa segmen CDS (misalnya karena struktur ekson), segmen tersebut dikelompokkan per transkrip, disusun sesuai urutan koordinatnya, lalu digabung menjadi satu urutan CDS lengkap. Proses ini menghasilkan CDS tersambung (spliced CDS) yang konsisten dengan struktur gen pada anotasi final.

4. Translasi CDS Menjadi Sekuens Protein

Setelah CDS tersusun, gffread menerjemahkan CDS menjadi rangkaian asam amino untuk menghasilkan berkas FASTA protein. Karena translasi dilakukan dari CDS yang didefinisikan oleh anotasi, identitas transkrip atau gen tetap dapat ditelusuri kembali melalui header FASTA, sehingga mendukung pelacakan pada tahap analisis orthologi dan anotasi fungsi serta domain protein

5. Keluaran (Output)

Tahap ini menghasilkan berkas FASTA untuk masing masing genom, minimal mencakup:

- FASTA CDS, yaitu PR25.final.cds.all.fa dan RD23.final.cds.all.fa.
- FASTA protein, yaitu PR25.final.pep.all.fa dan RD23.final.pep.all.fa.


FASTA protein menjadi masukan utama untuk pembersihan atau kurasi sekuens protein, inferensi orthologi (misalnya pembentukan orthogroup), serta anotasi fungsi dan domain berbasis protein.

FASTA CDS disimpan sebagai rujukan nukleotida apabila diperlukan pemeriksaan ulang model CDS pada tahap kurasi, tanpa mengubah anotasi struktural yang sudah ditetapkan pada tahap Liftoff dan standarisasi anotasi.

4.3.4 Desain Pembersihan Sekuens Protein

Tahap pembersihan sekuens protein dilakukan setelah proses pembentukan proteome (hasil translasi CDS menjadi protein) untuk memastikan bahwa himpunan

protein yang digunakan pada analisis lanjutan merupakan sekuens yang valid secara format dan cukup informatif untuk analisis berbasis kemiripan sekuens. Pada penelitian ini, tahapan downstream seperti inferensi orthologi dan anotasi fungsi atau domain sangat bergantung pada kualitas representasi sekuens sehingga jika sekuens yang sangat pendek, mengandung karakter tidak valid, residu ambigu berlebihan, atau memuat tanda stop internal dapat meningkatkan risiko kecocokan homolog yang tidak spesifik dan menurunkan keterandalan analisis.



Gambar 4. 7 Desain Pembersihan Sekuens Protein

Alur kerja pembersihan sekuens protein dapat dibagi menjadi lima tahap utama sebagai berikut.

1. Pengumpulan Sekuens Protein

Seluruh sekuens protein disiapkan dalam format FASTA dan dikelompokkan berdasarkan sumber genom (PR25, RD23, dan *Oryza longistaminata*) agar proses pembersihan diterapkan secara konsisten pada setiap proteom dan menghasilkan keluaran proteom bersih per genom.

2. Pemeriksaan Validitas Karakter Asam Amino dan Residu Ambigu

Tahap berikutnya adalah memeriksa komposisi karakter pada setiap sekuens protein:

- Pemeriksaan karakter asam amino standar: setiap residu pada sekuens protein diperiksa satu per satu, hanya karakter yang termasuk ke dalam 20 asam amino standar (A, C, D, E, F, G, H, I, K, L, M, N, P, Q, R, S, T, V, W, Y) yang dianggap valid.
- Penanganan karakter tidak valid dan residu ambigu: sekuens yang mengandung karakter di luar himpunan ini (misalnya angka, simbol, atau huruf lain) diklasifikasikan sebagai sekuens tidak valid dan dihapus dari dataset, karakter seperti X yang menandakan asam amino tidak diketahui

dianggap sebagai residu ambigu sehingga jika proporsi X dalam suatu sekuens terlalu tinggi, sekuens tersebut dapat dihapus karena berpotensi mengganggu proses alignment dan pencocokan domain.

- Penanganan simbol stop internal: Jika ditemukan simbol * (yang secara umum digunakan untuk menandai kodon stop pada sekuens protein hasil translasi otomatis) pada posisi internal sekuens, hal tersebut menunjukkan adanya kodon stop internal pada ORF. Kodon stop internal dapat muncul karena beberapa kemungkinan, misalnya mutasi stop prematur, pemotongan CDS yang belum lengkap, anotasi gen yang kurang tepat, atau karakteristik biologis tertentu, sehingga sekuens seperti ini biasanya perlu ditinjau terlebih dahulu. Bergantung pada kebijakan pembersihan yang diterapkan, sekuens dengan kodon stop internal dapat difilter keluar dari dataset apabila fokus analisis hanya pada protein yang diasumsikan memiliki ORF kontinu tanpa stop prematur, atau tetap dipertahankan tetapi diberi penanda sebagai sekuens “berisiko” atau berkualitas rendah, sehingga tidak disalahartikan pada saat interpretasi hasil orthologi maupun anotasi fungsi.

Tahap ini memastikan bahwa hanya sekuens yang tersusun terutama dari asam amino standar dan dengan tingkat ambiguitas yang masih dapat diterima yang dipertahankan.

3. Penyaringan Berdasarkan Panjang Sekuens Protein

Setelah validitas karakter dipastikan, dilakukan penyaringan berdasarkan panjang sekuens. Sekuens yang terlalu pendek dikeluarkan karena umumnya kurang informatif untuk analisis kesamaan sekuens dan berisiko menghasilkan kecocokan tidak spesifik. Ambang panjang minimum mengikuti ketentuan pada skrip pembersihan penelitian dan diterapkan konsisten pada seluruh genom. Sebagai pembandingan praktik yang lazim pada studi [90], beberapa pipeline melaporkan pembuangan protein berukuran sangat pendek, misalnya di bawah 50 residu asam amino, pada tahap kurasi keluaran anotasi.


4. Penyusunan Proteome Bersih

Tahap akhir menyusun berkas FASTA proteom bersih untuk masing masing genom

yang hanya berisi sekuens yang lolos kriteria tahap sebelumnya. Selain FASTA bersih, dicatat ringkasan jumlah sekuens sebelum dan sesudah pembersihan untuk setiap genom sebagai dokumentasi dampak pembersihan terhadap ukuran dataset dan sebagai bagian transparansi metode.

4.4 Desain Analisis *Orthology* Gen dengan OrthoFinder

Tahap analisis orthologi pada penelitian ini bertujuan untuk mengelompokkan gen homolog ke dalam orthogroup serta mengidentifikasi pasangan gen ortholog di antara tiga proteome (PR25, RD23, dan *Oryza longistaminata*). Hasil OrthoFinder dipakai sebagai dasar untuk melihat orthogroup yang dibagi bersama maupun spesifik spesies, dan menyediakan daftar ortholog antarpasangan spesies sebagai dasar pelabelan asal gen PR25 (misalnya *RD23 only*, *O. longistaminata only*, *BOTH*, atau spesifik PR25) sesuai definisi operasional penelitian. Secara umum, OrthoFinder memang dirancang untuk menghasilkan keluaran komparatif genomik seperti *orthogroups* dan *orthologs*, serta (bila diperlukan) *gene tree*, *species tree* terakar, dan pemetaan peristiwa duplikasi gen, dengan struktur output yang terorganisasi. Penggunaan OrthoFinder untuk pengelompokan orthogroup dan penurunan ortholog juga dilaporkan pada kajian filogenomik rumput (Poaceae) dalam paper [91] yang memanfaatkan hierarchical orthogroups (HOG) OrthoFinder, dan studi [92] yang menggunakan OrthoFinder untuk klusterisasi orthogroup berbasis kemiripan sekuens.



Gambar 4. 8 Desain Analisis Orthologi Gen dengan OrthoFinder

Berikut penjelasan alur analisis orthologi gen (OrthoFinder):

1. Input proteome bersih (FASTA)

Input berupa satu berkas FASTA protein per spesies (PR25, RD23, dan *O. longistaminata*) yang sudah melewati tahap kurasi proteome, sehingga setiap sekuens memiliki header dan identitas yang konsisten untuk dilacak kembali

pada output OrthoFinder.

2. Pemeriksaan awal berkas proteome

OrthoFinder melakukan pembacaan awal untuk memastikan berkas FASTA dapat diproses, setiap sekuens memiliki penanda (header) yang jelas, dan identitas sekuens tidak saling bertabrakan dalam satu spesies. Tahap ini menjaga agar hasil orthogroup dan ortholog dapat ditelusuri kembali ke ID gen atau protein secara konsisten.

3. Pencarian kemiripan sekuens *all versus all*

Seluruh protein dibandingkan lintas spesies untuk membangun dasar hubungan homologi berbasis kemiripan sekuens. Hasil pencarian kemiripan ini menjadi masukan utama untuk pengelompokan orthogroup pada tahap berikutnya.

4. Pembentukan orthogroup

Berdasarkan hubungan homologi yang terbentuk, OrthoFinder mengelompokkan gen ke dalam orthogroup, yaitu kelompok gen homolog yang diturunkan dari satu leluhur genetik pada tingkat keluarga gen. Orthogroup menjadi unit utama untuk membandingkan komposisi gen antar spesies dan untuk menelusuri kelompok gen yang dibagi bersama maupun spesifik spesies.

5. Penentuan ortholog antarpasangan spesies

OrthoFinder menghasilkan keluaran khusus untuk pasangan spesies, sehingga daftar ortholog (misalnya PR25–RD23 dan PR25–*O. longistaminata*) dapat dipakai sebagai dasar identifikasi kedekatan gen PR25 terhadap tetua. Untuk kebutuhan perbandingan dua spesies, keluaran ortholog antarpasangan memang merupakan keluaran yang langsung digunakan.

6. Output Orthofinder

Output utama OrthoFinder yang digunakan dalam penelitian ini meliputi:

- Orthogroups.tsv: daftar orthogroup dan anggota gen/protein dari masing-masing spesies
- Orthogroups.GeneCount.tsv: ringkasan jumlah gen per orthogroup per spesies
- Direktori Orthologues: daftar pasangan ortholog untuk setiap pasangan

spesies (PR25–RD23, PR25–*O. longistaminata*, RD23–*O. longistaminata*)

- Berkas gene tree per orthogroup dan species tree yang telah di-root.

Dalam desain penelitian ini, hasil OrthoFinder dimanfaatkan untuk:

- Pelabelan asal gen PR25

Daftar ortholog PR25–RD23 dan PR25–*O. longistaminata* digunakan untuk mengelompokkan gen PR25 menjadi kategori asal, misalnya: gen yang memiliki ortholog kuat pada RD23, gen yang memiliki ortholog kuat pada *O. longistaminata*, gen yang berasosiasi pada keduanya (BOTH), atau gen yang tidak memiliki pasangan ortholog jelas pada kedua tetua (spesifik PR25).

- Integrasi dengan anotasi fungsi dan domain

Hasil orthogroup dan label asal gen menjadi kunci integrasi dengan anotasi fungsi (EggNOG mapper) dan anotasi domain (InterProScan) untuk membangun interpretasi kontribusi fungsional gen tetua terhadap profil fungsional PR25 pada tahap berikutnya

4.5 Desain Anotasi Fungsi dan Domain Protein


Tahap ini memberikan makna biologis pada gen PR25 melalui anotasi fungsi (EggNOG-mapper v2) dan domain/motif protein (InterProScan).

4.5.1 Desain Anotasi Fungsi Gen dengan EggNOG-mapper v2

Tahap ini bertujuan untuk memberikan anotasi fungsi tingkat protein pada proteome PR25, RD23, dan *Oryza longistaminata* melalui pendekatan transfer anotasi berbasis orthologi. eggNOG mapper v2 dirancang untuk melakukan anotasi fungsi dengan memanfaatkan penugasan orthologi yang telah dipraproses (precomputed) dari basis data eggNOG, sehingga anotasi yang ditransfer diprioritaskan dari ortholog halus (fine grained orthologs).

Pada penelitian ini, hasil anotasi eggNOG mapper digunakan untuk: membangun tabel fungsi per protein (GO, KEGG, EC, COG category, deskripsi), merangkum fungsi dominan per genom, dan mengintegrasikan label fungsi dengan hasil *orthogroup* atau *ortholog* (*OrthoFinder*) serta anotasi domain (InterProScan) pada

tahap interpretasi.



Gambar 4. 9 Desain Anotasi Fungsi Gen dengan EggNOG-mapper v2

Berikut penjelasan alur eggNOG Mapper tersebut:

- **Input: proteome bersih per genom**
Masukan berupa FASTA protein hasil ekstraksi dan pembersihan proteome. Identitas protein pada header FASTA dipertahankan konsisten agar dapat ditelusuri ke keluaran anotasi.
- **Pencarian kecocokan terhadap basis data eggNOG (tahap search)**
eggNOG mapper melakukan pencarian kesamaan sekuens protein query terhadap basis data eggNOG menggunakan mesin pencarian yang didukung (DIAMOND, MMseqs2, atau HMMER) untuk memperoleh kandidat homolog dan memilih hit terbaik sebagai dasar penugasan.
- **Penetapan seed ortholog (jangkar transfer anotasi)**
Dari hasil pencarian, sistem menetapkan seed ortholog, yaitu protein referensi paling representatif yang dipakai sebagai “jangkar” untuk menurunkan ortholog terkait dan menjadi sumber transfer anotasi. Konsep ini penting karena anotasi eggNOG mapper menekankan transfer dari ortholog yang relevan, bukan sekadar homolog terdekat secara umum.
- **Inferensi orthologi dan pembatasan cakupan taksonomi**
Berdasarkan seed ortholog dan struktur kelompok ortholog (*orthologous groups*, OG) pada eggNOG, sistem melakukan penurunan orthologi serta membatasi transfer anotasi sesuai cakupan taksonomi (*taxonomic scope*) yang dipilih, sehingga transfer anotasi tidak terlalu jauh secara evolusioner.
- **Transfer anotasi fungsi dan penyusunan label fungsi multi sumber**
Anotasi yang ditransfer dapat mencakup eggNOG OG dan level anotasi (*max annotation level*), *COG category*, deskripsi fungsi, dan nama protein


preferen, GO terms, EC number, serta berbagai komponen KEGG.

- Output eggnog Mapper

Output utama adalah berkas anotasi tabular (umumnya .emapper.annotations) yang memuat kolom kunci seperti: query, seed_ortholog, evaluate, score, eggNOG_OGs, max_annot_lvl, COG_category, Description, Preferred_name, GOs, EC, KEGG_ko, KEGG_Pathway, KEGG_Module, serta kolom tambahan seperti BRITe, CAZy, PFAMs, dan md5 (bergantung mode dan versi). Untuk keterlacakan proses, eggNOG mapper juga dapat menghasilkan berkas pendukung seperti daftar hits dan seed orthologs. Berkas pendukung ini berguna saat perlu menelusuri mengapa suatu protein memperoleh anotasi tertentu atau mengapa anotasi kosong.

4.5.2 Desain Analisis Domain dan Motif Protein dengan InterProScan

Tahap ini bertujuan untuk melakukan anotasi berbasis signature pada proteome PR25, RD23, dan *Oryza longistaminata* guna memperoleh informasi domain protein, famili protein, motif atau situs fungsional. InterProScan merupakan perangkat lunak yang digunakan untuk mencari sekuens protein terhadap signature (model prediktif) yang berasal dari berbagai basis data anggota InterPro, kemudian mengintegrasikan hasilnya menjadi label anotasi yang terpadu melalui InterPro.



Gambar 4. 10 Desain Analisis Domain dan Motif Protein dengan InterProScan

Berikut penjelasan alur proses interproscan:

- Input: proteome bersih dalam FASTA

Masukan berupa FASTA protein hasil ekstraksi dan pembersihan proteome. Setiap sekuens protein dipertahankan dengan identitas yang konsisten agar hasil anotasi dapat dipetakan kembali ke gen atau protein pada tabel integrasi

penelitian.

- **Pra proses: pembacaan FASTA dan penyiapan pekerjaan**
InterProScan melakukan pembacaan FASTA, validasi dasar format, dan menyiapkan pekerjaan pemindaian. Pada dataset berukuran besar, tahap ini dapat melibatkan pembagian pekerjaan menjadi beberapa bagian agar eksekusi lebih efisien, tanpa mengubah makna biologis dari hasil pemindaian.
- **Pemindaian signature terhadap basis data anggota InterPro**
Inti proses InterProScan adalah menjalankan pemindaian sekuens terhadap signature (model prediktif) dari beberapa basis data anggota InterPro untuk mendeteksi kecocokan yang merepresentasikan famili protein, domain, dan situs fungsional. InterPro menjelaskan bahwa signature ini berasal dari banyak sumber dan InterPro mengintegrasikan signature yang ekuivalen untuk memberikan klasifikasi protein yang konsisten.
- **Integrasi hasil menjadi anotasi InterPro**
Match dari berbagai signature kemudian digabungkan dan dipetakan ke entri InterPro, sehingga keluaran tidak hanya berupa “hit” per basis data, tetapi juga anotasi terpadu pada tingkat *InterPro entry* (misalnya identitas entri, deskripsi, serta pengelompokan domain atau famili yang sepadan).
- **Output Interproscan**
Pada desain penelitian ini, format output dipilih untuk memenuhi kebutuhan integrasi tabel dan pelacakan posisi domain, yaitu TSV untuk integrasi tabel anotasi dan peringkasan fungsi atau domain, XML atau JSON bila diperlukan struktur keluaran untuk parsing lanjutan., GFF3 bila diperlukan pelacakan fitur match terhadap koordinat sekuens (khususnya untuk integrasi fitur berbasis posisi). Dokumentasi InterProScan menyatakan format yang didukung meliputi TSV, XML, JSON, dan GFF3 (dengan konfigurasi default tertentu untuk input protein).

BAB V

IMPLEMENTASI

Bab ini membahas proses implementasi yang mencakup lingkungan implementasi, batasan implementasi, hingga implementasi interpretasi hasil.

5.1 Lingkungan Implementasi

Lingkungan implementasi dalam penelitian ini terdiri dari perangkat keras dan perangkat lunak yang digunakan selama proses analisis data dan pengembangan model. Spesifikasi masing-masing komponen dapat dilihat pada tabel berikut:

Tabel 5. 1 Spesifikasi Perangkat Keras

No.	Perangkat Keras	Spesifikasi
1	<i>Processor</i>	Intel(R) Core(TM) Ultra 7 155H (22 CPUs), 1.4GHz
2	<i>RAM (Random Access Memory)</i>	16 GB

Pada tabel 5.1 terdapat spesifikasi perangkat keras yang digunakan untuk melakukan implementasi penelitian ini yakni menggunakan processor Intel(R) Core(TM) Ultra 7 155H (22 CPUs), 1.4GHz, dengan RAM 16 GB.

Tabel 5. 2 Spesifikasi Perangkat Lunak

No.	Perangkat Lunak	Spesifikasi
1.	<i>OS (Operating System)</i>	Microsoft Windows 11 (64-bit) dengan Ubuntu 22.04 LTS melalui Windows Subsystem for Linux (WSL)
2.	Bahasa Pemrograman	Python, WDL (<i>Workflow Description Language</i>), Bash shell (melalui terminal Ubuntu-22.04 pada WSL)
2	Text Editor	Visual Studio Code, Jupyter Notebook (dijalankan sebagai ekstensi/interactive notebook di dalam Visual Studio Code)
3	Platform	Windows Subsystem for Linux (WSL2 – Ubuntu 22.04), DCS Cloud (BGI),

		<u>EggNOG-mapper web server</u> dan <u>Galaxy Europe</u> untuk menjalankan InterProScan.
--	--	--

5.2 Batasan Implementasi

Berikut batasan implementasi penelitian:

1. Batasan performa I/O Windows–WSL2: Pemrosesan file genom berukuran besar dapat melambat bila data disimpan/diakses lintas filesystem (misalnya dari /mnt/c) karena performa terbaik umumnya dicapai saat file Linux diproses di filesystem Linux (WSL).
2. Batasan kuota Galaxy Europe (InterProScan): Pelaksanaan InterProScan melalui Galaxy Europe dibatasi oleh kuota penyimpanan pengguna (misalnya 250 GB) sehingga ketika kuota penuh, job baru tidak dapat dijalankan sampai data dibersihkan.
3. Batasan layanan *web/cloud* (eggNOG-mapper & DCS Cloud): Anotasi melalui eggNOG-mapper web server dan proses di platform cloud dapat terpengaruh antrian job, beban server, dan kestabilan jaringan sehingga durasi eksekusi tidak sepenuhnya dapat dikendalikan dari sisi lokal.

5.3 Implementasi Evaluasi Kualitas Genom

Pada subbab ini menjelaskan implementasi yang dilakukan dengan BUSCO dan QUAST dengan WDL dalam DCS Cloud tersebut.

5.3.1 *Workflow Description Language (WDL)*

WDL (*Workflow Description Language*) adalah bahasa yang digunakan untuk mendefinisikan dan menjalankan alur kerja pemrosesan data.

Struktur utama WDL menggunakan struktur utama berikut:

1. Workflow: Mendefinisikan seluruh alur kerja.
2. Task: Mendefinisikan tugas spesifik dalam alur kerja.
3. Call: Digunakan untuk memanggil atau memicu tugas dalam alur kerja.
4. Command: Mendefinisikan perintah yang akan dieksekusi di node komputasi.
5. Output: Mendefinisikan output dari tugas atau alur kerja.
6. Runtime: Mendefinisikan parameter runtime tugas, seperti CPU, memori, dan Docker image.

Image adalah metode pengemasan perangkat lunak portabel yang digunakan untuk mengemas aplikasi dan semua lingkungan runtime, pustaka sistem, dan dependensinya ke dalam satu file. File ini dapat dimuat dan dijalankan oleh platform kontainerisasi (seperti Docker, Kubernetes, Github, dan lainnya), sehingga memungkinkan eksekusi yang cepat. Selain itu, pengguna dapat menggunakan berbagai jenis alat analisis dengan melakukan *image custom* yang dibuat oleh pengguna itu sendiri. Melalui *image custom*, pengguna dapat dengan bebas mengatur dependensi atau kontainer yang diperlukan oleh para pengguna.

Dengan kata lain, image adalah perangkat lunak yang berisi semua dependensi, perangkat lunak, dan konfigurasi yang diperlukan untuk menjalankan tugas WDL. Adapun pada penjelasan berikut adalah penjelasan penggunaan WDL untuk membuat BUSCO pada DCS Cloud.

5.3.2 Evaluasi Kelengkapan Genom dengan BUSCO

Pada tahap implementasi, evaluasi kelengkapan genom PR25, RD23, dan *Oryza longistaminata* dilakukan menggunakan sebuah pipeline berbasis Workflow Description Language (WDL). Pipeline ini didefinisikan dalam workflow bernama RunBusco yang memanggil task RunBuscoAnalysis untuk menjalankan BUSCO dengan pengaturan input, mode analisis, dataset lineage, jumlah CPU, dan memori yang sudah ditentukan secara eksplisit di dalam skrip. Dengan cara ini, setiap kali analisis dijalankan, BUSCO selalu menggunakan kombinasi parameter yang sama, dan peneliti hanya perlu mengganti berkas FASTA genom yang dianalisis tanpa mengubah perintah secara manual. Berikut skrip WDL versi lengkap untuk BUSCO.

```
version 1.0

workflow RunBusco {
  input {
    File sequence_file          # Input file dalam format FASTA
    untuk analisis.
    String mode                  # Mode analisis: "genome",
    "proteins", atau "transcriptome".
    File lineage_dataset_path   =
```

Institut Teknologi Del


```

"/Files/martha/Busco_Dataset/poales_odb10.2024-01-08.tar.gz" # Path ke
dataset lineage dalam format .tar.gz.

    Int memory = 10                                # Memori yang dialokasikan
    untuk analisis (dalam GB).

    Int cpu = 8                                     # Jumlah thread CPU yang
    digunakan untuk analisis.

    String output_name = "Output_ID"               # Nama direktori output untuk
    hasil analisis.
}

call RunBuscoAnalysis {
    input:
        sequence_file = sequence_file,
        mode = mode,
        lineage_dataset = lineage_dataset_path,
        cpu = cpu,
        memory = memory,
        output_name = output_name
}

output {
    File summary_file = RunBuscoAnalysis.summary_file
    File full_table = RunBuscoAnalysis.full_table
}
}

task RunBuscoAnalysis {
    input {
        File sequence_file                        # File input dalam format
        FASTA.
        String mode                               # Mode analisis.
        File lineage_dataset                      # Dataset lineage dalam format
        .tar.gz.
        Int cpu                                   # Jumlah thread CPU.
        Int memory                               # Memori yang dialokasikan
        (dalam GB).
        String output_name                       # Nama direktori output.
    }
}

```

```

command <<<
  set -e
  echo "Memulai analisis BUSCO..."
  mkdir -p "${output_name}"
  echo "Ekstraksi dataset lineage..."
  tar -xzf "${lineage_dataset}" -C "${output_name}"

  lineage_dir=$(tar -tf "${lineage_dataset}" | head -1 | cut -d '/'
-f 1)
  lineage_path="${output_name}/${lineage_dir}"

  echo "Jalankan analisis BUSCO..."
  busco -i "${sequence_file}" \
    -m "${mode}" \
    -l "${lineage_path}" \
    -c "${cpu}" \
    -o "${output_name}" \
    --force

>>>

runtime {
  docker_url:
"stereonote_hpc/marthanapitupulu_9edf816733f14a71adee06616e2bb53d_priv
ate:latest"
  cpu: cpu
  memory: "${memory}G"
}

output {
  File summary_file = "${output_name}/short_summary.*.${mode}.txt"
  File full_table =
"${output_name}/run_${output_name}/full_table.tsv"
}
}

```

Pseudocode 5. 1 Implementasi WDL BUSCO

Workflow RunBusco

Bagian workflow RunBusco mendefinisikan struktur utama pipeline serta parameter yang perlu diisi sebelum analisis dijalankan.

```
workflow RunBusco {
  input {
    File sequence_file          # Input file dalam format FASTA
    untuk analisis.
    String mode                  # Mode analisis: "genome",
    "proteins", atau "transcriptome".
    File lineage_dataset_path   =
    "/Files/martha/Busco_Dataset/poales_odb10.2024-01-08.tar.gz" # Path ke
    dataset lineage dalam format .tar.gz.
    Int memory = 10              # Memori yang dialokasikan
    untuk analisis (dalam GB).
    Int cpu = 8                  # Jumlah thread CPU yang
    digunakan untuk analisis.
    String output_name = "Output_ID" # Nama direktori output untuk
    hasil analisis.
  }

  call RunBuscoAnalysis {
    input:
      sequence_file = sequence_file,
      mode = mode,
      lineage_dataset = lineage_dataset_path,
      cpu = cpu,
      memory = memory,
      output_name = output_name
  }
}
```

Berikut penjelasan untuk kodingan pada bagian workflow RunBusco tersebut:

1. Blok input

Pada blok ini didefinisikan seluruh masukan yang dibutuhkan untuk menjalankan analisis BUSCO:

- **File sequence_file:** Berkas genom dalam format FASTA yang akan dievaluasi kelengkapannya (misalnya genom PR25, RD23, atau *O. longistaminata*).
- **String mode:** Mode analisis BUSCO, yang dapat diisi genome, proteins,

atau transcriptome. Dalam penelitian ini, mode yang relevan adalah genome karena input berupa genom ter-assemble.

- **File lineage_dataset_path:** Jalur menuju dataset lineage BUSCO dalam format .tar.gz, misalnya poales_odb10.2024-01-08.tar.gz yang digunakan untuk mengevaluasi genom pada ordo Poales (padi dan kerabatnya).
- **Int memory dan Int cpu:** Sumber daya komputasi yang dialokasikan, masing-masing untuk memori (GB) dan jumlah thread CPU yang digunakan saat menjalankan BUSCO.
- **String output_name:** Nama direktori output yang berfungsi sebagai penanda hasil analisis (misalnya nama sampel atau ID run).

2. Pemanggilan task RunBuscoAnalysis

Pada bagian `call RunBuscoAnalysis` bertujuan untuk mengatur agar task `RunBuscoAnalysis` dijalankan dengan seluruh parameter yang telah diberikan pada workflow. Dengan cara ini, pipeline memisahkan definisi alur kerja (workflow) dan detail eksekusi analisis (task).

3. Blok output workflow

Workflow mengekspose dua keluaran utama dari analisis BUSCO:

- **summary_file:** berkas ringkasan singkat (short summary) yang berisi persentase BUSCO Complete, Fragmented, dan Missing.
- **full_table:** tabel lengkap BUSCO (format TSV) yang berisi daftar marker ortholog dan status masing-masing (C/F/M) untuk genom yang dianalisis.
- Kedua keluaran ini kemudian digunakan pada tahap analisis dan visualisasi di bagian hasil dan pembahasan.

4. Task RunBuscoAnalysis

Bagian task `RunBuscoAnalysis` berisi definisi cara teknis menjalankan BUSCO melalui WDL di *DCS Cloud*

```
task RunBuscoAnalysis {
```

```

input {
    File sequence_file          # File input dalam format
FASTA.
    String mode                  # Mode analisis.
    File lineage_dataset        # Dataset lineage dalam format
.tar.gz.
    Int cpu                      # Jumlah thread CPU.
    Int memory                   # Memori yang dialokasikan
(dalam GB).
    String output_name          # Nama direktori output.
}

command <<<
    set -e
    echo "Memulai analisis BUSCO..."
    mkdir -p "${output_name}"
    echo "Ekstraksi dataset lineage..."
    tar -xzf "${lineage_dataset}" -C "${output_name}"

    lineage_dir=$(tar -tf "${lineage_dataset}" | head -1 | cut -d '/'
-f 1)
    lineage_path="${output_name}/${lineage_dir}"

    echo "Jalankan analisis BUSCO..."
    busco -i "${sequence_file}" \
        -m "${mode}" \
        -l "${lineage_path}" \
        -c "${cpu}" \
        -o "${output_name}" \
        --force

>>>

runtime {
    docker_url:
"stereonote_hpc/marthanapitupulu_9edf816733f14a71adee06616e2bb53d_priv
ate:latest"
    cpu: cpu
    memory: "${memory}G"

```

```

}

output {
  File summary_file = "${output_name}/short_summary.*.${mode}.txt"
  File               full_table                               =
"${output_name}/run_${output_name}/full_table.tsv"
}
}

```

Pseudocode 5. 2 Task RunBusco Analysis

Berikut penjelasan terhadap kodingan tersebut:

1) Blok input pada task

Mengulang kembali parameter yang dibutuhkan oleh BUSCO pada level task: `sequence_file`, `mode`, `lineage_dataset`, `cpu`, `memory`, dan `output_name` yang diteruskan dari workflow.

2) Blok *command*

Pada bagian task RunBuscoAnalysis, blok `command` berisi rangkaian perintah shell yang menjalankan seluruh proses analisis BUSCO, mulai dari menyiapkan direktori keluaran, mengekstrak dataset lineage dari berkas arsip `.tar.gz`, menentukan jalur folder lineage yang akan digunakan sebagai referensi, hingga mengeksekusi perintah `busco` dengan berkas genom input, mode analisis, jumlah CPU, dan lokasi dataset lineage sesuai parameter yang telah didefinisikan pada bagian input. Berikut penjelasan pada blok `command` ini:

- `set -e` : Mengatur agar proses berhenti otomatis jika terjadi kesalahan pada salah satu perintah, sehingga mencegah pipeline melanjutkan eksekusi dengan kondisi gagal.
- `mkdir -p "${output_name}"`: Membuat direktori output dengan nama yang ditentukan pada parameter `output_name`. Semua hasil BUSCO untuk run tersebut akan disimpan di dalam direktori ini.
- Ekstraksi dataset lineage: Dataset lineage BUSCO (misalnya `poales_odb10`) yang masih terkompresi (`.tar.gz`) diekstrak ke dalam direktori output sehingga dapat digunakan sebagai referensi saat menjalankan BUSCO.
- Penentuan `lineage_path`: Dua baris ini secara otomatis mengambil nama

folder utama dari arsip lineage_dataset, kemudian membentuk jalur lengkap lineage_path yang akan diberikan ke parameter -l pada BUSCO. Dengan cara ini, pipeline tidak bergantung pada penamaan folder yang ditulis tetap di dalam kode, tetapi secara otomatis menyesuaikan dengan nama folder lineage yang ada di dalam berkas arsip .tar.gz.

- Menjalankan BUSCO

Pada bagian ini, perintah busco dijalankan dengan beberapa parameter utama, yaitu -i yang berisi berkas genom dalam format FASTA yang akan dievaluasi, -m yang menentukan mode analisis (misalnya genome untuk input berupa genom ter-assemble), -l yang menunjuk ke jalur dataset lineage BUSCO (misalnya poales_odb10) sebagai kumpulan gen penanda yang digunakan sebagai referensi, -c yang mengatur jumlah thread CPU yang digunakan selama analisis, dan -o yang menentukan nama folder output tempat seluruh hasil BUSCO disimpan, sedangkan opsi --force digunakan untuk mengizinkan BUSCO menimpa direktori output dengan nama yang sama jika direktori tersebut sudah ada dari eksekusi sebelumnya.

3) Blok runtime

Blok runtime pada task RunBuscoAnalysis digunakan untuk mengatur sumber daya komputasi yang dialokasikan ketika analisis BUSCO dijalankan di lingkungan eksekusi. Pada bagian ini, nilai cpu dan memory menentukan jumlah thread prosesor dan besar memori (dalam gigabyte) yang akan digunakan sesuai dengan parameter yang diberikan pada blok input, sehingga penggunaan sumber daya dapat dikendalikan secara jelas. Selain itu, docker_url merujuk pada lingkungan eksekusi yang sudah dikonfigurasi sebelumnya dan berisi instalasi BUSCO beserta seluruh dependensinya. Dengan pengaturan ini, analisis BUSCO dijalankan di dalam lingkungan yang sama setiap kali pipeline dieksekusi, sehingga kinerja analisis tetap stabil dan hasil yang diperoleh konsisten antar-run.

4) Blok output pada task

Pada blok output pada task RunBuscoAnalysis, dua berkas utama hasil analisis BUSCO didefinisikan sebagai keluaran task agar dapat diakses kembali oleh workflow RunBusco dan digunakan pada tahap analisis berikutnya. Parameter summary_file mengacu pada berkas *short summary* BUSCO

(short_summary.*.\${mode}.txt) di dalam direktori \${output_name}, di mana tanda (*) digunakan untuk mewakili bagian nama file yang diisi otomatis oleh BUSCO (misalnya nama sampel atau prefix run), sedangkan \${mode} memastikan berkas yang diambil sesuai dengan mode analisis yang digunakan (misalnya genome). Berkas short summary ini berisi ringkasan metrik kelengkapan genom, seperti persentase marker BUSCO yang terklasifikasi sebagai Complete (lengkap), Fragmented (terfragmentasi), dan Missing (tidak ditemukan), sehingga memberikan gambaran umum kualitas konten gen pada genom yang dianalisis. Sementara itu, parameter full_table menunjuk ke berkas full_table.tsv di dalam direktori run_\${output_name}, yaitu folder kerja utama yang dibentuk oleh BUSCO untuk setiap eksekusi analisis; tabel ini memuat informasi detail untuk setiap marker BUSCO, termasuk ID marker, status (*Complete/Fragmented/Missing/Duplicated*), serta identitas sekuens yang memenuhinya pada genom yang diuji. Dengan mendefinisikan summary_file dan full_table sebagai keluaran resmi task, pipeline WDL memastikan bahwa kedua berkas tersebut otomatis tersimpan dan siap digunakan kembali, misalnya untuk dibaca dan digabungkan antar genom PR25, RD23, dan *O. longistaminata*, atau digunakan pada bab hasil dan pembahasan.

5.3.3 Evaluasi Struktur Assembly Genom dengan QUAST

Evaluasi struktur assembly genom PR25, RD23, dan *Oryza longistaminata* diimplementasikan menggunakan sebuah pipeline berbasis Workflow Description Language (WDL) yang membungkus pemanggilan QUAST ke dalam workflow RunQuast dan task Quast. Melalui workflow ini, berkas genom ter-assemble (dalam format FASTA) dianalisis dengan QUAST dengan pengaturan jumlah CPU, alokasi memori, dan opsi penggunaan genom referensi yang didefinisikan secara jelas di dalam skrip. Pendekatan ini memudahkan pelaksanaan analisis yang konsisten untuk beberapa genom, karena peneliti hanya perlu mengganti berkas input kontig dan, jika tersedia, berkas referensi, tanpa harus menulis ulang perintah QUAST secara manual.

version 1.0


```

workflow RunQuast {
  input {
    File contig_file
    File? reference_genome
    Int cpu = 4
    Int memory = 8
  }
  call Quast {
    input:
      input_file = contig_file,
      input_reference = reference_genome,
      input_cpu = cpu,
      input_memory = memory
  }
  output {
    File out = Quast.outdir
  }
}

task Quast {
  input {
    File input_file
    File? input_reference
    Int input_cpu
    Int input_memory
  }
  command {
    quast ~{input_file} \
    ~{if defined(input_reference) then "-r ~{input_reference}" else
""} \
    -t ~{input_cpu} \
    -o quastout
  }
  runtime {
    docker_url:
"stereonote_hpc/dedekurniawan_349e4377feeb4399857b14517ed13980_private
:latest"
    req_cpu: input_cpu
  }
}

```

```

    req_memory: "${input_memory}Gi"
  }
  output {
    File outdir = "quastout/"
  }
}

```

Pseudocode 5. 3 Implementasi WDL QUAST

Pada bagian workflow RunQuast, blok input mendefinisikan parameter-parameter yang diperlukan sebelum analisis dijalankan. Parameter File `contig_file` adalah berkas FASTA yang berisi kontig atau scaffolds hasil assembly genom yang akan dievaluasi kualitas strukturnya. Parameter File? `reference_genome` bersifat opsional (File?), yakni dapat diisi jika tersedia genom referensi yang ingin digunakan untuk membandingkan hasil assembly. Selain itu, `Int cpu = 4` dan `Int memory = 8` mengatur jumlah thread CPU dan memori (dalam gigabyte) yang dialokasikan untuk menjalankan QUAST; nilai default masing-masing adalah 4 CPU dan 8 GB, namun dapat diubah sesuai kebutuhan. Workflow kemudian memanggil task Quast melalui blok call Quast, dengan meneruskan `contig_file`, `reference_genome`, `cpu`, dan `memory` ke parameter input task. Pada blok output, workflow mengekspos satu keluaran utama, yaitu `File out = Quast.outdir`, yang mereferensikan direktori output QUAST yang dihasilkan oleh task Quast dan nantinya dapat diakses pada tahap analisis dan visualisasi lebih lanjut.

Task Quast berisi definisi teknis cara menjalankan program QUAST. Pada blok input, parameter `input_file` menampung berkas kontig FASTA yang dianalisis, `input_reference` menampung genom referensi opsional (jika digunakan), sedangkan `input_cpu` dan `input_memory` menentukan jumlah thread dan memori yang dialokasikan untuk proses ini. Blok command memuat perintah pemanggilan QUAST dalam bentuk skrip shell. Perintah `quast ~{input_file} \` menjalankan QUAST dengan berkas kontig sebagai input utama. Baris berikutnya, `~{if defined(input_reference) then "-r ~{input_reference}" else ""} \`, mengatur agar opsi `-r` hanya ditambahkan jika `input_reference` benar-benar diisi; jika tidak ada referensi yang diberikan, bagian ini dikosongkan sehingga QUAST dijalankan dalam mode tanpa referensi. Parameter `-t ~{input_cpu}` mengatur jumlah thread

CPU yang digunakan QUAST, sedangkan -o quastout menentukan bahwa seluruh output QUAST (laporan teks, tabel metrik, dan grafik) disimpan dalam direktori bernama quastout.

Pada blok runtime, task Quast mengatur lingkungan eksekusi dan sumber daya komputasi yang digunakan. Nilai `docker_url` menunjuk ke sebuah lingkungan kontainer yang sudah berisi instalasi QUAST beserta seluruh dependensinya, sehingga analisis dapat dijalankan dalam lingkungan yang konsisten setiap kali workflow dieksekusi. Parameter `req_cpu`: `input_cpu` dan `req_memory`: `"${input_memory}Gi"` memastikan bahwa jumlah CPU dan memori yang dialokasikan untuk kontainer QUAST mengikuti nilai yang diberikan pada input, sehingga penggunaan sumber daya dapat dikontrol dengan jelas. Terakhir, pada blok output, parameter `outdir` didefinisikan sebagai `"quastout/"`, yaitu direktori tempat QUAST menyimpan seluruh hasil evaluasi kualitas struktur assembly, termasuk metrik seperti jumlah kontig, panjang total genom ter-assemble, N50/L50, serta laporan-laporan pendukung lainnya. Direktori ini kemudian digunakan sebagai keluaran resmi task dan diakses pada tahap analisis lanjutan, misalnya saat hasil QUAST diringkas dan disajikan dalam bentuk tabel dan uraian pada bab hasil dan pembahasan.

5.4 Implementasi Data Preprocessing

Pada tahap ini, data preprocessing dilakukan melalui miniconda3 di WSL(Ubuntu) yang mana membuat lingkungan kerja terisolasi bernama `liftoff` berisi `Liftoff` dan perangkat lunak pendukungnya. Selain install `liftoff`, diinstall juga `gffread` untuk ekstraksi CDS/protein sehingga dengan lingkungan yang sama dapat memudahkan implementasi data preprocessing untuk penelitian ini.

```
# Mengaktifkan integrasi conda di shell bash (perlu di setiap sesi terminal baru)
eval "$({conda shell.bash hook})"

# Membuat environment baru bernama "liftoff"
# yang berisi Liftoff, minimap2, agat, dan gffread
conda create -n liftoff \
```

```

-c bioconda -c conda-forge \
liftoff minimap2 agat gffread\
-y

# Mengaktifkan environment "liftoff"
conda activate liftoff

# Verifikasi bahwa tool utama sudah terpasang
liftoff --version
minimap2 --version
gffread --version
agat_config -h

```

Pseudocode 5. 4 Penyiapan Lingkungan(Environment) dalam Conda

Berikut penjelasan kodingan menyiapkan lingkungan (env) dalam conda untuk melakukan data *preprocessing*:

- Perintah `eval "$(conda shell.bash hook)"` digunakan untuk menginisialisasi conda pada shell WSL, sehingga perintah conda dan conda activate dapat dikenali dan dijalankan. Setelah itu, environment spesifik yang dibutuhkan (misalnya liftoff) diaktifkan dengan perintah `conda activate liftoff`.
- `conda create`: perintah untuk membuat environment baru dan sekaligus menginstal paket di dalamnya.
- `-n liftoff`: nama environment yang dibuat adalah liftoff. Semua paket di bawah perintah ini akan dipasang khusus ke environment tersebut, terpisah dari environment base maupun environment lain.
- `-c bioconda`: Opsi `-c bioconda` digunakan untuk mengarahkan perintah conda create agar mengunduh paket-paket yang dibutuhkan dari channel Bioconda, yaitu repositori khusus perangkat lunak bioinformatika dan analisis data biologis. Channel ini menyediakan ribuan perangkat lunak yang umum digunakan dalam analisis genomik, termasuk perangkat lunak yang dipakai pada tahap preprocessing penelitian ini, seperti Liftoff, minimap2, dan gffread. Dengan menyertakan `-c bioconda` dalam perintah pembuatan environment liftoff, proses instalasi memastikan bahwa keempat program tersebut diambil dari sumber yang memang dikurasi untuk workflow

Institut Teknologi Del

bioinformatika di lingkungan conda, sehingga versi perangkat lunak yang digunakan pada tahap anotasi gen (Liftoff dan aligner minimap2), dan ekstraksi CDS/protein (gffread) konsisten dan sesuai untuk analisis genom padi dalam penelitian ini.

- -c conda-forge: Opsi -c conda-forge menambahkan channel conda-forge sebagai sumber berbagai pustaka umum, runtime, dan dependensi tingkat rendah yang dibutuhkan oleh paket-paket yang diambil dari Bioconda. Bila Bioconda berfokus pada aplikasi bioinformatika tingkat tinggi, seperti Liftoff, minimap2, agat, dan gffread, maka conda-forge menyediakan “fondasi” berupa pustaka C/C++ dan sistem (misalnya zlib, bzip2, libcurl), pustaka bahasa pemrograman, serta library pendukung lain yang diperlukan agar program-program tersebut dapat dikompilasi dan dijalankan dengan benar di lingkungan WSL. Dalam konteks Bab 5 Implementasi, penyertaan -c conda-forge pada perintah pembuatan environment liftoff memastikan bahwa seluruh dependensi non-bioinformatika yang menyokong Liftoff dan tool pendukungnya terpasang secara lengkap, sehingga environment liftoff stabil ketika digunakan pada tahap implementasi anotasi gen dan ekstraksi CDS/protein.
- liftoff minimap2 agat gffread: perangkat lunak yang langsung diinstal ke environment liftoff
- liftoff: program utama untuk mengangkat anotasi gen dari ZS97 ke PR25 dan RD23.
- minimap2: aligner genom–genom yang dipanggil secara internal oleh Liftoff. Hasil pemetaan/penyelarasan yang dihasilkan oleh minimap2 tidak disimpan dan tidak digunakan sebagai berkas keluaran tersendiri dalam alur kerja penelitian ini, tetapi dimanfaatkan secara langsung oleh Liftoff untuk menentukan kesesuaian region homolog antara genom referensi dan genom target, kemudian disusun menjadi anotasi gen baru dalam format GFF3.
- gffread: utilitas yang akan dipakai di subbab selanjutnya untuk mengekstrak CDS dan protein dari kombinasi GFF3 (hasil Liftoff) dan FASTA genom.
- AGAT (Another GTF/GFF Analysis Tools) adalah kumpulan skrip dan program yang dirancang khusus untuk bekerja dengan berkas anotasi gen

dalam format GFF dan GTF dimana menyediakan berbagai perintah untuk: memeriksa konsistensi dan kelengkapan anotasi (misalnya struktur gene–mRNA–exon–CDS), memperbaiki atau menormalkan anotasi yang bermasalah, menggabungkan atau memecah berkas anotasi, memfilter fitur tertentu (misalnya hanya gen protein-coding), serta mengekstrak sekuens dari anotasi menjadi berkas FASTA. Dalam konteks penelitian ini, AGAT digunakan untuk merapikan dan menstandarisasi anotasi GFF3 hasil Liftoff sebelum langkah lanjutan, yaitu ekstraksi CDS/protein dengan gffread.

- -y: memberi jawaban “yes” otomatis untuk semua konfirmasi instalasi, sehingga proses conda create berjalan tanpa perlu menekan “y” secara manual.
- conda activate liftoff mengaktifkan environment liftoff yang telah dibuat.
- Baris liftoff --version, minimap2 --version, dan gffread --version: digunakan untuk memastikan bahwa ketiga program sudah terinstal dan bisa dijalankan.
- agat_config -h: memanggil salah satu script AGAT dengan opsi bantuan (-h) untuk memastikan modul AGAT terbaca dengan benar di environment

Sebelum menggunakan liftoff, berkas genom dan anotasi referensi terlebih dahulu disiapkan dari sumber data yang digunakan dalam penelitian. Berkas ZS97.dna_sm.toplevel.fa dan ZS97.gff3 (dekompresi dari Oryza_sativa_zs97.ZS97RS3.62.gff3.gz) merepresentasikan genom referensi dan anotasi gen Oryza sativa indica kultivar ZS97 yang diperoleh dari basis data genom publik sebagai data referensi untuk digunakan. Demikian pula, berkas Oryza_longistaminata_v1.0.dna_sm.toplevel.fa dan OL.gff3 (hasil dekompresi dari Oryza_longistaminata_O_longistaminata_v1.0.62.gff3.gz) merupakan genom dan anotasi referensi Oryza longistaminata yang diunduh dari sumber referensi publik dan kemudian digunakan sebagai salah satu rujukan dalam penelitian ini. Berkas-berkas tersebut semula disimpan dalam bentuk terkompresi (.fa.gz, .gff3.gz) dan didekompresi pada lingkungan WSL sehingga tersedia sebagai berkas FASTA dan GFF3 tidak terkompresi yang selanjutnya dipakai sebagai masukan pada tahapan anotasi dengan Liftoff, pemrosesan anotasi dengan AGAT, dan ekstraksi CDS/protein dengan gffread.

5.4.1 Implementasi Anotasi Gen dengan AGAT-Liftoff

Pada tahap *preprocessing* ini, anotasi gen untuk genom PR25 dan RD23 dibangun dengan cara memetakan (lift-over) anotasi genom referensi *Oryza sativa indica* kultivar ZS97 menggunakan Liftoff. Untuk genom PR25, anotasi backbone dari ZS97 kemudian dilengkapi dengan gen tambahan yang bersumber dari genom liar *Oryza longistaminata*. Proses pelengkapan ini dilakukan dengan Liftoff dan disatukan menggunakan AGAT, sehingga dihasilkan satu berkas anotasi PR25 final yang akan menjadi dasar ekstraksi CDS dan protein.

```
#!/usr/bin/env bash
set -euo pipefail

# Inisialisasi conda dan environment liftoff
eval "$(conda shell.bash hook)"
conda activate liftoff

# Parameter umum
CPU=16
OUT="/mnt/d/result/output_bio"          # ↔ D:\result\output_bio\
LOG="$OUT/logs"

mkdir -p "$OUT/liftoff" "$LOG"

# Lokasi genom & anotasi referensi (sudah didekompres dari sumber publik
/ paket data lab)
ZS97_FA="$OUT/ZS97.dna_sm.toplevel.fa"
ZS97_GFF="$OUT/ZS97.gff3"
OL_FA="$OUT/Oryza_longistaminata_v1.0.dna_sm.toplevel.fa"
OL_GFF="$OUT/OL.gff3"

# Lokasi genom target PR25 dan RD23
PR25_FA="/mnt/d/TA1/pr25/01.chromosome/result/3ddna/review/PR25.FINAL.
fasta"
RD23_FA="/mnt/d/TA1/Rd23/02.chromosome/result/3ddna/review/RD23.FINAL.
fasta"
```

```

# 1. Anotasi backbone PR25 dengan Liftoff (ZS97 → PR25)
liftoff "$PR25_FA" "$ZS97_FA" \
  -g "$ZS97_GFF" \
  -o "$OUT/liftoff/PR25.from_ZS97.gff3" \
  -u "$OUT/liftoff/PR25.from_ZS97.unmapped.txt" \
  -p "$CPU" \
  -sc 0.95 \
  -a 0.6 \
  > "$LOG/PR25.from_ZS97.log" 2>&1

# 2. Anotasi backbone RD23 dengan Liftoff (ZS97 → RD23)
liftoff "$RD23_FA" "$ZS97_FA" \
  -g "$ZS97_GFF" \
  -o "$OUT/liftoff/RD23.from_ZS97.gff3" \
  -u "$OUT/liftoff/RD23.from_ZS97.unmapped.txt" \
  -p "$CPU" \
  -sc 0.95 \
  -a 0.6 \
  > "$LOG/RD23.from_ZS97.log" 2>&1

# 3. Rescue gen O. longistaminata ke PR25
liftoff "$PR25_FA" "$OL_FA" \
  -g "$OL_GFF" \
  -o "$OUT/liftoff/PR25.add_OL.gff3" \
  -u "$OUT/liftoff/PR25.add_OL.unmapped.txt" \
  -p "$CPU" \
  -sc 0.95 \
  -a 0.6 \
  > "$LOG/PR25.add_OL.log" 2>&1

# 4. Pembersihan anotasi OL pada PR25 dengan AGAT
agat_sp_clean_annotations.pl \
  --gff "$OUT/liftoff/PR25.add_OL.gff3" \
  --out "$OUT/liftoff/PR25.add_OL.gff3_polished"

# 5. Penggabungan backbone ZS97 + gen unik OL → anotasi PR25 final
GFF_BACKBONE="$OUT/liftoff/PR25.from_ZS97.gff3"
GFF_RESCUE_OL="$OUT/liftoff/PR25.add_OL.gff3_polished"

```



```

agat_sp_complement_annotations.pl \
  --ref "$GFF_BACKBONE" \
  --add "$GFF_RESCUE_OL" \
  --out "$OUT/liftoff/PR25.final_ZS97_backbone_plus_OLunique.gff3"

# 6. (Opsional) Ringkasan statistik anotasi PR25 dan RD23
agat_sp_stats_basic.pl \
  --gff "$OUT/liftoff/PR25.final_ZS97_backbone_plus_OLunique.gff3" \
  > "$OUT/liftoff/PR25.final_stats.txt"

agat_sp_stats_basic.pl \
  --gff "$OUT/liftoff/RD23.from_ZS97.gff3" \
  > "$OUT/liftoff/RD23.stats.txt"

```

Pseudocode 5. 5 Implementasi AGAT-Liftoff

Berikut penjelasan dari diberikan:

1. `#!/usr/bin/env bash` dan `set -euo pipefail`: Menentukan skrip dijalankan dengan bash dan memaksa skrip berhenti jika terjadi error, ada variabel yang belum terdefinisi, atau terjadi kegagalan dalam pipeline, sehingga mencegah keluaran yang tidak lengkap.
2. `eval "$(conda shell.bash hook)"` dan `conda activate liftoff`: Menginisialisasi perintah conda di shell WSL dan mengaktifkan environment liftoff yang berisi Liftoff, AGAT, dan gffread dengan konsisten.
 - CPU, OUT, ZS97_FA, ZS97_GFF, OL_FA, OL_GFF, PR25_FA, RD23_FA: Menetapkan jumlah thread CPU (16), direktori keluaran utama (`/mnt/d/result/output_bio`), serta lokasi berkas genom dan anotasi:
 - ZS97 (ZS97.dna_sm.toplevel.fa, ZS97.gff3) dan O. longistaminata (Oryza_longistaminata_v1.0.dna_sm.toplevel.fa, OL.gff3) adalah data publik yang digunakan untuk Penelitian ini.
3. PR25.FINAL.fasta dan RD23.FINAL.fasta adalah hasil assembly genom PR25 dan RD23 yang menjadi target anotasi.
4. Langkah 1 Liftoff ZS97 terhadap PR25
5. Tahap ini yang dimulai dengan liftoff `"$PR25_FA" "$ZS97_FA" \` dapat melakukan proses pemetaan model gen ZS97 (struktur gen, yaitu posisi gen,

mRNA, exon, CDS yang didefinisikan di ZS97.gff3) ke genom PR25.

- -o PR25.from_ZS97.gff3 menyimpan anotasi PR25 hasil pemetaan (backbone).
- -u PR25.from_ZS97.unmapped.txt mencatat gen ZS97 yang tidak terpetakan.
- -sc 0.95 dan -a 0.6 menetapkan ambang cakupan sekuens dan alignment agar hanya gen dengan pemetaan cukup lengkap yang diterima.
- Log proses disimpan ke PR25.from_ZS97.log untuk dokumentasi.

6. Langkah 2 Liftoff ZS97 pada RD23

Perintah Liftoff kedua identik, tetapi genom targetnya RD23 (RD23_FA).

- Output utama RD23.from_ZS97.gff3 digunakan sebagai anotasi RD23 pada tahap ekstraksi CDS/protein.
- RD23.from_ZS97.unmapped.txt hanya berfungsi sebagai catatan kontrol kualitas.

7. Langkah 3 Liftoff OL terhadap PR25

Pada tahap ini yang dimulai dengan liftoff "\$PR25_FA" "\$OL_FA" \ dilakukan pemetaan anotasi *O. longistaminata* ke genom PR25 untuk mencari gen tambahan yang tidak tercakup dalam backbone ZS97. Output PR25.add_OL.gff3 berisi kandidat gen OL yang berada pada koordinat PR25.

8. Langkah 4 Pembersihan anotasi OL (AGAT)

agat_sp_clean_annotations.pl membaca PR25.add_OL.gff3 dan menghasilkan PR25.add_OL.gff3_polished dengan struktur GFF3 yang sudah diperbaiki (relasi ID-Parent konsisten dan fitur yang tidak valid dibuang).

9. Langkah 5 Penggabungan backbone dan gen OL (AGAT)

Pada tahap ini yang dimulai dengan agat_sp_complement_annotations.pl bertujuan untuk menambahkan gen dari hasil pemetaan OL yang belum ada dalam backbone ZS97→PR25.

Output PR25.final_ZS97_backbone_plus_OLunique.gff3 adalah anotasi PR25 final yang dipakai pada tahap ekstraksi CDS dan protein.

5.4.2 Ekstraksi CDS dan Protein dengan Gffread

Setelah anotasi genom PR25 dan RD23 selesai dibangun, tahap *preprocessing* berikutnya adalah mengekstrak himpunan CDS dan protein yang konsisten dengan

anotasi final. Tahap ini menggunakan gffread dengan pasangan input berupa genom FASTA dan berkas anotasi GFF3 yang dihasilkan pada tahap sebelumnya. Hasil ekstraksi berupa berkas FASTA CDS dan protein akan digunakan pada analisis orthologi (OrthoFinder), anotasi fungsi (EggNOG-mapper v2), dan analisis domain protein (InterProScan).

```
# Aktivasi environment yang berisi gffread
OUT="/mnt/d/result/output_bio"

# Genom target (hasil assembly)
PR25_FA="/mnt/d/TA1/pr25/01.chromosome/result/3ddna/review/PR25.FINAL.
fasta"
RD23_FA="/mnt/d/TA1/Rd23/02.chromosome/result/3ddna/review/RD23.FINAL.
fasta"

# Anotasi final PR25 dan anotasi RD23 dari hasil Liftoff
PR25_GFF="$OUT/liftoff/PR25.final_ZS97_backbone_plus_OLunique.gff3"
RD23_GFF="$OUT/liftoff/RD23.from_ZS97.gff3"

mkdir -p "$OUT/proteins"

# 1) Ekstraksi CDS & protein dari PR25
gffread "$PR25_GFF" \
  -g "$PR25_FA" \
  -x "$OUT/proteins/PR25.final.cds.all.fa" \
  -y "$OUT/proteins/PR25.final.pep.all.fa"

# 2) Ekstraksi CDS & protein dari RD23
gffread "$RD23_GFF" \
  -g "$RD23_FA" \
  -x "$OUT/proteins/RD23.final.cds.all.fa" \
  -y "$OUT/proteins/RD23.final.pep.all.fa"
```

Pseudocode 5. 6 Ekstraksi CDS dan Protein dengan Gffread

Pada kodingan tersebut, variabel OUT digunakan untuk menetapkan direktori keluaran utama (/mnt/d/result/output_bio), sedangkan PR25_FA dan RD23_FA menunjuk ke berkas genom PR25 dan RD23 hasil assembly pada sisi WSL. Berkas anotasi PR25_GFF dan RD23_GFF mengacu pada

PR25.final_ZS97_backbone_plus_OLunique.gff3, yaitu anotasi PR25 final hasil penggabungan backbone ZS97 dan gen unik *Oryza longistaminata*, serta RD23.from_ZS97.gff3 yang merupakan anotasi RD23 hasil pemetaan dengan LiftOff pada tahap sebelumnya. Perintah `mkdir -p "$OUT/proteins"` digunakan untuk memastikan direktori keluaran proteins tersedia sebagai lokasi penyimpanan semua berkas FASTA yang dihasilkan.

Pemanggilan `gffread "$PR25_GFF" -g "$PR25_FA" -x "$OUT/proteins/PR25.final.cds.all.fa" -y "$OUT/proteins/PR25.final.pep.all.fa"` mengekstraksi sekuens CDS dari genom PR25 berdasarkan anotasi GFF3 final dan menyimpannya ke dalam berkas PR25.final.cds.all.fa melalui opsi -x, sekaligus menerjemahkan CDS tersebut menjadi sekuens asam amino dan menuliskannya ke PR25.final.pep.all.fa melalui opsi -y. Perintah `gffread` kedua menjalankan prosedur yang sama untuk genom RD23 dengan pasangan input RD23.FINAL.fasta dan RD23.from_ZS97.gff3, sehingga diperoleh berkas RD23.final.cds.all.fa dan RD23.final.pep.all.fa sebagai himpunan CDS dan protein RD23. Hasil ekstraksi `gffread` berupa empat berkas FASTA, yaitu PR25.final.cds.all.fa dan RD23.final.cds.all.fa yang berisi sekuens CDS, serta PR25.final.pep.all.fa dan RD23.final.pep.all.fa yang berisi sekuens protein. Pada penelitian ini, hanya berkas protein (.pep.all.fa) yang kemudian dibersihkan dan difilter lebih lanjut untuk menghasilkan himpunan protein final yang digunakan sebagai masukan pada analisis orthologi dengan OrthoFinder, anotasi fungsi dengan EggNOG-mapper v2, serta analisis domain dan keluarga protein dengan InterProScan.

5.4.3 Pembersihan Sekuen Protein

Sebelum dianalisis dengan OrthoFinder, sekuens protein hasil anotasi masih dapat mengandung karakter yang tidak diinginkan (misalnya . atau *) serta format huruf yang tidak konsisten (campuran huruf kecil dan besar). Karakter dan format yang tidak seragam ini berpotensi mengganggu proses pencarian kesamaan sekuens dan multiple sequence alignment, sehingga perlu dibersihkan terlebih dahulu. Pada tahap ini dilakukan pembersihan sekuens protein untuk ketiga genom (PR25, RD23, dan *Oryza longistaminata*) menggunakan skrip shell dan AWK, kemudian hasil yang telah dibersihkan disiapkan dalam direktori khusus sebagai input untuk

Institut Teknologi Del

OrthoFinder.

```
# Membuat direktori kerja untuk input OrthoFinder dan protein yang
sudah dibersihkan
mkdir -p "/mnt/d/result/output_bio/orthofinder_input"
mkdir -p "/mnt/d/result/output_bio/clean_proteins"

# Mendefinisikan script AWK untuk membersihkan sekuens protein
CLEAN='/^>/{print; next} {gsub(/[\.*]/,"",$0); print toupper($0)}'

# Membersihkan sekuens protein PR25
awk "$CLEAN" "/mnt/d/result/output_bio/proteins/PR25.final.pep.all.fa" \
\
> "/mnt/d/result/output_bio/clean_proteins/PR25.clean.fa"

# Membersihkan sekuens protein RD23
awk "$CLEAN" "/mnt/d/result/output_bio/proteins/RD23.final.pep.all.fa" \
\
> "/mnt/d/result/output_bio/clean_proteins/RD23.clean.fa"

# Membersihkan sekuens protein O. longistaminata
awk "$CLEAN" "/mnt/d/result/unzip/O_longistaminata.pep.all.fa" \
> "/mnt/d/result/output_bio/clean_proteins/OL.clean.fa"

# Membuat symlink dari file clean ke folder input OrthoFinder
ln -s "/mnt/d/result/output_bio/clean_proteins/PR25.clean.fa" \
"/mnt/d/result/output_bio/orthofinder_input/PR25.fa"

ln -s "/mnt/d/result/output_bio/clean_proteins/RD23.clean.fa" \
"/mnt/d/result/output_bio/orthofinder_input/RD23.fa"

ln -s "/mnt/d/result/output_bio/clean_proteins/OL.clean.fa" \
"/mnt/d/result/output_bio/orthofinder_input/OL.fa"

# Quality control cepat: mengecek apakah masih ada karakter . atau *
di file input
grep -n "[.*]" "/mnt/d/result/output_bio/orthofinder_input/*.fa" |
head
```

Pseudocode 5. 7 Pembersihan Sekuen Protein

Berikut penjelasan pada kodingan tersebut:

1. `mkdir -p "/mnt/d/result/output_bio/orthofinder_input"`
Fungsi: membuat direktori `orthofinder_input` untuk menampung berkas FASTA protein yang akan digunakan sebagai input OrthoFinder. Opsi `-p` memastikan perintah tidak gagal jika direktori sudah ada.
2. Output: direktori `/mnt/d/result/output_bio/orthofinder_input/`.
3. `mkdir -p "/mnt/d/result/output_bio/clean_proteins"`
Fungsi: membuat direktori `clean_proteins` untuk menyimpan berkas FASTA protein yang telah dibersihkan.
4. Output: direktori `/mnt/d/result/output_bio/clean_proteins/`.

5. `CLEAN='/^>/{print; next} {gsub(/[*]/,"",$0); print toupper($0)}'`

Fungsi: mendefinisikan skrip AWK bernama CLEAN yang akan digunakan berulang untuk membersihkan isi berkas FASTA.

6. `^>` : pola untuk mengenali baris header FASTA (baris yang diawali >).

- `{print; next}` : untuk baris header, baris dicetak apa adanya kemudian eksekusi dilanjutkan ke baris berikutnya tanpa diproses lebih lanjut.
- `gsub(/[*]/,"",$0)` : pada baris sekuens, menghapus seluruh karakter . dan *.
- `toupper($0)` : mengubah sekuens menjadi huruf besar semua.
- `print` : mencetak baris sekuens yang sudah dibersihkan dan diubah ke huruf besar.

Output: tidak menghasilkan berkas baru; hanya menyimpan “aturan pembersihan” yang kemudian digunakan oleh perintah awk berikutnya.

7. `awk "$CLEAN" "/mnt/d/result/output_bio/proteins/PR25.final.pep.all.fa" > "/mnt/d/result/output_bio/clean_proteins/PR25.clean.fa"`

Fungsi: menjalankan skrip AWK CLEAN pada berkas protein PR25 mentah dan menyimpan hasilnya ke berkas baru. Output: berkas FASTA `/mnt/d/result/output_bio/clean_proteins/PR25.clean.fa` yang berisi header yang sama dengan berkas asal, tetapi sekuens proteinnya telah dibersihkan dari karakter . dan * serta seluruh residu ditulis dalam huruf besar.

8. Perintah awk untuk RD23 dan O. longistaminata

Fungsi: melakukan langkah pembersihan yang sama pada berkas:

- `RD23.final.pep.all.fa` menjadi `RD23.clean.fa`
- `O_longistaminata.pep.all.fa` menjadi `OL.clean.fa`
- Output:
- `/mnt/d/result/output_bio/clean_proteins/RD23.clean.fa`
- `/mnt/d/result/output_bio/clean_proteins/OL.clean.fa`

9. `ln -s "/mnt/d/result/output_bio/clean_proteins/PR25.clean.fa" "/mnt/d/result/output_bio/orthofinder_input/PR25.fa"`

Fungsi: membuat symbolic link bernama `PR25.fa` di direktori `orthofinder_input` yang menunjuk ke berkas asli `PR25.clean.fa` di direktori `clean_proteins`. Dengan kata lain, `PR25.fa` bertindak seperti shortcut atau jalan pintas menuju `PR25.clean.fa`. Ketika OrthoFinder membaca `PR25.fa`,

sistem akan mengarahkan akses tersebut ke isi PR25.clean.fa.

Output: entri baru /mnt/d/result/output_bio/orthofinder_input/PR25.fa yang berperilaku sebagai berkas protein PR25 untuk OrthoFinder, tetapi tanpa menduplikasi isi berkas.

10. Perintah ln -s untuk RD23 dan OL

Fungsi: membuat symbolic link RD23.fa dan OL.fa di direktori orthofinder_input yang masing-masing menunjuk ke RD23.clean.fa dan OL.clean.fa.

Output di direktori /mnt/d/result/output_bio/orthofinder_input/:

- PR25.fa: link ke PR25.clean.fa
- RD23.fa: link ke RD23.clean.fa
- OL.fa: link ke OL.clean.fa

Dengan demikian, direktori orthofinder_input berisi nama-nama berkas yang rapi (PR25.fa, RD23.fa, OL.fa) yang akan digunakan sebagai input OrthoFinder, sementara data proteinnya tetap diambil dari berkas .clean.fa tanpa duplikasi.

11. grep -n "[.*]" "/mnt/d/result/output_bio/orthofinder_input/"*.fa | head

Fungsi: melakukan pemeriksaan cepat (quality control) untuk memastikan apakah masih ada karakter . atau * di berkas input yang akan dianalisis OrthoFinder.

- grep -n "[.*]" : mencari baris yang mengandung karakter (.) atau (*) dan menampilkan nomor barisnya.
- "/mnt/d/result/output_bio/orthofinder_input/"*.fa: pencarian dilakukan pada semua berkas FASTA (*.fa) di direktori orthofinder_input.
- | head : membatasi keluaran hanya pada beberapa baris pertama, sehingga log di terminal tetap ringkas.

Output: tidak menghasilkan berkas baru, tetapi menampilkan beberapa baris dari berkas .fa yang masih mengandung . atau * (biasanya hanya muncul pada bagian header, misalnya pada nama scaffold). Informasi ini digunakan untuk memastikan bahwa baris sekuens telah dibersihkan dengan benar.

5.4.4 Implementasi Pipeline Analisis

Subbab ini menjelaskan implementasi yang digunakan untuk menganalisis hasil dari data preprocessing. Adapun kodingan untuk subbab 5.4.4 ini dibuat dalam bab lampiran.

5.4.4.1 Implementasi Analisis Anotasi Gen Hasil Liftoff

Subbab ini menjelaskan implementasi kode program untuk menganalisis anotasi gen hasil liftoff pada genom PR25, RD23, dan PR25 final (backbone ZS97 + gen unik *O. longistaminata*). Analisis ini mencakup:

1. Perhitungan jumlah fitur anotasi (gene, mRNA, dan CDS) dari berkas GFF3 hasil liftoff.
2. Perhitungan jumlah gen referensi yang tidak berhasil dipetakan ke genom target (berkas .unmapped.txt).
3. Visualisasi perbandingan jumlah gen antar genom serta perbandingan gen mapped dan unmapped.

5.4.4.1.1 Fungsi Perhitungan Fitur Anotasi GFF3

Bagian ini mendefinisikan fungsi `count_features()` yang digunakan untuk menghitung jumlah fitur anotasi (gene, mRNA, dan CDS) pada setiap berkas GFF3 hasil liftoff.

5.4.4.1.2 Fungsi Perhitungan Gen Tidak Terpetakan

Selanjutnya, didefinisikan fungsi `count_unmapped()` untuk menghitung jumlah gen referensi ZS97 yang tidak berhasil dipetakan ke genom target (PR25 atau RD23) berdasarkan berkas .unmapped.txt yang dihasilkan liftoff.

5.4.4.1.3 Penyusunan Daftar Berkas Hasil Liftoff

Agar proses analisis lebih terstruktur, semua berkas yang dianalisis (GFF3, (nama file).unmapped.txt, dan file statistik liftoff) didefinisikan dalam bentuk kamus. Pendekatan ini memudahkan pengulangan (loop) pada tahap ringkasan dan visualisasi.

5.4.4.1.4 Visualisasi Jumlah Gen per Genom

Bagian ini mendefinisikan fungsi `plot_gene_counts()` yang bertujuan memvisualisasikan jumlah gen pada ketiga anotasi (PR25_from_ZS97, RD23_from_ZS97, dan PR25_final_backbone_plus_OL) dalam bentuk diagram batang.

5.4.4.1.5 Visualisasi Gen Mapped dan Unmapped

Fungsi kedua, `plot_mapped_vs_unmapped()`, digunakan untuk menampilkan perbandingan jumlah gen mapped dan unmapped pada PR25 dan RD23 dalam bentuk diagram batang bertumpuk (*stacked bar*).

5.4.4.1.6 Fungsi Utama Analisis dan Ringkasan Output

Seluruh fungsi sebelumnya dipanggil di dalam fungsi utama `main()`. Fungsi ini menghitung ringkasan fitur anotasi, menghitung jumlah gen unmapped, menampilkan cuplikan statistik liftoff, dan akhirnya memanggil fungsi visualisasi.

5.4.4.2 Analisis Standarisasi dan Penggabungan Anotasi dengan Hasil AGAT

Subbab ini menjelaskan implementasi kode program untuk menganalisis hasil standarisasi dan penggabungan anotasi gen PR25 menggunakan AGAT. Analisis difokuskan pada tiga berkas GFF3 utama, yaitu:

1. PR25.from_ZS97.gff3 (anotasi backbone PR25 hasil liftoff dari ZS97)
2. PR25.add_OL.gff3 (anotasi gen hasil penambahan *Oryza longistaminata*) dan
3. PR25.final_ZS97_backbone_plus_OLunique.gff3 (anotasi akhir PR25 setelah backbone ZS97 dan gen OL digabung serta distandarisasi dengan AGAT).

Kode program berikut digunakan untuk menghitung jumlah fitur utama (gene, mRNA, dan CDS) pada masing-masing berkas GFF3, kemudian menyusunnya ke dalam sebuah tabel ringkasan.

5.4.4.2.1 Fungsi `count_features_gff3` dan inisialisasi penghitung

Pada tahap ini, diperlukan sebuah fungsi bantu yang dapat membaca berkas anotasi GFF3 dan secara otomatis menghitung jumlah fitur penting yang akan dipantau,

yaitu gene, mRNA, dan CDS. Fungsi `count_features_gff3` dirancang sebagai komponen inti untuk melakukan rekapitulasi tersebut pada setiap berkas anotasi hasil Liftoff dan AGAT. Fungsi ini tidak hanya menentukan tipe fitur mana yang akan dihitung melalui parameter, tetapi juga menyiapkan struktur penghitung yang akan menampung hasil perhitungan dalam bentuk yang terstandar sehingga mudah digabungkan dan dianalisis pada langkah berikutnya.

5.4.4.2.2 Membaca baris per baris dari file GFF3

Setelah fungsi dan penghitung diinisialisasi, langkah berikutnya adalah mengatur cara berkas GFF3 dibaca dan dipilah sehingga hanya baris anotasi yang relevan yang diproses. Pada bagian ini, kode difokuskan untuk membuka berkas anotasi, membaca isinya secara berurutan baris demi baris, serta menyaring baris komentar atau baris yang tidak memuat informasi fitur. Mekanisme pembacaan bertahap ini memastikan bahwa struktur GFF3 tetap dihormati, sekaligus memberi dasar yang bersih untuk proses ekstraksi tipe fitur pada langkah selanjutnya.

5.4.4.2.3 Pembacaan Berkas GFF3 dan Rekapitulasi Jumlah Fitur

Setelah baris-baris anotasi yang tidak relevan disaring, langkah berikutnya adalah mengekstraksi tipe fitur dari setiap baris yang valid dan mengakumulasi jumlah kemunculannya. Selain itu, hasil perhitungan perlu dirangkum ke dalam struktur data yang seragam agar dapat digabungkan untuk beberapa berkas sekaligus. Bagian kode berikut mengatur proses pemecahan baris menjadi kolom, pemilihan kolom tipe fitur, penambahan nilai pada penghitung, serta penyusunan ringkasan akhir ke dalam sebuah *dictionary* untuk setiap berkas GFF3.

5.4.4.2.4 Memanggil fungsi untuk setiap file dan membuat DataFrame

Setelah fungsi `count_features_gff3` berhasil menyusun ringkasan jumlah fitur untuk satu berkas anotasi, langkah terakhir adalah menerapkan fungsi yang sama ke seluruh berkas GFF3 PR25 yang dianalisis, lalu menggabungkan hasilnya ke dalam sebuah tabel. Dengan cara ini, perbandingan jumlah gene, mRNA, dan CDS antar-tahap (hasil Liftoff awal, penambahan gen *O. longistaminata*, dan anotasi final setelah AGAT) dapat dilakukan secara sistematis. Potongan kode berikut

menunjukkan bagaimana fungsi dipanggil untuk setiap berkas, hasilnya dikumpulkan dalam bentuk list, kemudian dikonversi menjadi DataFrame pandas dan ditampilkan sebagai ringkasan statistik anotasi.

5.4.4.3 Implementasi analisis Ekstraksi CDS dan Protein dengan Hasil

Gffread

Pada tahap ini dilakukan analisis panjang sekuens protein yang dihasilkan dari proses ekstraksi CDS dan translasi protein menggunakan gffread. Sebelumnya, gffread diterapkan pada kombinasi berkas genom (PR25.FINAL.fasta dan RD23.FINAL.fasta) dan anotasi gen hasil Liftoff (PR25.from_ZS97.gff3 dan RD23.from_ZS97.gff3) untuk mengekstrak CDS dan menerjemahkannya menjadi sekuens protein dalam format FASTA, sehingga diperoleh berkas PR25.final.pep.all.fa dan RD23.final.pep.all.fa. Kedua berkas ini kemudian dianalisis lebih lanjut menggunakan skrip Python guna mengevaluasi jumlah sekuens protein yang dihasilkan serta sebaran panjangnya sebagai salah satu bentuk quality control terhadap hasil anotasi dan ekstraksi CDS.

5.4.4.4 Implementasi Analisis Pembersihan Sekuen Protein

Setelah sekuens protein diperoleh dari tahapan ekstraksi CDS dan translasi menggunakan gffread (berkas PR25.final.pep.all.fa, RD23.final.pep.all.fa, dan Oryza_longistaminata.O_longistaminata_v1.0.pep.all.fa), dilakukan tahap pembersihan sekuens (cleaning) untuk memastikan bahwa sekuens protein yang digunakan pada analisis lanjutan (OrthoFinder, EggNOG-mapper, dan InterProScan) telah bebas dari karakter yang tidak valid, konsisten formatnya, dan siap dianalisis secara komputasional. Hasil pembersihan ini disimpan dalam berkas PR25.clean.fa, RD23.clean.fa, dan OL.clean.fa. Untuk mengevaluasi dampak pembersihan terhadap sekuens protein, disusun melalui kodingan yang membandingkan berkas sebelum cleaning (.final.pep.all.fa atau proteom publik) dan sesudah cleaning (.clean.fa) untuk masing-masing spesies. Berikut alur kerja skrip analisis pembersihan sekuens terdiri atas tiga komponen utama:

1. Fungsi pembacaan berkas FASTA,
2. Fungsi perhitungan statistik panjang sekuens, dan

3. Fungsi ringkasan perbandingan antara berkas final dan clean.

5.4.5 Implementasi Analisis Orthologi dengan Orthofinder

Setelah sekuens protein PR25, RD23, dan *Oryza longistaminata* dibersihkan dan disusun menjadi tiga berkas FASTA terpisah (PR25.fa, RD23.fa, dan OL.fa), tahap berikutnya adalah melakukan analisis orthologi menggunakan OrthoFinder v2.5.5. OrthoFinder mengotomatisasi serangkaian langkah analisis komparatif, mulai dari pencarian kesamaan sekuens all-versus-all, pengelompokan gen homolog ke dalam orthogroup, hingga inferensi pohon gen dan pohon spesies ter-root. Dalam implementasi ini, OrthoFinder dikonfigurasi untuk menggunakan DIAMOND sebagai mesin pencarian kesamaan sekuens, MAFFT sebagai program *multiple sequence alignment (MSA)*, dan IQ-TREE sebagai perangkat lunak inferensi pohon gen, dengan memanfaatkan 16 thread CPU untuk mempercepat komputasi. Sebelum menjalankan OrthoFinder untuk mengidentifikasi orthogroup dan hubungan ortholog–paralog antara PR25, RD23, dan *O. longistaminata*, terlebih dahulu dilakukan instalasi OrthoFinder beserta perangkat lunak pendukung utamanya di dalam satu environment conda tersendiri.

5.4.6 Implementasi Anotasi Fungsi Gen dengan EggNOG-mapper

Anotasi fungsi protein untuk genom *Oryza sativa indica* cv. PR25, *O. sativa indica* cv. RD23, dan *Oryza longistaminata* pada penelitian ini dilakukan menggunakan eggNOG-mapper v2. EggNOG-mapper v2 merupakan pengembangan dari eggNOG-mapper generasi pertama yang melakukan anotasi fungsi skala genom berdasarkan penugasan orthology yang telah dipra-hitung dalam basis data eggNOG v5, serta menyediakan fitur tambahan seperti prediksi domain protein cepat dan dekorasi berkas GFF secara otomatis [64].

Basis data eggNOG 5.0 sendiri menyusun >5.000 organisme dan >4 juta orthologous groups dalam kerangka hirarkis lintas takson (bakteri, archaea, eukariota, virus) dengan anotasi fungsi terkurasi [93]. Hal ini membuat eggNOG 5.0 menjadi salah satu sumber utama untuk anotasi fungsi berbasis orthology, termasuk untuk genom tanaman budidaya seperti padi yang sudah terwakili di dalam koleksi orthologous groups tersebut.

Dalam penelitian ini, eggNOG-mapper dimanfaatkan untuk mentransfer informasi fungsi (kategori COG/eggNOG, istilah Gene Ontology (GO), jalur metabolik, dan domain Pfam) dari ortholog yang telah teranotasi ke sekuens protein PR25, RD23, dan *O. longistaminata*. Informasi ini kemudian diintegrasikan dengan hasil analisis orthologi (OrthoFinder) dan analisis domain/motif protein (InterProScan) pada subbab berikutnya untuk mengidentifikasi kelompok gen yang berpotensi terkait dengan ketahanan, rhizomatousness, dan sifat agronomis penting lainnya.

1. Persiapan berkas input protein

Sekuens protein yang dianotasi merupakan hasil pembersihan sekuens protein (lihat subbab 5.4.3) dan disimpan dalam berkas:

- D:\result\output_bio\clean_proteins\PR25.clean.fa
- D:\result\output_bio\clean_proteins\RD23.clean.fa
- D:\result\output_bio\clean_proteins\OL.clean.fa

Karena antarmuka web eggNOG-mapper menerima input berupa FASTA terkompresi gzip (.fa.gz), masing-masing berkas dikompresi di lingkungan WSL2/Ubuntu menggunakan perintah berikut:


```
gzip -c /mnt/d/result/output_bio/clean_proteins/PR25.clean.fa  
> /mnt/d/result/output_bio/PR25.clean.fa.gz  
gzip -c  
/mnt/d/result/output_bio/clean_proteins/RD23.clean.fa >  
/mnt/d/result/output_bio/RD23.clean.fa.gz  
gzip -c /mnt/d/result/output_bio/clean_proteins/OL.clean.fa  
> /mnt/d/result/output_bio/OL.clean.fa.gz
```

Pseudocode 5. 8 Zip Output dari Pembersihan Sekuen Protein

Opsi -c memastikan berkas FASTA asli tetap dipertahankan, sementara hasil kompresi ditulis ke berkas baru dengan ekstensi .fa.gz. Dengan demikian diperoleh tiga berkas input (PR25.clean.fa.gz, RD23.clean.fa.gz, dan OL.clean.fa.gz) yang kemudian diunggah satu per satu ke server eggNOG-mapper.

2. Pengaturan tipe data, pemilihan database eggNOG 5, dan alasan tidak memakai Novel Families

Pengaturan awal di antarmuka web dilakukan sebagai berikut:



Gambar 5. 1 Tampilan EggNOG-mapper

Dalam proses pada gambar 5.1, menggunakan data protein sehingga pilih opsi Proteins karena input merupakan sekuens asam amino hasil prediksi gen dan pembersihan, bukan genom mentah atau CDS.

Bagian basis data pada *Search against database: eggNOG 5* (database utama) diatur untuk menggunakan eggNOG 5 sebagai database target. Pada jurnal [64] menjelaskan bahwa eggNOG-mapper v2 telah sepenuhnya diperbarui untuk memakai data orthology dan anotasi fungsi dari eggNOG v5, yang dioptimalkan untuk anotasi genom dan metagenom skala besar [64]. Pada jurnal [93], menegaskan bahwa eggNOG 5.0 mencakup ribuan genom eukariota termasuk tanaman darat, sehingga menyediakan landasan kuat untuk anotasi genom tanaman seperti *Oryza sativa* [93]. Meskipun genom PR25 dan RD23 merupakan varietas internal yang belum dipublikasikan sebagai genom referensi di basis data publik, keduanya tetap berasal dari spesies yang sudah sangat dikenal, yaitu *Oryza sativa* ssp. *indica*. Secara evolusioner, gen-gen PR25 dan RD23 diharapkan memiliki banyak ortholog dengan genom padi lain (misalnya 9311, Nipponbare, dan kultivar lain) yang sudah terindeks dalam orthologous groups eggNOG. Dengan demikian, anotasi berbasis orthology di eggNOG 5 tetap relevan untuk kedua varietas ini, karena fungsi gen ditransfer dari ortholog padi dan tanaman darat lain yang sudah teranotasi.

Alasan tidak menggunakan database “Novel Families” di eggNOG-mapper
Versi terbaru eggNOG-mapper telah mengintegrasikan katalog novel protein families (FESNov) dan menyediakannya sebagai opsi database Novel Families.

Dalam artikel [94], menunjukkan bahwa katalog ini dibangun terutama dari gen-gen “unknown” pada mikroorganisme yang belum dibudidayakan dan dataset metagenom lingkungan, dengan tujuan mendefinisikan keluarga protein baru yang tidak terwakili di orthologous groups konvensional [94]. Fokus utama FESNov dan Novel Families adalah mengelompokkan ORF tak dikenal dari bakteri dan archaea yang sulit dikarakterisasi, menyediakan anotasi awal untuk metagenom mikroba yang sangat berbeda dari organisme model, bukan menggantikan basis data orthology utama untuk organisme yang sudah terwakili secara baik seperti padi [94].

Dalam konteks penelitian ini:

- PR25 dan RD23 adalah varietas baru dalam spesies *O. sativa indica*, bukan spesies baru dan bukan berasal dari komunitas mikroba lingkungan.
- Tujuan penelitian adalah menghubungkan gen PR25 dan RD23 dengan ortholog padi dan kerabat lainnya yang sudah dikenal untuk sifat ketahanan, rhizomatousness, dan self-incompatibility, bukan melakukan eksplorasi besar-besaran keluarga gen mikroba yang belum terkarakterisasi.
- Menggunakan Novel Families berpotensi menghasilkan banyak anotasi “keluarga baru” yang minim informasi fungsi (GO/KEGG) dan kurang relevan untuk genom padi, sehingga justru menambah kebisingan dan menyulitkan interpretasi biologis.
- Oleh karena itu, pada penelitian ini tidak mengaktifkan database Novel Families dan hanya menggunakan basis data utama eggNOG 5, yang lebih sesuai dengan tujuan untuk memetakan gen PR25, RD23, dan *O. longistaminata* ke ortholog tanaman yang sudah teranotasi dengan baik.

Secara internal, eggNOG-mapper v2 menggunakan DIAMOND sebagai sequence search engine default untuk memetakan protein query ke orthologous groups eggNOG dengan kecepatan tinggi dan sensitivitas yang baik untuk anotasi fungsi skala genom [64].

3. Pengaturan filter pencarian (search filters), alasan tidak memakai ambang 90%, dan mengapa setiap parameter berbeda

Pada tahap anotasi dengan eggNOG-mapper v2, filter pencarian diatur sebagai berikut:

- Minimum hit e-value = 0,001 ($1e-3$)
- Minimum hit bit-score = 60
- Percentage identity = 40%
- Minimum % query coverage = 50%
- Minimum % subject coverage = 50%

Keempat parameter ini sengaja tidak disetarakan menjadi 90% karena masing-masing merepresentasikan aspek yang berbeda (signifikansi statistik, kekuatan alignment, tingkat kemiripan residu, dan proporsi panjang sekuens yang sejajar). Jika semuanya “ditarik” ke 90%, hampir semua hit lintas genom padi akan terbuang dan hanya menyisakan sekuens yang sangat mirip di dalam satu genom saja. Di bawah ini penjelasan untuk setiap parameter:

E-value minimum $1e-3$

E-value mengukur berapa banyak alignment dengan skor sama atau lebih baik yang diharapkan muncul secara kebetulan dalam basis data. Semakin kecil nilainya, semakin ketat filter yang dipakai.

Berdasarkan jurnal [95], dikatakan bahwa kinerja prediksi GO dengan strategi homology sangat bergantung pada kombinasi tool dan pengaturan parameter pencarian, termasuk E-value yang menunjukkan bahwa pengaturan E-value yang terlalu ketat menurunkan recall, sedangkan pengaturan moderat (misalnya $1e-3$ – $1e-5$) memberikan keseimbangan yang baik antara sensitivitas dan spesifisitas pada benchmark besar [95]. Berdasarkan paper [96] pada AnnotaPipeline dikatakan bahwa BLASTp dijalankan dengan E-value $1e-5$ dan anotasi dipilih berdasarkan hit dengan bit-score tertinggi, menunjukkan bahwa rentang E-value $1e-3$ – $1e-5$ merupakan praktik umum pada pipeline anotasi fungsional skala genom, bukan nilai ekstrem seperti $1e-20$ atau $1e-50$ yang akan mengorbankan banyak hit bermakna [96].

Dengan mempertimbangkan dua studi tersebut, E-value $1e-3$ dipilih sebagai batas moderat: cukup kecil untuk menghilangkan kecocokan acak, tetapi tidak seketat $1e-$

10 atau lebih kecil sehingga masih mempertahankan ortholog yang divergen antar genom PR25, RD23, dan *O. longistaminata*. Karena sudah dikombinasi dengan filter identitas, coverage, dan bit-score, tidak perlu mengatur E-value sampai ekstrem (misalnya $1e-90$).

Bit-score minimum 60

Bit-score menggambarkan kekuatan alignment yang telah dinormalisasi terhadap ukuran basis data. Semakin tinggi bit-score, semakin kecil peluang alignment tersebut muncul secara acak.

Berdasarkan paper [96], dikatakan bahwa pada AnnotaPipeline, anotasi dipilih berdasarkan hit dengan bit-score tertinggi setelah menerapkan filter identitas dan coverage minimum, menegaskan bahwa bit-score yang tinggi merupakan indikator kualitas alignment yang penting untuk transfer anotasi [96]. Berdasarkan jurnal [95], dikatakan bahwa dalam evaluasi besar mereka, kombinasi parameter yang menghasilkan F-measure terbaik untuk prediksi GO selalu melibatkan penyaringan terhadap alignment yang cukup kuat, bukan semua hit dengan skor rendah. Jurnal tersebut menekankan pentingnya pemilihan skor dan E-value yang memberikan trade-off optimal antara sensitivitas dan ketepatan [95].

Dengan mengacu pada itu, $\text{bit-score} \geq 60$ digunakan sebagai batas praktis untuk membuang alignment yang terlalu pendek atau lemah. Jika ambang dinaikkan menjadi 90 atau lebih tinggi, kombinasi dengan identitas $\geq 40\%$ dan coverage $\geq 50\%$ akan membuat banyak ortholog yang secara biologis relevan ikut tereliminasi, sehingga cakupan anotasi menjadi terlalu sempit.

Percentage identity 40%

Persentase identitas menunjukkan proporsi residu yang identik antara dua sekuens. Pada bagian ini dipakai 40% sebagai batas bawah, bukan 70% atau 90%, karena: Berdasarkan jurnal [97], dikatakan bahwa pipeline mereka melakukan “sequence filtering” dengan syarat hasil pencarian harus memiliki setidaknya 40% kesamaan sekuens dan 60% cakupan penyelarasan dari sekuens kueri dan sekuens target sebelum transfer GO dilakukan, sehingga 40% digunakan sebagai cutoff praktis

untuk anotasi yang andal [97]. Berdasarkan jurnal [96], dikatakan bahwa AnnotaPipeline mensyaratkan sequence identity 40% dan coverage $\geq 30\%$ sebagai ambang minimal untuk transfer anotasi dari homolog, kembali menunjukkan bahwa 40% adalah nilai yang umum dipakai untuk pipeline anotasi eukariot skala besar [96]. Berdasarkan jurnal [98], dikatakan bahwa model prediksi substrat enzim mereka mencapai akurasi 83% ketika pasangan enzim memiliki identitas sekuens 40–60%, jauh lebih tinggi dibanding interval 0–40%, sehingga rentang di atas 40% identitas dikaitkan dengan pelestarian fungsi dan spesifisitas yang lebih baik [98].

Dari tiga contoh tersebut terlihat bahwa 40% identitas diperlakukan sebagai batas antara homolog “dekat” yang masih cukup aman untuk transfer fungsi dan homolog “jauh” di bawah 30% yang masuk twilight zone. Jika identitas dibuat 70% atau 90%, ortholog antar genom padi (khususnya antara *O. sativa* dan *O. longistaminata*) hampir pasti terbuang, dan analisis tidak lagi menangkap kontribusi gen yang telah mengalami divergensi namun masih fungsional.

Coverage minimal 50% untuk query dan subject

Coverage menunjukkan berapa persen panjang sekuens query dan subject yang tercakup oleh alignment. Di sini digunakan batas $\geq 50\%$ untuk kedua arah.

Berdasarkan jurnal [97], [99], dikatakan bahwa PANNZER2 menerapkan filter “at least 40% sequence identity and 60% alignment coverage of both the query and target sequences” sebelum sebuah hit dipertimbangkan untuk transfer GO, sehingga coverage 60% menjadi praktik standar pada salah satu server anotasi fungsi yang sering dipakai [97], [99].


Berdasarkan jurnal [96], dikatakan bahwa AnnotaPipeline menggunakan coverage minimal 30% bersamaan dengan identitas 40% dan “sequence positivity” 60% untuk transfer anotasi, menunjukkan bahwa beberapa pipeline memilih cutoff coverage yang sedikit lebih longgar ketika dikombinasikan dengan filter lain yang ketat [96].

Dengan referensi tersebut, coverage 50% dipilih sebagai kompromi di antara praktik yang berbeda:

- Lebih ketat daripada 30% (sehingga mengurangi risiko transfer fungsi hanya dari fragmen pendek),
- Tetapi sedikit lebih longgar dibanding 60%, agar ortholog yang mengalami penambahan/penghilangan domain atau perpanjangan ekor N/C-terminal tetap dapat tertangkap.
- Jika coverage dinaikkan menjadi 90% untuk query dan subject, maka protein yang hanya berbeda beberapa domain atau memiliki segmen terminal tambahan merupakan hal yang sangat umum pada gen ketahanan dan regulator tanaman sehingga akan tersaring habis, padahal perubahan domain tidak selalu berarti fungsi utama berubah total.

Dengan demikian, kombinasi E-value $1e-3$, bit-score ≥ 60 , identitas $\geq 40\%$, dan coverage $\geq 50\%$ bukan sekadar mengikuti default EggNOG-mapper, tetapi disusun supaya sejalan dengan praktik terbaik pada berbagai pipeline anotasi modern (PANNZER, AnnotaPipeline), tidak terlalu ketat seperti 90% yang akan menghilangkan sebagian besar ortholog divergen antara PR25, RD23, dan O. longistaminata, sehingga justru melemahkan tujuan analisis komparatif genom padi di penelitian.

4. Pengaturan opsi anotasi (annotation options) dan justifikasinya



Gambar 5. 2 Tampilan Opsi Anotasi pada EggNOG-mapper

Pada bagian “Annotation options”, pengaturan yang digunakan adalah Taxonomic
Institut Teknologi Del

Scope: “Auto adjust per query (RECOMMENDED)”. Berdasarkan jurnal [64], menjelaskan bahwa eggNOG-mapper v2 secara default membatasi transfer anotasi ke ortholog dalam klad taksonomi terdekat untuk mengurangi kesalahan anotasi lintas klad [64]. Dengan memilih “Auto adjust per query”, tool secara otomatis memilih cakupan takson yang relevan per sekuens, sehingga anotasi gen PR25, RD23, dan *O. longistaminata* terutama berasal dari tanaman darat/monokot yang dekat secara evolusioner [96].

Orthology restrictions: “Transfer annotations from any ortholog”

EggNOG-mapper mendukung pembatasan ke one-to-one ortholog, tetapi untuk genom tanaman yang kaya duplikasi gen, hubungan ortholog realistis sering berupa one-to-many atau many-to-many. Pada jurnal [64], menunjukkan bahwa pemodelan orthology yang fine-grained di eggNOG memungkinkan transfer anotasi dari ortholog berbeda tipe, selama didukung homologi yang kuat [64]. Dengan memilih “from any ortholog” dan tetap mempertahankan filter ketat (E-value, skor, identitas, coverage), penelitian ini memaksimalkan cakupan anotasi tanpa melepas kontrol kualitas.

Gene Ontology evidence: “Transfer non-electronic annotations”

Gene Ontology (GO) membedakan anotasi dengan bukti eksperimen/kurasi (non-elektronik) dan anotasi elektronik (IEA). Studi [100], [101], menekankan bahwa anotasi elektronik sangat berguna untuk cakupan luas, tetapi anotasi berbasis bukti non-elektronik cenderung lebih spesifik dan dipercaya untuk analisis yang menuntut akurasi tinggi [100], [101]. Dengan hanya mentransfer non-electronic annotations, penelitian ini secara eksplisit memprioritaskan GO term dengan dukungan eksperimen atau kurasi manual, sehingga meningkatkan keandalan daftar fungsi yang digunakan dalam analisis.

PFAM refinement: “Report PFAM domains from orthologs”


Pfam merupakan salah satu basis data domain protein terkemuka dan menjadi bagian inti dari InterPro. Dalam jurnal [64], dikatakan bahwa PFAM mencakup hampir 22.000 keluarga domain dan digunakan luas dalam karakterisasi domain

protein tanaman, termasuk domain NB-ARC dan LRR pada gen ketahanan [64]. Selain itu, mengaktifkan PFAM refinement memastikan bahwa, selain fungsi (GO, COG/eggNOG, jalur), eggNOG-mapper juga menghasilkan informasi domain Pfam dari ortholog, yang kemudian dikombinasikan dengan hasil InterProScan.

SMART annotation: “Skip SMART annotation”


Karena analisis domain multi-basis data yang lebih komprehensif akan dilakukan pada tahap InterProScan, melewati SMART pada tahap eggNOG-mapper menghemat waktu komputasi server tanpa mengurangi informasi domain secara signifikan. Fokus di eggNOG-mapper adalah anotasi fungsi berbasis orthology dan domain Pfam cepat, sedangkan InterProScan digunakan sebagai tahap lanjutan untuk integrasi domain lintas database.

5. Eksekusi dan *Output* yang dihasilkan



Gambar 5. 3 Server Status EggNOG-mapping

Setelah semua parameter dan opsi anotasi diatur, job dijalankan dengan menekan tombol “Submit”. Status job dapat dipantau melalui tabel “Server Status” pada halaman web eggNOG-mapper. Jika proses selesai, sistem mengirim surel otomatis ke alamat email yang didaftarkan (misalnya mabrina070@gmail.com) berisi ringkasan konfigurasi dan tautan unduhan hasil anotasi.



Gambar 5. 4 Notifikasi EggNOG-mapper melalui Email

Untuk setiap genom (PR25, RD23, dan *O. longistaminata*), diperoleh beberapa berkas keluaran utama:

- berkas anotasi utama (.emapper.annotations)
- berkas anotasi dalam format spreadsheet (.emapper.annotations.xlsx)
- daftar seed orthologs (.emapper.seed_orthologs)
- berkas GFF teranotasi (.emapper.gff) [64].

Seluruh keluaran ini kemudian digunakan pada tahap berikutnya untuk:

- Membandingkan fungsi gen antara PR25, RD23, dan *O. longistaminata* berdasarkan kategori COG/eggNOG, istilah GO, dan jalur metabolik.
- Mengintegrasikan informasi domain Pfam dari eggNOG-mapper dengan hasil InterProScan untuk mengidentifikasi domain-domain kunci (misalnya NB-ARC, LRR, dan domain regulator lainnya) serta kelompok gen yang terkait dengan ketahanan, toleransi stres, dan sifat agronomis penting.

Dengan demikian, implementasi eggNOG-mapper v2 dalam penelitian ini tidak sekadar mengikuti pengaturan bawaan, melainkan disusun dengan menyesuaikan parameter dan opsi anotasi terhadap rekomendasi metodologis terkini dalam anotasi fungsi berbasis orthology serta karakteristik biologis genom PR25, RD23, dan *Oryza longistaminata*, sehingga hasil anotasi fungsinya memiliki cakupan yang luas sekaligus dapat dipertanggungjawabkan secara metodologis.


5.4.7 Implementasi Analisis Domain dan Motif Protein dengan InterProScan

Pada penelitian ini, analisis domain dan motif protein dilakukan menggunakan InterProScan 5.59-91.0 yang diakses melalui platform Galaxy (usegalaxy.eu). InterProScan merupakan perangkat lunak yang men-scan sekuens protein terhadap kumpulan protein signature dari berbagai member database InterPro (misalnya Pfam, PANTHER, PROSITE, SMART, TIGRFAM, dsb.) untuk mengidentifikasi keluarga protein, domain, dan situs fungsional yang terkonservasi.

Dalam konteks InterPro, protein signature adalah model prediktif (misalnya profil hidden Markov model/HMM, pattern, atau profil posisi) yang didesain dari multiple sequence alignment sekelompok protein homolog dan merepresentasikan satu keluarga protein, satu domain, atau satu motif fungsional tertentu. Signature-signature inilah yang disimpan di basis data seperti Pfam dan PROSITE, kemudian diintegrasikan oleh InterPro ke dalam satu entri teranotasi. Berikut tahapannya:

1. Input dan tipe sekuens


InPR25.clean.fa berisi kumpulan sekuens protein PR25 hasil tahapan prediksi dan pembersihan sekuens pada subbab sebelumnya. Berkas ini diunggah ke Galaxy dan dipilih pada parameter “Protein FASTA File”. Pada opsi “Type of the input sequences” dipilih “Protein”, karena InterProScan bekerja pada tingkat sekuens asam amino, bukan pada sekuens DNA genom mentah atau assembly genom. Dengan pengaturan ini, seluruh metode signature yang memang dirancang untuk protein dapat dijalankan secara optimal.



Gambar 5. 5 Tampilan Interproscan melalui website Galaxy

2. Pemilihan basis data InterProScan dan aplikasi utama

Pada bagian “InterProScan database” dipilih “InterProScan 5.59-91.0” sesuai versi yang disediakan Galaxy (Gambar 4). Versi ini memanggil kumpulan signature dari berbagai basis data anggota InterPro yang saling melengkapi.



Gambar 5. 6 Tampilan Basis Data yang digunakan pada Interproscan melalui Galaxy


3. Pada bagian “Applications to run”, semua aplikasi utama untuk anotasi domain dan motif diaktifkan . Daftar aplikasi yang dipilih meliputi:

- TIGRFAM: keluarga protein berbasis profil HMM terkurasi, banyak dipakai untuk anotasi fungsi enzim dan kompleks protein.
- FunFam: functional families dari CATH/FunFam yang mengelompokkan domain ke dalam famili dengan fungsi serupa.
- SFLD: Structure–Function Linkage Database untuk enzim, menekankan hubungan struktur–fungsi.
- SUPERFAMILY: anotasi domain struktural otonom berbasis model SCOP yang menyatukan famili homolog jauh.

- PANTHER: basis data keluarga protein dan pohon filogenetik yang mengelompokkan gen ke dalam famili dan subfamili dengan anotasi fungsi biologis.
- Gene3D: anotasi domain struktural CATH ke dalam protein, memberikan konteks 3D untuk domain yang terdeteksi.
- HAMAP: anotasi otomatis berkualitas tinggi, terutama untuk protein mikroba, berbasis profil HMM dan aturan anotasi.
- PROSITE Profiles: model profil HMM untuk domain dan motif fungsional yang lebih panjang.
- PROSITE Pattern: motif pendek (patterns) yang merepresentasikan situs aktif, motif pengikatan ion/logam, atau motif regulasi; PROSITE sendiri dideskripsikan sebagai basis data domain, keluarga, dan situs fungsional protein yang terus diperbarui.
- Coils: prediksi daerah coiled-coil, penting untuk protein adaptor dan komponen kompleks multiprotein.
- SMART: dua modul SMART yang memprediksi domain dan arsitektur domain berdasarkan multiple sequence alignment dan model HMM.
- PRINTS: fingerprint motifs, yaitu kombinasi motif pendek konservasi yang mengkarakterisasi suatu keluarga protein.
- PIRSR: keluarga protein berbasis HMM dan aturan situs spesifik (Site Rules).
- PIRSF: keluarga protein UniProt berbasis HMM yang mengelompokkan protein homolog.
- AntiFam: profil HMM untuk mendeteksi dan menandai ORF artifisial/spurious, sehingga membantu memfilter anotasi yang tidak biologis.
- Pfam: salah satu basis data domain/families terbesar yang menggunakan profil HMM untuk mengklasifikasikan protein ke dalam keluarga dan domain; rilis terbaru menambahkan banyak keluarga baru dan memperbarui anotasi domain, termasuk domain yang relevan dengan protein tanaman.
- MobiDBLite: prediksi daerah intrinsically disordered (IDR), yaitu segmen protein yang tidak memiliki struktur 3D tetap namun sering penting untuk regulasi dan interaksi protein.

Kombinasi aplikasi diaktifkan untuk:

- Memaksimalkan cakupan domain dan motif (melalui Pfam, PANTHER, TIGRFAM, SMART, SUPERFAMILY, Gene3D, PRINTS, PIRSF, PIRSR).
- Mengidentifikasi situs fungsional pendek seperti motif aktif atau motif fosforilasi (PROSITE profiles/patterns).
- Menangkap fitur struktural global seperti koil, daerah tidak terlipat, dan domain multi-heliks (Coils, MobiDBLite, SUPERFAMILY, Gene3D).
- Menyaring anotasi yang mungkin artefak (AntiFam), sehingga fokus analisis tetap pada domain yang benar-benar biologis.



Gambar 5. 7 Tampilan Interproscan dengan Aplikasi berlisensi untuk non-komersial melalui Galaxy

4. Aplikasi berlisensi terbatas untuk penggunaan non-komersial

Selain aplikasi utama di atas, InterProScan pada Galaxy menyediakan beberapa program dengan lisensi terbatas. Pada bagian “Use applications with restricted license, only for non-commercial use?” dipilih “Yes” sehingga memungkinkan penggunaan:

- Phobius: prediksi gabungan topologi transmembran dan signal peptide.
- SignalP (eukaryotes): prediksi keberadaan signal peptide dan posisi cleavage site pada protein eukariotik menggunakan pendekatan deep neural networks, yang secara signifikan meningkatkan akurasi dibanding versi sebelumnya.
- TMHMM: prediksi heliks transmembran pada protein membran integral.

Ketiga program ini dipakai karena informasi signal peptide dan heliks transmembran penting untuk membedakan protein yang disekresikan, protein membran plasma, dan protein sitosolik, menafsirkan domain yang ditemukan InterProScan dalam konteks arsitektur membran (misalnya reseptor LRR di membran, kanal ion, transporter). Pengaturan ini tetap sesuai dengan syarat lisensi, karena seluruh analisis pada penelitian ini dilakukan untuk tujuan akademik/non-komersial.

5. Pengaturan anotasi tambahan dan format keluaran

The screenshot shows the 'Additional Options' section of the InterProScan configuration. It includes the following settings:

- Include pathway information:** Set to 'Yes'. Description: 'Option that provides mappings from matches to pathway information, which is based on the matched manually curated InterPro entries. (--pathways)'
- Include Gene Ontology (GO) mappings:** Set to 'Yes'. Description: 'Look up of corresponding Gene Ontology annotation. Implies -iplookup option. (--goterms)'
- Provide additional mappings:** Set to 'No'. Description: 'Provide mappings from matched member database signatures to the InterPro entries that they are integrated into (--iplookup)'
- Output format:** Set to 'Tab-separated values format (TSV)'. Other options include GFF3, XML, and JSON.
- Additional Options:**
 - Email notification:** Set to 'No'. Description: 'Send an email notification when the job completes.'
 - Attempt to re-use jobs with identical parameters?** Set to 'No'. Description: 'This may skip executing jobs that you have already run.'

At the bottom, there is a 'Run Tool' button and a 'Help' section titled 'What it does' which states: 'Interproscan is a batch tool to query the InterPro database. It provides annotations based on multiple searches of profile and other functional databases'.

Gambar 5. 8 Pengaturan Konfigurasi Lanjutan pada Interproscan melalui Galaxy
Pada bagian konfigurasi lanjutan dilakukan pengaturan sebagai berikut:

- *Include pathway information = Yes*
InterProScan diminta menambahkan pemetaan domain yang terdeteksi ke jalur biologis yang terkurasi (misalnya Reactome atau jalur lain yang terhubung melalui InterPro). Hal ini membantu menghubungkan domain tertentu dengan proses biologis tingkat jalur, misalnya lintasan sinyal stres, metabolisme karbohidrat, atau respon imun tanaman.
- *Include Gene Ontology (GO) mappings = Yes*
Setiap entri InterPro yang cocok dengan domain/motif pada protein PR25 secara otomatis dipetakan ke term GO (*Biological Process, Molecular Function, Cellular Component*) yang sudah dikurasi oleh tim InterPro.

Dengan demikian, hasil InterProScan tidak hanya berisi nama domain, tetapi juga anotasi fungsi yang lebih terstandar.

- *Provide additional mappings = No*

Opsi ini dibiarkan pada nilai No, sehingga hanya pemetaan GO dan jalur yang berasal dari entri InterPro yang digunakan. Hal ini menyederhanakan output dan menghindari duplikasi anotasi dari basis data lain yang mungkin tumpang tindih.

- *Output format: TSV, GFF3, XML, JSON*

Beberapa format keluaran diaktifkan sekaligus, yaitu tsv (tab-separated values): tabel ringkas yang berisi, untuk setiap protein, daftar signature yang cocok, ID InterPro, nama domain, posisi domain, serta term GO/jalur terkait. Format ini menjadi basis utama untuk analisis lanjutan dan integrasi dengan hasil OrthoFinder dan EggNOG-mapper di Jupyter Notebook. Lalu, gff3: berkas anotasi berformat standar genom, yang memetakan domain/motif sebagai fitur pada koordinat sekuens protein. Format ini berguna apabila anotasi domain ingin divisualisasikan atau diproyeksikan kembali ke koordinat genom. Lalu, xml dan json: menyimpan struktur anotasi lengkap, termasuk hierarki InterPro, relasi antar domain, dan metadata tambahan. Berkas ini disimpan untuk keperluan dokumentasi dan kemungkinan analisis lanjutan yang memerlukan detail struktur data InterProScan.

Pelaksanaan pada Interproscan dan Output

Setelah semua parameter ditetapkan, analisis dijalankan dengan menekan tombol “Run Tool”. Galaxy mengeksekusi InterProScan 5.59-91.0 sebagai job terpisah dan menghasilkan beberapa berkas output (TSV, GFF3, XML, JSON) di history yang sama. Secara umum, setiap baris pada berkas TSV merepresentasikan:

- Satu hit domain/motif untuk suatu protein PR25
- ID dan nama basis data anggota yang menghasilkan kecocokan (misalnya ID domain Pfam seperti PF00069 atau ID motif PROSITE seperti PS50011)
- ID InterPro terintegrasi
- koordinat domain (start–end pada sekuens protein),
- Term GO dan ID jalur yang relevan.

Dalam penelitian ini, hasil InterProScan kemudian:

- Digabungkan dengan informasi orthogroup dan pasangan gen turunan (PR25-RD23-O. longistaminata) sehingga dapat diidentifikasi domain khas pada gen-gen yang muncul sebagai turunan RD23 saja, OL saja, maupun gabungan.
- Dipakai untuk menandai gen kandidat yang membawa domain terkait ketahanan, sinyal, atau regulasi transkripsi (misalnya domain NBS-LRR, kinase, heliks transmembran reseptor, domain faktor transkripsi tertentu).
- Memberikan konteks struktural (domain, motif, disorder, sinyal sekresi, dan heliks transmembran) yang melengkapi anotasi fungsi berbasis homologi dari EggNOG-mapper.

Dengan demikian, implementasi InterProScan pada subbab ini menjadi komponen penting untuk memahami arsitektur domain dan motif pada genom PR25 (dan pembandingnya), yang kemudian diinterpretasikan dalam konteks ketahanan, adaptasi, dan sifat agronomis lainnya pada bab pembahasan berikutnya.

5.4.8 Implementasi Integrasi Hasil

Pada subbab ini dijelaskan implementasi integrasi hasil analisis orthologi, anotasi fungsi, dan anotasi domain/motif protein ke dalam satu tabel master yang digunakan sebagai dasar analisis gen turunan pada genom PR25. Integrasi dilakukan dengan serangkaian skrip Python yang memanfaatkan keluaran:

- OrthoFinder: berkas orthogroup dan pairwise orthologues (PR25 vs RD23, PR25 vs O. longistaminata),
- EggNOG-mapper v2: berkas anotasi fungsi (deskripsi, GO term, KEGG orthology, dan lintasan),
- InterProScan: berkas anotasi domain dan motif protein (deskripsi domain InterPro, Pfam, dan GO term pendukung).

Secara umum, integrasi dilakukan dalam beberapa tahap. Tahap pertama memfokuskan pada penetapan status ortholog setiap gen PR25 serta penyusunan statistik ringkas jumlah gen per kategori status (RD23_only, OL_only, BOTH, NONE). Tahap ini menjadi fondasi untuk tahap berikutnya, yaitu normalisasi ID

gen, penggabungan anotasi fungsi dari EggNOG-mapper dan InterProScan, serta klasifikasi kategori fungsi biologis.

5.4.8.1 Penentuan Status Ortholog Gen PR25 pada RD23 dan *Oryza longistaminata*

Bertujuan mengklasifikasikan setiap gen PR25 berdasarkan keberadaan relasi ortholog terhadap dua genom pembanding (tetua), yaitu RD23 dan *O. longistaminata*, menggunakan keluaran pairwise orthologues OrthoFinder. Selain status, blok ini juga menambahkan informasi orthogroup (OGs) dan OG_primary agar hasilnya dapat dipakai sebagai dasar integrasi dan analisis lanjutan. Orthogroup merupakan unit dasar untuk analisis komparatif multi-spesies, sementara ortholog sering dipakai untuk perbandingan lintas dua spesies [59].

Input yang digunakan dalam kodingan tersebut:

1. File keluaran OrthoFinder (pairwise orthologues) untuk PR25 vs RD23 dan PR25 vs OL: PR25__v__RD23.tsv, PR25__v__OL.tsv
2. Parameter dan path keluaran:
 - OF_ROOT: direktori hasil OrthoFinder (Results_Sep29)
 - OUT_DIR: folder penyimpanan tabel ringkasan
 - STATUS_TSV: target output PR25_status.tsv
3. Library utama untuk membaca file TSV dan mengelola struktur data: csv, pandas, defaultdict, serta utilitas regex (re) untuk parsing ID/OG.

Proses/Implementasi:

1. Konfigurasi path dan mode eksekusi: program menetapkan lokasi dua file pairwise (PAIR_PR25_RD23 dan PAIR_PR25_OL) serta menentukan apakah hasil hanya ditinjau (preview) atau disimpan permanen (PREVIEW_ONLY). Bagian ini memastikan pipeline dapat direplikasi (jalur input–output eksplisit) dan mencegah error akibat path yang tidak sesuai.
2. Parsing file *pairwise* untuk membentuk peta relasi PR25–partner dan PR25–orthogroup
Fungsi `parse_pairwise_multi()` membaca file TSV pairwise OrthoFinder

dengan langkah inti berikut:

- Membaca header lalu menentukan indeks kolom Orthogroup, kolom PR25, dan kolom partner (RD23 atau OL).
- Memecah isi sel yang dapat berisi banyak ID (dipisah koma) melalui `split_many()` sehingga setiap baris dapat menghasilkan banyak pasangan ortholog.
- Mengisi tiga struktur data, yaitu `pr25_to_partners` (himpunan ID partner untuk tiap PR25_id), `pr25_to_og` (himpunan orthogroup untuk tiap PR25_id), `pr25_all_ids`: himpunan semua ID PR25 yang muncul pada file pairwise
- Langkah ini penting karena output pairwise OrthoFinder sering memuat relasi 1:many atau many:many, sehingga pendekatan berbasis “set” menjaga semua pasangan ortholog tetap tercatat.

3. Menggabungkan hasil PR25–RD23 dan PR25–OL

Keluaran parsing dari dua file pairwise kemudian digabungkan, yaitu `pr25_all = pr25_from_rd23 | pr25_from_ol` sehingga daftar gen PR25 yang diproses adalah semua gen PR25 yang memiliki pasangan ortholog setidaknya pada salah satu parental.

4. Sanity check pola ID (kontrol mutu identitas gen)

Fungsi `frac()` menghitung proporsi ID PR25 (sampel hingga 3000 ID) yang cocok terhadap pola ID “PR25-like” (bercorak hasil liftover/anotasi backbone tertentu), pola ID “OL-like” (bercorak OL). Tujuan langkah ini adalah validasi cepat bahwa kolom PR25 pada output OrthoFinder benar-benar didominasi oleh skema ID yang diharapkan, dan mendeteksi dini kemungkinan masalah seperti pencampuran ID, kontaminasi label FASTA, atau inkonsistensi anotasi. Ini relevan karena kualitas dan konsistensi anotasi gen terbukti dapat mengubah hasil inferensi orthology secara nyata (jumlah gen yang dianggap ber-ortholog, komposisi grup, hingga recall/akurasi) .

5. Penetapan status ortholog per gen PR25

Untuk setiap PR25_id, program mengambil:

- `r_partners`: partner RD23 (jika ada)
- `o_partners`: partner OL (jika ada)

Kemudian menetapkan status:

- BOTH: ada ortholog di RD23 dan OL
- RD23_only: hanya ada ortholog di RD23
- OL_only: hanya ada ortholog di OL
- NONE: tidak ada di keduanya (pada run bernilai 0 karena pr25_all berasal dari gabungan ID yang muncul di pairwise).

Status ini adalah klasifikasi operasional berbasis “terdeteksi/tidak terdeteksi” oleh OrthoFinder pada dataset dan parameter yang digunakan, sehingga bukan bukti tunggal bahwa gen tersebut “berasal” dari tetua tertentu. Perbedaan anotasi, gen terfragmentasi, gen hilang, atau perbedaan prediksi model gen dapat menyebabkan ortholog tidak terdeteksi atau bergeser kategorinya .

6. Penggabungan informasi OG dan pemilihan OG utama

Program menggabungkan orthogroup dari kedua sisi:

- `ogs = rd23_ogs[PR25_id] U ol_ogs[PR25_id]`

Lalu menyimpan:

- OGs = daftar semua OG terkait (sebagai string)
- OG_primary = satu OG representatif yang dipilih deterministik oleh `pick_primary()` (berdasarkan nomor OG terkecil)

Secara praktis, OG_primary dipakai sebagai kunci stabil untuk integrasi tabel lintas langkah (misalnya penggabungan ke anotasi fungsi atau rekap per-orthogroup), sementara OGs mempertahankan informasi lengkap jika sebuah gen terasosiasi dengan lebih dari satu OG pada output pairwise.

Output:

- Output utama, yaitu PR25_status.tsv berisi kolom PR25_id, status, RD23_partner, OL_partner, OGs, OG_primary.
- Output ringkas di layar (log), yaitu proporsi sanity check pola ID, rekap jumlah gen per status (RD23_only, OL_only, BOTH, NONE), dan preview 10 baris pertama sebagai verifikasi format.

Pada penelitian ini, kategori BOTH, RD23_only, OL_only, dan NONE merupakan klasifikasi operasional yang dibangun dari keluaran OrthoFinder, yaitu berdasarkan apakah hubungan ortholog PR25 terhadap RD23 dan/atau O. longistaminata

terdeteksi pada analisis yang dilakukan. Oleh karena itu, status tersebut digunakan sebagai indikator komputasional untuk merangkum pola keterkaitan gen PR25 dengan gen pada kedua tetua, sehingga dapat dipakai sebagai dasar integrasi anotasi fungsi (EggNOG-mapper dan InterProScan) dan analisis kontribusi fungsi per kategori. Perlu diperhatikan bahwa keterdeteksian hubungan ortholog dapat dipengaruhi oleh faktor teknis pada data input, terutama kualitas dan konsistensi anotasi/model gen (misalnya perbedaan representasi protein, gen yang terprediksi parsial, atau perbedaan struktur gen), sehingga beberapa gen dapat bergeser kategorinya apabila input anotasi berubah. Temuan bahwa variasi anotasi dapat memengaruhi inferensi orthologi juga dilaporkan pada [60], [102] yang membandingkan beberapa sumber/model anotasi dan menunjukkan perbedaan yang bermakna pada hasil orthology assignment [60], [102].

5.4.8.2 Implementasi Quality Control dan Validasi Konsistensi Data Protein

Blok 2 diimplementasikan sebagai *Quality Control (QC)* dan validasi konsistensi data setelah FASTA protein tersedia (*original* dan *clean*) serta setelah tabel status PR25 dari Blok 1 terbentuk, namun sebelum integrasi data besar pada blok lanjutan. Di tahap ini, memastikan bahwa:

- Berkas FASTA clean dan original untuk PR25, RD23, dan OL ada, tidak kosong, dan berformat FASTA yang valid.
- Komposisi ID antara FASTA clean vs original identik (tidak ada gen yang hilang atau duplikat yang tidak diinginkan).
- Tabel status PR25 (PR25_status.tsv) dan Orthogroups.tsv dari OrthoFinder lengkap dan konsisten

Tahap QC eksplisit pada Blok 2 ini selaras dengan praktik baik dalam analisis genom modern: setelah seluruh alat utama (OrthoFinder, EggNOG-mapper, dan InterProScan) dijalankan, kualitas dan konsistensi berkas input–output diverifikasi kembali (keberadaan file, format FASTA, kesesuaian ID, dan cakupan orthogroup). Subbab ini menjelaskan implementasi quality control (QC) terhadap berbagai berkas yang digunakan pada analisis hilir, yaitu: FASTA protein sebelum dan sesudah pembersihan, ringkasan status gen PR25 (PR25_status.tsv), berkas orthogroup hasil OrthoFinder, serta ketersediaan berkas gene tree. Tahap ini

bertujuan memastikan tidak ada masalah teknis (misalnya file korup, ID tidak konsisten, atau orthogroup tidak lengkap) sebelum hasilnya dipakai untuk pemetaan ID dan integrasi anotasi pada Blok 3 [41].

5.4.8.2.1 Pemeriksaan Integritas dan Keterbacaan Berkas FASTA Protein (*Original* dan *Clean*)

Tujuan dari subbab ini untuk memastikan file FASTA protein ada, tidak kosong, dapat dibaca, dan berformat FASTA yang benar, sehingga pipeline tidak berjalan dengan input korup/parsial. Praktik pemeriksaan awal seperti ini sejalan dengan studi[103], menekankan verifikasi ringkas sebelum langkah analitik [103].

- Input: path file FASTA (mis. PR25.clean.fa, PR25.final.pep.all.fa, RD23.clean.fa, dan lainnya).
- Prosesnya menggunakan `check_fasta_health(path, preview_lines)`: mengecek keberadaan file (`exists`) dan ukuran file (`size_bytes`, `size_mb`) untuk mendeteksi file hilang/kosong, membaca beberapa baris awal untuk memastikan file readable, validasi indikasi FASTA dengan `looks_like_fasta` (baris pertama diawali >), menghitung `headers_in_preview` sebagai indikator bahwa file benar-benar memuat record FASTA.
- Output: dictionary ringkasan kesehatan file (`readable`, `looks_like_fasta`, ukuran, dan error bila bermasalah).

5.4.8.2.2 Ekstraksi ID FASTA dan deteksi duplikasi ID

Penjelasan pada subbab ini, yaitu:

1. Tujuan: memastikan ID protein (yang akan menjadi “kunci” penggabungan data antar-output) dapat diekstrak dengan aturan yang konsisten, serta tidak ada ID duplikat yang berpotensi mengacaukan pemetaan hasil OrthoFinder/EggNOG/InterProScan pada tahap integrasi. Pengendalian redundansi/duplikasi relevan dalam analisis komparatif karena representasi ganda dapat menggeser ringkasan/hasil downstream [62], [64], [71].
2. Input: file FASTA protein (untuk ekstraksi ID) dan list ID (untuk analisis duplikasi).

3. Proses:

- `fasta_ids(path, limit)` : membaca file FASTA dan mengambil `raw_id` dari setiap header (token pertama setelah >), menghasilkan list ID yang merepresentasikan semua protein dalam file tersebut.
 - `duplicate_id_stats(ids)` : menghitung frekuensi kemunculan ID dengan Counter, menentukan berapa ID yang muncul lebih dari sekali (`n_duplicate_ids`) dan contoh ID duplikat.
4. Output: `fasta_ids` yang memiliki list ID protein, dan `duplicate_id_stats` yang merupakan ringkasan duplikasi (`unique_ids`, `n_duplicate_ids`, dan lainnya).

5.4.8.2.3 Perbandingan FASTA clean vs original

Berikut penjelasan dalam subbab ini berupa:

Hasil perbandingan FASTA menunjukkan bahwa tahap pembersihan/standarisasi sekuens protein pada penelitian ini berfungsi sebagai QC untuk memastikan format dan konsistensi ID, serta memeriksa adanya duplikasi teknis. Pada dataset yang digunakan, tidak ditemukan ID protein ganda (duplikasi = 0) dan seluruh ID pada berkas clean tetap cocok dengan berkas original (overlap 100%), sehingga tahap ini tidak perlu menghapus atau menambah entri apa pun; berkas clean dinyatakan siap dipakai sebagai input analisis orthologi dan anotasi fungsi [60], [102]. Dengan demikian, *cleaning* pada penelitian ini lebih tepat dipahami sebagai proses validasi dan standardisasi input (bukan seleksi/pembuangan).

- Input: dua file FASTA untuk dibandingkan (mis. PR25.clean.fa vs PR25.final.pep.all.fa).
- Proses dalam kodingan ini menggunakan `compare_fasta_sets(path_a, path_b)`, yaitu memanggil `fasta_ids()` untuk mengambil ID dari masing-masing file, mengubah menjadi himpunan (`set_a`, `set_b`) untuk menghitung intersection (ID yang sama), `only_A` dan `only_B` (ID yang hilang/bertambah), dan `overlap_pct_of_A` sebagai indikator konsistensi (idealnya 100%), serta memanggil `duplicate_id_stats()` untuk memastikan tidak ada ID duplikat di kedua file.
- Output: ringkasan overlap dan selisih ID (`only_A`, `only_B`) + ringkasan duplikasi tiap file (`A_dup`, `B_dup`).

5.4.8.2.4 Validasi struktur PR25_status.tsv

Tujuan: memastikan tabel PR25_status.tsv (output perantara) dapat dibaca, memiliki skema kolom yang lengkap/konsisten, serta menunjukkan ringkasan yang wajar (distribusi status dan keterisian orthogroup/OG) sehingga layak digunakan sebagai dasar integrasi data pada tahap berikutnya. Blok 2 diperlukan karena hasil analisis ortholog bergantung pada konsistensi data protein yang dipakai. Karena itu, perbedaan anotasi gen/protein antar dataset dapat memengaruhi hasil pengelompokan orthogroup, sehingga validasi input menjadi tahap wajib sebelum integrasi hasil [60], [102].

- Input: path PR25_status.tsv.
- Proses pada kodingan ini menggunakan `validate_pr25_status_tsv(status_tsv)` untuk membaca TSV menjadi DataFrame (`pd.read_csv`) agar struktur tabular terkonfirmasi, mengecek keberadaan kolom wajib (`required_cols`) dan mencatat yang hilang (`missing_required_cols`), menghitung `status_counts` (jumlah gen per kategori status) sebagai ringkasan hasil, menghitung `og_coverage` untuk memastikan kolom OGs terisi (indikator setiap baris punya informasi orthogroup).
- Output: dictionary ringkasan validasi (`missing_required_cols`, `status_counts`, `og_coverage`, dan lainnya).

5.4.8.2.5 Validasi Orthogroups.tsv dan scan gene trees

Tujuan dari kodingan ini untuk memastikan Orthogroups.tsv valid dan kolom spesies terdeteksi, menghitung PR25-only orthogroups sebagai konteks OG yang tidak melibatkan RD23/OL, memastikan ketersediaan gene trees untuk penelusuran OG tertentu, dan menghasilkan keputusan “aman lanjut” berbasis *issue-check*. Praktik evaluasi/*benchmark orthology inference* dan ketersediaan artefak (OG, pohon) merupakan bagian umum dalam pemakaian metode orthologi di komparatif genomik, salah satunya pada jurnal [60], [102].

- Input: Orthogroups.tsv, path Resolved_Gene_Trees (dan opsional Gene_Trees).
- Proses: program mengenali kolom spesies pada file Orthogroups.tsv, menandai orthogroup yang hanya berisi gen PR25 (PR25-only), memeriksa keberadaan

file pohon gen per-orthogroup (misalnya OG0001189_tree.txt), lalu merangkum hasil pengecekan menjadi daftar masalah penting sebagai dasar keputusan apakah analisis aman dilanjutkan.

- Output: kodingan pada subbab ini menghasilkan ringkasan hasil pengecekan yang meliputi validitas dan statistik dasar file Orthogroups.tsv, ketersediaan berkas gene tree per-orthogroup (mis. OG0000000_tree.txt) pada folder hasil OrthoFinder, dan keputusan otomatis “aman dilanjutkan” yang dinyatakan dengan variabel boolean `safe_to_proceed` (True/False).

5.4.8.3 Implementasi Integrasi Hasil Analisis Orthologi dan Anotasi Fungsi Gen PR25

Subbab ini merupakan penjelasan untuk subbab blok 3 yang diimplementasikan sebagai tahap integrasi orthologi dan anotasi fungsi untuk membangun tabel final gen PR25 yang sudah memiliki status hubungan ortholog terhadap RD23 dan/atau *O. longistaminata* (Sumber_Gen: BOTH/RD23_only/OL_only), anotasi fungsi dari EggNOG-mapper dan InterProScan, ringkasan fungsi utama (Fungsi_Utama), serta klasifikasi Status_Fungsi (KNOWN dan UNKNOWN) dan visualisasinya (donut & barplot). Tahap standardisasi ID dan integrasi ini penting karena literatur menunjukkan bahwa perbedaan kualitas/variasi anotasi gen dapat menghasilkan perbedaan nyata pada hasil inferensi orthologi, sehingga pemetaan ID yang konsisten dan strategi integrasi anotasi menjadi kunci agar hasil downstream stabil dan dapat dipertanggungjawabkan [102].

5.4.8.3.1 Standardisasi ID gen lintas file (FASTA → ID gen baru PR25/RD23; OL dipertahankan)

Tujuan dari subbab ini untuk menyeragamkan ID gen/protein sebagai “kunci penggabungan data”, sehingga hasil OrthoFinder (orthogroup/partner) dapat digabungkan secara tepat dengan anotasi fungsi dari EggNOG-mapper dan InterProScan tanpa terjadi salah-cocok atau data yang tidak terbaca saat *merge*. Pada [102], menunjukkan variasi anotasi gen dapat memengaruhi hasil *orthology assignment* sehingga jadi normalisasi ID adalah fondasi integrasi [102].

1. Input: daftar ID FASTA protein (PR25/RD23/OL) dari header FASTA.

2. Proses:

- `extract_zs97_core(id_str)`: mengekstrak pola inti ID ZS97 dari header FASTA, agar berbagai format header tetap bisa ditangani.
- `zs97_to_new_gene(tag, zs97_id)`: mengubah ID ZS97 menjadi format gen baru yang konsisten untuk PR25/RD23.
- `build_id_mapping(fasta_ids, tag)`: membangun dua arah mapping (old ke new dan new ke varian old) serta menghitung unmapped (ID yang tidak cocok pola).

3. Output: `old_to_new`, `new_to_olds`, dan `unmapped`.

Berkas protein PR25 memuat 52.209 record sekuens yang merepresentasikan protein hasil translasi transkrip/isoform, sehingga satu gen dapat muncul sebagai beberapa record dengan sufiks isoform (misalnya `_01`, `_02`). Setelah dilakukan normalisasi ke ID tingkat-gen (format PR25gChrXXGYYYYYY), beberapa isoform yang berasal dari gen yang sama digabung pada satu ID gen sehingga jumlah gen unik yang berhasil dipetakan menjadi 34.776, sedangkan 2.781 record tidak terpetakan karena format ID-nya tidak sesuai pola penamaan ZS97 yang digunakan sebagai aturan konversi. Pada RD23, file protein berisi 49.849 record yang juga bersifat per-transkrip/isoform, sehingga jumlah record tidak identik dengan jumlah gen unik setelah konversi ID tingkat-gen (RD23gChrXXGYYYYYY). Normalisasi ini menghasilkan 35.015 gen terpetakan karena beberapa isoform dipetakan ke gen yang sama, sedangkan record yang tidak sesuai pola ID yang diharapkan akan tercatat sebagai *unmapped* dan memerlukan penanganan mapping khusus. Pada spesies *Oryza longistaminata*, skema ID protein pada FASTA dipertahankan (tanpa normalisasi ke format ZS97), sehingga pemetaan dilakukan secara langsung 1:1, yaitu setiap ID OL pada FASTA menjadi ID yang digunakan pada tahap integrasi berikutnya. Setelah ID diseragamkan, tahap berikutnya adalah membaca orthologues (pairwise) dan menetapkan `Sumber_Gen` untuk tiap gen PR25 [104].

5.4.8.3.2 Parsing orthologues (PR25-RD23, PR25-OL): Status `Sumber_Gen` dan `partner`

Tujuan dari subbab ini yaitu mengekstrak hasil ortholog PR25–RD23 dan PR25–OL dari output OrthoFinder untuk membangun tabel relasi yang konsisten (daftar partner dan Orthogroup/OG tiap gen PR25), lalu mengklasifikasikan gen PR25 ke

Institut Teknologi Del

kategori Sumber_Gen (BOTH/RD23_only/OL_only) sebagai dasar integrasi anotasi fungsi. Langkah ini sejalan dengan praktik komparatif genomik karena inferensi orthologi merupakan tahap inti yang dibenchmark oleh komunitas (mis. Quest for Orthologs) dan diketahui sensitif terhadap perbedaan kualitas/struktur anotasi gen [60], [102].

1. Input: file orthologues TSV dari OrthoFinder (PR25 vs RD23; PR25 vs OL) dan mapping ID (old ke new).
2. Proses:
 - parse_orthologues: membaca kolom Orthogroup, PR25, dan kolom partner; memecah anggota (split by koma); mengonversi old_id ke new_gene; mengisi:
 - pr25_to_partners[PR25_gene] = {partner_gene}
 - pr25_to_ogs[PR25_gene] = {OG}
 - Menghitung ID yang gagal termapping (unmapped_pr25, unmapped_partner).
3. assign_sumber_gen: menetapkan status BOTH/RD23_only/OL_only berdasarkan ada tidaknya partner ortholog.
4. Output: dictionary partner, dictionary OG, dan statistik unmapped; serta label Sumber_Gen per gen PR25.

RD23 orthologues mencakup 33.012 gen PR25, sedangkan OL orthologues mencakup 20.497 gen PR25. Gabungannya menjadi 33.305 gen PR25 unik yang diproses ke tabel final. Unmapped pada PR25 (251 untuk RD23; 2.066 untuk OL) menunjukkan ada ID PR25 pada file orthologues yang tidak cocok mapping (biasanya variasi format ID). Setelah status Sumber_Gen dan pasangan ortholog terbentuk, tahap berikutnya adalah membaca anotasi fungsi dari EggNOG-mapper dan InterProScan.

5.4.8.3.3 Membaca output EggNOG-mapper & InterProScan terhadap kolom fungsi, GO, KEGG, Pfam

Tujuan untuk menormalisasi keluaran dua sumber anotasi (EggNOG-mapper & InterPro/InterProScan) menjadi tabel ringkas per protein yang siap diindeks dan digabungkan ke gen PR25. EggNOG-mapper v2 dirancang untuk anotasi fungsi

berbasis orthology dengan keluaran seperti deskripsi & jalur (termasuk GO/KEGG), sedangkan InterPro menyediakan anotasi berbasis protein family/domain yang umum dipakai untuk menguatkan interpretasi fungsi [64], [70].

1. Input: file `.emapper.annotations.tsv` (EggNOG-mapper) dan file TSV InterProScan untuk PR25/RD23/OL.
2. Proses:
 - `read_eggnog`: menemukan header `#query`, membaca baris anotasi, lalu menjaga kolom inti (`description`, `gos`, `kegg_ko`, dan lainnya).
 - `read_interpro`: membaca baris InterProScan, mengambil deskripsi domain (`ipr_desc/sig_desc`), GO, Pfam, lalu mengagregasi per query sehingga satu query punya ringkasan `ipr_descs`, `pfams`, `gos`, `ipr_accs`.
3. Output: DataFrame ringkas anotasi EggNOG dan InterPro per query.

Adapun EggNOG *records* pada tiga spesies, yaitu PR25 sebanyak 38.763, RD23 sebanyak 39.062, OL sebanyak 25.483. Sedangkan pada InterPro *records* pada tiga spesies, yaitu PR25 sebanyak 33.981, RD23 sebanyak 40.253, OL sebanyak 27.131. Perbedaan jumlah *record* ini wajar karena cakupan metode/pustaka anotasi berbeda dan tidak semua query menghasilkan anotasi penuh pada setiap sistem [64], [70]. Setelah anotasi dibaca, perlu membangun index agar anotasi bisa “ditempelkan” ke ID gen baru (PR25gChr).

5.4.8.3.4 Reverse lookup: mengaitkan anotasi (old/query ID) ke gen baru (new_gene)

Tujuan subbab ini untuk menjembatani perbedaan “nama” antara ID di file anotasi (umumnya berbasis query) dan ID gen baru hasil standardisasi, sehingga penggabungan anotasi tidak gagal karena *mismatch ID*. Ini relevan karena kualitas/variasi gene models dan format ID memang diketahui dapat berdampak pada langkah orthology, sehingga strategi pemetaan yang eksplisit membantu menjaga konsistensi integrasi [102].

- Input: DataFrame anotasi (`annot_df`) dan mapping `new_to_old` (gen baru dari varian `old_id`).
- Proses dalam kodingan ini menggunakan `build_annotation_index` untuk membuat kamus `old_to_row` untuk akses cepat per query; lalu untuk tiap

new_gene memilih satu old_id yang punya anotasi dan menyimpannya ke idx[new_gene].

- Output: idx (new_gene ke list record anotasi) untuk EggNOG dan InterPro pada PR25/RD23/OL.

Dengan demikian, PR25 pada EggNOG *match rate* 73,8% dan PR25 InterPro *match rate* 66,9% artinya tidak semua gen baru menemukan pasangan query yang cocok pada file anotasi (bisa karena ID tidak muncul sebagai query, tidak ada hit, atau terfilter saat ringkas). Selain itu, OL match rate lebih tinggi karena mapping 1:1 terhadap ID OL. Setelah index siap, tahap inti BLOK 3 adalah merge anotasi per gen PR25, menentukan Fungsi_Utama, dan menetapkan Status_Fungsi (KNOWN/UNKNOWN) dan visualisasi.

5.4.8.3.5 Merge anotasi per gen PR25 menghasilkan Fungsi_Utama, Status_Fungsi, ringkasan dan visualisasi

Tujuan subbab ini untuk menghasilkan tabel final TA berisi gen PR25 yang sudah digabung dengan: status Sumber_Gen, partner ortholog, anotasi EggNOG & InterPro, ringkasan Fungsi_Utama, dan label Status_Fungsi. Pendekatan menggabungkan anotasi berbasis orthology (EggNOG) dan berbasis domain/family (InterPro) adalah praktik yang lazim untuk memperkuat interpretasi fungsi karena masing-masing sumber memberikan sudut pandang anotasi yang berbeda.

[64], [70]

1. Input: hasil partner/status dari orthologues, index anotasi EggNOG & InterPro (PR25 dan fallback RD23/OL), aturan kata kunci unknown.
2. Proses:
 - is_unknown_desc(text): mendeteksi deskripsi tidak-informatif (“hypothetical/uncharacterized/unknown”) secara konsisten.
 - pilih_fungsi_utama(f_eggnog, f_interpro): memilih deskripsi yang paling informatif (prioritas EggNOG jika informatif; jika tidak InterPro).
 - status_fungsi(f_eggnog, f_interpro): menetapkan UNKNOWN hanya bila keduanya unknown dan jika salah satu informatif maka dikategorikan KNOWN.
3. Output: kolom Fungsi_Utama dan Status_Fungsi yang kemudian dipakai

untuk ringkasan dan gambar.

Dengan demikian, total gen PR25 yang masuk tabel final (berdasarkan gen yang terdeteksi di orthologues gabungan), yaitu 33.305 gen. Lalu, distribusi Sumber_Gen, yaitu BOTH sebanyak 60,66% (20.2040), RD23_only sebanyak 38,46% (12.808), OL_only sebanyak 0,88% (293). Selain itu, output pada blok ini menghasilkan gambar donut dan gambar gambar bar per sumber gen. Gambar donut tersebut berisi proporsi KNOWN 77,5% (25.826 gen) dengan UNKNOWN 22,5% (7.479 gen) yang berarti mayoritas gen PR25 dalam set analisis memperoleh anotasi fungsi informatif dari minimal salah satu sumber (EggNOG/InterPro). Lalu, gambar bar per Sumber_Gen berisi kelompok BOTH paling “banyak anotasi” (KNOWN 91,7%), sedangkan RD23_only memiliki porsi UNKNOWN lebih tinggi (UNKNOWN 44,9%). Ini biasanya mencerminkan bahwa sebagian gen pada subset tertentu lebih sulit dipetakan ke fungsi (misalnya kurangnya hit orthology kuat atau domain yang jelas), sehingga integrasi dua sumber anotasi membantu meminimalkan “unknown” tetapi tidak selalu menghilangkannya [64], [70].

Dengan lima komponen inti di atas, BLOK 3 membentuk pipeline integrasi yang lengkap: dimulai dari standardisasi ID, dilanjutkan parsing orthologues untuk menetapkan Sumber_Gen dan partner, lalu membaca dan mengindeks anotasi EggNOG-mapper dan InterProScan, kemudian melakukan merge untuk menghasilkan tabel final penelitian ini beserta Fungsi_Utama dan Status_Fungsi (KNOWN/UNKNOWN) serta visualisasinya. Secara metodologis, penempatan BLOK 3 setelah QC (BLOK 2) dan penggunaan pemetaan ID yang eksplisit membantu menjaga stabilitas hasil integrasi, sejalan dengan temuan bahwa variasi anotasi gen dapat memengaruhi hasil inferensi orthologi sehingga konsistensi data masukan dan strategi integrasi perlu dibuat transparan di laporan.

5.4.8.4 Implementasi Visualisasi Distribusi Sumber_Gen dan Identifikasi Fungsi Dominan Gen PR25 (Top-10) pada Kategori KNOWN

Pada subbab ini, setiap gen PR25 diklasifikasikan menjadi KNOWN atau UNKNOWN berdasarkan ketersediaan informasi fungsi dari hasil anotasi (misalnya EggNOG dan/atau InterPro), sehingga status fungsional gen dapat diringkas secara konsisten untuk analisis lanjutan. Selanjutnya dibuat kolom

Institut Teknologi Del

flag/penanda boolean (True/False) untuk masing-masing sumber anotasi (Fungsi_Utama, EggNOG, InterPro) agar proses pemfilteran gen, perhitungan jumlah/persentase, serta pembuatan grafik ringkasan dapat dilakukan secara otomatis.

5.4.8.4.1 Definisi Status Fungsional Gen (KNOWN/UNKNOWN) dan Pembuatan Flag/Penanda Boolean per Sumber Anotasi (Fungsi_Utama, EggNOG, InterPro)

Pada tahap ini dibuat penanda (flag)/indikator biner untuk setiap gen PR25 guna menunjukkan apakah anotasi fungsinya tergolong unknown atau known pada masing-masing sumber anotasi (EggNOG-mapper dan InterProScan). Selanjutnya, kedua penanda tersebut digabungkan untuk menetapkan Status_Fungsi dimana gen dikategorikan UNKNOWN bila keduanya tidak memberi deskripsi fungsi yang informatif, dan dikategorikan KNOWN bila minimal salah satu sumber memberikan petunjuk fungsi yang bermakna.

Tujuan dari subbab ini untuk membuat aturan yang konsisten untuk memisahkan gen yang punya anotasi informatif (KNOWN) vs yang anotasinya masih generik/tidak spesifik (UNKNOWN), untuk setiap sumber fungsi (Utama/EggNOG/InterPro).

1. Input: DataFrame df hasil tabel final (kolom minimal: Fungsi_Utama, Fungsi_EggNOG, Fungsi_InterPro).
2. Proses:
 - `is_unknown_desc(text)`: memutuskan “UNKNOWN” bila deskripsi kosong/NA atau mengandung kata kunci generik seperti hypothetical protein dan uncharacterized. Ini cocok untuk kebutuhan ringkasan karena EggNOG-mapper menghasilkan deskripsi fungsi berbasis orthologi [70], sedangkan InterPro merangkum domain/families protein dan kadang memberi label generik bila bukti belum spesifik .
 - `df["is_known_"] = ~apply(is_unknown_desc)`: mengubah hasil fungsi menjadi flag boolean yang nanti dipakai untuk filter KNOWN/UNKNOWN dan ringkasan persentase.
3. Output: tiga kolom flag: is_known_Fungsi_Utama,

is_known_Fungsi_EggNOG, is_known_Fungsi_InterPro.

5.4.8.4.2 Donut distribusi Sumber_Gen dan Export daftar gen per kelompok

Tujuan: menampilkan komposisi kategori Sumber_Gen dalam bentuk donut yang cepat dibaca, dan menyediakan file Excel berisi daftar gen per kelompok untuk pelacakan/validasi manual.

1. Input: DataFrame df yang punya kolom Sumber_Gen (BOTH/RD23_only/OL_only).
2. Proses:
 - Donut Sumber_Gen : menghitung ukuran tiap kelompok dan menulis legend berisi jumlah gen dan persentase lalu menyimpan ke 01_donut_SumberGen_v21.png.
 - Export Excel per kelompok : memfilter df[df["Sumber_Gen"]==group] lalu menulis tiap subset ke sheet berbeda (BOTH/RD23_only/OL_only).
3. Output: Gambar donut distribusi Sumber_Gen (Gambar 4 pada PDF output) dan Excel Block4_Genes_by_SumberGen_v21.xlsx (3 sheet).

Dengan demikian dapat dikatakan bahwa:

- BOTH: gen PR25 berada dalam orthogroup yang punya pasangan ortholog di RD23 dan OL.
- RD23_only: ortholog terdeteksi di RD23 tetapi tidak di OL.
- OL_only: ortholog terdeteksi di OL tetapi tidak di RD23.

Kerangka pengelompokan gen berbasis ortholog/orthogroup sejalan dengan praktik yang umum di komparatif genomik, karena berbagai metode inferensi orthologi memang dinilai dan dibandingkan menggunakan benchmark terstandar yang dikelola komunitas, seperti *Orthology Benchmark Service* dari konsorsium [60]. Benchmark ini menyediakan dataset/proteom referensi dan prosedur evaluasi yang sama, sehingga keluaran dari berbagai metode dapat dibandingkan secara konsisten [60].

5.4.8.4.3 Export KNOWN/UNKNOWN per Sumber_Gen (plus ringkasan persentase)

Tujuan dari subbab ini untuk keluaran implementasi yang terstruktur dan mudah diverifikasi ulang, berupa: berkas Excel gen KNOWN dan UNKNOWN untuk tiap definisi fungsi, serta tabel ringkasan jumlah dan persentase KNOWN/UNKNOWN per Sumber_Gen. Format ini memudahkan penelusuran hasil karena setiap keputusan klasifikasi (berdasarkan flag) dapat dicek kembali melalui pemisahan data dan ringkasan terhitung.

1. Input: DataFrame df, nama kolom fungsi (mis. Fungsi_Utama), dan flag boolean penanda “known” dengan is_known_Fungsi_Utama.
2. Proses:
 - export_known_unknown: memisahkan data menjadi subset df_known dan subset df_unknown menggunakan flag, lalu mengeksport keduanya ke Excel sebagai artefak yang mudah diperiksa kembali.
 - export_known_unknown: membangun ringkasan per Sumber_Gen yang berisi n_known / n_unknown / total / persentase, lalu mengeksportnya ke CSV agar bisa memeriksa pola hasil tanpa harus menghitung ulang dari awal.
3. Outputnya digunakan untuk masing-masing label (FungsiUtama, EggNOG, InterPro) dihasilkan:
 - Block4_<label>_KNOWN_only_v21.xlsx
 - Block_<label>_UNKNOWN_only_v21.xlsx
 - Block4_<label>_KNOWN_UNKNOWN_summary_v21.csv
 - Pemanggilan fungsinya dilakukan untuk tiga jenis fungsi: Utama, EggNOG, InterPro.

5.4.8.4.4 Menyusun “Top-10 fungsi” (kategori KNOWN) sebagai basis heatmap

Tujuannya untuk membangun matriks Top-10 yang konsisten untuk semua visualisasi: baris = fungsi, kolom = kelompok (BOTH/RD23_only/OL_only + PR25_all), isi = jumlah (n) dan persentase (%).

1. Input: df_src yang sudah difilter hanya gen KNOWN, serta nama kolom fungsi (mis. Fungsi_Utama).

2. Proses dalam kodingan tersebut menggunakan `build_top10_summary(df_src, func_col, top_n)`: menghitung ukuran setiap kelompok (`group_sizes`) sebagai penyebut persentase, menghitung frekuensi fungsi per kelompok (`groupby([func_col, "Sumber_Gen"]).size()`), menentukan 10 fungsi paling dominan berdasarkan total kemunculan lintas kelompok (`func_totals.head(10)`), membangun pivot `pivot_n (n)` dan `pivot_pct (%)`, serta menambahkan kolom `PR25_all` sebagai total seluruh kelompok.
3. Outputnya menghasilkan tiga objek:
 - `pivot_n` (jumlah gen per fungsi per kelompok),
 - `pivot_pct` (persentase),
 - `group_sizes_all` (ukuran kelompok untuk anotasi judul/legend).

5.4.8.4.5 Heatmap Top-10 dan Barplot Top-10 per kelompok (BOTH/RD23_only/OL_only)

Tujuan dari subbab ini untuk:

Heatmap: memperlihatkan Top-10 fungsi secara ringkas lintas kelompok (BOTH/RD23_only/OL_only + PR25_all).

Barplot per kelompok: memperlihatkan Top-10 fungsi khusus untuk tiap kelompok (mis. RD23_only saja), dan khusus OL_only juga diekspor daftar gennya ke Excel agar mudah diverifikasi.

1. Input: output dari `build_top10_summary` + DataFrame KNOWN (`df_fu_known, df_egg_known, df_ipr_known`).
2. Proses:
 - `plot_top10_heatmap`: menggunakan `pcolormesh` agar sel heatmap tidak bergaris putih, dan memberi tanda “-” di depan label fungsi sebagai penanda visual/bullet, bukan operasi minus.
 - `plot_top10_single_group`: membuat barplot Top-10 untuk satu kelompok (mis. BOTH), menulis label `n gen` dan `(% terhadap total kelompok)`, lalu menyimpan PNG; jika `export_excel_path` diisi (khusus OL_only), daftar gen pembentuk Top-10 ikut diekspor ke Excel.
3. Output:
 - Heatmap Top-10 (kategori KNOWN): Top-10 Fungsi Utama (integrasi

EggNOG+InterPro), Top-10 Fungsi_EggNOG, Top-10 Fungsi_InterPro

- Barplot Top-10 per kelompok: Top-10 Fungsi_Utama per kelompok, Top-10 Fungsi_EggNOG per kelompok, Top-10 Fungsi_InterPro per kelompok

BAB VI

HASIL DAN PEMBAHASAN

Berikut merupakan bab hasil dan pembahasan terhadap hasil implementasi yang dilakukan pada bab sebelumnya.

6.1 Analisis Kualitas Perakitan Genom

Pada bagian ini, menjelaskan hasil dari implementasi BUSCO dan QUASt terhadap 3 spesies, yaitu *Oryza sativa* subsp. *indica* RD23, *Oryza longistaminata*, dan *Oryza sativa* subsp. *indica* kultivar PR25.

6.1.1 Evaluasi Kelengkapan Konten Gen pada Perakitan Genom

Pada subbab ini, menjelaskan evaluasi kelengkapan konten gen pada perakitan genom yang dilakukan dengan BUSCO (Benchmarking Universal Single-Copy Orthologs) BUSCO mengevaluasi kualitas perakitan dari segi kelengkapan konten gen. Ini dilakukan dengan mencari gen-gen ortolog salinan tunggal yang diharapkan ada di hampir semua spesies dalam kelompok taksonomi tertentu (misalnya, Poales untuk padi). Kelengkapan dan duplikasi gen BUSCO dapat memberikan indikasi kualitas perakitan dan anotasi gen. Berikut hasil dari implementasi BUSCO:

Tabel 6. 1 Hasil BUSCO

Genom	<i>Complete (%)</i>	<i>Complete and Single-Copy (%)</i>	<i>Complete and Duplicated (%)</i>	<i>Fragmented (%)</i>	<i>Missing(%)</i>
PR25	99.8	98.1	1.6	0.1	0.1
RD23	99.8	98.0	1.7	0.1	0.1
<i>Oryza longistaminata</i>	90.2	87.5	2.6	5.0	4.9

Tabel tersebut merangkum hasil analisis BUSCO dengan dataset *poales_odb10* pada ketiga genom yang digunakan, dan menunjukkan bahwa PR25 dan RD23 memiliki kelengkapan ruang gen yang hampir identik, dengan nilai Complete

BUSCO sangat tinggi (99,8%) yang didominasi oleh gen *single-copy* (98,1% pada PR25 dan 98,0% pada RD23) serta hanya 1,6–1,7% gen *duplicated*, sementara kategori *Fragmented* dan *Missing* masing-masing hanya 0,1%; kombinasi ini menempatkan kedua genom pada kelas perakitan “berkualitas sangat tinggi” yang secara praktis dianggap near-complete dan sangat layak dijadikan dasar alih anotasi, analisis orthologi, dan anotasi fungsi tanpa kekhawatiran besar terkait kehilangan gen inti. Sebaliknya, genom *Oryza longistaminata* memiliki nilai *Complete* yang cukup rendah, yaitu 90,2%, dengan proporsi *Fragmented* (5,0%) dan *Missing* (4,9%) yang lebih tinggi, sehingga meskipun masih termasuk kategori kelengkapan yang baik dan cukup representatif sebagai referensi genom liar, hasil ini mengindikasikan bahwa ruang gen inti Poales pada spesies ini belum seterwakili dua genom lainnya. Dengan kondisi tersebut, jumlah gen PR25 yang berhasil diidentifikasi sebagai turunan atau ortholog langsung dari *O. longistaminata* kemungkinan sedikit lebih rendah dari keadaan sebenarnya, sedangkan perbandingan antara PR25 dan RD23 dapat dianggap lebih andal karena keduanya didukung oleh genom dengan tingkat kelengkapan ruang gen yang hampir sempurna.

6.1.2 Evaluasi Struktur Perakitan Genom

QUAST digunakan untuk mengevaluasi kualitas struktur perakitan genom melalui metrik kontiguitas dan metrik gap, sehingga kelayakan rakitan sebagai masukan analisis lanjutan dapat dinilai secara terukur. Ringkasan QUAST pada tabel 6.1.2, memuat metrik kontiguitas (jumlah contig, total panjang *assembly*, panjang contig terbesar, N50, N90, L50, L90) serta metrik gap “# N’s per 100 kbp”. Metrik “# N’s per 100 kbp” merepresentasikan kepadatan basa ambigu N, yaitu jumlah basa N rata rata per 100.000 bp. Dengan demikian, nilai 10.155,31 N per 100 kbp pada *Oryza longistaminata* setara dengan sekitar 10,16 persen posisi basa yang berupa N, sedangkan PR25 32,71 N per 100 kbp setara sekitar 0,033 persen dan RD23 4,68 N per 100 kbp setara sekitar 0,0047 persen. Nilai ini dipakai sebagai indikator kuantitatif tingkat gap atau bagian sekuens yang belum terpecahkan pada perakitan, sehingga semakin tinggi nilainya semakin besar proporsi basa ambigu yang berpotensi mengganggu analisis berbasis struktur dan gen [89], [105].

Tabel 6. 2 Hasil QUAST

<i>Assembly</i>	# <i>contigs</i>	<i>Total length (bp)</i>	<i>Largest contig</i>	<i>GC (%)</i>	<i>N50 (bp)</i>	<i>N90 (bp)</i>	<i>L</i> 50	<i>L</i> 90	# <i>N's</i> <i>per</i> <i>100</i> <i>kbp</i>
PR25.FINAL	13	39589 9173	439565 31	43.6 5	31960 027	24176 651	6	1 1	32.7 1
RD23.FINAL	199	40627 2223	447307 79	43.8 7	32118 244	26005 425	6	1 1	4.68
<i>Oryza_longistaminata</i> .O_longistaminata_v1.0.dna.toplevel	22477	31494 5577	112703 2	41.5 3	97754	14606	877	383	1015 5.31

Berdasarkan Tabel Hasil QUAST tersebut, assembly PR25 menunjukkan kontiguitas sangat tinggi karena hanya terdiri atas 13 contig dengan total panjang 395.899.173 bp dan panjang contig terbesar 43.956.531 bp; metrik N50 sebesar 31.960.027 bp dan L50 = 6 menunjukkan bahwa minimal 6 contig terpanjang sudah mencakup setidaknya 50 persen dari total panjang *assembly*. Pola yang sebanding juga terlihat pada RD23, yang memiliki N50 32.118.244 bp dan L50 = 6, meskipun jumlah contig RD23 lebih banyak (199 contig) dengan total panjang 406.272.223 bp dan contig terbesar 44.730.779 bp. Komposisi GC PR25 (43,65 persen) dan RD23 (43,87 persen) berbeda hanya 0,22 poin persentase, sehingga konsisten pada tingkat komposisi basa untuk dua *assembly Oryza sativa* yang dibandingkan. Sebaliknya, assembly *Oryza longistaminata* jauh lebih terfragmentasi secara kuantitatif karena terdiri atas 22.477 contig dengan N50 hanya 97.754 bp dan L50 = 877, sehingga diperlukan sedikitnya 877 contig terpanjang untuk mencapai 50 persen panjang total assembly; selain itu, contig terbesar hanya 1.127.032 bp, jauh di bawah PR25 dan RD23 yang berada pada kisaran puluhan megabasa. Perbedaan ini juga diperkuat oleh metrik gap: kepadatan basa N pada *Oryza longistaminata*

(10.155,31 N per 100 kbp, sekitar 10,16 persen) sekitar 311 kali lebih tinggi daripada PR25 (32,71 N per 100 kbp) dan sekitar 2.170 kali lebih tinggi daripada RD23 (4,68 N per 100 kbp). Dengan konfigurasi tersebut, hasil analisis yang melibatkan *Oryza longistaminata* harus diinterpretasikan dengan batasan metodologis yang eksplisit pada tahap inferensi orthologi dan integrasi anotasi fungsi, karena fragmentasi assembly dan tingginya proporsi gap dapat menyebabkan gen terbelah di banyak contig, terbaca sebagai fragmen, atau tidak teranotasi secara utuh; kondisi ini berpotensi menurunkan sensitivitas deteksi ortholog serta menggeser komposisi keluarga gen yang teramati. Penekanan berbasis metrik kontiguitas dan gap ini konsisten dengan praktik evaluasi rakitan modern [89] yang menempatkan indikator kontiguitas dan kelengkapan sebagai prasyarat sebelum penarikan kesimpulan biologis [89].

6.2 Hasil Data Preprocessing

Pada subbab ini merupakan penjelasan hasil analisis data preprocessing yang dilakukan untuk Anotasi Gen dengan Liftoff, Standarisasi dan penggabungan anotasi dengan AGAT, Ekstraksi CDS dan Protein dengan gffread.

6.2.1 Analisis Hasil Anotasi Gen PR25 dan RD23 dengan Liftoff


Dalam subbab ini menjelaskan analisis pada anotasi gen PR25 dan RD23 dengan liftoff.

6.2.1.1 Jumlah gen hasil transfer anotasi

Anotasi gen pada genom *O. sativa indica* cv. PR25 dan RD23 diperoleh dengan mentransfer anotasi referensi *Zhenshan 97 (ZS97)* menggunakan Liftoff. Liftoff dirancang khusus untuk memetakan anotasi gen dari satu genom ke genom lain yang sama atau berkerabat dekat dengan memaksimalkan identitas sekuens sambil mempertahankan struktur ekson–intron setiap transkrip [38], [43]. Karena sifatnya yang fokus pada pelestarian struktur gen, Liftoff saat ini menjadi salah satu alat standar untuk transfer anotasi dalam jurnal [43], [83].

Hasil ringkasan Liftoff menunjukkan bahwa ketika anotasi ZS97 dipetakan langsung ke genom PR25 dan RD23, jumlah gen yang dihasilkan sangat sebanding,

yaitu 34.800 gen pada PR25_from_ZS97 dan 35.028 gen pada RD23_from_ZS97. Setelah anotasi PR25 ditambahkan dengan gen-gen unik dari *Oryza longistaminata*, jumlah gen meningkat menjadi 37.581 gen pada berkas PR25_final_backbone_plus_OL. Dengan demikian, anotasi akhir PR25 memiliki sekitar 2.781 gen lebih banyak daripada anotasi awal PR25_from_ZS97 (8%) dan 2.553 gen lebih banyak dibandingkan RD23_from_ZS97 (7,3%). Peningkatan ini konsisten dengan peran *O. longistaminata* sebagai sumber gen liar perenial yang membawa banyak alel tambahan untuk toleransi cekaman dan sifat rimpang [106].



Gambar 6. 1 Perbandingan jumlah gen hasil anotasi Liftoff pada PR25 dan RD23


Batang biru menunjukkan jumlah gen pada anotasi PR25_from_ZS97, RD23_from_ZS97, dan PR25_final_backbone_plus_OL. Angka di atas batang merepresentasikan jumlah gen total pada masing-masing genom/versi anotasi.

Gambar tersebut menegaskan bahwa PR25_from_ZS97 dan RD23_from_ZS97 memiliki tinggi batang yang hampir sama, menunjukkan bahwa sebagian besar gen inti indica yang teranotasi pada ZS97 berhasil ditransfer secara konsisten ke kedua genom target. Hal ini sejalan dengan proses liftoff dalam jurnal [43] yang dioptimalkan untuk genom yang berkerabat dekat, di mana tingkat keberhasilan pemetaan biasanya sangat tinggi ($\geq 98-99\%$) ketika kualitas perakitan memadai [38], [43]. Sebaliknya, batang untuk PR25_final_backbone_plus_OL tampak lebih

tinggi, merefleksikan penambahan gen-gen unik dari *O. longistaminata* yang disisipkan ke dalam kerangka anotasi berbasis ZS97. Dari sisi biologis, hasil ini mendukung hipotesis bahwa PR25 tidak hanya membawa “inti” genom *O. sativa indica* (dari RD23/ZS97), tetapi juga memuat kontribusi genetik tambahan dari tetua liar perenial yang berpotensi terkait dengan sifat-sifat unggul seperti kemampuan regrowth, keberadaan rimpang, dan toleransi cekaman.

6.2.1.2 Proporsi gen mapped dan unmapped

Selain jumlah gen total, kualitas transfer anotasi juga dapat dinilai dari proporsi gen referensi yang berhasil dipetakan (mapped) dan yang gagal dipetakan (*unmapped*). Berdasarkan perhitungan dari berkas .unmapped.txt, Liftoff memetakan 34.800 gen ZS97 ke genom PR25 dan menyisakan 885 gen yang tidak terpetakan. Untuk RD23, sebanyak 35.028 gen berhasil dipetakan, sementara 657 gen tetap unmapped. Nilai ini setara dengan tingkat keberhasilan anotasi sekitar 97,52% untuk PR25 dan 98,16% untuk RD23.



Gambar 6. 2 Jumlah Gen *Mapped* dan *Unmapped* Hasil Liftoff

Gambar 6.2 merupakan jumlah gen *mapped* dan *unmapped* hasil transfer anotasi Liftoff dari ZS97 ke genom PR25 dan RD23. Batang menunjukkan total gen ZS97 yang diproyeksikan ke masing-masing genom. Segmen biru merepresentasikan gen mapped, sedangkan segmen oranye menunjukkan gen unmapped. Angka di dalam

batang adalah jumlah gen mapped, sedangkan angka di bagian atas segmen oranye menunjukkan jumlah gen unmapped.

Gambar 6.2 memperlihatkan bahwa proporsi segmen biru (*mapped*) jauh lebih besar dibandingkan segmen oranye (*unmapped*) pada kedua genom. Pola ini menunjukkan bahwa perakitan PR25 dan RD23 sangat kompatibel dengan genom referensi ZS97, sehingga Liftoff dapat memetakan sebagian besar gen dengan struktur yang utuh. Proporsi *unmapped* yang relatif kecil (2–2,5%) masih masuk akal untuk genom yang telah mengalami perbedaan struktural, mutasi, kehilangan gen, atau gap perakitan dibandingkan referensi. Studi [38], [43] mengevaluasi Liftoff pada berbagai genom juga melaporkan tingkat keberhasilan pemetaan yang tinggi (≥ 98 –99% gen terangkat dengan identitas sekuens tinggi), dengan sisa gen unmapped biasanya terkait dengan perbedaan nyata antara genom target dan referensi [38], [43], [107].

PR25 memiliki sedikit lebih banyak gen yang gagal dipetakan (885 vs 657), yang dapat mencerminkan dua kemungkinan utama, yaitu adanya variasi struktural atau perbedaan lokus pada PR25 akibat hibridisasi dengan *O. longistaminata*, sehingga sebagian gen ZS97 tidak menemukan pasangan yang cocok di genom PR25 atau perbedaan kualitas lokal perakitan (misalnya adanya gap atau region yang sulit dirakit), yang membuat beberapa gen referensi tidak terwakili secara penuh. Namun, karena proporsi unmapped masih kecil, efeknya terhadap analisis downstream relatif terbatas dibandingkan keseluruhan gene space yang berhasil dipetakan.

6.2.1.3 Implikasi terhadap kualitas genom dan kontribusi *O. longistaminata*

Ringkasan Liftoff juga memberikan informasi tambahan mengenai struktur transkrip, seperti jumlah mRNA, CDS, ekson, dan UTR. Untuk PR25, berkas statistik melaporkan 37.581 gen dan 52.252 mRNA, dengan 52.210 CDS dan 308.251 ekson, sedangkan RD23 memiliki 35.028 gen dan 49.752 mRNA dengan pola jumlah CDS dan ekson yang serupa. Selain itu, lebih dari separuh mRNA pada kedua genom memiliki UTR di kedua sisi (5' dan 3'), yang menunjukkan bahwa banyak transkrip yang terannotasi memiliki struktur regulasi yang relatif lengkap.

UTR diketahui berperan penting dalam pengaturan stabilitas mRNA dan efisiensi translasi, sehingga keberadaan UTR yang teranotasi dengan baik memberi indikasi bahwa anotasi yang diperoleh tidak hanya mencakup daerah pengkode protein, tetapi juga elemen regulasi utama. Dari sudut pandang kualitas genom, kombinasi antara persentase gen mapped yang tinggi dan struktur transkrip yang lengkap mendukung bahwa perakitan PR25 dan RD23 memiliki representasi gene space yang baik dan layak menjadi dasar untuk analisis orthology, anotasi fungsi, serta identifikasi gen turunan pada tahap berikutnya.

Pada anotasi akhir PR25 (PR25_final_backbone_plus_OL) memuat sekitar 8% lebih banyak gen dibandingkan anotasi awal berbasis ZS97 mengindikasikan bahwa integrasi gen-gen unik *O. longistaminata* berhasil menambah lapisan variasi genetik baru pada genom PR25. Pada studi [106], *Oryza longistaminata* dikenal sebagai spesies liar perenial yang kaya sifat agronomis bernilai, seperti biomassa tinggi, efisiensi penggunaan nitrogen, toleransi cekaman, dan keberadaan rimpang, kumpulan gen tambahan ini menjadi kandidat penting untuk dikaitkan dengan sifat-sifat perennial dan ketahanan PR25 pada analisis fungsional di subbab-subbab berikutnya.

6.2.2 Analisis Hasil Ekstraksi CDS dan Protein dengan gffread

Pada tahap ini, anotasi gen hasil Liftoff dimanfaatkan untuk mengekstrak sekuens CDS (coding sequence) dan protein dari genom PR25 dan RD23 menggunakan alat baris perintah gffread. Ekstraksi ini penting karena analisis lanjutan seperti OrthoFinder, EggNOG-mapper, dan InterProScan tidak bekerja langsung pada berkas anotasi GFF3, tetapi memerlukan input berupa sekuens nukleotida CDS atau sekuens asam amino protein dalam format FASTA.

Dari kombinasi anotasi GFF3 dan genom FASTA tersebut, gffread kemudian menghasilkan output berupa berkas FASTA yang berisi seluruh CDS yang diprediksi (.cds.all.fa) dan seluruh protein yang diterjemahkan dari CDS (.pep.all.fa). Dalam penelitian ini, hasil ekstraksi yang digunakan untuk analisis lebih lanjut adalah berkas protein:

- D:\result\output_bio\proteins\PR25.final.pep.all.fa

- D:\result\output_bio\proteins\RD23.final.pep.all.fa

Memuat seluruh sekuens protein yang diturunkan dari anotasi gen hasil Liftoff pada PR25 dan RD23.

Tabel 6. 3 Analisis Output Gffread

Genom	Jumlah Sequence (n_seq)	Panjang Minimum (aa)	Panjang Maksimum (aa)	Panjang rata-rata
PR25	52209	1	6122	393.33
RD23	49849	1	5499	406.43

Berdasarkan tabel 6.3, gffread berhasil mengekstrak lebih dari 50.000 sekuens protein dari masing-masing genom, dengan jumlah 52.209 protein untuk PR25 dan 49.849 protein untuk RD23. Rentang panjang protein yang dihasilkan cukup lebar, mulai dari 1 asam amino hingga lebih dari 5.000 asam amino, dengan panjang rata-rata sekitar 393 aa untuk PR25 dan 406 aa untuk RD23. Nilai-nilai ini menunjukkan bahwa dataset protein mencakup baik protein pendek (misalnya peptida regulator atau fragmen kecil), maupun protein besar yang tersusun dari banyak domain.

6.3 Integrasi Data


Pada subbab ini menjelaskan integrasi data terhadap hasil orthofinder, eggnog mapper, dan interproscan yang dilakukan pada tiga spesies padi dalam penelitian ini.

6.3.1 Proporsi gen PR25 dengan anotasi fungsi informatif (KNOWN) dan tidak informatif (UNKNOWN) berdasarkan integrasi eggNOG-mapper v2 dan InterProScan

Subbab ini menyajikan proporsi gen PR25 yang memperoleh anotasi fungsi berdasarkan integrasi dua sumber anotasi komputasional, yaitu eggNOG mapper v2 dan InterProScan. eggNOG mapper v2 melakukan anotasi fungsi berbasis penugasan ortholog yang dipra hitung, sehingga label fungsi (misalnya deskripsi fungsi dan pemetaan Gene Ontology) diturunkan dari relasi ortholog yang teridentifikasi pada basis data rujukan [64]. InterPro merupakan basis data klasifikasi protein berbasis signature (keluarga protein, domain, dan situs

konservatif), sedangkan InterProScan memindai sekuens protein untuk mendeteksi kecocokan terhadap signature InterPro dan menghasilkan anotasi berbasis domain atau keluarga protein [70].

Dalam penelitian ini, KNOWN didefinisikan sebagai gen PR25 yang memiliki anotasi fungsi informatif pada keluaran eggNOG mapper v2 atau InterProScan. UNKNOWN didefinisikan sebagai gen PR25 yang tidak memiliki anotasi fungsi informatif pada keluaran keduanya.



Gambar 6.3. 1 Distribusi Gen PR25 dengan Status Fungsi

Berdasarkan Gambar 6.3.1, dari total 33.305 gen PR25 yang dianalisis, kategori KNOWN berjumlah 25.828 gen (77,5%), sedangkan kategori UNKNOWN berjumlah 7.477 gen (22,5%). Nilai tersebut merupakan hasil pengelompokan KNOWN dan UNKNOWN setelah integrasi dua sumber anotasi komputasional diterapkan pada seluruh gen PR25 yang dianalisis.

Tabel 6. 4 Cuplikan dari PR25_Final_Table_for_TA_Functional_Only.xlsx

Gen_PR25	Sumber_Gen	Partner_RD23	Partner_OL	Fungsi_Utama	Status_Fungsi
PR25gChr01 G000010	BOTH	RD23gChr01 G000010	KN541486.1 _FGP001	Domain in Tre-2, BUB2p, and Cdc16p. Probable Rab-GAPs.	KNOWN
PR25gChr01 G000020	RD23_only	RD23gChr01 G000020		Belongs to the cytochrome P450 family	KNOWN
PR25gChr01 G000810	OL_only		KN539550.1 _FGP004	Phosphatidylethanolamine-binding protein	KNOWN

Tabel 6.4 dari PR25_Final_Table_for_TA_Functional_Only.xlsx disajikan sebagai contoh baris data pada tingkat gen untuk kategori KNOWN yang menjadi dasar ringkasan pada Gambar 6.3.1. Setiap baris memuat ID gen PR25 (Gen_PR25) dan kategori asal gen (Sumber_Gen: BOTH, RD23_only, atau OL_only), kemudian diikuti pasangan ortholog yang terdeteksi pada tetua yang relevan (Partner_RD23 dan atau Partner_OL). Kolom Fungsi_Utama menampilkan label fungsi ringkas yang dapat ditafsirkan (misalnya “Belongs to the cytochrome P450 family” atau “Phosphatidylethanolamine binding protein”), dan baris tersebut ditandai dengan Status_Fungsi = KNOWN, sehingga tabel ini memperlihatkan bahwa gen pada kelompok KNOWN memiliki anotasi fungsi informatif pada hasil integrasi. Cuplikan ini diberikan sebagai ilustrasi format dan isi tabel integrasi, sedangkan perhitungan proporsi KNOWN pada subbab ini tetap merujuk pada ringkasan kuantitatif pada Gambar 6.3.1, sesuai kaidah pelaporan yang menyarankan tabel mendukung pemahaman tanpa menduplikasi isi utama gambar atau teks.

Tabel 6. 5 Cuplikan dari PR25_Final_Table_for_TA_Unknown_Only.xlsx


Gen_PR25	Sumber	Partner_RD	Partner_OL	Fungsi_	Status_
----------	--------	------------	------------	---------	---------

	_Gen	23		Utama	Fungsi
PR25gChr01 G014420	RD23_only	RD23gChr01 G014420			UNKNO WN
PR25gChr01 G015180	OL_only		KN540438.1 _FGP001	Protein of unknown function, DUF594	UNKNO WN
PR25gChr01 G016800	BOTH	RD23gChr01 G016800	KN543554.1 _FGP001	Domain of unknown function (DUF344 4)	UNKNO WN

Tabel cuplikan dari PR25_Final_Table_for_TA_Unknown_Only.xlsx disajikan sebagai baris data pada tingkat gen untuk kategori UNKNOWN, yaitu gen yang belum memperoleh anotasi fungsi informatif pada dua sumber anotasi yang diintegrasikan dalam penelitian ini. Sama seperti tabel KNOWN, setiap baris menampilkan ID gen PR25 (Gen_PR25), kategori asal gen (Sumber_Gen), serta pasangan ortholog yang terdeteksi (Partner_RD23 dan atau Partner_OL) bila tersedia. Perbedaannya terlihat pada kolom Fungsi_Utama, yang dapat kosong atau berisi penanda ketidakjelasan fungsi seperti protein atau domain of unknown function (DUF), dan seluruh baris tersebut ditandai dengan Status_Fungsi = UNKNOWN. Dengan demikian, tabel ini menunjukkan bentuk data yang menyebabkan suatu gen diklasifikasikan sebagai UNKNOWN dalam ringkasan Gambar 6.3.1, sambil tetap menjaga bahwa angka proporsi UNKNOWN pada subbab ini berasal dari ringkasan kuantitatif pada gambar, bukan dari cuplikan tabel, sesuai pedoman bahwa data pada tabel atau gambar tidak perlu diulang secara berlebihan di teks.

6.3.2 Distribusi status anotasi fungsi (KNOWN/UNKNOWN) menurut asal gen

Subbab ini menyajikan distribusi status anotasi fungsi (KNOWN atau UNKNOWN) berdasarkan kategori asal gen (Sumber_Gen) yang diturunkan dari hasil inferensi ortholog. Kategori Sumber_Gen dibedakan menjadi tiga kategori, yaitu BOTH (gen PR25 memiliki ortholog terdeteksi pada RD23 dan *Oryza longistaminata*), RD23 only (ortholog terdeteksi hanya pada RD23), dan OL only (ortholog terdeteksi hanya pada *Oryza longistaminata*). Pada subbab ini, kategori BOTH, RD23 only, dan OL only diperlakukan sebagai kategori operasional berbasis deteksi ortholog pada data dan parameter analisis yang digunakan.



Gambar 6.3. 2 Jumlah Gen PR25 dengan Status Gen per Sumber Gen


Berdasarkan Gambar 6.3.2, pada kategori BOTH, gen KNOWN berjumlah 18.525 dari 20.204 gen (91,7%), sedangkan gen UNKNOWN berjumlah 1.679 dari 20.204 gen (8,3%). Pada kategori RD23 only, gen KNOWN berjumlah 7.062 dari 12.808 gen (55,1%), sedangkan gen UNKNOWN berjumlah 5.746 dari 12.808 gen (44,9%). Pada kategori OL only, gen KNOWN berjumlah 241 dari 293 gen (82,3%), sedangkan gen UNKNOWN berjumlah 52 dari 293 gen (17,7%).

Karena kategori OL only hanya terdiri dari 293 gen, persentase pada kategori tersebut dibaca sebagai ringkasan untuk kelompok 293 gen itu, dan tidak digunakan untuk menyatakan pola pada keseluruhan gen PR25. Sebagai batas interpretasi metodologis, inferensi ortholog dapat menghasilkan kesalahan yang bersifat

sistematis, dan kesalahan tersebut dapat memengaruhi analisis lanjutan yang menggunakan himpunan ortholog sebagai masukan [108]. Oleh karena itu, kategori BOTH, RD23 only, dan OL only pada subbab ini dipertahankan sebagai ringkasan berbasis deteksi ortholog pada analisis yang digunakan.

6.3.3 Komposisi gen PR25 berdasarkan asal ortholog (BOTH, RD23_only, OL_only)

Subbab ini menyajikan komposisi gen PR25 menurut kategori Sumber_Gen (BOTH, RD23 only, dan OL only) yang diperoleh dari hasil inferensi ortholog. Penyajian komposisi ini digunakan sebagai konteks kuantitatif untuk membaca hasil pada subbab 6.3.1 dan 6.3.2, terutama ketika status KNOWN dan UNKNOWN dibandingkan antar kategori Sumber_Gen.




Gambar 6.3. 3 Distribusi Gen Turunan pada PR25

Berdasarkan Gambar 6.3.3, dari total 33.305 gen PR25 yang terpetakan dalam relasi ortholog, kategori BOTH berjumlah 20.204 gen (60,7%), kategori RD23 only berjumlah 12.808 gen (38,5%), dan kategori OL only berjumlah 293 gen (0,9%). Angka tersebut menyatakan komposisi kategori deteksi ortholog pada dataset PR25 yang dianalisis menggunakan dua tetua pembanding. Sebagai konteks biologis pemilihan dua tetua pembanding, studi padi perenial [2], melaporkan bahwa padi

perennial dikembangkan melalui program pemuliaan yang melibatkan hibridisasi padi budidaya (*Oryza sativa*) dan *Oryza longistaminata*, sehingga perbandingan terhadap dua tetua tersebut relevan untuk analisis komparatif pada tingkat gen atau protein.

6.3.4 Fungsi Utama Dominan Gen PR25 (Kategori KNOWN)

Subbab ini menyajikan sepuluh label Fungsi_Utama paling dominan pada gen PR25 kategori KNOWN, serta distribusinya pada setiap kelompok Sumber_Gen (RD23_only, OL_only, BOTH) dan agregat PR25_all. Label Fungsi_Utama merupakan ringkasan anotasi hasil integrasi dua pendekatan, yaitu anotasi berbasis penugasan ortholog (eggNOG mapper v2) [64] dan anotasi berbasis signature protein (InterProScan/InterPro) [73].



Gambar 6.3. 4 Heatmap Top 10 Fungsi_Utama pada PR25

Tabel 6.6 berikut menyajikan isi setiap sel heatmap dalam format jumlah gen (persentase). Persentase pada setiap sel adalah proporsi terhadap total gen KNOWN pada kolom tersebut, sesuai dengan heatmap.

Tabel 6. 6 Makna Fungsi Gen bagian 1

Fungsi _Utam	RD23 _only	OL_ only	BOT H	PR25 _all	Makna biologis (ringkas)	Dukungan jurnal (makna
-----------------	---------------	-------------	----------	--------------	-----------------------------	---------------------------

a	(n=7. 062)	(n=2 41)	(n=18 .523)	(n=25 .826)		biologis)
SignalP -TM	312 (4,42 %)	4 (1,6 6%)	84 (0,45 %)	400 (1,55 %)	Protein diprediksi memiliki signal peptide dan heliks transmembran. Umum pada protein membran yang masuk jalur sekretori, termasuk reseptor atau komponen membran yang terlibat pada persepsi sinyal dan interaksi patogen.	Studi OsSSP1 menunjukkan protein sekretori (berbasis signal peptide) berperan pada ketahanan, dengan persepsi oleh reseptor membran [109], [110].
SignalP -TM SignalP -noTM	220 (3,13 %)	2 (0,8 3%)	143 (0,77 %)	365 (1,41 %)	Kelompok protein yang diprediksi terkait signal peptide, dengan variasi fitur membran. Digunakan sebagai indikator protein yang berada pada jalur sekretori atau berasosiasi dengan membran dalam anotasi komputasional.	Protein sekretori dan reseptor membran pada sistem imun padi (OsSSP1–OsSSR1–OsBAK1) [109], [110].
Protein	43	3	247	293	Domain kinase	OsNAC120

kinase domain	(0,61 %)	(1,2 4%)	(1,33 %)	(1,13 %)	menandai enzim fosforilasi yang menjadi komponen utama transduksi sinyal (hormon, stres abiotik, dan respons pertahanan).	dan komponen pensinyalan ABA/GA menunjukkan keterkaitan pensinyalan protein kinase (jalur fosforilasi) dalam kontrol respons fisiologis padi [111].
SignalP -noTM	197 (2,79 %)	3 (1,2 4%)	67 (0,36 %)	267 (1,03 %)	protein diprediksi memiliki signal peptide tanpa heliks transmembran; lazim pada protein yang disekresikan ke apoplas atau dinding sel, termasuk protein kecil sekretori dan protein pertahanan.	OsSSP1 dibuktikan dapat disekresikan ke apoplas dan memicu respons imun [109], [110].
NB-ARC domain	44 (0,62 %)	15 (6,2 2%)	159 (0,86 %)	218 (0,84 %)	NB ARC adalah domain inti reseptor imun intraseluler NLR (nucleotide binding);	Gen NLR padi Xa47 membuktikan kelas NLR berperan pada ketahanan

					berkaitan dengan aktivasi respons pertahanan.	penyakit [112].
Belongs to the cytochrome P450 family	62 (0,88 %)	2 (0,83 %)	152 (0,82 %)	216 (0,84 %)	P450 adalah enzim oksidatif dan banyak berperan pada metabolisme sekunder dan jalur terkait ketahanan atau adaptasi.	CYP716A16 (P450) dilaporkan berperan pada regulasi ketahanan penyakit pada padi [113].
Belongs to the UDP-glycosyltransferase family	40 (0,57 %)	2 (0,83 %)	92 (0,50 %)	134 (0,52 %)	UDP glikosiltransferase memodifikasi metabolit melalui glikosilasi sehingga terkait stabilitas metabolit, homeostasis membran, dan adaptasi stres.	OsUGT706D2 berperan toleransi dingin dan submergence pada membran plasma [114].
Myb-like DNA-binding domain	49 (0,69 %)	1 (0,41 %)	84 (0,45 %)	134 (0,52 %)	Domain MYB menandai faktor transkripsi yang mengatur jaringan gen, termasuk regulasi respons lingkungan dan metabolisme.	MYB (OsMYB58) berperan dalam regulasi program fisiologis dan pertumbuhan [115].
Ser/Thr protein kinase	25 (0,35 %)	7 (2,90 %)	93 (0,50 %)	125 (0,48 %)	Serin treonin kinase adalah subkelompok	OsNAC120 dan modul respons stres

family					protein kinase untuk transduksi sinyal. Umum pada respons hormon dan stres.	padi terkait ABA/GA berbasis fosforilasi (protein kinase) pada jalur regulasi stres [111].
PPR repeat	21 (0,30 %)	0 (0,0 %)	98 (0,53 %)	119 (0,46 %)	Protein PPR, terkait pengaturan pascatranskripsi pada organel (mitokondria atau kloroplas), khususnya RNA editing dan stabilitas transkrip yang memengaruhi pertumbuhan serta toleransi stres.	OsPPR674 dilaporkan mengatur RNA editing mitokondria dan memengaruhi pertumbuhan serta sensitivitas kekeringan [116].


Berdasarkan gambar dan tabel tersebut, dapat diketahui bahwa:

- Pada PR25_all, tiga label berbasis sekretori atau membran berada pada nilai tertinggi dalam Top 10: SignalP TM 400 (1,55%), SignalP TM | SignalP noTM 365 (1,41%), dan SignalP noTM 267 (1,03%).
- RD23_only menunjukkan proporsi label sekretori atau membran yang lebih tinggi dibanding BOTH: misalnya SignalP TM 312 (4,42%) pada RD23_only dibanding 84 (0,45%) pada BOTH; dan SignalP noTM 197 (2,79%) pada RD23_only dibanding 67 (0,36%) pada BOTH.
- OL_only menunjukkan proporsi tertinggi untuk NB ARC domain 15 (6,22%), sedangkan RD23_only 44 (0,62%) dan BOTH 159 (0,86%).

Pada gen PR25 kategori KNOWN, komponen sekretori atau membran merupakan kelompok terbesar dalam Top 10 pada agregat PR25_all (SignalP TM 400 (1,55%), SignalP TM | SignalP noTM 365 (1,41%), dan SignalP noTM 267 (1,03%)). Selain itu, OL_only memiliki proporsi tertinggi untuk penanda reseptor imun NLR (NB ARC 6,22%) dibanding RD23_only (0,62%), BOTH (0,86%), dan PR25_all (0,84%). Oleh karena itu, pada subset OL_only, label NB ARC merupakan label yang paling menonjol secara proporsi dibanding kelompok lain.

6.3.5 Top-10 Fungsi_EggNOG (EggNOG-mapper) pada gen PR25 (kategori KNOWN) per kelompok Sumber_Gen

Subbab ini merangkum sepuluh label fungsi paling dominan yang berasal dari keluaran eggNOG mapper v2 pada gen PR25 kategori KNOWN. Karena eggNOG mapper v2 menugaskan fungsi melalui kerangka orthology yang teranotasi, label pada heatmap merepresentasikan kelas fungsi yang dipetakan dari kelompok ortholog rujukan [64].



Gambar 6.3. 5 Heatmap Top 10 Fungsi_EggNOG pada PR25

Gambar 6.3.5 merupakan Top 10 Fungsi_EggNOG (KNOWN) jumlah dan persentase gen per kelompok Sumber_Gen (RD23_only, OL_only, BOTH, PR25_all).

Untuk menghindari pengulangan definisi, makna biologis dan dukungan jurnal bagi label fungsi atau fitur yang telah dijelaskan pada Subbab 6.3.4 (Tabel 6.6) tidak dituliskan ulang pada subbab ini. Pada subbab ini, makna biologis dan dukungan jurnal hanya ditambahkan untuk label yang baru muncul pada heatmap subbab ini.

Tabel 6. 7 Makna Fungsi Gen bagian 2

Fungsi _EggN OG (Fungsi i_Utama)	RD23 _only (n=7. 062)	OL_ only (n=2 41)	BOT H (n=18 .523)	PR25 _all (n=25 .826)	Makna biologis (ringkas)	Dukungan jurnal (makna biologis)
No apical meristem (NAM) protein	21 (0,43 %)	0 (0,0 0%)	82 (0,50 %)	103 (0,48 %)	NAM mengarah pada keluarga NAC yang berfungsi regulator transkripsi pada perkembangan dan respons stres.	OsNAC120 mengatur keseimbangan pertumbuhan dan toleransi kekeringan [111].
Zinc finger	38 (0,78 %)	0 (0,0 0%)	51 (0,31 %)	89 (0,42 %)	Label zinc finger menandai protein yang memiliki domain pengikat DNA dan lazim berperan sebagai faktor transkripsi. Dalam padi, sebagian zinc finger (contoh keluarga Di19) berfungsi sebagai	OsDi19 3 (zinc finger) dibuktikan sebagai faktor transkripsi zinc finger yang terinduksi kekeringan dan berkontribusi pada aklimatisasi kekeringan

					regulator ekspresi gen pada kondisi cekaman kekeringan.	[117].
Belongs to the protein kinase superfamily	13 (0,27 %)	2 (1,03 %)	74 (0,45 %)	89 (0,42 %)	Protein teranotasi sebagai anggota superfamily protein kinase (berdasarkan domain kinase), sehingga berpotensi berfungsi sebagai enzim fosforilasi dalam regulasi sel.	Integrasi GA dan ABA pada padi memperlihatkan pentingnya komponen protein kinase dalam jalur sinyal stres [111].

Berdasarkan gambar 6.3.5 tersebut, berikut penjelasannya:

- PR25_all pada EggNOG menunjukkan puncak pada Protein kinase domain 293 (1,37%) dan NB ARC domain 216 (1,01%), diikuti P450 218 (1,02%).
- OL_only menunjukkan proporsi tertinggi untuk label pertahanan: NB ARC 15 (7,69%), jauh di atas RD23_only 44 (0,91%) dan BOTH 159 (0,98%).
- RD23_only relatif lebih tinggi pada P450 62 (1,28%) dan MYB 49 (1,01%) dibanding BOTH untuk dua label tersebut (P450 0,93%; MYB 0,52%).

Profil EggNOG pada PR25_all ditopang oleh komponen protein kinase (1,37%) serta label terkait pertahanan NLR (NB ARC 1,01%) dan metabolisme P450 (1,02%). Perbedaan antar kelompok paling menonjol terlihat pada OL_only karena label NB ARC mencapai 15 gen (7,69%), sedangkan pada RD23_only 44 gen (0,91%) dan pada BOTH 159 gen (0,98%). Dengan demikian, pada subset OL_only, label NB ARC muncul dengan proporsi lebih tinggi dibanding dua kelompok lainnya.

Tabel 6. 8 Cuplikasi Isi Output eggNOG mapper dengan Fungsi_EggNOG


Gen_ PR25	Su mb er_ Ge n	Part ner_ RD2 3	Part ner_ OL	Fungsi_U tama	Fungsi _EggN OG	Fu ngs i_I nte rPr o	is_k no wn _Fu ngsi _Ut am a	is_k now n_F ung si_E ggN OG	is_kn own_ Fungs i_Inte rPro
PR25 gChr 01G0 0024 0	BO TH	RD23 gChr 01G0 0024 0	KN5 3882 6.1_F GP02 3	BEST Arabidops is thaliana protein match is hydroxypr oline-rich glycoprote in family protein (TAIR AT5G524 30.1)	BEST Arabid opsis thalian a protein match is hydrox yprolin e-rich glycopr otein family protein (TAIR AT5G5 2430.1)	Un cha ract eriz ed pro tein At1 g76 660 - like	TR UE	TR UE	FALS E
PR25 gChr 01G0 0201 0	RD 23 _o nly	RD23 gChr 01G0 0201 0		Zinc finger protein	Zinc finger protein	-	TR UE	TR UE	FALS E

PR25 gChr 06G0 2083 0	OL _o nly		KN5 4159 5.1_F GP00 3	Indole-3- acetic acid- amido synthetase	Indole-3- acetic acid- amido synthetase	-	TR UE	TR UE	FALS E
-----------------------------------	-----------------	--	-----------------------------------	---	---	---	----------	----------	-----------

Tabel cuplikan ini menyajikan baris gen PR25 yang memuat keluaran anotasi eggNOG mapper v2 pada kolom Fungsi_EggNOG. Setiap baris berisi Gen_PR25 sebagai identitas gen, Sumber_Gen sebagai kategori deteksi ortholog (BOTH, RD23_only, OL_only), serta Partner_RD23 dan atau Partner_OL sebagai pasangan ortholog yang terdeteksi pada tetua yang relevan. Kolom Fungsi_EggNOG berisi label fungsi yang diturunkan melalui anotasi berbasis penugasan ortholog yang telah diprahitung pada basis data eggNOG, sehingga label fungsi pada level gen dapat ditelusuri pada keluaran EggNOG [64]. Kolom logika is_known_Fungsi_EggNOG yang bernilai TRUE pada baris cuplikan menunjukkan bahwa anotasi EggNOG pada baris tersebut diperlakukan sebagai anotasi informatif menurut aturan integrasi yang digunakan, sedangkan nilai FALSE pada is_known_Fungsi_InterPro pada cuplikan ini menunjukkan bahwa, untuk baris gen yang ditampilkan, bukti InterProScan tidak tercatat sebagai anotasi informatif pada kolom terkait. Dengan demikian, tabel berfungsi sebagai ilustrasi bentuk data level gen yang mendasari ringkasan Top 10 pada heatmap Subbab 6.3.5, tanpa mengulang ringkasan kuantitatif yang telah disajikan pada visualisasi.

6.3.6 Top-10 Fungsi_InterPro (InterProScan) pada gen PR25 (kategori KNOWN) per kelompok Sumber_Gen

Subbab ini membahas Top-10 label InterProScan pada gen PR25 kategori KNOWN (total n=25.218 gen). Berbeda dari EggNOG yang kuat di transfer fungsi berbasis orthology, InterPro lebih menonjolkan bukti berbasis *domain/family/signature* dan juga fitur sekuens seperti signal peptide serta transmembrane region, sehingga lebih sensitif untuk menangkap “tipe protein” (sekretori/membran, domain resistensi, enzim ROS, dan sebagainya) [70], [73].



Gambar 6.3. 6 Top-10 Fungsi InterPro (InterProScan) pada gen PR25 per kelompok Sumber_Gen

Gambar 6.3.6 merupakan Top 10 Fungsi InterPro (KNOWN) – jumlah & persentase gen per kelompok Sumber_Gen (RD23_only, OL_only, BOTH, PR25_all).

Sama seperti subbab 6.3.5, label fungsi atau fitur yang telah dijelaskan pada Subbab 6.3.4 dan 6.3.5 tidak dituliskan ulang pada subbab ini untuk menghindari pengulangan definisi yaitu makna biologis dan dukungan jurnal. Pada subbab ini, makna biologis dan dukungan jurnal hanya ditambahkan untuk label yang baru muncul pada heatmap subbab ini.

Tabel 6. 9 Makna Fungsi Gen bagian 3

Fungsi_Interproscan (Fungsi_Uutama)	RD23_only (n=7.062)	OL_only (n=241)	BOTH (n=18.523)	PR25_all (n=25.826)	Makna biologis (ringkas)	Dukungan jurnal (makna biologis)
Apoptotic protease activating	18 (0,26%)	11 (4,64%)	110 (0,60%)	139 (0,55%)	Signature ketahanan (LRR/NB-	NLR padi Xa47 dapat

factors, helical domain Disease resistance protein signature Disease resistance protein, plants L domain like Leucine rich repeat domain superfamily					ARC dan signature protein ketahanan tanaman).	meningkatkan ketahanan berbasis domain padi [112].
EXPRESSED PROTEIN	54 (0,79%)	0 (0,00%)	65 (0,36%)	119 (0,47%)	Protein terprediksi/t erekspresi. Anotasi signature informatif bisa terbatas.	Kerangka InterPro menjelaskan anotasi berbasis signature yang terdeteksi [73].
GLYCOSYLTRANSFERASE Glycogen Phosphorylase B Glycosyltransferase UDP Glycosyltransferase glycogen phosphorylase	20 (0,29%)	1 (0,42%)	59 (0,32%)	80 (0,32%)	Enzim glikosilasi untuk modifikasi metabolit yang terkait adaptasi stres dan proteksi membran.	OsUGT90A1 dibuktikan melindungi membran pada stres dingin [114].

UDP glucuronosyl UDP glucosyltransfe rase						
TRANSMEM BRANE PROTEIN	33 (0,49%)	0 (0,0 0%)	34 (0,19%)	67 (0,27 %)	Protein integral membran mencakup transporter dan reseptor yang memediasi persepsi sinyal dan homeostasis .	OsS1Fa1 (protein dengan domain transmem bran) dibuktikan berkontrib usi pada toleransi kekeringa n [118].
Transcription factor GRAS	11 (0,16%)	0 (0,0 0%)	42 (0,23%)	53 (0,21 %)	TF GRAS adalah regulator transkripsi yang terkait perkembang an dan respons stres/hormo nal.	Profil transkrip GRAS padi pada perlakuan ABA dan salinitas [119].
Haem peroxidase Haem peroxidase superfamily	7 (0,10%)	0 (0,0 0%)	35 (0,19%)	42 (0,17 %)	Peroksidase kelas tanaman berperan pada	WOX11– OsPRX13 0 memperta hankan

Peroxidase Peroxidase active site Peroxidase domain 2					pengaturan homeostasis ROS yang memengaruhi ketahanan stres.	homeostasis ROS dan meningkatkan toleransi kekeringan [120].
Small auxin up RNA	24 (0,35%)	0 (0,00%)	17 (0,09%)	41 (0,16%)	SAUR adalah gen respons auksin memengaruhi pertumbuhan dan perkembangan. Sebagian anggota memengaruhi arsitektur akar dan ketahanan kekeringan.	OsSAUR1 1 dibuktikan meningkatkan perakaran dalam dan meningkatkan ketahanan kekeringan [121].

Berikut penjelasan berdasarkan gambar 6.3.6 tersebut:

- Pada PR25_all, tiga label sekretori atau membran berada pada proporsi tertinggi dalam Top 10 InterPro: SignalP TM 438 (1,74%), SignalP TM | SignalP noTM 399 (1,58%), dan SignalP noTM 290 (1,15%).
- RD23_only menunjukkan proporsi lebih tinggi untuk label sekretori atau membran dibanding BOTH, misalnya SignalP TM 337 (4,96%) pada RD23_only dibanding 97 (0,53%) pada BOTH.

- OL_only menonjol pada label ketahanan berbasis signature domain (baris domain ketahanan): 11 (4,64%) pada OL_only dibanding 18 (0,26%) pada RD23_only dan 110 (0,60%) pada BOTH.

Keluaran InterPro menegaskan dominasi fitur sekretori atau membran pada agregat PR25_all (SignalP TM 1,74%; SignalP TM | SignalP noTM 1,58%; SignalP noTM 1,15%). Selain itu, OL_only memiliki proporsi tertinggi untuk label signature ketahanan, yaitu 11 gen (4,64%), dibanding RD23_only 18 gen (0,26%) dan BOTH 110 gen (0,60%). Dengan demikian, pada subset OL_only, label signature ketahanan muncul dengan proporsi lebih tinggi dibanding dua kelompok lainnya.

Tabel 6. 10 Cuplikan Isi Output Interproscan dengan Fungsi_Interpro


Gen_ PR25	Su mb er_ Ge n	Part ner_ RD2 3	Part ner_ OL	Fungsi_U tama	Fun gsi_ Egg NO G	Fungsi _Inter Pro	is_k no wn _Fu ngsi _Ut am a	is_k now n_F ung si_E ggN OG	is_kn own_ Fungs i_Inte rPro
PR25 gChr 01G0 0013 0	BO TH	RD23 gChr 01G0 0013 0	KN5 3882 6.1_F GP02 2	EXPRES SED PROTEIN	-	EXPR ESSE D PROT EIN	TR UE	FAL SE	TRUE
PR25 gChr 01G0 0017 0	RD 23 _o nly	RD23 gChr 01G0 0017 0		OS01G01 02500 PROTEIN SignalP- TM	-	OS01 G0102 500 PROT EIN Signal P-TM	TR UE	FAL SE	TRUE

PR25	OL		KN5	SignalP-		Signal	TR	FAL	TRUE
gChr	_o		3995	noTM		P-	UE	SE	
01G0	nly		1.1_F			noTM			
1609			GP00						
0			3						

Tabel cuplikan ini menyajikan baris gen PR25 yang memuat keluaran anotasi InterProScan pada kolom Fungsi_InterPro. Setiap baris berisi Gen_PR25 sebagai identitas gen, Sumber_Gen sebagai kategori deteksi ortholog, serta Partner_RD23 dan atau Partner_OL sebagai pasangan ortholog yang terdeteksi. Kolom Fungsi_InterPro memuat label signature InterPro (keluarga protein, domain, atau situs konservatif) yang diperoleh dari pemindaian sekuens terhadap signature yang dihimpun InterPro; keluaran tersebut merepresentasikan klasifikasi berbasis signature pada level gen atau protein [70]. Kolom logika is_known_Fungsi_InterPro yang bernilai TRUE pada baris cuplikan menunjukkan bahwa anotasi InterPro pada baris tersebut diperlakukan sebagai anotasi informatif menurut aturan integrasi, sedangkan nilai FALSE pada is_known_Fungsi_EggNOG pada cuplikan ini menunjukkan bahwa anotasi EggNOG tidak tercatat sebagai anotasi informatif pada kolom terkait untuk baris gen yang ditampilkan. Dengan demikian, tabel berfungsi sebagai ilustrasi data level gen yang mendasari ringkasan Top 10 pada heatmap Subbab 6.3.6, sementara pembahasan dominansi label tetap merujuk pada ringkasan kuantitatif pada visualisasi.

6.3.7 Top-10 Fungsi_Utama pada gen BOTH (Gen Homologi D23 dengan *O. longistaminata*) kategori KNOWN

Subbab ini membahas gen BOTH (n = 18.523 KNOWN), yaitu gen PR25 yang memiliki pasangan ortholog baik ke RD23 maupun ke *O. longistaminata*, sehingga merepresentasikan “inti konservatif” yang relatif stabil di antara ketiganya.




Gambar 6.3. 7 Top-10 Fungsi_Utama pada gen BOTH (KNOWN)

Adapun makna biologis serta dukungan jurnal untuk setiap label Fungsi_Utama yang muncul pada tabel telah diuraikan pada Subbab 6.3.4–6.3.6. Karena itu, subbab ini tidak mengulang definisi fungsi yang sama, melainkan menekankan perbedaan pola dominansi antar kelompok melalui pembuktian berbasis angka pada barplot. Pendekatan ini menjaga keterlacakan hasil sekaligus menghindari repetisi antara teks, tabel, dan subbab sebelumnya.

Berdasarkan gambar 6.3.7 tersebut, kelompok BOTH menunjukkan dominansi modul pensinyalan dan pertahanan yang bersifat luas, ditunjukkan oleh Protein kinase domain 247 gen (1,33%) sebagai peringkat pertama dan NB-ARC domain 159 gen (0,86%) sebagai peringkat kedua. Dominansi ini diikuti komponen metabolisme adaptif Belongs to the cytochrome P450 family 152 gen (0,82%), serta fitur sekretori atau membran SignalP-TM | SignalP-noTM 143 gen (0,77%) dan SignalP-TM 84 gen (0,43%). Kelompok ini juga memuat regulator dan komponen pendukung yang tetap menonjol pada basis besar BOTH, yaitu PPR repeat 98 gen (0,53%), Ser Thr protein kinase family 93 gen (0,50%), Belongs to the UDP-glycosyltransferase family 92 gen (0,50%), Myb-like DNA-binding domain 84 gen (0,45%), serta No apical meristem (NAM) protein 82 gen (0,44%). Secara biologis (mengacu Subbab 6.3.4–6.3.6), kombinasi tersebut konsisten dengan dominansi kelas protein pensinyalan berbasis fosforilasi (protein kinase), sensor imun intraseluler (NB-ARC), enzim metabolisme sekunder adaptif (P450 dan UGT), protein jalur sekretori atau membran (SignalP), regulator transkripsi (MYB dan NAC), serta regulator organel berbasis pengaturan RNA (PPR).

6.3.8 Top-10 Fungsi_Utama pada gen RD23_only – kategori KNOWN

Subbab ini membahas gen yang spesifik turunan RD23 (n = 7.062 KNOWN), sehingga pola top-10-nya menonjolkan kontribusi “khusus RD23” terhadap profil PR25.



Gambar 6.3. 8 Top-10 Fungsi_Utama pada gen RD23_only

Sama seperti subbab 6.3.7, Makna biologis dan dukungan jurnal untuk label Fungsi_Utama yang telah dibahas pada Subbab 6.3.4–6.3.6 tidak diulang; penjelasan hanya ditambahkan untuk RING-like zinc finger karena label tersebut belum muncul pada subbab sebelumnya, sehingga memerlukan definisi biologis ringkas dan satu rujukan jurnal pendukung. Dengan demikian, subbab ini tetap ringkas, bebas duplikasi, dan fokus pada pembacaan pola berbasis angka.

Tabel 6. 11 Makna Fungsi Gen bagian 4


Fungsi Utama	Jumlah dan Persentase	Makna Biologis dan Dukungan Jurnal
RING-like zinc finger	40 (0,57%)	RING menandai E3 ubiquitin ligase yang dapat mengatur intensitas respons pertahanan melalui ubiquitinasi komponen sinyal. OsPUB57 (U-box E3 ligase) dilaporkan memengaruhi ketahanan blas padi [122].

Berdasarkan gambar 6.3.8 tersebut, kelompok RD23_only paling menonjol pada

pengayaan protein jalur sekretori atau membran, dibuktikan oleh tiga label SignalP sebagai tiga peringkat teratas: SignalP-TM 312 gen (4,42%), SignalP-TM | SignalP-noTM 220 gen (3,12%), dan SignalP-noTM 197 gen (2,79%) (total 729 gen; 10,33%). Setelah itu, kontribusi metabolisme adaptif muncul pada Belongs to the cytochrome P450 family 62 gen (0,88%) dan Belongs to the UDP-glycosyltransferase family 40 gen (0,57%), sedangkan modul regulasi dan pertahanan hadir melalui Myb-like DNA-binding domain 49 gen (0,69%), Protein kinase domain 44 gen (0,62%), dan NB-ARC domain 44 gen (0,62%). Selain itu, EXPRESSED PROTEIN 50 gen (0,71%) menunjukkan adanya fraksi gen yang terdeteksi namun beranotasi terbatas pada tingkat label ringkas, dan RING-like zinc finger 40 gen (0,57%) merepresentasikan komponen regulator pascatranslasi yang menonjol pada subset ini. Secara biologis (mengacu Subbab 6.3.4–6.3.6), pola angka tersebut konsisten dengan dominansi kelas protein sekretori atau membran (SignalP), disertai komponen pensinyalan (kinase), pertahanan (NB-ARC), dan metabolisme adaptif (P450 serta UGT) pada kontribusi spesifik RD23.

6.3.9 Top-10 Fungsi_Utama pada gen OL_only – kategori KNOWN

Subbab ini membahas gen yang spesifik turunan *O. longistaminata* (n = 241 KNOWN). Karena basisnya kecil, setiap fungsi yang muncul pada Top-10 biasanya mengindikasikan kontribusi yang sangat “spesifik dan tajam”.



Gambar 6.3. 9 Top-10 Fungsi_Utama pada gen OL_only

Sama seperti subbab sebelumnya, label fungsi atau fitur yang telah dijelaskan pada Subbab 6.3.4, 6.3.5, 6.3.6, dan 6.3.8 tidak dituliskan ulang pada subbab ini untuk menghindari pengulangan definisi yaitu makna biologis dan dukungan jurnal. Pada

subbab ini, makna biologis dan dukungan jurnal hanya ditambahkan untuk label yang baru muncul pada barplot subbab ini:

Tabel 6. 12 Makna Fungsi Gen bagian 5

Fungsi Utama	Jumlah dan Persentase	Makna Biologis dan Dukungan Jurnal
Wall-associated receptor kinase	12 (4,98%)	Gen Pb4 yang mengode wall-associated kinase dilaporkan berkontribusi pada ketahanan blas padi dan memiliki arsitektur protein khas reseptor permukaan (signal peptide, domain ekstraseluler, dan domain kinase Ser/Thr), sehingga mendukung interpretasi bahwa kemunculan WAK pada OL_only merefleksikan kontribusi reseptor permukaan terkait pertahanan [123].
Disease resistance protein	8 (3,32%)	Disease resistance protein pada anotasi domain umumnya mengarah pada protein ketahanan (sering berkaitan dengan arsitektur NLR atau komponen imunitas lain). Studi genomik pada gen blast Ptr menunjukkan keterkaitan lokus ketahanan dengan protein armadillo-repeat dan konteks resistensi blas [124].
ARM REPEAT SUPERFAMILY PROTEIN	4 (1,66%)	Ptr dilaporkan sebagai alel dari protein armadillo-repeat yang berasosiasi dengan ketahanan blas pada analisis asosiasi dan pemetaan genom, sehingga kemunculan ARM repeat pada OL_only dapat dibaca sebagai

		kontribusi regulator berbasis interaksi protein dalam konteks pertahanan [124].
Core component of nucleosome. Nucleosomes wrap and compact DNA into chromatin, limiting DNA accessibility to the cellular machineries which require DNA as a template. Histones thereby play a central role in transcription regulation, DNA repair, DNA replication and chromosomal stability. DNA accessibility is regulated via a complex set of post-translational modifications of histones, also called histone code, and nucleosome remodeling	3 (1,24%)	Core component of nucleosome mengindikasikan keberadaan protein yang berfungsi sebagai komponen nukleosom atau histon yang membungkus dan memadatkan DNA menjadi kromatin, sehingga berperan pada pengaturan aksesibilitas DNA dan regulasi ekspresi gen. Sebagai contoh relevansi biologis bahwa kontrol kromatin berpengaruh pada respons stres pada padi, menunjukkan OsHDA716 (HDAC) menekan toleransi dingin melalui deasetilasi dan penurunan stabilitas OsbZIP46, menegaskan bahwa regulasi asetilasi terkait kromatin dapat memodulasi respons stres [125].
Protein desumoylation	3 (1,24%)	Jalur SUMOylation dan deSUMOylation merupakan regulasi pascatranslasi yang memengaruhi jaringan transkripsi dan performa stres. SUMOylation DELLA SLR1 dilaporkan memodulasi respons transkripsi dan meningkatkan kinerja hasil di bawah stres salinitas, sehingga

		label terkait SUMO mendukung interpretasi adanya lapisan regulasi cepat pada OL_only [126].
--	--	---

Berdasarkan gambar 6.3.9, Kelompok OL_only memperlihatkan kontribusi yang “tajam” pada modul pertahanan dan pensinyalan permukaan karena basis kelompok kecil, ditunjukkan oleh proporsi tertinggi NB-ARC domain 15 gen (6,22%), disusul Wall-associated receptor kinase 12 gen (4,98%) dan disease resistance protein 8 gen (3,32%). Lapisan pensinyalan tambahan juga tampak pada Ser Thr protein kinase family 7 gen (2,90%), serta dukungan interaksi protein dan kompartemen membran melalui ARM REPEAT SUPERFAMILY PROTEIN 4 gen (1,66%) dan SignalP-TM 4 gen (1,66%). Di luar komponen pertahanan, OL_only memuat indikator regulasi ekspresi dan regulasi pascatranslasi melalui Core component of nucleosome 3 gen (1,24%) dan protein desumoylation 3 gen (1,24%), disertai Protein kinase domain 3 gen (1,24%) dan SignalP-noTM 3 gen (1,24%). Secara biologis (mengacu Subbab 6.3.4–6.3.6 dan penjelasan yang telah ditetapkan pada bagian ini), konfigurasi angka tersebut mendukung pembacaan bahwa OL_only menonjol pada komponen ketahanan (NB-ARC dan label ketahanan), reseptor permukaan atau pensinyalan (WAK dan kinase), serta regulator tingkat kromatin dan modifikasi pascatranslasi, yang secara proporsional lebih terlihat karena ukuran kelompok lebih kecil.

BAB VII

KESIMPULAN DAN SARAN

7.1 Kesimpulan

1. Kualitas struktur perakitan genom PR25 dan RD23 sangat memadai, sedangkan assembly *Oryza longistaminata* pada penelitian ini memiliki keterbatasan struktural yang signifikan. PR25 tersusun atas 13 contig dengan N50 31.960.027 bp dan L50 = 6, sedangkan RD23 tersusun atas 199 contig tetapi tetap memiliki N50 32.118.244 bp dan L50 = 6. Sebaliknya, *O. longistaminata* tersusun atas 22.477 contig dengan N50 97.754 bp dan L50 = 877, serta memiliki #N = 10.155,31 per 100 kbp (setara sekitar 10,16% dari setiap 100.000 basa berupa N). Perbedaan ini menunjukkan bahwa PR25 dan RD23 memiliki kontiguitas tinggi (sebagian besar panjang genom tertopang oleh sedikit contig besar), sedangkan assembly *O. longistaminata* jauh lebih terfragmentasi dan mengandung gap yang sangat tinggi, sehingga berpotensi menurunkan ketelitian analisis lintas spesies yang bergantung pada kesinambungan sekuens dan kelengkapan model gen.
2. Transfer anotasi gen menggunakan Liftoff pada PR25 dan RD23 berhasil tinggi, sehingga gene space utama yang dianalisis bersifat representatif. Liftoff memetakan 34.800 gen ke PR25 dengan 885 gen unmapped (keberhasilan 97,52%) dan memetakan 35.028 gen ke RD23 dengan 657 gen unmapped (keberhasilan 98,16%). Capaian pemetaan yang tinggi ini menunjukkan bahwa sebagian besar struktur gen referensi berhasil dipertahankan pada target genom, sehingga anotasi yang digunakan pada tahap analisis berikutnya memiliki landasan yang kuat.
3. Penambahan gen unik dari *O. longistaminata* pada anotasi akhir PR25 meningkatkan jumlah gen secara nyata. Anotasi PR25 berbasis ZS97 menghasilkan 34.800 gen, sedangkan anotasi akhir PR25_final_backbone_plus_OL mencapai 37.581 gen, sehingga terdapat tambahan 2.781 gen (sekitar 8%) dibanding PR25_from_ZS97. Temuan ini menunjukkan bahwa kontribusi gen dari tetua liar tidak hanya bersifat konseptual, tetapi benar benar tercermin sebagai penambahan konten anotasi gen pada PR25 yang kemudian dianalisis.

4. Hasil orthologi menunjukkan PR25 didominasi gen inti konservatif (BOTH), sementara ketidakpastian anotasi fungsi paling besar berasal dari kelompok RD23_only. Dari 33.305 gen PR25 yang terpetakan dalam relasi ortholog, komposisinya adalah BOTH = 20.204 (60,7%), RD23_only = 12.808 (38,5%), dan OL_only = 293 (0,9%). Pada status anotasi fungsi per kategori, kelompok BOTH memiliki KNOWN 18.525/20.204 (91,7%), sedangkan RD23_only hanya KNOWN 7.062/12.808 (55,1%) dan memiliki UNKNOWN 5.746/12.808 (44,9%) sebagai sumber utama ketidakpastian biologis. Secara keseluruhan, gen PR25 berstatus KNOWN 25.828 (77,5%) dan UNKNOWN 7.477 (22,5%), sehingga prioritas penguatan interpretasi biologis secara rasional adalah menurunkan porsi UNKNOWN, terutama pada RD23_only.
5. Profil fungsi dominan PR25 (kategori KNOWN) menonjol pada komponen sekretori atau membran pada agregat PR25_all, disertai dominansi modul pensinyalan berbasis kinase. Pada ringkasan Fungsi_Utama (integrasi), tiga label sekretori atau membran berada pada nilai tertinggi di PR25_all, yaitu SignalP-TM = 400 (1,55%), SignalP-TM|SignalP-noTM = 365 (1,41%), dan SignalP-noTM = 267 (1,02%). Secara biologis, dominansi label sekretori atau membran konsisten dengan peran protein sekretori dan protein membran sebagai antarmuka utama sel dalam persepsi lingkungan, termasuk respons stres biotik, sementara keberadaan domain kinase pada kelompok Top 10 menunjukkan kuatnya kontribusi jalur pensinyalan dalam profil fungsi PR25.
6. Kelompok BOTH membentuk inti fungsional konservatif PR25, dengan dominansi pensinyalan dan pertahanan yang stabil pada himpunan gen yang besar. Pada BOTH (n = 18.525), label dominan mencakup Protein kinase domain = 247 (1,33%), NB-ARC domain = 159 (0,86%), dan Cytochrome P450 = 152 (0,82%), serta komponen sekretori atau membran seperti SignalP-TM|SignalP-noTM = 143 (0,77%). Secara biologis, dominansi protein kinase mendukung peran regulasi pensinyalan, sedangkan NB-ARC mengindikasikan keberadaan komponen imun berbasis NLR yang lazim terlibat dalam ketahanan penyakit; karena kelompok BOTH merupakan mayoritas dan memiliki proporsi KNOWN tinggi, pola ini paling stabil untuk

ditafsirkan sebagai profil inti PR25.

7. RD23_only memperlihatkan penguatan proporsi fitur sekretori atau membran yang jauh lebih tinggi dibanding BOTH, sehingga menjadi pembeda utama antara kedua kelompok. Pada RD23_only, SignalP-TM = 312 (4,42%) dibanding BOTH 84 (0,45%), dan SignalP-noTM = 197 (2,79%) dibanding BOTH 67 (0,36%). Secara biologis, peningkatan tajam pada label SignalP di RD23_only mengarah pada dominansi protein yang diprediksi masuk jalur sekresi atau berasosiasi membran, yang secara fungsional relevan karena banyak respons pertahanan tanaman dimediasi oleh protein apoplastik, peptida sekretori, dan reseptor membran sebagai komponen pengenalan serta pemicu respons imun.
8. OL_only paling khas untuk sinyal ketahanan berbasis NLR dan reseptor permukaan, tetapi interpretasinya wajib diposisikan sebagai ringkasan himpunan kecil ($n = 293$) sehingga sensitif terhadap perubahan kecil jumlah gen. Karena OL_only hanya 293 gen (0,9%), maka perubahan puluhan gen saja dapat menggeser persentase secara nyata. Oleh sebab itu, OL_only lebih tepat diperlakukan sebagai “kumpulan kandidat kontribusi liar” yang memberi indikasi arah fungsi, bukan sebagai representasi menyeluruh dari karakter fungsional genom PR25.
9. OL_only menunjukkan sinyal pertahanan yang paling menonjol, terutama pada modul imun NLR (NB-ARC) dan reseptor permukaan (WAK), dengan dukungan signature resistensi lain. Pada OL_only, proporsi NB-ARC domain = 15 (6,22%) merupakan yang tertinggi dibanding RD23_only 44 (0,62%) dan BOTH 156 (0,84%), sehingga kelompok ini memperlihatkan penguatan relatif kandidat komponen imun berbasis NLR. Selain itu, keluaran InterProScan pada OL_only juga menampilkan penguatan modul pertahanan permukaan dan signature resistensi, yaitu Wall-associated *receptor kinase* = 12 (4,98%) dan disease *resistance protein* = 8 (3,32%), disertai komponen pendukung interaksi protein seperti ARM repeat = 4 (1,66%). Secara biologis, kombinasi NLR (NB-ARC) dan reseptor permukaan seperti WAK merupakan dua poros penting sistem imun tanaman: pengenalan di permukaan dan respons intraseluler, sedangkan ARM repeat dapat terkait

dengan regulasi interaksi protein pada jalur ketahanan. Namun, karena OL_only adalah himpunan kecil, seluruh penafsiran ini harus dibaca sebagai ringkasan kandidat pada 293 gen, bukan sebagai generalisasi profil ketahanan seluruh genom PR25.

10. Untuk menjawab Pertanyaan Penelitian 1: “Bagaimana gen gen pada *Oryza sativa ssp. indica cv. PR25* dapat diidentifikasi dan diklasifikasikan berdasarkan hubungan ortholog dengan *Oryza sativa ssp. indica cv. RD23* dan *Oryza longistaminata* ke dalam kelompok asal gen RD23_only, OL_only, dan BOTH?”, penelitian ini mengklasifikasikan gen PR25 berbasis hasil inferensi ortholog pada himpunan proteom yang dianalisis. Dari 33.305 gen PR25 yang terpetakan dalam relasi ortholog, komposisi akhirnya adalah BOTH = 20.204 gen (60,7%), RD23_only = 12.808 gen (38,5%), dan OL_only = 293 gen (0,9%). Secara konseptual, kategori BOTH merepresentasikan gen PR25 yang memiliki pasangan ortholog pada kedua tetua pembandingan, sedangkan RD23_only dan OL_only merepresentasikan gen PR25 yang hanya terdeteksi memiliki pasangan ortholog pada salah satu tetua pada konfigurasi data dan parameter analisis yang digunakan. Karena inferensi ortholog bersifat sangat dipengaruhi oleh kualitas *assembly*, kelengkapan anotasi, fragmentasi sekuens, serta perbedaan metode, maka ketiga kategori tersebut harus diposisikan sebagai kategori operasional berbasis deteksi ortholog, bukan sebagai bukti tunggal pewarisan gen pada tingkat genom. Batas interpretasi ini terutama penting untuk OL_only, karena ukurannya kecil (293 gen) sehingga sensitif terhadap perubahan kecil jumlah gen, dan kualitas *assembly O. longistaminata* pada penelitian ini sangat terfragmentasi (22.477 contig; N50 97.754 bp) dan banyak gap (#N 10.155,31 per 100 kbp), yang dapat meningkatkan peluang gen terpotong atau ortholog tidak terdeteksi.

11. Untuk menjawab Pertanyaan Penelitian 2: “Fungsi biologis dominan apa yang dimiliki gen gen PR25 pada setiap kelompok asal gen (RD23_only, OL_only, BOTH) berdasarkan proporsi anotasi fungsi (misalnya *domain family GO*), dan bagaimana perbedaan dominansi serta proporsi fungsi antar kelompok tersebut membentuk profil fungsional PR25?”, penelitian ini

mengintegrasikan anotasi berbasis orthology dan signature domain untuk menilai dominansi fungsi per kelompok. Pada agregat PR25_all (n = 25.828 gen KNOWN), label dominan menonjol pada fitur sekretori atau membran dan pensinyalan, dibuktikan oleh SignalP-TM 400 (1,55%), SignalP-TM|SignalP-noTM 365 (1,41%), SignalP-noTM 267 (1,03%), serta komponen pensinyalan *protein kinase domain* 293 (1,13%). Perbedaan kontribusi antar kelompok asal gen membentuk profil fungsional PR25 sebagai berikut:

- RD23_only menunjukkan proporsi lebih tinggi untuk modul sekretori atau membran dibanding BOTH, misalnya SignalP-TM 312 (4,42%) pada RD23_only dengan 84 (0,45%) pada BOTH.
- OL_only lebih menonjol pada kandidat modul ketahanan berbasis NLR, tercermin dari NB-ARC 15 (6,22%) pada OL_only, lebih tinggi dibanding RD23_only 44 (0,62%) dan BOTH 159 (0,86%).

Dengan demikian, profil fungsional PR25 dapat diringkas sebagai dominansi inti konservatif (BOTH) yang stabil dan kaya modul pensinyalan serta pertahanan, disertai kontribusi RD23_only yang menonjol pada fitur sekretori atau membran, dan sinyal ketahanan khas pada OL_only yang perlu dibaca hati hati karena ukuran himpunan kecil serta keterbatasan kualitas *assembly* pembandingan.

7.2 Saran

1. Gunakan *assembly* *O. longistaminata* yang lebih kontigu dan gap rendah, atau lakukan penguatan kualitas anotasi sebelum inferensi orthologi lintas spesies ditarik lebih jauh. Dengan 22.477 contig, N50 97.754 bp, dan #N 10.155,31 per 100 kbp, peningkatan kualitas referensi *O. longistaminata* berpotensi langsung memperkecil bias fragmentasi terhadap deteksi ortholog dan analisis komparatif.
2. Prioritaskan peningkatan cakupan anotasi fungsi pada kelompok RD23_only karena menyumbang porsi UNKNOWN terbesar. RD23_only memiliki 5.746 gen UNKNOWN (44,9%), jauh lebih tinggi dibanding BOTH (1.681 gen UNKNOWN; 8,3%). Karena RD23_only juga merupakan fraksi besar (12.808

gen; 38,5%), penguatan anotasi pada kelompok ini paling berdampak untuk memperkuat interpretasi profil fungsi PR25 secara keseluruhan.

3. Lakukan validasi kandidat pertahanan yang menonjol pada OL_only dengan verifikasi spesifik domain. Karena OL_only menampilkan sinyal kuat pada NB-ARC, WAK, dan signature resistensi lain, validasi kandidat dapat difokuskan pada kurasi NLR (misalnya NB-ARC bersama repeat LRR bila ada) dan reseptor permukaan, sehingga kandidat yang benar benar relevan dapat diprioritaskan.
4. Tambahkan lapisan data pendukung untuk memperkuat inferensi fungsi, terutama untuk label terkait stres dan regulasi. Label seperti peroksidase, SAUR, modul kromatin, dan jalur SUMO menunjukkan keterkaitan dengan stres dan regulasi; integrasi bukti tambahan seperti ekspresi jaringan, kondisi stres, atau validasi kandidat terpilih akan memperkuat kesimpulan biologis yang ditarik dari anotasi komputasional.

DAFTAR PUSTAKA

- [1] P. L. C. Paul *et al.*, ‘Rice growth and yield responses to saline water irrigation are related to Na⁺/K⁺ ratio in plants’, *PLOS ONE*, vol. 19, no. 11, p. e0312372, Nov. 2024, doi: 10.1371/journal.pone.0312372.
- [2] S. Zhang *et al.*, ‘Sustained productivity and agronomic potential of perennial rice’, *Nat. Sustain.*, vol. 6, no. 1, pp. 28–38, 2023, doi: 10.1038/s41893-022-00997-3.
- [3] Y. Zhang *et al.*, ‘An innovated crop management scheme for perennial rice cropping system and its impacts on sustainable rice production’, *Eur. J. Agron.*, vol. 122, p. 126186, Jan. 2021, doi: 10.1016/j.eja.2020.126186.
- [4] P. Qin *et al.*, ‘Pan-genome analysis of 33 genetically diverse rice accessions reveals hidden genomic variations’, *Cell*, vol. 184, no. 13, pp. 3542–3558.e16, 2021, doi: 10.1016/j.cell.2021.04.046.
- [5] D. Guo *et al.*, ‘A pangenome reference of wild and cultivated rice’, *Nature*, vol. 642, no. 8068, pp. 662–671, Jun. 2025, doi: 10.1038/s41586-025-08883-6.
- [6] W. Li *et al.*, ‘Improved hybrid *de novo* genome assembly and annotation of African wild rice, *Oryza longistaminata*, from Illumina and PacBio sequencing reads’, *Plant Genome*, vol. 13, no. 1, p. e20001, Mar. 2020, doi: 10.1002/tpg2.20001.
- [7] W. Li *et al.*, ‘A Genetic Network Underlying Rhizome Development in *Oryza longistaminata*’, *Front. Plant Sci.*, vol. 13, no. April, pp. 1–12, 2022, doi: 10.3389/fpls.2022.866165.
- [8] X. Lian *et al.*, ‘Spatiotemporal transcriptomic atlas of rhizome formation in *Oryza longistaminata*’, *Plant Biotechnol. J.*, vol. 22, no. 6, pp. 1652–1668, Jun. 2024, doi: 10.1111/pbi.14294.
- [9] W. Long *et al.*, ‘Genome evolution and diversity of wild and cultivated rice species’, *Nat. Commun.*, vol. 15, no. 1, p. 9994, Nov. 2024, doi: 10.1038/s41467-024-54427-3.
- [10] J. C. Stein *et al.*, ‘Genomes of 13 domesticated and wild rice relatives highlight genetic conservation, turnover and innovation across the genus *Oryza*’, *Nat. Genet.*, vol. 50, no. 2, pp. 285–296, Feb. 2018, doi: 10.1038/s41588-018-0040-0.
- [11] G. Huang *et al.*, ‘Performance, Economics and Potential Impact of Perennial Rice PR23 Relative to Annual Rice Cultivars at Multiple Locations in Yunnan Province of China’, *Sustainability*, vol. 10, no. 4, p. 1086, Apr. 2018, doi: 10.3390/su10041086.
- [12] G. Zhang, ‘The Next Generation of Rice: Inter-Subspecific Indica-Japonica Hybrid Rice’, *Front. Plant Sci.*, vol. 13, p. 857896, Mar. 2022, doi: 10.3389/fpls.2022.857896.
- [13] L. Jiang, L. Wu, Y. Wang, Q. Xu, Z. Xu, and W. Chen, ‘Research progress on the divergence and genetic basis of agronomic traits in xian and geng rice’, *Crop J.*, vol. 10, no. 4, pp. 924–931, Aug. 2022, doi: 10.1016/j.cj.2022.02.006.
- [14] S. Tong, M. Ashikari, K. Nagai, and O. Pedersen, ‘Can the Wild Perennial, Rhizomatous Rice Species *Oryza longistaminata* be a Candidate for De Novo Domestication?’, *Rice*, vol. 16, no. 1, 2023, doi: 10.1186/s12284-023-00630-7.
- [15] Z. Wang, D. Cheng, C. Fan, C. Zhang, C. Zhang, and Z. Liu, ‘Cell Type-Specific Differentiation Between Indica and Japonica Rice Root Tip Responses to Different Environments Based on Single-Cell RNA Sequencing’, *Front. Genet.*, vol. 12, p. 659500, May 2021, doi: 10.3389/fgene.2021.659500.
- [16] F. Wang *et al.*, ‘Geographic Divergence and Putative Candidate Gene Discovery of Rice Grain Quality in China’, *Rice*, vol. 18, no. 1, p. 102, Dec. 2025, doi: 10.1186/s12284-025-00859-4.
- [17] M. Vajrabhaya, W. Kumpun, and S. Chadchawan, ‘The Solute Accumulation: The Mechanism for Drought Tolerance in RD23 Rice (*Oryza sativa* L) Lines’,

- ScienceAsia*, vol. 27, no. 2, pp. 93–97, 2001, doi: 10.2306/scienceasia1513-1874.2001.27.093.
- [18] C. Guo *et al.*, ‘Physiological Properties of Perennial Rice Regenerating Cultivation in Two Years with Four Harvests’, *Plants*, vol. 12, no. 22, 2023, doi: 10.3390/plants12223910.
 - [19] M. R. Labroo *et al.*, ‘Solving the mystery of Obake rice in Africa: population structure analyses of *Oryza longistaminata* reveal three genetic groups and evidence of both recent and ancient introgression with *O. sativa*’, *Front. Plant Sci.*, vol. 14, p. 1278196, Nov. 2023, doi: 10.3389/fpls.2023.1278196.
 - [20] V. Shanmugam *et al.*, ‘Perennial Rice – An Alternative to the “One-sow, One-harvest” Rice Production: Benefits, Challenges, and Future Prospects’, *Farming Syst.*, p. 100137, Jan. 2025, doi: 10.1016/j.farsys.2025.100137.
 - [21] C. Guo *et al.*, ‘Physiological Properties of Perennial Rice Regenerating Cultivation in Two Years with Four Harvests’, *Plants*, vol. 12, no. 22, p. 3910, Nov. 2023, doi: 10.3390/plants12223910.
 - [22] D. Gao, Z. Pan, H. Pan, Y. Gu, and H. Li, ‘Center Degenerated Walking-Primer PCR: A Novel and Universal Genome-Walking Method’, *Curr. Issues Mol. Biol.*, vol. 47, no. 8, p. 602, Aug. 2025, doi: 10.3390/cimb47080602.
 - [23] J. Wu *et al.*, ‘A Chromosome Level Genome Assembly of a Winter Turnip Rape (*Brassica rapa* L.) to Explore the Genetic Basis of Cold Tolerance’, *Front. Plant Sci.*, vol. 13, p. 936958, Jul. 2022, doi: 10.3389/fpls.2022.936958.
 - [24] G. A. Logsdon *et al.*, ‘Complex genetic variation in nearly complete human genomes’, Sep. 25, 2024, *Genomics*. doi: 10.1101/2024.09.24.614721.
 - [25] N. Szakállas *et al.*, ‘Methodological Comparison of Short-Read and Long-Read Sequencing Methods on Colorectal Cancer Samples’, *Int. J. Mol. Sci.*, vol. 26, no. 18, p. 9254, Sep. 2025, doi: 10.3390/ijms26189254.
 - [26] J. Cao *et al.*, ‘Chromosome-level genome assembly and characterization of the *Calophaca sinica* genome’, *DNA Res.*, vol. 31, no. 3, p. dsae011, Jun. 2024, doi: 10.1093/dnares/dsae011.
 - [27] F. Tegenfeldt, D. Kuznetsov, M. Manni, M. Berkeley, E. M. Zdobnov, and E. V. Kriventseva, ‘OrthoDB and BUSCO update: annotation of orthologs with wider sampling of genomes’, *Nucleic Acids Res.*, vol. 53, no. D1, pp. D516–D522, Jan. 2025, doi: 10.1093/nar/gkae987.
 - [28] M. Manni, M. R. Berkeley, M. Seppey, and E. M. Zdobnov, ‘BUSCO: Assessing Genomic Data Quality and Beyond’, *Curr. Protoc.*, vol. 1, no. 12, p. e323, Dec. 2021, doi: 10.1002/cpz1.323.
 - [29] R. M. Waterhouse *et al.*, ‘BUSCO Applications from Quality Assessments to Gene Prediction and Phylogenomics’, *Mol. Biol. Evol.*, vol. 35, no. 3, pp. 543–548, Mar. 2018, doi: 10.1093/molbev/msx319.
 - [30] M. Yan, B.-S. Su, Y.-X. Huang, Z.-B. Xu, Z.-H. Jiang, and X. Wang, ‘Chromosome-level Genome Assembly of *Theretra japonica* (Lepidoptera: Sphingidae)’, *Sci. Data*, vol. 11, no. 1, p. 770, Jul. 2024, doi: 10.1038/s41597-024-03500-z.
 - [31] Ma. C. F. Javier *et al.*, ‘Draft genome of the endangered visayan spotted deer (*Rusa alfredi*), a Philippine endemic species’, *Gigabyte*, vol. 2025, p. gigabyte150, Feb. 2025, doi: 10.46471/gigabyte.150.
 - [32] M. Manni, M. R. Berkeley, M. Seppey, F. A. Simão, and E. M. Zdobnov, ‘BUSCO Update: Novel and Streamlined Workflows along with Broader and Deeper Phylogenetic Coverage for Scoring of Eukaryotic, Prokaryotic, and Viral Genomes’, *Mol. Biol. Evol.*, vol. 38, no. 10, pp. 4647–4654, Sep. 2021, doi: 10.1093/molbev/msab199.
 - [33] E. R. Hanschen, B. T. Hovde, and S. R. Starkenburg, ‘An evaluation of methodology to determine algal genome completeness’, *Algal Res.*, vol. 51, p. 102019, Oct. 2020, doi: 10.1016/j.algal.2020.102019.

- [34] H. Li, ‘Protein-to-genome alignment with minimap2’, *Bioinformatics*, vol. 39, no. 1, p. btad014, Jan. 2023, doi: 10.1093/bioinformatics/btad014.
- [35] T. Brown *et al.*, ‘Chromosome-scale genome assembly reveals how repeat elements shape non-coding RNA landscapes active during newt limb regeneration’, *Cell Genomics*, vol. 5, no. 2, p. 100761, Feb. 2025, doi: 10.1016/j.xgen.2025.100761.
- [36] Department of Computer Science, Y.M. College, Bharati Vidyapeeth Deemed University, Pune, Maharashtra, India., S. More*, Dr. A. More, and Department of Computer Applications and System Studies, IMED, Bharati Vidyapeeth Deemed University, Pune, Maharashtra, India, ‘Assessment the Quality of Genome Assemblies by using QUAST Tool for Metagenomics’, *Int. J. Recent Technol. Eng. IJRTE*, vol. 8, no. 6, pp. 4253–4259, Mar. 2020, doi: 10.35940/ijrte.E6435.038620.
- [37] H. Jung *et al.*, ‘Twelve quick steps for genome assembly and annotation in the classroom’, *PLOS Comput. Biol.*, vol. 16, no. 11, p. e1008325, Nov. 2020, doi: 10.1371/journal.pcbi.1008325.
- [38] A. Shumate and S. L. Salzberg, ‘Liftoff: accurate mapping of gene annotations’, *Bioinformatics*, vol. 37, no. 12, pp. 1639–1643, Jul. 2021, doi: 10.1093/bioinformatics/btaa1016.
- [39] M. Kang *et al.*, ‘The pan-genome and local adaptation of *Arabidopsis thaliana*’, *Nat. Commun.*, vol. 14, no. 1, p. 6259, Oct. 2023, doi: 10.1038/s41467-023-42029-4.
- [40] M. Benoit *et al.*, ‘Solanum pan-genetics reveals paralogues as contingencies in crop engineering’, *Nature*, vol. 640, no. 8057, pp. 135–145, Apr. 2025, doi: 10.1038/s41586-025-08619-6.
- [41] A. H. Freedman and T. B. Sackton, ‘Building better genome annotations across the tree of life’, Apr. 15, 2024, *Bioinformatics*. doi: 10.1101/2024.04.12.589245.
- [42] K.-H. Chao *et al.*, ‘Combining DNA and protein alignments to improve genome annotation with LiftOn’, *Genome Res.*, p. genome;gr.279620.124v2, Dec. 2024, doi: 10.1101/gr.279620.124.
- [43] A. Shumate and S. Salzberg, ‘LiftoffTools: a toolkit for comparing gene annotations mapped between genome assemblies’, 2024.
- [44] J. Dainat *et al.*, *NBISweden/AGAT: AGAT v1.5.1.* (Jul. 2025). Zenodo. doi: 10.5281/zenodo.16317950.
- [45] H. Almutairi *et al.*, ‘Chromosome-scale genome sequencing, assembly and annotation of six genomes from subfamily Leishmaniinae’, *Sci. Data*, vol. 8, no. 1, p. 234, Sep. 2021, doi: 10.1038/s41597-021-01017-3.
- [46] Z. Luo *et al.*, ‘Haplotype-phased genome assemblies and annotation of the northern white-cheeked gibbon (*Nomascus leucogenys*)’, *Sci. Data*, vol. 11, no. 1, p. 1279, Nov. 2024, doi: 10.1038/s41597-024-04073-7.
- [47] I. Pawłowicz, P. Kopeć, and A. Kosmala, ‘The draft genome assembly and annotation of allotetraploid *Festuca glaucescens*’, *BMC Plant Biol.*, vol. 25, no. 1, p. 1590, Nov. 2025, doi: 10.1186/s12870-025-07558-8.
- [48] G. Pertea and Pertea, Mihaela, ‘GFF Utilities: GffRead and GffCompare’, <https://f1000research.com/>, Sep. 2020, doi: <https://doi.org/10.12688/f1000research.23297.2>.
- [49] T. Kon *et al.*, ‘Chromosome-level genome assembly of the doctor fish (*Garra rufa*)’, Mar. 14, 2025, *Genomics*. doi: 10.1101/2025.03.11.642249.
- [50] Y. Peng *et al.*, ‘Landscape of structural variants reveals insights for local adaptations in the Asian corn borer’, *Cell Rep.*, vol. 43, no. 11, p. 114928, Nov. 2024, doi: 10.1016/j.celrep.2024.114928.
- [51] G. P. Schettini, M. Morozyuk, and F. H. Biase, ‘Identification of novel cattle (*Bos taurus*) genes and biological insights of their function in pre-implantation embryo development’, *BMC Genomics*, vol. 25, no. 1, p. 775, Aug. 2024, doi: 10.1186/s12864-024-10685-5.
- [52] Y. Yuan *et al.*, ‘Evolutionary Dynamics of Glycoside Hydrolase Family 1 Provide

- Insights into Insect–Plant Interactions in Lepidoptera’, *Insects*, vol. 16, no. 7, p. 727, Jul. 2025, doi: 10.3390/insects16070727.
- [53] M. Du *et al.*, ‘Structural and deleterious burdens and their effects on yield traits in foxtail millet domestication’, *iScience*, vol. 28, no. 9, p. 113295, Sep. 2025, doi: 10.1016/j.isci.2025.113295.
 - [54] M. R. Habib, M. Posavi, A. Lekired, and S.-M. Zhang, ‘Exploring the genome-wide transcriptomic responses of *Bulinus truncatus* to *Schistosoma haematobium* infection: An important host-parasite system involved in the transmission of human urogenital schistosomiasis’, *Mol. Immunol.*, vol. 175, pp. 74–88, Nov. 2024, doi: 10.1016/j.molimm.2024.09.006.
 - [55] Z.-H. Zhang *et al.*, ‘Enhanced Functional Potential of Pseudogene-associated lncRNA Genes in Mammals’, Mar. 25, 2025, *Genomics*. doi: 10.1101/2025.03.21.644463.
 - [56] J. Wu *et al.*, ‘Duplications and Losses of the Detoxification Enzyme Glycosyltransferase 1 Are Related to Insect Adaptations to Plant Feeding’, *Int. J. Mol. Sci.*, vol. 25, no. 11, p. 6080, May 2024, doi: 10.3390/ijms25116080.
 - [57] S. Frail *et al.*, ‘Genomes of nitrogen-fixing eukaryotes reveal an alternate path for organellogenesis’, *Proc. Natl. Acad. Sci.*, vol. 122, no. 33, p. e2507237122, Aug. 2025, doi: 10.1073/pnas.2507237122.
 - [58] D. M. Emms and S. Kelly, ‘OrthoFinder: phylogenetic orthology inference for comparative genomics’, *Genome Biol.*, vol. 20, no. 1, p. 238, Dec. 2019, doi: 10.1186/s13059-019-1832-y.
 - [59] D. M. Emms and S. Kelly, ‘Benchmarking Orthogroup Inference Accuracy: Revisiting Orthobench’, *Genome Biol. Evol.*, vol. 12, no. 12, pp. 2258–2266, Dec. 2020, doi: 10.1093/gbe/evaa211.
 - [60] Y. Nevers *et al.*, ‘The Quest for Orthologs orthology benchmark service in 2022’, *Nucleic Acids Res.*, vol. 50, no. W1, pp. W623–W632, Jul. 2022, doi: 10.1093/nar/gkac330.
 - [61] A. Altenhoff *et al.*, ‘New developments for the Quest for Orthologs benchmark service’, *NAR Genomics Bioinforma.*, vol. 6, no. 4, p. lqae167, Sep. 2024, doi: 10.1093/nargab/lqae167.
 - [62] F. Almeida-Silva and Y. Van de Peer, ‘Assessing the quality of comparative genomics data and results with the *cogec* R/Bioconductor package’, *Methods Ecol. Evol.*, vol. 14, no. 12, pp. 2942–2952, Dec. 2023, doi: 10.1111/2041-210X.14243.
 - [63] D. M. Emms and S. Kelly, ‘OrthoFinder: solving fundamental biases in whole genome comparisons dramatically improves orthogroup inference accuracy’, *Genome Biol.*, vol. 16, no. 1, p. 157, Aug. 2015, doi: 10.1186/s13059-015-0721-2.
 - [64] C. P. Cantalapiedra, A. Hernández-Plaza, I. Letunic, P. Bork, and J. Huerta-Cepas, ‘eggNOG-mapper v2: Functional Annotation, Orthology Assignments, and Domain Prediction at the Metagenomic Scale’, *Mol. Biol. Evol.*, vol. 38, no. 12, pp. 5825–5829, Dec. 2021, doi: 10.1093/molbev/msab293.
 - [65] A. Hernández-Plaza *et al.*, ‘eggNOG 6.0: enabling comparative genomics across 12 535 organisms’, *Nucleic Acids Res.*, vol. 51, no. D1, pp. D389–D394, Jan. 2023, doi: 10.1093/nar/gkac1022.
 - [66] B. Buchfink, K. Reuter, and H.-G. Drost, ‘Sensitive protein alignments at tree-of-life scale using DIAMOND’, *Nat. Methods*, vol. 18, no. 4, pp. 366–368, Apr. 2021, doi: 10.1038/s41592-021-01101-x.
 - [67] F. Gabler *et al.*, ‘Protein Sequence Analysis Using the MPI Bioinformatics Toolkit’, *Curr. Protoc. Bioinforma.*, vol. 72, no. 1, p. e108, Dec. 2020, doi: 10.1002/cpbi.108.
 - [68] B. J. Nestor, P. E. Bayer, C. G. T. Fernandez, D. Edwards, and P. M. Finnegan, ‘Approaches to increase the validity of gene family identification using manual homology search tools’, *Genetica*, vol. 151, no. 6, pp. 325–338, Dec. 2023, doi: 10.1007/s10709-023-00196-8.

- [69] B. Shrestha and B. Adhikari, ‘Scoring protein sequence alignments using deep learning’, *Bioinformatics*, vol. 38, no. 11, pp. 2988–2995, May 2022, doi: 10.1093/bioinformatics/btac210.
- [70] M. Blum *et al.*, ‘The InterPro protein families and domains database: 20 years on’, *Nucleic Acids Res.*, vol. 49, no. D1, pp. D344–D354, Jan. 2021, doi: 10.1093/nar/gkaa977.
- [71] M. Blum *et al.*, ‘InterPro: the protein sequence classification resource in 2025’, *Nucleic Acids Res.*, vol. 53, no. D1, pp. D444–D456, Jan. 2025, doi: 10.1093/nar/gkae1082.
- [72] P. Jones *et al.*, ‘InterProScan 5: genome-scale protein function classification’, *Bioinformatics*, vol. 30, no. 9, pp. 1236–1240, May 2014, doi: 10.1093/bioinformatics/btu031.
- [73] T. Paysan-Lafosse *et al.*, ‘Interpro in 2022’, *Nucleic Acids Res.*, vol. 51, no. D1, pp. D418–D427, Jan. 2023, doi: 10.1093/nar/gkac993.
- [74] J. Mistry *et al.*, ‘Pfam: The protein families database in 2021’, *Nucleic Acids Res.*, vol. 49, no. D1, pp. D412–D419, Jan. 2021, doi: 10.1093/nar/gkaa913.
- [75] S. Lu *et al.*, ‘CDD/SPARCLE: the conserved domain database in 2020’, *Nucleic Acids Res.*, vol. 48, no. D1, pp. D265–D268, Jan. 2020, doi: 10.1093/nar/gkz991.
- [76] H. Mi *et al.*, ‘PANTHER version 16: a revised family classification, tree-based classification tool, enhancer regions and extensive API’, *Nucleic Acids Res.*, vol. 49, no. D1, pp. D394–D403, Jan. 2021, doi: 10.1093/nar/gkaa1106.
- [77] I. Sillitoe *et al.*, ‘CATH: increased structural coverage of functional space’, *Nucleic Acids Res.*, vol. 49, no. D1, pp. D266–D273, Jan. 2021, doi: 10.1093/nar/gkaa1079.
- [78] V. P. Waman *et al.*, ‘CATH v4.4: major expansion of CATH by experimental and predicted structural data’, *Nucleic Acids Res.*, vol. 53, no. D1, pp. D348–D355, Jan. 2025, doi: 10.1093/nar/gkae1087.
- [79] I. Letunic, S. Khedkar, and P. Bork, ‘SMART: recent updates, new developments and status in 2020’, *Nucleic Acids Res.*, vol. 49, no. D1, pp. D458–D460, Jan. 2021, doi: 10.1093/nar/gkaa937.
- [80] L. Shang *et al.*, ‘A super pan-genomic landscape of rice’, *Cell Res.*, vol. 32, no. 10, pp. 878–896, 2022, doi: 10.1038/s41422-022-00685-z.
- [81] X. Guang *et al.*, ‘Telomere-to-telomere African wild rice (*Oryza longistaminata*) reference genome reveals segmental and structural variation’, *GigaScience*, vol. 14, p. g1af074, Jan. 2025, doi: 10.1093/gigascience/g1af074.
- [82] ‘ACGT’. [Online]. Available: <https://www.genome.gov/genetics-glossary/acgt>
- [83] M. Zagorščak *et al.*, ‘Evidence-based unification of potato gene models with the UniTato collaborative genome browser’, *Front. Plant Sci.*, vol. 15, p. 1352253, Jun. 2024, doi: 10.3389/fpls.2024.1352253.
- [84] L. Laczkó, N. A. Nagy, Á. Nagy, Á. Maroda, and P. Sály, ‘An updated reference genome of *Barbatula barbatula* (Linnaeus, 1758)’, *Sci. Data*, vol. 12, no. 1, p. 137, Jan. 2025, doi: 10.1038/s41597-025-04469-z.
- [85] A. Zaremba, M. Marszałek-Zeńczak, A. Dutta, A. Samelak-Czajka, and P. Jackowiak, ‘A modular pipeline for evidence-integrated genome annotation across species: A case study on *Schmidtea mediterranea*’, *Genomics*, vol. 117, no. 6, p. 111104, Nov. 2025, doi: 10.1016/j.ygeno.2025.111104.
- [86] The UniProt Consortium *et al.*, ‘UniProt: the universal protein knowledgebase in 2021’, *Nucleic Acids Res.*, vol. 49, no. D1, pp. D480–D489, Jan. 2021, doi: 10.1093/nar/gkaa1100.
- [87] A. Gurevich, V. Saveliev, N. Vyahhi, and G. Tesler, ‘QUAST: quality assessment tool for genome assemblies’, *Bioinformatics*, vol. 29, no. 8, pp. 1072–1075, Apr. 2013, doi: 10.1093/bioinformatics/btt086.
- [88] J. Inoue, ‘ORTHOSCOPE*: A Phylogenetic Pipeline to Infer Gene Histories from Genome-Wide Data’, *Mol. Biol. Evol.*, vol. 39, no. 1, p. msab301, Jan. 2022, doi: 10.1093/molbev/msab301.

10.1093/molbev/msab301.

- [89] N. Manchanda *et al.*, ‘GenomeQC: a quality assessment tool for genome assemblies and gene structure annotations’, *BMC Genomics*, vol. 21, no. 1, p. 193, Dec. 2020, doi: 10.1186/s12864-020-6568-2.
- [90] H. Ambreen *et al.*, ‘Long-read-based draft genome sequence of Indian black gram IPU-94-1 “Uttara”: Insights into disease resistance and seed storage protein genes’, *Plant Genome*, vol. 15, no. 3, p. e20234, Sep. 2022, doi: 10.1002/tpg2.20234.
- [91] Grass Phylogeny Working Group III, ‘A nuclear phylogenomic tree of grasses (Poaceae) recovers current classification despite gene tree incongruence’, *New Phytol.*, vol. 245, no. 2, pp. 818–834, Jan. 2025, doi: 10.1111/nph.20263.
- [92] N. Walden, ‘Synteny Identifies Reliable Orthologs for Phylogenomics and Comparative Genomics of the Brassicaceae’.
- [93] J. Huerta-Cepas *et al.*, ‘eggNOG 5.0: a hierarchical, functionally and phylogenetically annotated orthology resource based on 5090 organisms and 2502 viruses’, *Nucleic Acids Res.*, vol. 47, no. D1, pp. D309–D314, Jan. 2019, doi: 10.1093/nar/gky1085.
- [94] Á. Rodríguez Del Río *et al.*, ‘Functional and evolutionary significance of unknown genes from uncultivated taxa’, *Nature*, vol. 626, no. 7998, pp. 377–384, Feb. 2024, doi: 10.1038/s41586-023-06955-z.
- [95] C. Zhang and L. Freddolino, ‘A large-scale assessment of sequence database search tools for homology-based protein function prediction’, *Brief. Bioinform.*, vol. 25, no. 4, p. bbae349, May 2024, doi: 10.1093/bib/bbae349.
- [96] G. A. Maia *et al.*, ‘AnnotAPipeline: An integrated tool to annotate eukaryotic proteins using multi-omics data’, *Front. Genet.*, vol. 13, p. 1020100, Nov. 2022, doi: 10.3389/fgene.2022.1020100.
- [97] P. Törönen and L. Holm, ‘PANNZER —A practical tool for protein function prediction’, *Protein Sci.*, vol. 31, no. 1, pp. 118–128, Jan. 2022, doi: 10.1002/pro.4193.
- [98] A. Kroll, S. Ranjan, M. K. M. Engqvist, and M. J. Lercher, ‘A general model to predict small molecule substrates of enzymes based on machine and deep learning’, *Nat. Commun.*, vol. 14, no. 1, p. 2787, May 2023, doi: 10.1038/s41467-023-38347-2.
- [99] P. Törönen, A. Medlar, and L. Holm, ‘PANNZER2: a rapid functional annotation web server’, *Nucleic Acids Res.*, vol. 46, no. W1, pp. W84–W88, Jul. 2018, doi: 10.1093/nar/gky350.
- [100] N. Škunca, A. Altenhoff, and C. Dessimoz, ‘Quality of Computationally Inferred Gene Ontology Annotations’, *PLoS Comput. Biol.*, vol. 8, no. 5, p. e1002533, May 2012, doi: 10.1371/journal.pcbi.1002533.
- [101] The Gene Ontology Consortium *et al.*, ‘The Gene Ontology knowledgebase in 2023’, *GENETICS*, vol. 224, no. 1, p. iyad031, May 2023, doi: 10.1093/genetics/iyad031.
- [102] S. Prieto-Baños, Y. Nevers, A. Altenhoff, A. Warwick Vesztrocy, C. Dessimoz, and N. M. Glover, ‘Annotation matters: the effect of structural gene annotation on orthology inference’, *Bioinformatics*, vol. 41, no. 7, p. btaf365, Jul. 2025, doi: 10.1093/bioinformatics/btaf365.
- [103] C. Piñeiro and J. C. Pichel, ‘BigSeqKit : a parallel Big Data toolkit to process FASTA and FASTQ files at scale’, *GigaScience*, vol. 12, p. giad062, Dec. 2022, doi: 10.1093/gigascience/giad062.
- [104] K. L. Howe *et al.*, ‘Ensembl 2021’, *Nucleic Acids Res.*, vol. 49, no. D1, pp. D884–D891, Jan. 2021, doi: 10.1093/nar/gkaa942.
- [105] L. Coombe, R. L. Warren, J. Wong, V. Nikolic, and I. Birol, ‘ntLink: A Toolkit for De Novo Genome Assembly Scaffolding and Mapping Using Long Reads’, *Curr. Protoc.*, vol. 3, no. 4, p. e733, Apr. 2023, doi: 10.1002/cpz1.733.
- [106] X. Peng, J. Xie, W. Li, H. Xie, Y. Cai, and X. Ding, ‘Comparison of wild rice (*Oryza*

Institut Teknologi Del

- longistaminata) tissues identifies rhizome-specific bacterial and archaeal endophytic microbiomes communities and network structures', *PLOS ONE*, vol. 16, no. 2, p. e0246687, Feb. 2021, doi: 10.1371/journal.pone.0246687.
- [107] M. C. Heuermann *et al.*, 'White paper: standards for handling and analyzing plant pan-genomes', 2025.
- [108] P. Natsidis, P. Kapli, P. H. Schiffer, and M. J. Telford, 'Systematic errors in orthology inference and their effects on evolutionary analyses', *iScience*, vol. 24, no. 2, p. 102110, Feb. 2021, doi: 10.1016/j.isci.2021.102110.
- [109] T. Zhao *et al.*, 'Recognition of the inducible, secretory small protein OsSSP1 by the membrane receptor OsSSR1 and the co-receptor OsBAK1 confers rice resistance to the blast fungus', *Mol. Plant*, vol. 17, no. 5, pp. 807–823, May 2024, doi: 10.1016/j.molp.2024.04.009.
- [110] Y.-J. Lim and Y.-H. Lee, 'Guardian of the rice: Unveiling OsSSP1 for broad-spectrum disease resistance', *Mol. Plant*, vol. 17, no. 7, pp. 996–998, Jul. 2024, doi: 10.1016/j.molp.2024.06.002.
- [111] Z. Xie *et al.*, 'OsNAC120 balances plant growth and drought tolerance by integrating GA and ABA signaling in rice', *Plant Commun.*, vol. 5, no. 3, p. 100782, Mar. 2024, doi: 10.1016/j.xplc.2023.100782.
- [112] Y. Lu *et al.*, 'A new NLR disease resistance gene Xa47 confers durable and broad-spectrum resistance to bacterial blight in rice', *Front. Plant Sci.*, vol. 13, p. 1037901, Nov. 2022, doi: 10.3389/fpls.2022.1037901.
- [113] A. Wang, L. Ma, X. Shu, Y. Jiang, J. Liang, and A. Zheng, 'Rice (*Oryza sativa* L.) cytochrome P450 protein 716A subfamily CYP716A16 regulates disease resistance', *BMC Genomics*, vol. 23, no. 1, p. 343, Dec. 2022, doi: 10.1186/s12864-022-08568-8.
- [114] W. K. Min, K. H. Lee, J. T. Song, and H. S. Seo, 'Rice small protein OsS1Fa1 participates in stress responses as an inner nuclear membrane protein', *Plant Signal. Behav.*, vol. 19, no. 1, p. 2439252, Dec. 2024, doi: 10.1080/15592324.2024.2439252.
- [115] D. Baek *et al.*, 'OsMYB58 Negatively Regulates Plant Growth and Development by Regulating Phosphate Homeostasis', *Int. J. Mol. Sci.*, vol. 25, no. 4, p. 2209, Feb. 2024, doi: 10.3390/ijms25042209.
- [116] J. Li *et al.*, 'The Pentatricopeptide Repeat Protein OsPPR674 Regulates Rice Growth and Drought Sensitivity by Modulating RNA Editing of the Mitochondrial Transcript *ccmC*', *Int. J. Mol. Sci.*, vol. 26, no. 6, p. 2646, Mar. 2025, doi: 10.3390/ijms26062646.
- [117] Y. Li, T. Mu, T. Ren, and P. Li, 'Drought-Induced Zinc Finger Transcription Factor OsDi19-3 Positively Regulates Drought Stress Acclimatization in Rice (*Oryza sativa* L.)', *Plants*, vol. 14, no. 10, p. 1560, May 2025, doi: 10.3390/plants14101560.
- [118] S.-I. Kim, K. H. Lee, J. S. Kwak, D. H. Kwon, J. T. Song, and H. S. Seo, 'Overexpression of Rice OsS1Fa1 Gene Confers Drought Tolerance in Arabidopsis', *Plants*, vol. 10, no. 10, p. 2181, Oct. 2021, doi: 10.3390/plants10102181.
- [119] M. Dutta, A. Saha, M. Moin, and P. B. Kirti, 'Genome-Wide Identification, Transcript Profiling and Bioinformatic Analyses of GRAS Transcription Factor Genes in Rice', *Front. Plant Sci.*, vol. 12, p. 777285, Nov. 2021, doi: 10.3389/fpls.2021.777285.
- [120] M. Tan, Y. Wang, and Y. Zhao, 'WOX11-OsPRX130 module confers rice drought tolerance by maintaining ROS homeostasis in rice root', *Rice*, vol. 18, no. 1, p. 55, Dec. 2025, doi: 10.1186/s12284-025-00800-9.
- [121] K. Xu *et al.*, 'Overexpression of a novel small auxin-up RNA gene, OsSAUR11, enhances rice deep rootedness', *BMC Plant Biol.*, vol. 23, no. 1, p. 319, Jun. 2023, doi: 10.1186/s12870-023-04320-w.
- [122] J. Zhang *et al.*, 'Ubiquitin Ligase Gene OsPUB57 Negatively Regulates Rice Blast Resistance', *Plants*, vol. 14, no. 5, p. 758, Mar. 2025, doi: 10.3390/plants14050758.

- [123] Y. Fan *et al.*, ‘Genome-Wide Association Study Identifies Rice Panicle Blast-Resistant Gene Pb4 Encoding a Wall-Associated Kinase’, *Int. J. Mol. Sci.*, vol. 25, no. 2, p. 830, Jan. 2024, doi: 10.3390/ijms25020830.
- [124] J. R. Greenwood *et al.*, ‘Genome-wide association analysis uncovers rice blast resistance alleles of Ptr and Pia’, *Commun. Biol.*, vol. 7, no. 1, p. 607, May 2024, doi: 10.1038/s42003-024-06244-z.
- [125] Y. Sun, ‘Histone deacetylase OsHDA716 represses rice chilling tolerance by deacetylating OsbZIP46 to reduce its transactivation function and protein stability’.
- [126] T. Fernandes *et al.*, ‘SUMOylation of rice DELLA SLR1 modulates transcriptional responses and improves yield under salt stress’, *Planta*, vol. 260, no. 6, p. 136, Dec. 2024, doi: 10.1007/s00425-024-04565-1.

LAMPIRAN

Lampiran 1: Implementasi Pipeline Analisis pada Anotasi Gen Hasil Liftoff
(subbab 5.4.4.1)

import os

Institut Teknologi Del

```

from pathlib import Path
import matplotlib.pyplot as plt

# =====
# 1. SETTING FOLDER DASAR
# =====

BASE_DIR = Path(r"D:\result\output_bio\liftoff")
# Kalau pakai WSL: BASE_DIR = Path("/mnt/d/result/output_bio/liftoff")

# =====
# 2. FUNGSI UNTUK ANALISIS GFF3
# =====

def count_features(gff_path, features=("gene", "mRNA", "CDS")):
    """
    Menghitung jumlah fitur (misal: gene, mRNA, CDS) di file GFF3.
    """
    counts = {f: 0 for f in features}
    with open(gff_path, encoding="utf-8") as f:
        for line in f:
            if not line.strip() or line.startswith("#"):
                continue
            cols = line.split("\t")
            if len(cols) < 3:
                continue
            feat = cols[2]
            if feat in counts:
                counts[feat] += 1
    return counts

def count_unmapped(unmapped_path):
    """
    Menghitung jumlah gen referensi yang tidak terpetakan
    di file .unmapped.txt hasil Liftoff.
    """

```

```

c = 0
with open(unmapped_path, encoding="utf-8") as f:
    for line in f:
        line = line.strip()
        if not line or line.startswith("#"):
            continue
        c += 1
    return c

# =====
# 3. DAFTAR FILE YANG DIANALISIS
# =====

gff_files = {
    "PR25_from_ZS97": BASE_DIR / "PR25.from_ZS97.gff3",
    "RD23_from_ZS97": BASE_DIR / "RD23.from_ZS97.gff3",
    "PR25_final_backbone_plus_OL": BASE_DIR /
    "PR25.final_ZS97_backbone_plus_OLunique.gff3",
}

unmapped_files = {
    "PR25_unmapped_from_ZS97": BASE_DIR /
    "PR25.from_ZS97.unmapped.txt",
    "RD23_unmapped_from_ZS97": BASE_DIR /
    "RD23.from_ZS97.unmapped.txt",
}

liftoff_stats_files = {
    "PR25": BASE_DIR / "PR25.final_stats.txt",
    "RD23": BASE_DIR / "RD23.stats.txt",
}

# =====
# 4. FUNGSI MEMBUAT VISUALISASI
# =====

```

```

def plot_gene_counts(summary):
    """
    Bar plot jumlah gen pada:
    - PR25_from_ZS97
    - RD23_from_ZS97
    - PR25_final_backbone_plus_OL

    Menampilkan angka jumlah gen di atas setiap batang.
    """
    labels = []
    values = []

    # urutan bar
    for label in ["PR25_from_ZS97", "RD23_from_ZS97",
"PR25_final_backbone_plus_OL"]:
        if label in summary:
            labels.append(label)
            values.append(summary[label]["gene"])

    x = range(len(labels))

    plt.figure(figsize=(7, 5))
    bars = plt.bar(x, values)
    plt.ylabel("Jumlah gen", fontsize=11)
    # >>> judul diperbaiki: tidak pakai 'Liftoff vs final PR25' lagi
    plt.title("Perbandingan jumlah gen pada PR25 dan RD23",
fontsize=12)
    plt.xticks(x, labels, rotation=20, ha="right", fontsize=10)

    # Tambahkan angka di atas tiap batang
    for xi, val in zip(x, values):
        plt.text(
            xi,
            val + max(values) * 0.01,      # sedikit di atas batang
            f"{val:,.}",
            ha="center",
            va="bottom",
            fontsize=11,

```

```

        fontweight="bold"
    )

    plt.tight_layout()
    plt.show()

def plot_mapped_vs_unmapped(summary, unmapped_summary):
    """
    Bar plot stacked jumlah gen mapped dan unmapped
    untuk PR25 dan RD23 berdasarkan hasil Liftoff.

    Legend jelas: 'Mapped' dan 'Unmapped'.
    """
    data = []

    for genome_label, mapped_label in [
        ("PR25", "PR25_from_ZS97"),
        ("RD23", "RD23_from_ZS97"),
    ]:
        mapped_genes = summary[mapped_label]["gene"]
        unmapped_key = f"{genome_label}_unmapped_from_ZS97"
        unmapped_genes = unmapped_summary.get(unmapped_key, 0)
        total = mapped_genes + unmapped_genes
        if total == 0:
            mapped_pct = 0.0
            unmapped_pct = 0.0
        else:
            mapped_pct = mapped_genes / total * 100.0
            unmapped_pct = unmapped_genes / total * 100.0
        data.append((genome_label, mapped_genes, unmapped_genes,
mapped_pct, unmapped_pct))

    labels = [d[0] for d in data]
    mapped_vals = [d[1] for d in data]
    unmapped_vals = [d[2] for d in data]

    x = range(len(labels))

```

```

plt.figure()
bars_mapped = plt.bar(x, mapped_vals, label="Mapped")
bars_unmapped = plt.bar(x, unmapped_vals, bottom=mapped_vals,
label="Unmapped")

plt.xticks(x, labels, fontsize=10)
plt.ylabel("Jumlah gen", fontsize=11)
# >>> judul diperbaiki: memakai 'mapped dan unmapped'
plt.title("Jumlah gen mapped dan unmapped hasil Liftoff",
fontsize=12)
plt.legend(fontsize=10)

# Tambahkan angka pada segmen mapped dan unmapped dengan font besar
for xi, mapped, unmapped in zip(x, mapped_vals, unmapped_vals):
    if mapped > 0:
        plt.text(
            xi,
            mapped / 2,
            f"{mapped:,"},
            ha="center",
            va="center",
            fontsize=11,
            fontweight="bold",
            color="white",
        )
    if unmapped > 0:
        plt.text(
            xi,
            mapped + unmapped / 2,
            f"{unmapped:,"},
            ha="center",
            va="center",
            fontsize=11,
            fontweight="bold",
            color="black",
        )

plt.tight_layout()

```

```

plt.show()

# Cetak juga ringkasan persen ke terminal
print("\n=== Persentase gen mapped dan unmapped ===")
print("{:<10} {:>10} {:>10} {:>10} {:>10}".format(
    "Genom", "mapped", "unmapped", "%mapped", "%unmapped"
))
print("-" * 60)
for genome_label, mapped_genes, unmapped_genes, mapped_pct,
unmapped_pct in data:
    print("{:<10} {:>10} {:>10} {:>9.2f}% {:>9.2f}%".format(
        genome_label, mapped_genes, unmapped_genes, mapped_pct,
unmapped_pct
    ))

# =====
# 5. MAIN: HITUNG & VISUALISASI
# =====

def main():
    # ---- hitung fitur GFF3 ----
    summary = {}

    print("=== RINGKASAN FITUR GFF3 (gene, mRNA, CDS) ===")
    print("{:<35} {:>10} {:>10} {:>10}".format("File", "gene", "mRNA",
"CDS"))
    print("-" * 70)

    for label, path in gff_files.items():
        if not path.exists():
            print(f"{label:<35} FILE TIDAK DITEMUKAN: {path}")
            continue
        counts = count_features(path)
        summary[label] = counts
        print("{:<35} {:>10} {:>10} {:>10}".format(
            label, counts["gene"], counts["mRNA"], counts["CDS"]
        ))

```

```

# ---- hitung unmapped ----
unmapped_summary = {}
print("\n=== RINGKASAN GEN TIDAK TERPETAKAN (Liftoff unmapped)
===")
print("{:<35} {:>10}".format("File", "n_unmapped"))
print("-" * 50)

for label, path in unmapped_files.items():
    if not path.exists():
        print(f"{label:<35} FILE TIDAK DITEMUKAN: {path}")
        continue
    n_un = count_unmapped(path)
    unmapped_summary[label] = n_un
    print("{:<35} {:>10}".format(label, n_un))

# ---- tampilkan cuplikan statistik Liftoff ----
for genome_label, stats_path in liftoff_stats_files.items():
    if stats_path.exists():
        print(f"\n=== Cuplikan statistik Liftoff: {stats_path.name}
({genome_label}) ===")
        with open(stats_path, encoding="utf-8") as f:
            for i, line in enumerate(f):
                if i >= 15:
                    break
                print(line.rstrip())
    else:
        print(f"\nTidak menemukan file statistik: {stats_path}")

# ---- tampilkan grafik jumlah gen ----
plot_gene_counts(summary)

# ---- tampilkan grafik mapped vs unmapped ----
plot_mapped_vs_unmapped(summary, unmapped_summary)

if __name__ == "__main__":
    main()

```


Lampiran 2: Implementasi Pipeline Analisis Standarisasi dan Penggabungan Anotasi dengan Hasil AGAT (subbab 5.4.4.2)

```
def count_features_gff3(gff_path, feature_types=("gene", "mRNA",
"CDS")):
    """
    Menghitung jumlah fitur tertentu (mis. gene, mRNA, CDS)
    pada berkas GFF3 hasil Liftoff/AGAT.

    Parameters
    -----
    gff_path : str
        Path ke file GFF3.
    feature_types : tuple of str
        Tipe fitur yang ingin dihitung (kolom ke-3 pada GFF3).

    Returns
    -----
    dict
        {'file': <nama>, 'gene': int, 'mRNA': int, 'CDS': int, ...}
    """
    counts = Counter()
    with open(gff_path, encoding="utf-8") as fh:
        for line in fh:
            if not line or line.startswith("#"):
                continue
            fields = line.rstrip("\n").split("\t")
            if len(fields) < 3:
                continue
            ftype = fields[2]
            if ftype in feature_types:
                counts[ftype] += 1

    result = {"File": os.path.basename(gff_path)}
    for f in feature_types:
        result[f] = counts.get(f, 0)
    return result
```

```
# ----- pemanggilan untuk data-----

gff_files = [
    r"D:\result\output_bio\liftoff\PR25.from_ZS97.gff3",
    r"D:\result\output_bio\liftoff\PR25.add_OL.gff3",

    r"D:\result\output_bio\liftoff\PR25.final_ZS97_backbone_plus_OLunique.
    gff3",
]

rows = [count_features_gff3(p) for p in gff_files]
df = pd.DataFrame(rows)
print(df)

# Kalau mau simpan ke TSV/Excel untuk dimasukkan ke Tabel
df.to_csv(r"D:\result\output_bio\liftoff\PR25_AGAT_feature_counts.tsv"
,
        sep="\t", index=False)
```

Lampiran 3: Implementasi Analisis Ekstraksi CDS dan Protein dengan Hasil Gffread (subbab 5.4.4.3)

```
from pathlib import Path

# ==== 1. SET BASE FOLDER SESUAI WINDOWS ====
BASE_DIR = Path(r"D:\result\output_bio\proteins")

protein_files = {
    "PR25": BASE_DIR / "PR25.final.pep.all.fa",
    "RD23": BASE_DIR / "RD23.final.pep.all.fa",
}

# Cek dulu apakah benar-benar ketemu
for label, p in protein_files.items():
    print(label, "->", p, "exists?", p.exists())
```

```

# ==== 2. FUNGSI BACA FASTA & HITUNG PANJANG SEKUENS ====
def fasta_lengths(path: Path):
    lengths = []
    if not path.exists():
        raise FileNotFoundError(f"File tidak ditemukan: {path}")
    with open(path, encoding="utf-8") as f:
        seq_len = 0
        for line in f:
            line = line.strip()
            if not line:
                continue
            if line.startswith(">"):
                if seq_len > 0:
                    lengths.append(seq_len)
                    seq_len = 0
            else:
                seq_len += len(line)
        if seq_len > 0:
            lengths.append(seq_len)
    return lengths

# ==== 3. HITUNG STATISTIK SEDERHANA ====
print("\nGenom      n_seq      min_len      max_len      mean")
print("-----")

import statistics as stats

for label, path in protein_files.items():
    if not path.exists():
        print(f"{label:<8}  FILE TIDAK DITEMUKAN: {path}")
        continue

    lens = fasta_lengths(path)
    n_seq = len(lens)
    min_len = min(lens)
    max_len = max(lens)

```

```

mean_len = stats.mean(lens)

print(f"{label:<8}      {n_seq:8d}      {min_len:10d}      {max_len:10d}
{mean_len:10.2f}")

```

Lampiran 4: Implementasi Pipeline Analisis Pembersihan Sekuen Protein (subbab 5.4.4.4)

```

from pathlib import Path

# =====
# 1. Fungsi bantu FASTA
# =====

def read_fasta_dict(path):
    """
    Baca FASTA menjadi dict: id -> sequence (string tanpa newline).
    ID diambil dari token pertama setelah '>'.
    """
    path = Path(path)
    seqs = {}
    current_id = None
    chunks = []

    with path.open(encoding="utf-8") as f:
        for line in f:
            line = line.strip()
            if not line:
                continue
            if line.startswith(">"):
                # simpan sekuens sebelumnya
                if current_id is not None:
                    seqs[current_id] = "".join(chunks)

```

```

        header = line[1:]
        current_id = header.split()[0]
        chunks = []
        else:
            chunks.append(line)

# simpan sekuens terakhir
if current_id is not None:
    seqs[current_id] = "".join(chunks)

return seqs

def fasta_stats(seqs):
    """
    Hitung statistik dasar panjang sekuens: n, min, max, mean.
    seqs: dict id -> sequence
    """
    lengths = [len(s) for s in seqs.values()]
    if not lengths:
        return 0, 0, 0, 0.0
    n = len(lengths)
    min_len = min(lengths)
    max_len = max(lengths)
    mean_len = sum(lengths) / n
    return n, min_len, max_len, mean_len

def ringkasan_final_vs_clean(label, final_path, clean_path):
    """
    Menampilkan ringkasan sederhana:
    - jumlah ID final & clean

```

```

- berapa ID yang sekuensnya berubah
- statistik panjang sekuens (n, min, max, mean) untuk final & clean
"""

final_path = Path(final_path)
clean_path = Path(clean_path)

print(f"\n=== {label} ===")
print(f"Final : {final_path} exists? {final_path.exists()}")
print(f"Clean : {clean_path} exists? {clean_path.exists()}")

if not final_path.exists() or not clean_path.exists():
    print("!! Salah satu file tidak ditemukan, cek lagi path-nya.")
    return

final_seqs = read_fasta_dict(final_path)
clean_seqs = read_fasta_dict(clean_path)

final_ids = set(final_seqs.keys())
clean_ids = set(clean_seqs.keys())

common_ids = final_ids & clean_ids

# hitung berapa ID yang sekuensnya berubah setelah cleaning
changed = 0
for i in common_ids:
    if final_seqs[i] != clean_seqs[i]:
        changed += 1

print(f"Total ID final : {len(final_ids)}")
print(f"Total ID clean : {len(clean_ids)}")
print(f"ID yang sama di kedua file : {len(common_ids)}")
print(f"ID sama tapi sekuens BERBEDA (terpengaruh cleaning) : {changed}")

```

```

# statistik panjang sekuens
n_f, min_f, max_f, mean_f = fasta_stats(final_seqs)
n_c, min_c, max_c, mean_c = fasta_stats(clean_seqs)

print("\nRingkasan panjang sekuens (aa):")
print("{:<10} {:>8} {:>8} {:>8} {:>10}".format(
    "File", "n_seq", "min", "max", "mean"
))
print("-" * 50)
print("{:<10} {:>8} {:>8} {:>8} {:>10.2f}".format(
    "final", n_f, min_f, max_f, mean_f
))
print("{:<10} {:>8} {:>8} {:>8} {:>10.2f}".format(
    "clean", n_c, min_c, max_c, mean_c
))

# =====
# 2. Panggil untuk 3 spesies
# =====

ringkasan_final_vs_clean(
    "PR25",
    r"D:\result\output_bio\proteins\PR25.final.pep.all.fa",
    r"D:\result\output_bio\clean_proteins\PR25.clean.fa"
)

ringkasan_final_vs_clean(
    "RD23",
    r"D:\result\output_bio\proteins\RD23.final.pep.all.fa",
    r"D:\result\output_bio\clean_proteins\RD23.clean.fa"
)

```

```
)

ringkasan_final_vs_clean(
    "O. longistaminata",

    r"D:\TA1\combined_pep\Oryza_longistaminata.O_longistaminata_v1.0.pep.all.
    fa",
    r"D:\result\output_bio\clean_proteins\OL.clean.fa"
)
```

Lampiran 5: Implementasi Penentuan Status Ortholog Gen PR25 pada RD23 dan Oryza longistaminata (subbab 5.4.8.1)

```
# =====
# BLOK 1 – STATUS PR25 (FINAL)
# - Hitung status PR25 vs RD23 & OL
# - Tambah OGs & OG_primary untuk dipakai blok 4/5
# - Sanity check pola ID
# =====

import os, re, csv
import pandas as pd
from collections import defaultdict

# ----- 1) KONFIGURASI PATH -----
OF_ROOT = r"D:\result\output_bio\OF_PR25_RD23_OL_MSA_20250929_141953\Results_Sep29"
PAIR_PR25_RD23 = os.path.join(OF_ROOT, r"Orthologues\Orthologues_PR25\PR25__v__RD23.tsv")
PAIR_PR25_OL = os.path.join(OF_ROOT, r"Orthologues\Orthologues_PR25\PR25__v__OL.tsv")

OUT_DIR = r"D:\result\output_bio\tables"
STATUS_TSV = os.path.join(OUT_DIR, "PR25_status.tsv")

# >>> set ke False untuk MENYIMPAN
PREVIEW_ONLY = False

# ----- 2) UTIL PARSER -----
def parse_pairwise_multi(path, pr25_label="PR25"):
    pr25_to_partners = defaultdict(set)
    pr25_to_og = defaultdict(set)
    pr25_all_ids = set()

    if not os.path.exists(path):
        raise FileNotFoundError(f"Tidak ditemukan: {path}")
```

Institut Teknologi Del


```

with open(path, encoding="utf-8", newline="") as f:
    rdr = csv.reader(f, delimiter="\t")
    header = next(rdr, None)
    if header is None:
        raise ValueError(f"File kosong: {path}")

    og_idx = header.index("Orthogroup")
    pr25_idx = header.index(pr25_label)
    partner_idx = [i for i in range(len(header)) if i not in
(og_idx, pr25_idx)][0]

    def split_many(cell):
        if not cell: return []
        return [x.strip() for x in cell.split(",") if x.strip()]

    for row in rdr:
        if not row or len(row) <= partner_idx:
            continue
        og = row[og_idx].strip()
        pr25_list = split_many(row[pr25_idx])
        partner_list = split_many(row[partner_idx])

        for p in pr25_list:
            pr25_all_ids.add(p)
            pr25_to_og[p].add(og)
            for q in partner_list:
                pr25_to_partners[p].add(q)

    return pr25_to_partners, pr25_to_og, pr25_all_ids

def pick_primary(ogs_set):
    if not ogs_set:
        return ""
    def og_num(og):
        m = re.match(r"OG0*([0-9]+)$", str(og).strip().upper())
        return int(m.group(1)) if m else 10**9
    return sorted((o.strip().upper() for o in ogs_set),
key=og_num)[0]

# ----- 3) BACA 2 FILE PAIRWISE -----
rd23_map, rd23_ogs, pr25_from_rd23 =
parse_pairwise_multi(PAIR_PR25_RD23, pr25_label="PR25")
ol_map, ol_ogs, pr25_from_ol =
parse_pairwise_multi(PAIR_PR25_OL, pr25_label="PR25")
pr25_all = pr25_from_rd23 | pr25_from_ol

# ----- 4) SANITY CHECK pola ID -----
def frac(pattern, ids, limit=3000):
    import itertools
    if not ids: return 0.0
    rgx = re.compile(pattern)
    samp = list(itertools.islice(iter(ids), 0, limit))
    hit = sum(1 for x in samp if rgx.search(str(x)))

```

```

        return hit / len(samp)

PR25_LIKE = r"OsZS97_\d+G\d+_\d+"
OL_LIKE   = r"AMDW\d+\. \d+_FG[PT]\d+"

pr25_like = frac(PR25_LIKE, pr25_all)
ol_like   = frac(OL_LIKE,   pr25_all)
print(f"[Sanity] PR25-like fraction di kolom PR25: {pr25_like:.3f}")
print(f"[Sanity] OL-like fraction di kolom PR25: {ol_like:.3f}")
print("[Info] OrthoFinder memakai nama file FASTA sebagai nama
        spesies (kolom), "
        "dan ID diambil dari header FASTA; orthogroups/orthologues
        tersusun per-spesies. ")

# ----- 5) HITUNG STATUS & RANGKAI TABEL -----
rows = []
count = {"RD23_only":0, "OL_only":0, "BOTH":0, "NONE":0}

for pr25 in sorted(pr25_all):
    r_partners = rd23_map.get(pr25, set())
    o_partners = ol_map.get(pr25, set())
    has_r = len(r_partners) > 0
    has_o = len(o_partners) > 0

    if has_r and has_o: status = "BOTH"
    elif has_r:        status = "RD23_only"
    elif has_o:        status = "OL_only"
    else:              status = "NONE"
    count[status] += 1

    ogs = (rd23_ogs.get(pr25, set())) | (ol_ogs.get(pr25, set()))
    rows.append({
        "PR25_id":      pr25,
        "status":       status,
        "RD23_partner": ";".join(sorted(r_partners)),
        "OL_partner":   ";".join(sorted(o_partners)),
        "OGs":          ";".join(sorted(ogs)) if ogs else "",
        "OG_primary":   pick_primary(ogs),
    })

df_status = pd.DataFrame(rows, columns=[
    "PR25_id", "status", "RD23_partner", "OL_partner", "OGs", "OG_primary"
])

# ----- 6) PREVIEW / SAVE -----
print("\n=== RINGKASAN STATUS ===")
for k in ("RD23_only", "OL_only", "BOTH", "NONE"):
    print(f"{k:10s}: {count[k]:,}")

print("\n=== PREVIEW 10 BARIS PERTAMA ===")
print(df_status.head(10).to_string(index=False))

if PREVIEW_ONLY:

```

```

        print("\n[NOTE]    PREVIEW_ONLY=True    →    belum    menyimpan
PR25_status.tsv")
    else:
        os.makedirs(OUT_DIR, exist_ok=True)
        df_status.to_csv(STATUS_TSV, sep="\t", index=False)
        print(f"[SAVED] {STATUS_TSV} | rows={len(df_status):,}")

```

Lampiran 6: Implementasi Quality Control dan Validasi Konsistensi Data Protein (subbab 5.4.8.2)

```

# ===== BLOK 2 (QC/Preview dengan VALIDASI LENGKAP) =====
# ----- KONFIGURASI PATH -----
OUT_DIR      = r"D:\result\output_bio\tables"
STATUS_TSV   = os.path.join(OUT_DIR, "PR25_status.tsv")

OG_FILE                                             =
r"D:\result\output_bio\OF_PR25_RD23_OL_MSA_20250929_141953\Results_Sep
29\Orthogroups\Orthogroups.tsv"

PR25_CLEAN   = r"D:\result\output_bio\clean_proteins\PR25.clean.fa"
PR25_ORIG    = r"D:\result\output_bio\proteins\PR25.final.pep.all.fa"
RD23_CLEAN   = r"D:\result\output_bio\clean_proteins\RD23.clean.fa"
RD23_ORIG    = r"D:\result\output_bio\proteins\RD23.final.pep.all.fa"
OL_CLEAN     = r"D:\result\output_bio\clean_proteins\OL.clean.fa"
OL_PUB_PEP                                       =
r"D:\TA1\combined_pep\Oryza_longistaminata.O_longistaminata_v1.0.pep.a
ll.fa"

GENE_TREES_DIR                                     =
r"D:\result\output_bio\OF_PR25_RD23_OL_MSA_20250929_141953\Results_Sep
29\Gene_Trees"
RESOLVED_GENE_TREES_DIR=
r"D:\result\output_bio\OF_PR25_RD23_OL_MSA_20250929_141953\Results_Sep
29\Resolved_Gene_Trees"

# ----- PARAMETER TAMPILAN -----
PREVIEW_ROWS_STATUS = 5
PREVIEW_IDS_PER_SET = 5
PREVIEW_OG_ROWS     = 5
PREVIEW_HAS_TREE     = 5

```

```

PREVIEW_NO_TREE      = 5

# ----- UTIL -----

def _open(path):
    """Smart file opener untuk .gz dan regular files"""
    if not os.path.exists(path):
        return None
    return gzip.open(path, "rt", encoding="utf-8", errors="ignore") if
str(path).lower().endswith(".gz") \
        else open(path, "rt", encoding="utf-8", errors="ignore")

def fasta_ids(path, limit=None):
    """Extract IDs dari file FASTA"""
    ids = []
    f = _open(path)
    if f is None:
        print(f"[WARNING] File tidak dapat dibuka: {path}")
        return ids

    with f:
        for ln in f:
            if ln.startswith(">"):
                raw_id = ln[1:].strip().split()[0]
                ids.append(raw_id)
                if limit and len(ids) >= limit:
                    break

    return ids

def check_file_health(path, label):
    """Comprehensive file health check"""
    print(f"\n{'='*60}")
    print(f"FILE HEALTH CHECK: {label}")
    print(f"{'='*60}")
    print(f"Path: {path}")

    if not os.path.exists(path):
        print(f"❌ STATUS: File TIDAK DITEMUKAN")
        return False

```

```

size_bytes = os.path.getsize(path)
size_mb = size_bytes / (1024*1024)
print(f"✓ File exists: {size_mb:.2f} MB ({size_bytes:,} bytes)")

if size_bytes == 0:
    print(f"✗ STATUS: File KOSONG (0 bytes)")
    return False

# Try to read first few lines
try:
    f = _open(path)
    if f is None:
        print(f"✗ STATUS: File tidak dapat dibuka")
        return False

    with f:
        lines = []
        for i, ln in enumerate(f):
            lines.append(ln.strip())
            if i >= 9: # Read first 10 lines
                break

        if not lines:
            print(f"✗ STATUS: File kosong atau tidak terbaca")
            return False

        print(f"✓ Readable: YES")
        print(f"✓ First line: {lines[0][:80]}...")

        # Count sequences
        seq_count = sum(1 for ln in lines if ln.startswith(">"))
        print(f"✓ Sequences in first 10 lines: {seq_count}")

        if lines[0].startswith(">"):
            print(f"✓ Format: Valid FASTA")
        else:

```

```

        print(f"⚠ Format: May not be FASTA (doesn't start with
'>')")

        return True

    except Exception as e:
        print(f"❌ ERROR reading file: {e}")
        return False

def quick_check_pair(A, B, label, show_dupe=True):
    """Compare two FASTA files with detailed stats"""
    print(f"\n{'='*70}")
    print(f"PAIRWISE COMPARISON: {label}")
    print(f"{'='*70}")

    A_ids = fasta_ids(A)
    B_ids = fasta_ids(B)
    setA, setB = set(A_ids), set(B_ids)
    inter = len(setA & setB)
    onlyA = len(setA - setB)
    onlyB = len(setB - setA)

    print(f"File A: {os.path.basename(A)}")
    print(f"  Total IDs: {len(A_ids):,}")
    print(f"  Unique IDs: {len(setA):,}")

    print(f"\nFile B: {os.path.basename(B)}")
    print(f"  Total IDs: {len(B_ids):,}")
    print(f"  Unique IDs: {len(setB):,}")

    print(f"\nSet Operations:")
    print(f"  Intersection (A n B): {inter:,}")
    print(f"  Only in A (A - B): {onlyA:,}")
    print(f"  Only in B (B - A): {onlyB:,}")

    if len(setA) > 0:
        overlap_pct = (inter / len(setA)) * 100

```

```

print(f" Overlap %: {overlap_pct:.2f}%")

# Duplicate check
if show_dupe:
    ca = Counter(A_ids)
    cb = Counter(B_ids)
    dupeA = [k for k,v in ca.items() if v>1]
    dupeB = [k for k,v in cb.items() if v>1]

    print(f"\nDuplicate Check:")
    print(f"    A - Duplicates: {len(dupeA):,} | Max count:
{max(ca.values()) if ca else 0}")
    print(f"    B - Duplicates: {len(dupeB):,} | Max count:
{max(cb.values()) if cb else 0}")

    if dupeA:
        print(f"    A - Examples: {dupeA[:3]}")
    if dupeB:
        print(f"    B - Examples: {dupeB[:3]}")

# Sample IDs
exA = A_ids[:PREVIEW_IDS_PER_SET]
exB = B_ids[:PREVIEW_IDS_PER_SET]

print(f"\nSample IDs from A (first {min(len(exA),
PREVIEW_IDS_PER_SET)}):")
for i, id_str in enumerate(exA, 1):
    print(f" {i}. {id_str}")

print(f"\nSample IDs from B (first {min(len(exB),
PREVIEW_IDS_PER_SET)}):")
for i, id_str in enumerate(exB, 1):
    print(f" {i}. {id_str}")

# ----- MAIN QC WORKFLOW -----
print("="*80)
print("BLOK 2 - QUALITY CONTROL & VALIDATION")
print("="*80)

```

```

# 1. FILE HEALTH CHECKS
print("\n" + "="*80)
print("SECTION 1: FILE HEALTH CHECKS")
print("="*80)

files_to_check = [
    (PR25_CLEAN, "PR25 Clean FASTA"),
    (PR25_ORIG, "PR25 Original FASTA"),
    (RD23_CLEAN, "RD23 Clean FASTA"),
    (RD23_ORIG, "RD23 Original FASTA"),
    (OL_CLEAN, "OL Clean FASTA"),
    (OL_PUB_PEP, "OL Public PEP FASTA"),
]

file_health_summary = {}
for fpath, flabel in files_to_check:
    is_healthy = check_file_health(fpath, flabel)
    file_health_summary[flabel] = is_healthy

# Summary
print("\n" + "="*80)
print("FILE HEALTH SUMMARY")
print("="*80)
for flabel, is_healthy in file_health_summary.items():
    status = "✓ HEALTHY" if is_healthy else "X PROBLEM"
    print(f"{status:12s} | {flabel}")

# 2. PAIRWISE COMPARISONS
print("\n" + "="*80)
print("SECTION 2: PAIRWISE FASTA COMPARISONS")
print("="*80)

quick_check_pair(PR25_CLEAN, PR25_ORIG, "PR25_clean_vs_original")
quick_check_pair(RD23_CLEAN, RD23_ORIG, "RD23_clean_vs_original")
quick_check_pair(OL_CLEAN, OL_PUB_PEP, "OL_clean_vs_public_pep")

# 3. STATUS FILE CHECK

```



```

print("\n" + "="*80)
print("SECTION 3: PR25_STATUS.TSV VALIDATION")
print("="*80)

if not os.path.isfile(STATUS_TSV):
    print(f"✗ STATUS_TSV tidak ditemukan: {STATUS_TSV}")
else:
    df_status = pd.read_csv(STATUS_TSV, sep="\t", dtype=str).fillna("")
    print(f"✓ File loaded: {len(df_status):,} rows")

    print(f"\n--- Column Information ---")
    print(f"Columns: {list(df_status.columns)}")
    print(f"\n--- First {PREVIEW_ROWS_STATUS} rows ---")
    cols_show = [c for c in ["PR25_id", "status", "OG_primary", "OGs"] if
c in df_status.columns]

print(df_status[cols_show].head(PREVIEW_ROWS_STATUS).to_string(index=False))

    print(f"\n--- Status Breakdown ---")
    if "status" in df_status.columns:
        status_counts = df_status["status"].value_counts()
        total = len(df_status)
        for st, cnt in status_counts.items():
            pct = (cnt/total)*100
            print(f" {st:12s}: {cnt:7,} ({pct:5.2f}%)")

    print(f"\n--- OG Coverage ---")
    if "OGs" in df_status.columns:
        with_og = (df_status["OGs"].str.len() > 0).sum()
        pct = (with_og/len(df_status))*100
        print(f" Rows with OGs: {with_og:,} / {len(df_status):,}
({pct:.2f}%)")

# 4. ORTHOGROUPS FILE CHECK
print("\n" + "="*80)
print("SECTION 4: ORTHOGROUPS FILE VALIDATION")

```

```

print("="*80)

if not os.path.isfile(OG_FILE):
    print(f"✗ Orthogroups file tidak ditemukan: {OG_FILE}")
else:
    sep = "\t" if OG_FILE.lower().endswith(".tsv") else ","
    df_og = pd.read_csv(OG_FILE, sep=sep, dtype=str).fillna("")

    print(f"✓ File loaded: {len(df_og):,} orthogroups")
    print(f"✓ Columns: {list(df_og.columns)}")

    # Detect species columns
    col_pr25 = next((c for c in df_og.columns if
c.upper().startswith("PR25")), None)
    col_rd23 = next((c for c in df_og.columns if
c.upper().startswith("RD23")), None)
    col_ol = next((c for c in df_og.columns if
c.upper().startswith("OL")), None)

    print(f"\n--- Species Columns Detected ---")
    print(f" PR25: {col_pr25}")
    print(f" RD23: {col_rd23}")
    print(f" OL: {col_ol}")

    # PR25-only orthogroups
    if all([col_pr25, col_rd23, col_ol]):
        def nonempty(x): return bool(str(x).strip())
        mask_pr25_only = df_og[col_pr25].map(nonempty) &
~df_og[col_rd23].map(nonempty) & ~df_og[col_ol].map(nonempty)
        n_pr25_only = mask_pr25_only.sum()

        print(f"\n--- PR25-only Orthogroups ---")
        print(f" Count: {n_pr25_only:,}")

        if n_pr25_only > 0:
            df_po = df_og.loc[mask_pr25_only, ["Orthogroup",
col_pr25]].head(PREVIEW_OG_ROWS).copy()

```

```

df_po.rename(columns={col_pr25:"PR25_ids"}, inplace=True)

# Show with member count
def count_members(s):
    parts = [p.strip() for p in str(s).split(",") if
p.strip()]
    return f"({len(parts)} members)"

df_po["Count"] = df_po["PR25_ids"].map(count_members)
print(f"\n First {PREVIEW_OG_ROWS} PR25-only OGs:")
print(df_po[["Orthogroup",
"Count"]].to_string(index=False))

# 5. GENE TREES SCAN
print("\n" + "="*80)
print("SECTION 5: GENE TREES AVAILABILITY")
print("="*80)

og_pat = re.compile(r"^(OG\d{7})_tree\.txt$", re.IGNORECASE)

def scan_tree_dir(dir_path, tree_map):
    """Scan directory for tree files"""
    dirp = Path(dir_path)
    print(f"\nScanning: {dir_path}")
    print(f" Exists: {dirp.exists()}")

    if not dirp.exists():
        return 0

    count = 0
    for p in dirp.iterdir():
        if p.is_file():
            m = og_pat.match(p.name)
            if m:
                og = m.group(1).upper()
                if og not in tree_map:
                    tree_map[og] = str(p)
                count += 1

```

```

    print(f" Tree files found: {count:,}")
    print(f" Total OGs indexed: {len(tree_map):,}")
    return count

tree_map = {}
resolved_count = scan_tree_dir(RESOLVED_GENE_TREES_DIR, tree_map)
regular_count = scan_tree_dir(GENE_TREES_DIR, tree_map)

print(f"\n--- Tree Summary ---")
print(f" Resolved trees: {resolved_count:,}")
print(f" Regular trees: {regular_count:,}")
print(f" Total unique OGs with trees: {len(tree_map):,}")

# Sample tree paths
print(f"\n Sample tree paths (first 3):")
for i, (og, path) in enumerate(list(tree_map.items())[:3], 1):
    print(f"    {i}. {og}: {path}")

# 6. FINAL RECOMMENDATIONS
print("\n" + "="*80)
print("SECTION 6: RECOMMENDATIONS FOR BLOK 3")
print("="*80)

issues = []
warnings = []

# Check file health
if not file_health_summary.get("PR25 Original FASTA", False):
    issues.append("PR25 Original FASTA bermasalah - pastikan file ada dan readable")
if not file_health_summary.get("RD23 Original FASTA", False):
    issues.append("RD23 Original FASTA bermasalah - pastikan file ada dan readable")

# Check if clean files have content
pr25_clean_ids = fasta_ids(PR25_CLEAN, limit=1)
rd23_clean_ids = fasta_ids(RD23_CLEAN, limit=1)

```

```

ol_clean_ids = fasta_ids(OL_CLEAN, limit=1)

if not pr25_clean_ids:
    issues.append("PR25 Clean FASTA kosong atau tidak terbaca")
if not rd23_clean_ids:
    issues.append("RD23 Clean FASTA kosong atau tidak terbaca")
if not ol_clean_ids:
    issues.append("OL Clean FASTA kosong atau tidak terbaca")

if issues:
    print("\n❌ CRITICAL ISSUES DETECTED:")
    for i, issue in enumerate(issues, 1):
        print(f" {i}. {issue}")
else:
    print("\n✓ No critical issues detected")

if warnings:
    print("\n⚠ WARNINGS:")
    for i, warn in enumerate(warnings, 1):
        print(f" {i}. {warn}")

print("\n--- Next Steps ---")
print("1. Jika ada CRITICAL ISSUES, perbaiki file-file tersebut dulu")
print("2. Jika semua OK, lanjut ke BLOK 3 FINAL")
print("3. BLOK 3 akan gunakan GFF mapping untuk ID conversion")
print("4. Annotation akan di-merge dari PR25, RD23, dan OL")

print("\n" + "="*80)
print("BLOK 2 QC SELESAI")
print("="*80)

```